数据仓库与数据挖掘 2022 B 卷

Please note that due to my limited knowledge, the following answer are for reference only. by Albert Yang

一．什么是支持度，什么是可信度？给定如下交易数据库，如果用户给定的最小支持度是60%，请问项目集合{牙膏、牙刷、面包} 是否是频繁项集？如果用户给定的最小可信度是80%，请问能否产生关联规则{牙膏、牙刷}—>{饼干}？(20分)

交易号	items bought
10	{牙膏、牙刷、牛奶、饼干}
20	{牙膏、牙刷、饼干}
30	{牙膏、牙刷、面包}
40	{牙膏、牙刷、面包、面包、饼干}
50	{牙膏、牙刷、牛奶、饼干}

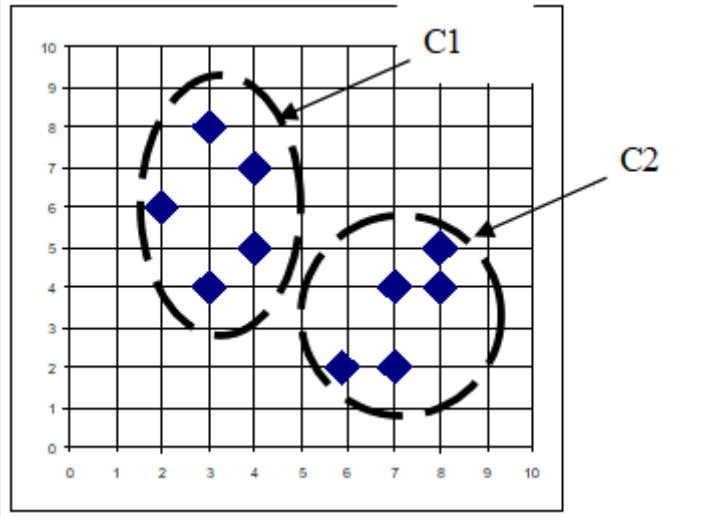
答:

- 什么是支持度，什么是可信度?
  - 支持度是指项集 X 和 Y在数据库 D 中同时出现的概率，即 $\sup = P(X \cup Y)$
  - 可信度是指项集 X 出现的情况下，项集 Y 在数据库 D 中同时出现的条件概率，即 $\text{conf} = P(Y|X) = \frac{P(X \cup Y)}{P(X)}$
- 频繁项集
  - {牙膏、牙刷、面包}的频度为2，而最小支持度是60%，最小支持频度为3，所以该项目集不是频繁项集。
- 关联规则
  - {牙膏、牙刷} 出现的频度为 5，而{牙膏、牙刷、饼干}出现的频度为4，上述两个项目集都满足最小支持60%，而且该关联规则的可信度为 4/5 = 80%，满足最小可信度的要求，所以能产生关联规则。

二．请从输入参数个数、能找出的聚类模式的形状、鲁棒性3个方面对如下聚类算法进行比较：k-Means算法、DBSCAN算法、OPTICS算法和BIRCH算法。（20分）

	K-means	DBSCAN	OPTICS	BIRCH
参数个数	1个参数为 k	x	x	x
聚类模式的形状	一般只能找出凸的形状	x	x	x
鲁棒性	对噪声敏感，不够鲁棒	x	x	x

三．设某聚类算法的聚类结果如下图所示，第一个簇（C1）中5个对象分别为（3，4）、（4，5）、（2，6）、（3，8）、（4，7），第二个簇（C2）中5个对象分别为（6，2）、（7，2）、（7，4）、（8，4）、（8，5），请算出C1和C2之间的中心点距离（用欧几里得距离函数）。(10分)



答：C1 中心点为:

$$\left\lfloor \frac{3+4+2+3+4}{5} \right\rfloor = 3$$

$$\left\lfloor \frac{4+5+6+8+7}{5} \right\rfloor = 6$$

即为(3, 6)

C2 中心点为：

$$\left\lfloor \frac{6+7+7+8+8}{5} \right\rfloor = 7$$

$$\left\lfloor \frac{2+2+4+4+5}{5} \right\rfloor = 3$$

即为(7, 3)

欧几里得距离为 $d(x,y) = \sqrt[2]{\sum (x-y)^2}$

$d = \sqrt[2]{(3-7)^2 + (6-3)^2} = \sqrt[2]{25} = 5$

四、什么是频繁序列？什么是最大序列？现有如下序列数据库，假设用户给定的最小支持度是50%，请问序列<EB>和序列<(EB)>的支持度分别是多少？它们是否是频繁序列？它们是否是最大序列？（20分）

顾客号	购物事件
0001	<A(ABC)>
0002	<CE(BC)>
0003	<(EBC)>
0004	<(EF)(BFE)>

答：

- 频繁序列
  - 如果某序列 x 在一个给定的序列数据库 D 里，并给定最小频度，如果 x 在数据库 D 里出现的频度大于最小频度，则说序列 x 是频繁的。
- 最大序列
  - 给定一个序列集合，如果某序列 x 不包含于任何一个其他的序列中，则称 x 是最大的序列。

- <EB>
  - 支持度为 2 / 4 = 50%
  - 是频繁序列
  - 不是最大序列
- <(EB)>
  - 支持度为 1/4 = 25%
  - 不是频繁序列
  - 不是最大序列

五、在下面的顾客数据库表中，假设Buys_computer是类标签属性，给定新元组“>40, High, no,fair”，请问如果用朴素贝叶斯分类法的话，该新元组的类标签应该是什么？请写出计算步骤。(30分)

Age	Income	student	credit_rating	Class: buys_computer
<=30	High	no	fair	No
<=30	High	no	excellent	No
31...40	High	no	fair	Yes
>40	Medium	no	fair	Yes
>40	Low	yes	fair	Yes
>40	Low	yes	excellent	No
31...40	Low	yes	excellent	Yes
<=30	Medium	no	fair	No
<=30	Low	yes	fair	Yes
>40	Medium	yes	fair	Yes
<=30	Medium	yes	excellent	Yes
31...40	Medium	no	excellent	Yes
31...40	High	yes	fair	Yes
>40	Medium	no	excellent	No

答:

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

$$P(C_i|X) \propto P(X|C_i)P(C_i)$$

$$P(C_i|>40, \text{High}, \text{no}, \text{fair}) = P(>40, \text{High}, \text{no}, \text{fair}|C_i)P(C_i)$$

$$P(C_{yes}) = 9/14, \quad P(C_{no}) = 5/14$$

$$P(>40|C_{yes}) = 3/9, \quad P(\text{High}|C_{yes}) = 2/9, \quad P(\text{no}|C_{yes}) = 3/9, \quad P(\text{fair}|C_{yes}) = 6/9$$

$$P(>40|C_{no}) = 2/5, \quad P(\text{High}|C_{no}) = 2/5, \quad P(\text{no}|C_{no}) = 4/5, \quad P(\text{fair}|C_{no}) = 2/5$$

$$\begin{aligned} P(C_{yes}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{yes}) \cdot P(\text{High}|C_{yes}) \cdot P(\text{no}|C_{yes}) \cdot P(\text{fair}|C_{yes}) \cdot P(C_{yes}) \\ &= \frac{3}{9} \cdot \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} \cdot \frac{9}{14} = \frac{2}{189} = 0.011 \end{aligned}$$

$$\begin{aligned} P(C_{no}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{no}) \cdot P(\text{High}|C_{no}) \cdot P(\text{no}|C_{no}) \cdot P(\text{fair}|C_{no}) \cdot P(C_{no}) \\ &= \frac{2}{5} \cdot \frac{2}{5} \cdot \frac{4}{5} \cdot \frac{2}{5} \cdot \frac{5}{14} = \frac{16}{875} = 0.018 \end{aligned}$$

即该新元组的标签为 No

《数据仓库与数据挖掘》试题

一．现有如下交易数据库，设用户给出的最小支持度是 60%、最小可信度是 75%

(a) 请用 **Apriori** 算法找出所有的频繁项目集。（10 分）

(b) 请找出所有的关联规则。（10 分）

(b) 请用 FP-Growth 算法找出频繁项(item)，并据此画出相应的 FP-tree。（5 分）

(d) 请从算法组件化思想的角度，比较 Apriori 算法和 FP-Growth 算法的异同。（5 分）

顾客号	交易商品集合
1	{O, P, Q, R, S, T}
2	{O, P, R, S }
3	{O, P, S }
4	{O, P, Q, Q }
5	{O, P, P }

二、假设数据挖掘的任务是将如下的 6 个点（用(x,y)代表位置）聚类为三个类。

A1(3,9)，A2(2,7)，A3(6,9)，A4(1,3)，A5(4,9)，A6(2,7)

距离函数是曼哈顿函数。

(a) 假设初始我们选择 A1，A3 和 A5 为每个聚类的中心，请用 k-means 算法给出在第二次循环执行后的聚类结果及其中心。(20 分)

(b) 请分析并举例说明 K-means 算法的缺点，针对这些缺点，请设计一种改进的聚类算法，给出算法思路的描述（可以是学过的或者没有学过的算法，言之有理即可）。(10 分)

三、什么是子序列？如何判定序列 A 是否是序列 B 的子序列？在如下序列数据库中， <ad> 分别是哪些序列的子序列？<ad>的支持度是多少？<(ab)>的支持度又是多少？（20 分）

SID	Sequence
10	<a(abc)(ac)d(cf)>
20	<(ad)c(bc)(ae)>
30	<(ef)(ab)(df)cb>
40	<eg(af)cbc>

四、请对任意一种决策树算法（比如 ID3 算法）的建树过程和决策过程进行描述。（20 分）

《数据仓库与数据挖掘》试题

一．现有如下交易数据库，设用户给出的最小支持度是 60%、最小可信度是 75%

(a) 请用 **Apriori** 算法找出所有的频繁项目集。（10 分）

(b) 请找出所有的关联规则。（10 分）

(b) 请用 FP-Growth 算法找出频繁项(item)，并据此画出相应的 FP-tree。（5 分）

(d) 请从算法组件化思想的角度，比较 Apriori 算法和 FP-Growth 算法的异同。（5 分）

顾客号	交易商品集合
1	{O, P, Q, R, S, T}
2	{O, P, R, S }
3	{O, P, S }
4	{O, P, Q, Q }
5	{O, P, P }

二、假设数据挖掘的任务是将如下的 6 个点（用(x,y)代表位置）聚类为三个类。

A1(3,9)，A2(2,7)，A3(6,9)，A4(1,3)，A5(4,9)，A6(2,7)

距离函数是曼哈顿函数。

(a) 假设初始我们选择 A1，A3 和 A5 为每个聚类的中心，请用 k-means 算法给出在第二次循环执行后的聚类结果及其中心。(20 分)

(b) 请分析并举例说明 K-means 算法的缺点，针对这些缺点，请设计一种改进的聚类算法，给出算法思路的描述（可以是学过的或者没有学过的算法，言之有理即可）。(10 分)

三、什么是子序列？如何判定序列 A 是否是序列 B 的子序列？在如下序列数据库中， <ad> 分别是哪些序列的子序列？<ad>的支持度是多少？<(ab)>的支持度又是多少？（20 分）

SID	Sequence
10	<a(abc)(ac)d(cf)>
20	<(ad)c(bc)(ae)>
30	<(ef)(ab)(df)cb>
40	<eg(af)cbc>

四、请对任意一种决策树算法（比如 ID3 算法）的建树过程和决策过程进行描述。（20 分）

以下是对《数据仓库与数据挖掘》试题的详细解答：

一、关联规则挖掘（Apriori 与 FP-Growth）

(a) Apriori 算法找出频繁项集

交易数据库：

顾客号	交易商品集合
1	{O, P, Q, R, S, T}
2	{O, P, R, S}
3	{O, P, S}
4	{O, P, Q}
5	{O, P}

最小支持度 = 60%，即出现次数 ≥ 3（5 条交易中至少出现 3 次）

步骤：

1. **C1（1-项集）：**

项集	支持度
O	5
P	5
Q	2
R	2
S	3
T	1

L1（频繁 1-项集）： {O}, {P}, {S}

2. **C2（2-项集）**：

项集	支持度
{O,P}	5
{O,S}	3
{P,S}	3

L2（频繁 2-项集）：{O,P}, {O,S}, {P,S}

3. **C3（3-项集）**：

项集	支持度
{O,P,S}	3

最终频繁项集：
{O}, {P}, {S}, {O,P}, {O,S}, {P,S}, {O,P,S}

(b) 找出所有关联规则

最小置信度 = 75%

从频繁项集 {O,P,S} 生成规则：

- O,P → S：支持度 = 3，置信度 = 3/5 = 60% ❌
- O,S → P：支持度 = 3，置信度 = 3/3 = 100% ✅
- P,S → O：支持度 = 3，置信度 = 3/3 = 100% ✅
- O → P,S：支持度 = 3，置信度 = 3/5 = 60% ❌
- P → O,S：支持度 = 3，置信度 = 3/5 = 60% ❌
- S → O,P：支持度 = 3，置信度 = 3/3 = 100% ✅

有效规则：

{O,S} → P

{P,S} → O

{S} → {O,P}

(c) FP-Growth 算法与 FP-tree

步骤：

1. 计算频繁 1-项集（同 Apriori）：{O:5}, {P:5}, {S:3}
2. 按支持度降序排序项：P, O, S
3. 按此顺序重排每条交易：

交易	重排后
1	P, O, S
2	P, O, S
3	P, O, S
4	P, O
5	P, O

4. **构建 FP-tree：**

```text
根
|
P:5
|
O:5
|
S:3
```

FP-tree 为一条链，因为所有交易都包含 P 和 O，且 S 出现在前三条交易中。

(d) Apriori 与 FP-Growth 比较

方面	Apriori	FP-Growth
思想	逐层生成候选集，剪枝	构建频繁模式树，无需候选集
扫描次数	多次扫描数据库	两次扫描
效率	候选集多时效率低	适合稠密数据集
组件化	生成候选 + 剪枝 + 计数	构建 FP-tree + 挖掘条件模式基

相同点：都用于挖掘频繁项集，支持度剪枝思想一致。
不同点：Apriori 产生大量候选，FP-Growth 通过树结构压缩数据，效率更高。

二、聚类分析（K-means）

(a) K-means 第二次迭代结果

点：A1(3,9), A2(2,7), A3(6,9), A4(1,3), A5(4,9), A6(2,7)
初始中心：A1(3,9), A3(6,9), A5(4,9)
距离函数：曼哈顿距离

第一次迭代聚类：

- 中心1(3,9)：A1(0), A2(4), A3(3), A4(8), A5(1), A6(4) → 最近：A1, A5
- 中心2(6,9)：A1(3), A2(6), A3(0), A4(11), A5(2), A6(6) → 最近：A3
- 中心3(4,9)：A1(1), A2(4), A3(2), A4(9), A5(0), A6(4) → 最近：A2, A4, A6

新中心：

- C1: A1(3,9), A5(4,9) → 中心 (3.5, 9)
- C2: A3(6,9) → 中心 (6, 9)
- C3: A2(2,7), A4(1,3), A6(2,7) → 中心 (1.67, 5.67)

第二次迭代聚类：

- 新中心1(3.5,9)：A1(1.5), A2(4.5), A3(2.5), A4(9.5), A5(0.5), A6(4.5) → 最近：A1, A3, A5
- 新中心2(6,9)：A1(3), A2(6), A3(0), A4(11), A5(2), A6(6) → 最近：无（被中心1抢走）
- 新中心3(1.67,5.67)：A1(6.34), A2(1.34), A3(7.34), A4(2.67), A5(6.34), A6(1.34) → 最近：A2, A4, A6

最终聚类：
C1: A1, A3, A5
C2: 无
C3: A2, A4, A6

中心更新：
C1: ((3+6+4)/3, (9+9+9)/3) = (4.33, 9)
C2: 无点，可删除或重新初始化
C3: ((2+1+2)/3, (7+3+7)/3) = (1.67, 5.67)

(b) K-means 缺点与改进

缺点：

- 对初始中心敏感
- 只能发现球形簇
- 对噪声和异常点敏感
- 需指定 k 值

改进算法：DBSCAN

- 基于密度，能发现任意形状簇
- 不需要指定 k
- 对噪声鲁棒

子序列定义

序列 A 是序列 B 的子序列，如果 A 的元素按顺序出现在 B 中，且每个元素是 B 中某个元素的子集（按项集序列匹配）。

<ad> 是否为子序列判断

- S10: <a(abc)(ac)d(cf)> → a 在第一个元素，d 在第四个元素 → ✅
- S20: <(ad)c(bc)(ae)> → a 和 d 在第一个元素中同时出现 → ✅（同一项集也算）
- S30: <(ef)(ab)(df)cb> → a 在第二个元素，d 在第三个元素 → ✅
- S40: <eg(af)cbc> → a 在第二个元素，但无 d → ❌

<ad> 的支持度：出现在 S10, S20, S30 → 3/4 = 75%

<(ab)> 的支持度：

- S10: a 在第一个元素，b 在第二个元素 → ✅
- S20: a 在第一个元素，b 在第三个元素 → ✅
- S30: a 在第二个元素，b 在第二个元素（同一项集） → ✅
- S40: a 在第二个元素，但无 b → ❌

支持度 = 3/4 = 75%

四、决策树算法（ID3）

建树过程：

1. 选择最优属性（信息增益最大）作为根节点
2. 按该属性取值划分数据集
3. 对每个子集递归建树，直到：
   - 所有样本属于同一类
   - 无属性可用 → 投票决定叶节点类别
   - 无样本 → 返回父节点多数类

决策过程：

从根节点开始，根据样本属性值沿树向下走到叶节点，叶节点的类别即为预测结果。

如果需要我将这些内容整理成答题卡或 PDF 格式，请告诉我。

数据仓库与数据挖掘 2022 B 卷

Please note that due to my limited knowledge, the following answer are for reference only. by Albert Yang

一．什么是支持度，什么是可信度？给定如下交易数据库，如果用户给定的最小支持度是60%，请问项目集合{牙膏、牙刷、面包} 是否是频繁项集？如果用户给定的最小可信度是80%，请问能否产生关联规则{牙膏、牙刷}—>{饼干}？(20分)

交易号	items bought
10	{牙膏、牙刷、牛奶、饼干}
20	{牙膏、牙刷、饼干}
30	{牙膏、牙刷、面包}
40	{牙膏、牙刷、面包、面包、饼干}
50	{牙膏、牙刷、牛奶、饼干}

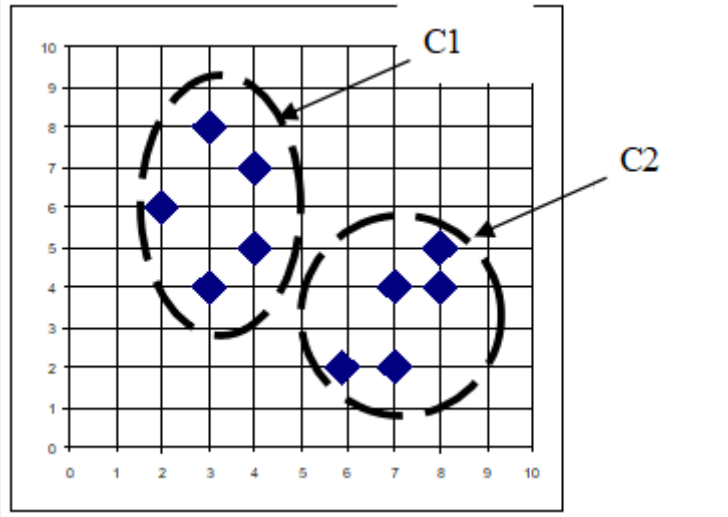
答:

- 什么是支持度，什么是可信度?
  - 支持度是指项集 X 和 Y在数据库 D 中同时出现的概率，即 $\sup = P(X \cup Y)$
  - 可信度是指项集 X 出现的情况下，项集 Y 在数据库 D 中同时出现的条件概率，即 $\text{conf} = P(Y|X) = \frac{P(X \cup Y)}{P(X)}$
- 频繁项集
  - {牙膏、牙刷、面包}的频度为2，而最小支持度是60%，最小支持频度为3，所以该项目集不是频繁项集。
- 关联规则
  - {牙膏、牙刷} 出现的频度为 5，而{牙膏、牙刷、饼干}出现的频度为4，上述两个项目集都满足最小支持60%，而且该关联规则的可信度为 4/5 = 80%，满足最小可信度的要求，所以能产生关联规则。

二．请从输入参数个数、能找出的聚类模式的形状、鲁棒性3个方面对如下聚类算法进行比较：k-Means算法、DBSCAN算法、OPTICS算法和BIRCH算法。（20分）

	K-means	DBSCAN	OPTICS	BIRCH
参数个数	1个参数为 k	x	x	x
聚类模式的形状	一般只能找出凸的形状	x	x	x
鲁棒性	对噪声敏感，不够鲁棒	x	x	x

三．设某聚类算法的聚类结果如下图所示，第一个簇（C1）中5个对象分别为（3，4）、（4，5）、（2，6）、（3，8）、（4，7），第二个簇（C2）中5个对象分别为（6，2）、（7，2）、（7，4）、（8，4）、（8，5），请算出C1和C2之间的中心点距离（用欧几里得距离函数）。(10分)



答：C1 中心点为:

$$\left\lfloor \frac{3+4+2+3+4}{5} \right\rfloor = 3$$

$$\left\lfloor \frac{4+5+6+8+7}{5} \right\rfloor = 6$$

即为(3, 6)

C2 中心点为：

$$\left\lfloor \frac{6+7+7+8+8}{5} \right\rfloor = 7$$

$$\left\lfloor \frac{2+2+4+4+5}{5} \right\rfloor = 3$$

即为(7, 3)

欧几里得距离为 $d(x,y) = \sqrt[2]{\sum (x-y)^2}$

$d = \sqrt[2]{(3-7)^2 + (6-3)^2} = \sqrt[2]{25} = 5$

四、什么是频繁序列？什么是最大序列？现有如下序列数据库，假设用户给定的最小支持度是50%，请问序列<EB>和序列<(EB)>的支持度分别是多少？它们是否是频繁序列？它们是否是最大序列？（20分）

顾客号	购物事件
0001	<A(ABC)>
0002	<CE(BC)>
0003	<(EBC)>
0004	<(EF)(BFE)>

答：

- 频繁序列
  - 如果某序列 x 在一个给定的序列数据库 D 里，并给定最小频度，如果 x 在数据库 D 里出现的频度大于最小频度，则说序列 x 是频繁的。
- 最大序列
  - 给定一个序列集合，如果某序列 x 不包含于任何一个其他的序列中，则称 x 是最大的序列。

- <EB>
  - 支持度为 2 / 4 = 50%
  - 是频繁序列
  - 不是最大序列
- <(EB)>
  - 支持度为 1/4 = 25%
  - 不是频繁序列
  - 不是最大序列

五、在下面的顾客数据库表中，假设Buys_computer是类标签属性，给定新元组“>40, High, no,fair”，请问如果用朴素贝叶斯分类法的话，该新元组的类标签应该是什么？请写出计算步骤。(30分)

Age	Income	student	credit_rating	Class: buys_computer
<=30	High	no	fair	No
<=30	High	no	excellent	No
31...40	High	no	fair	Yes
>40	Medium	no	fair	Yes
>40	Low	yes	fair	Yes
>40	Low	yes	excellent	No
31...40	Low	yes	excellent	Yes
<=30	Medium	no	fair	No
<=30	Low	yes	fair	Yes
>40	Medium	yes	fair	Yes
<=30	Medium	yes	excellent	Yes
31...40	Medium	no	excellent	Yes
31...40	High	yes	fair	Yes
>40	Medium	no	excellent	No

答:

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

$$P(C_i|X) \propto P(X|C_i)P(C_i)$$

$$P(C_i|>40, \text{High}, \text{no}, \text{fair}) = P(>40, \text{High}, \text{no}, \text{fair}|C_i)P(C_i)$$

$$P(C_{yes}) = 9/14, \quad P(C_{no}) = 5/14$$

$$P(>40|C_{yes}) = 3/9, \quad P(\text{High}|C_{yes}) = 2/9, \quad P(\text{no}|C_{yes}) = 3/9, \quad P(\text{fair}|C_{yes}) = 6/9$$

$$P(>40|C_{no}) = 2/5, \quad P(\text{High}|C_{no}) = 2/5, \quad P(\text{no}|C_{no}) = 4/5, \quad P(\text{fair}|C_{no}) = 2/5$$

$$\begin{aligned} P(C_{yes}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{yes}) \cdot P(\text{High}|C_{yes}) \cdot P(\text{no}|C_{yes}) \cdot P(\text{fair}|C_{yes}) \cdot P(C_{yes}) \\ &= \frac{3}{9} \cdot \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} \cdot \frac{9}{14} = \frac{2}{189} = 0.011 \end{aligned}$$

$$\begin{aligned} P(C_{no}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{no}) \cdot P(\text{High}|C_{no}) \cdot P(\text{no}|C_{no}) \cdot P(\text{fair}|C_{no}) \cdot P(C_{no}) \\ &= \frac{2}{5} \cdot \frac{2}{5} \cdot \frac{4}{5} \cdot \frac{2}{5} \cdot \frac{5}{14} = \frac{16}{875} = 0.018 \end{aligned}$$

即该新元组的标签为 No