文本处理深度学习模型——卷积神经网络（CNN）

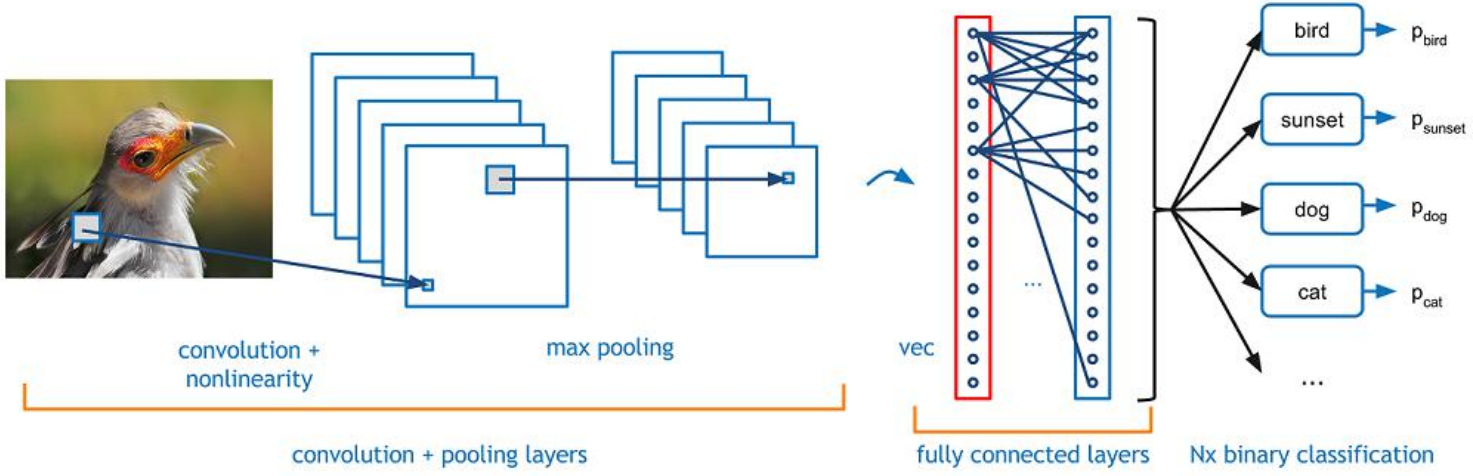
- 使用卷积神经网络（CNN）模型对文本进行分类

大纲；结构框架

- 关于 CNN:
- 了解卷积神经网络
- 指定卷积神经网络的层结构
- 使用卷积神经网络对文本数据进行分类

中心体

- 卷积神经网络（CNN或ConvNet）是深度学习领域最流行的算法之一，这是一种机器学习方法，模型能够直接从图像、视频、文本或音频中学习执行分类任务。



中心体

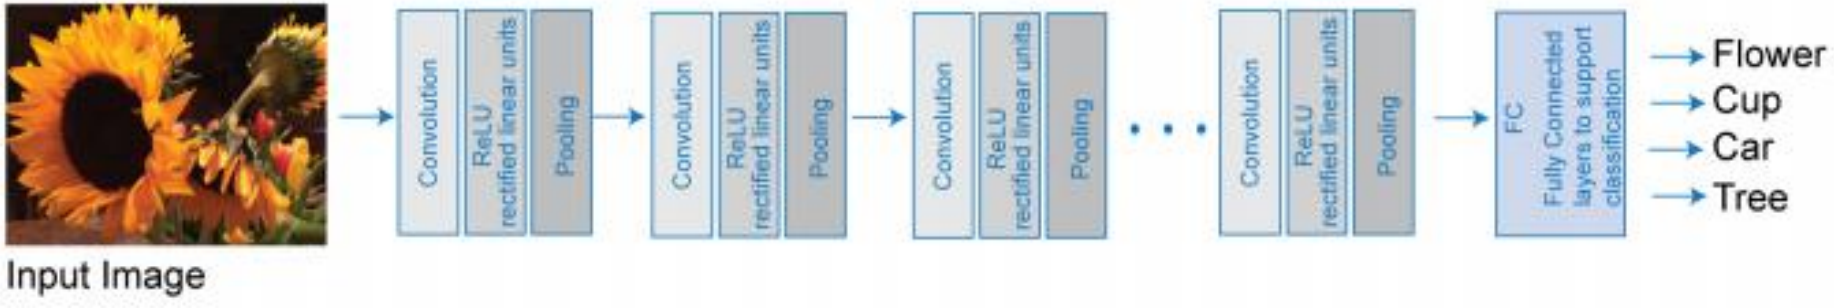
- 卷积神经网络（ConvNets）特别适用于以图像作为输入的情况，尽管它们也广泛应用于文本、信号及其他连续响应等场景。与其他类型的神经网络相比，其主要区别体现在以下几个方面：
- 卷积神经网络的灵感源自视觉皮层的生物结构，该结构包含简单细胞与复杂细胞的排列。研究发现这些细胞会根据视野的不同亚区被激活，这些亚区被称为感受野。

中心体

- 受本研究结果启发，卷积层中的神经元并非像其他类型神经网络那样采用全连接结构，而是与该层之前的各子区域相连。这些神经元对图像中这些子区域之外的区域均无响应。
- 这些子区域可能存在重叠，因此卷积神经网络（ConvNet）中的神经元会产生空间相关的输出；而在其他类型的神经网络中，神经元之间不共享任何连接，而是产生独立的输出。

中心体

- 此外，在具有全连接神经元的神经网络中，随着输入数据量的增加，参数（权重）的数量会迅速增加。卷积神经网络通过减少连接数量、采用共享权重以及进行下采样，从而降低参数数量。
- CNN由卷积层、池化层和全连接层组成。



中心体

- 卷积神经网络（ConvNet）各层中的神经元以三维方式排列，可将三维输入信号转换为三维输出结果。以图像输入为例：第一层（输入层）接收具有高度、宽度及图像颜色通道等维度的三维图像数据；该卷积层中的神经元会作用于图像的特定区域，并将其转化为三维输出信号。

中心体

- 每一层中的隐藏单元（神经元）会学习原始输入数据的非线性组合，这一过程称为特征提取。从一层学到的这些特征（也称为激活值）将作为下一层的输入；最终，这些特征将成为网络末端分类器或回归函数的输入参数。

中心体

- 卷积神经网络（ConvNet）的架构会根据所包含的层类型及数量而有所不同；具体层的类型与数量则取决于具体的应用场景或数据特性。例如，若输入数据为分类型响应，则必须包含分类函数和分类层；而若输入数据为连续型响应，则需在网络末端添加回归层。

中心体

- 仅包含一到两个卷积层的小型网络可能足以处理少量灰度图像数据；而对于包含数百万张彩色图像的复杂数据集，则可能需要采用具有多个卷积层和全连接层的更复杂网络。

中心体

- 您可以在 MATLAB 中按以下方式连接卷积神经网络的各层:

层：[图像输入层 ([28 28 1])]
二维卷积层（5,20）
reluLayer
最大池化二维层（参数：2、“步长”为2）
fullyConnectedLayer(10)
softmaxLayer
classificationLayer];

中心体

- 定义好网络的各层后，您必须指定相关参数。
  training options using the trainingOptions function. For example,

options = trainingOptions('sgdm');

- 随后，您可以使用 `trainNetwork` 函数，利用训练数据对网络进行训练。所需参数包括数据集、神经网络层结构以及训练选项。
  become the inputs to the training function. For example,

convnet = trainNetwork(data,layers,options);

指定卷积神经网络的层结构

- 构建并训练新的卷积神经网络（ConvNet）的第一步是定义其网络架构。网络架构会根据所使用的层类型及层数而有所不同，具体选择取决于具体应用场景或数据特性。例如：若处理分类响应数据，则需包含softmax层和分类层；若处理连续型响应数据，则在网络末端需添加回归层。

指定卷积神经网络的层结构

- 仅包含一到两个卷积层的较小网络，或许已足以处理少量灰度图像数据；而对于包含数百万张彩色图像的复杂数据集，则可能需要采用包含多个卷积层和全连接层的更复杂网络。
- 要指定所有层均依次连接的深度神经网络架构，请直接创建一个层数组。例如，若需构建一个将28×28灰度图像分类为10个类别的深度网络，请指定相应的层数组。

指定卷积神经网络的层结构

层：[

imageInputLayer([28 28 1])

二维卷积层（3,16，“填充”，1）

批处理层：卷积层、重复层、最大池化层（2D）（参数：2、“步长”为2）

卷积二维层（3,32，“填充”，1）

batchNormalizationLayer

reluLayer

fullyConnectedLayer(10)

softmaxLayer

classificationLayer];

指定卷积神经网络的层结构

- layers 是一个由**Layer**对象组成的数组。随后可将 layers 作为训练函数 trainNetwork 的输入参数。
- 要指定所有层均依次连接的神经网络架构，请直接创建一个层数组。要指定具有多个输入或输出层的网络架构，请使用**LayerGraph**对象。

图像输入层

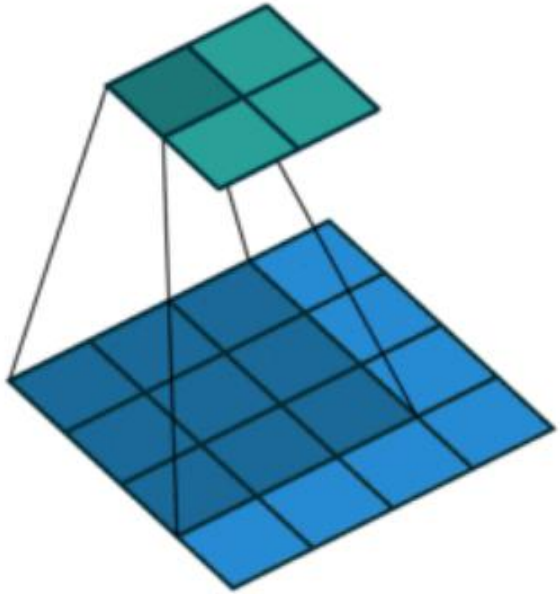
- 使用*imageInputLayer*创建图像输入层。
- 图像输入层将图像输入神经网络并进行数据归一化处理。
- 使用*inputSize*参数指定图像尺寸。图像尺寸对应于该图像的高度、宽度及颜色通道数。例如，灰度图像的通道数为1，彩色图像的通道数为3。

卷积层

- 二维卷积层会对输入应用滑动卷积滤波器。使用*convolution2dLayer*创建二维卷积层。该卷积层包含以下组件：**滤波器和步长**。
- 卷积层由连接到输入图像子区域或前一层输出结果的神经元组成。该层在扫描图像时学习这些区域所定位的特征。使用*convolution2dLayer*函数创建层时，可通过filterSize输入参数指定这些区域的尺寸。

卷积层

- 该图像展示了一个3×3滤波器对输入信号进行扫描的过程。下方图示为输入信号，上方图示为输出信号。



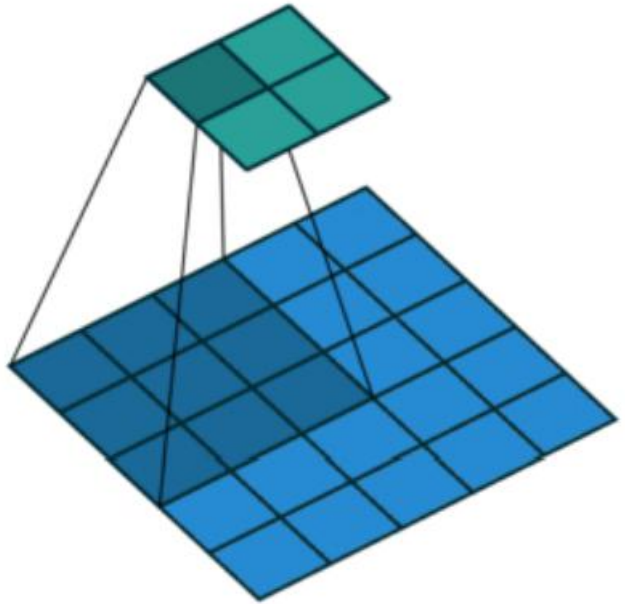
MIN UNIVERSITY OF CHINA

卷积层

- 滤波器移动时的步长称为*步幅*。您可通过*步幅*名称-值对参数指定该步长。神经元连接的局部区域可能根据filterSize和‘stride’值发生重叠。

卷积层

- 该图像展示了一个3×3滤波器以步长为2遍历输入数据。下图表示输入数据，上图表示输出结果。



Y OF CHINA

卷积层

- 滤波器中的权重数量为 h × w × c，其中 h 分别表示滤波器的高度和宽度，c 表示输入图像的通道数。例如，若输入为彩色图像，则颜色通道数为 3。滤波器的数量决定了卷积层输出结果的通道数。请使用 `convolution2dLayer` 函数的 `numFilters` 参数指定所需的滤波器数量。

膨胀卷积

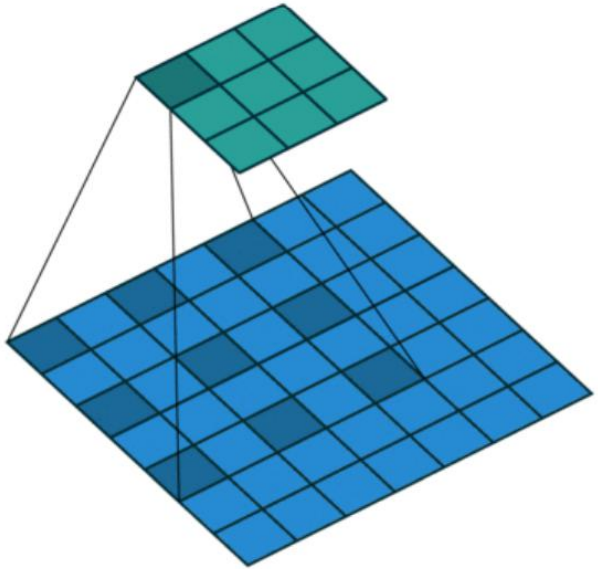
- 扩张卷积是一种通过在滤波器元素之间插入空隙来扩展滤波器的卷积运算。请使用‘DilationFactor’属性指定扩张因子。
- 采用扩张卷积技术可在不增加参数数量或计算量的前提下，扩大神经层的感受野（即该层可感知的输入区域）。

膨胀卷积

- 该层通过在每个滤波器元素之间插入零值来扩展滤波器。膨胀因子决定了采样输入信号的步长，即等效于滤波器的上采样因子；其计算公式为：有效滤波器尺寸 =（滤波器尺寸 − 1）× 膨胀因子 + 1。例如，具有膨胀因子[2 2]的3×3滤波器，等同于在各元素之间插入零值的5×5滤波器。

膨胀卷积

- 该图像展示了经过两倍因子扩张的3×3滤波器对输入信号进行扫描的结果。下图表示输入信号，上图表示输出信号。



ENMIN UNIVERSITY OF CHINA

功能地图

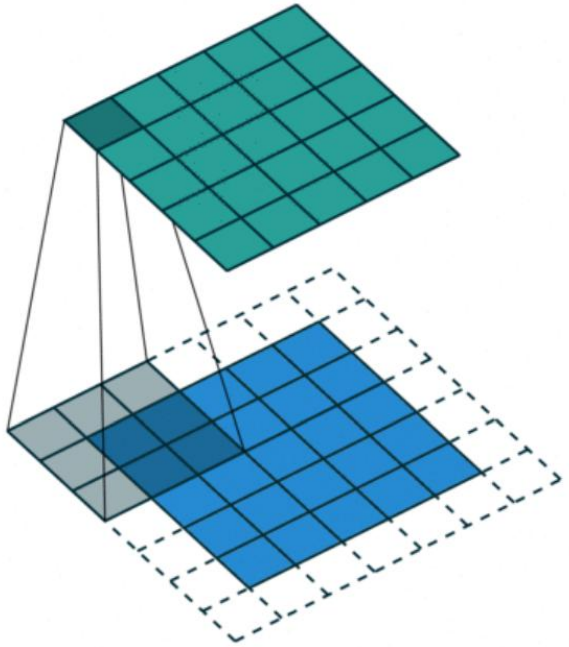
- 当滤波器沿输入信号移动时，它会在卷积运算中使用相同的权重矩阵和相同的偏置值，从而生成特征图。每个特征图都是采用不同权重矩阵和不同偏置值进行卷积运算的结果；因此，特征图的数量等于滤波器的数量。卷积层中的总参数数量为 ((h × w × c + 1) × 滤波器数量)，其中 1 表示偏置值。

零填充

- 您还可以使用“Padding”名称-值对参数，在输入图像的上下左右边框处应用零填充。零填充是指在图像输入的边框处添加由零组成的行或列。通过调整填充值，您可以控制图层的输出尺寸。

零填充

- 该图像展示了一个3×3滤波器以大小为1的填充值遍历输入数据。下图表示输入数据，上图表示输出结果。



CHINA

输出大小

- 卷积层的输出高度和宽度为（输入尺寸）。
  – （过滤器尺寸 × 1）× 扩张因子 + 1）+ 2 × 填充值 / 步长 + 1。该数值必须为整数，以确保整个图像被完全覆盖。如果上述参数组合仍无法实现完全覆盖，则软件默认会在卷积运算中忽略图像右侧和底部边缘的剩余部分。

神经元数量

- 输出高度与宽度的乘积即为特征图中的神经元总数（记为Map Size）。卷积层中的神经元总数（输出尺寸）等于Map Size乘以滤波器数量。
- 通常，这些神经元的输出结果会经过某种非线性处理方式，例如修正线性单元（ReLU）。

神经元数量

- 例如，假设输入图像为一个32×32×3的彩色图像。对于具有八个滤波器、滤波器尺寸为5×5的卷积层，每个滤波器的权重数量为5×5×3=75，该层的总参数量为(75+1)×8=608。若步长在每个方向均为2且指定2大小的填充，则每个特征图的尺寸为16×16。这是因为（32×32×3）乘以2×2等于648，而每个特征图需要存储75个权重值；若采用2×2的填充，则每个特征图仅需存储75个权重值。
  - (5 + 2 × 2) / 2 + 1 = 16.5；图像右侧和底部的一些最外层零填充数据被舍弃。最终，该层中的神经元总数为 16 × 16 × 8 = 2048。

批量归一化层

- 使用 `batchNormalizationLayer` 创建一个批量归一化层。
- 批归一化层可对每个输入通道在小批量数据上进行归一化处理。为加快卷积神经网络的训练速度并降低其对网络初始化参数的敏感性，应在卷积层与非线性层（如ReLU层）之间引入批归一化层。

批量归一化层

- 该层首先通过减去小批量均值并除以小批量标准差，对每个通道的激活值进行归一化处理；随后将输入信号偏移一个可学习的偏移量 β，并按可学习的比例因子 γ 进行缩放。β 和 γ 均为可学习参数，在网络训练过程中会持续更新。

批量归一化层

- 批归一化层能够对神经网络中传播的激活值和梯度进行归一化处理，从而使网络训练转化为更易优化的问题。您可以尝试提高学习率；也可以降低L2正则化项或丢弃率（dropout）。使用批归一化层时，训练过程中特定图像的激活值会取决于该图像恰好出现在哪个小批量样本中。为充分发挥这种正则化效果，请在每个训练周期前对训练数据进行随机打乱。

卷积神经网络（ReLU）层

- 使用 reluLayer 创建一个 ReLU 层。
- ReLU层会对每个元素执行阈值运算。
  输入值中，所有小于零的数值均被设置为零。

$$f(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

最大池化层与平均池化层

- 最大池化层通过将输入数据划分为矩形池化区域并计算每个区域的最大值来实现下采样。可使用 maxPooling2dLayer 构建该层。
- 平均池化层通过将输入数据划分为矩形池化区域并计算每个区域的平均值来实现下采样。可使用 averagePooling2dLayer 创建该层。

最大池化层与平均池化层

- 池化层在卷积层之后用于下采样，从而减少后续层的连接数量。它们本身不执行任何学习任务，但能降低后续层需要学习的参数数量，并有助于缓解过拟合问题。
- 池化层以您通过“stride”名称-值对参数指定的步长，沿输入数据进行水平和垂直方向扫描。若池化尺寸小于或等于步长，则各池化区域不会重叠。

丢弃层

- 使用 dropoutLayer 创建一个丢弃层。该层会以指定概率随机将输入元素置零。
- 在训练过程中，该层会根据丢弃掩码 rand（大小为 X）乘以概率值，将输入元素随机设为零（X 表示该层的输入），随后将剩余元素按 1/(1-概率值) 进行缩放。这一操作能有效改变网络在不同训练轮次间的底层架构结构，从而防止网络过拟合。丢弃掩码的数值越大，在训练过程中被舍弃的元素数量就越多。
- 在预测时，该层的输出与其输入值相等。

RENMIN UNIVERSITY OF CHINA

全连接层

- 使用 fullyConnectedLayer 创建一个全连接层。该层会将输入与权重矩阵相乘，然后添加偏置向量。
- 卷积层（及下采样层）之后接有一个或多个全连接层。

全连接层

- 顾名思义，全连接层中的所有神经元均与前一层的所有神经元相连。该层整合了前几层在图像中学习到的所有特征（局部信息），以识别更宏观的模式。在分类任务中，最后一个全连接层会综合这些特征对图像进行分类；因此网络最后一层全连接层的outputSize参数必须等于数据集的类别数量。而在回归任务中，输出尺寸则需等于响应变量的数量。

Softmax层与分类层

- softmax层会对输入数据应用softmax函数。请使用softmaxLayer模块创建一个softmax层。
- 分类层用于计算具有互斥类别的多类别分类问题中的交叉熵损失。可使用classificationLayer创建该分类层。
- 对于分类问题，最终的全连接层之后必须依次接入一个softmax层和一个分类层。

回归层

- 使用 `regressionLayer` 创建一个回归层。
- 回归层用于计算回归问题中的半均方误差损失。对于典型的回归问题，回归层必须位于最终的全连接层之后。

使用卷积神经网络对文本数据进行分类

- 本示例展示了如何使用卷积神经网络对文本数据进行分类。要利用卷积技术进行文本分类，首先需将文本数据转换为图像形式：通过填充或截断观测值使其长度恒定为S，并利用词嵌入方法将文档转换为长度为C的词向量序列；最终可将文档表示为1×S×C尺寸的图像（即高度为1、宽度为S、通道数为C的图像）。

使用卷积神经网络对文本数据进行分类

- 要将CSV文件中的文本数据转换为图像，请创建一个tabularTextDatastore对象，然后将从该对象中读取的数据进行转换。通过调用带有自定义转换函数的transform方法，将tabularTextDatastore对象转换为适用于深度学习的图像数据。transformTextData函数接收从数据存储中读取的数据及预训练词嵌入向量，并将每个观测值转换为词向量数组。

使用卷积神经网络对文本数据进行分类

- 本示例使用不同宽度的一维卷积滤波器训练神经网络。每个滤波器的宽度对应其可识别的词数（即n元语法长度）。该网络包含多个卷积层分支，因此能够支持不同的n元语法长度。

加载预训练的Word嵌入向量及数据

- 加载预训练的 fastText 词嵌入。

emb = fastTextWordEmbedding;

- 根据 factoryReports.csv 中的数据创建一个表格型文本数据存储。仅读取“描述”和“类别”列中的数据。

filenameTrain = "factoryReports.csv";

文本名称 = “描述”;

类别名称 = “类别”;

ttdsTrain = tabularTextDatastore(filenameTrain,'SelectedVariableNames',[textName labelName]);

tabularTextDatastore

- 使用TabularTextDatastore对象来管理包含列式或表格化数据的大型文本文件集合，此类集合未必能完全容纳于内存中。
- 表格数据是以矩形形式排列的数据，每行包含相同数量的条目。

加载数据

- 创建一个自定义转换函数，将从数据存储中读取的数据转换为包含预测变量和响应值的表格。`transformTextData`函数可接收从`tabularTextDatastore`对象读取的数据，并返回包含预测变量与响应值的表格。预测变量为按`sequenceLength`维度乘以`C`维的词向量数组（由词嵌入向量`emb`表示，其中`C`为嵌入维度）；响应值则为`classNames`类别集合中的分类标签。

加载数据

- 使用readLabels函数读取训练数据中的标签，并找出唯一的类别名称。

```
labels = readLabels(ttdsTrain,labelName);
classNames = unique(labels);
numObservations = numel(labels);
```

读取标签

```
function labels = readLabels(ttds,labelName)
   ttdsNew = copy(ttds);
   ttdsNew.SelectedVariableNames = labelName;
   tbl = readall(ttdsNew);
   标　签　　=　表　格　。
(labelName)；结束
```

加载数据

使用transformTextData函数转换数据存储，并指定序列长度为14。

```
sequenceLength = 14;
tdsTrain = transform(ttdsTrain, @(data) transformTextData(data,sequenceLength,emb,classNames))
```

转换文本数据函数

- transformTextData函数接收从tabularTextDatastore对象中读取的数据，并返回包含预测变量与响应值的表格。预测变量为按序列长度乘C维的词向量数组（由词嵌入emb表示，其中C为嵌入维度）；响应值则为分类名classNames中各类别的分类标签。

转换文本数据函数

函数 `dataTransformed` = `transformTextData(data，sequenceLength，emb，classNames)`% 预处理文档。

textData = data{:,

1}；% 预处理文本

dataTransformed = preprocessText(textData,sequenceLength,emb);

% 阅读标签。

标签 = 数据{:，2};

响应类型：分类型（标签、类别）；% 将数据转换为表格。

数据已转换。响应结果如下：end

预处理文本功能

```
函数 tbl = preprocessText（textData，sequenceLength，emb）
  documents = tokenizedDocument(textData);
  文档 = 更少（文档）；
  % Convert documents to embeddingDimension-by-sequenceLength-by-1 images.
  predictors = doc2sequence(emb,documents,'Length',sequenceLength); % Reshape
  images to be of size 1-by-sequenceLength-embeddingDimension.predictors =
  cellfun(@(X) permute(X,[3 2 1]),predictors,'UniformOutput',false); tbl = table;
  表。预测变量 = 预测变量；结
束
```

加载数据

- 预览转换后的数据存储。预测变量为1×S×C数组，其中S表示序列长度，C表示特征数量（即嵌入维度）；响应变量为分类标签。

预览（tdsTrain）

答案：一个 8×2 的表格。

预测因子与反应之间的关系

{1×14×300 单一机械故障

{1×14×300 单一机械故障

{1×14×300 单个电子故障 ……

定义网络架构

以下步骤描述了网络架构。

- 指定输入尺寸为1×S×C，其中S表示序列长度，C表示特征数量（即嵌入维度）。
- 针对长度为2、3、4和5的n元组，分别构建包含卷积层、批量归一化层、ReLU激活函数层、丢弃层以及最大池化层的网络模块。
- 对于每个块，需指定200个尺寸为1×N的卷积滤波器以及尺寸为1×S的池化区域（其中N表示n元语法长度）。

定义网络架构

- 将输入层与各模块相连，并使用深度拼接层将各模块的输出结果进行拼接。
- 为对输出结果进行分类，需包含一个输出维度为K的全连接层、一个softmax层以及一个分类层，其中K表示类别数量。

定义网络架构

- 首先，在层结构中需指定输入层、单字组处理的第一个模块、深度拼接层、全连接层、softmax层以及分类层。

numFeatures = 嵌入维度;

输入大小 = [1 序列长度 × 特征数量];

numFilters = 200;

ngramLengths = [2 3 4 5];

numBlocks = numel(ngramLengths);

numClasses = numel(classNames);

定义网络架构

- 创建包含输入层的图层结构。将归一化选项设置为“none”，层名称设置为“input”。

```
layer = imageInputLayer(inputSize,'Normalization','none','Name','input');
lgraph = layerGraph(layer);
```

- 针对每种n元语法长度，分别构建包含卷积层、批量归一化层、ReLU激活函数层、丢弃层和最大池化层的模块组，并将每个模块组连接至输入层。

对于 j = 1 至 numBlocks，

N = ngramLengths(j)；

block = [

卷积二维层（[1 N]，滤波器数量，名称，“conv”+N，填充值，“same”）；批量归一化层（名称，“bn”+N）

卷积层（‘名称’，‘relu’+N）

丢弃层（0.2，“名称”，“drop”+N）

maxPooling2dLayer([1 sequenceLength],'Name',"max"+N)];

lgraph = addLayers(lgraph,block);

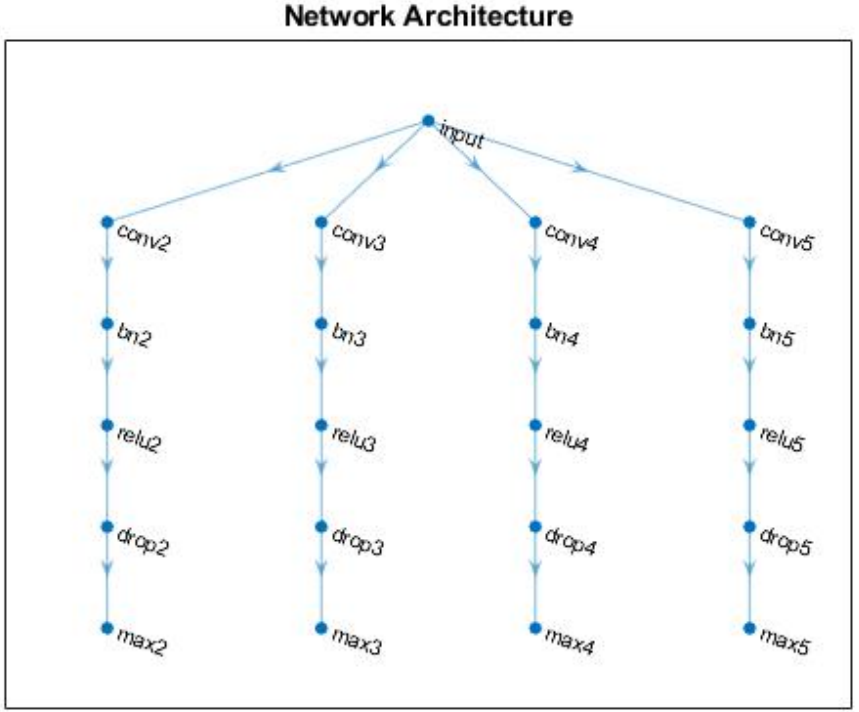
lgraph = connectLayers(lgraph，‘input’，‘conv’+N)；end

定义网络架构

- 在图表中查看网络架构。

图表（lgraph）

标题：“网络架构”



定义网络架构

- 添加深度拼接层、全连接层、softmax层以及分类层。

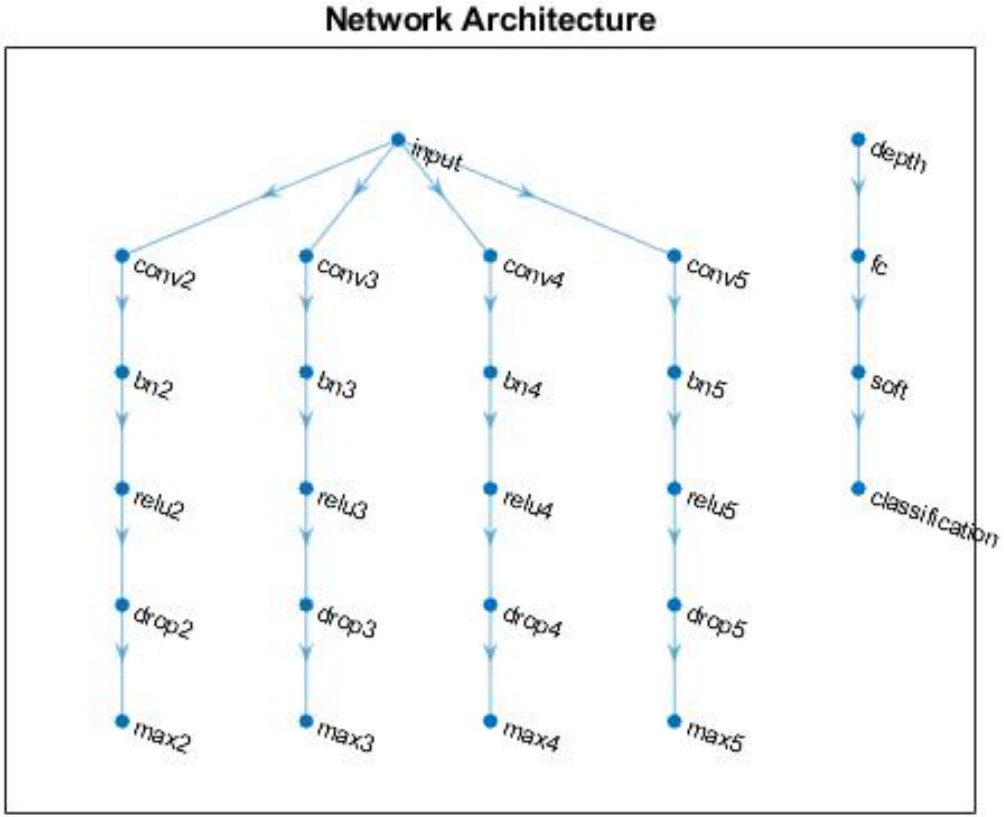
```
层：[
 深度连接层（numBlocks、‘名称’、‘深度’）；全连接
 层（numClasses、‘名称’、‘fc’）
 softmax层（“名称”，“软”）
 classificationLayer('Name','classification')];
lgraph = addLayers(lgraph,layers);
```

定义网络架构

图

图表（lgraph）

标题：“网络架构”



定义网络架构

- 将最大池化层与深度拼接层相连，并在图表中查看最终网络架构。

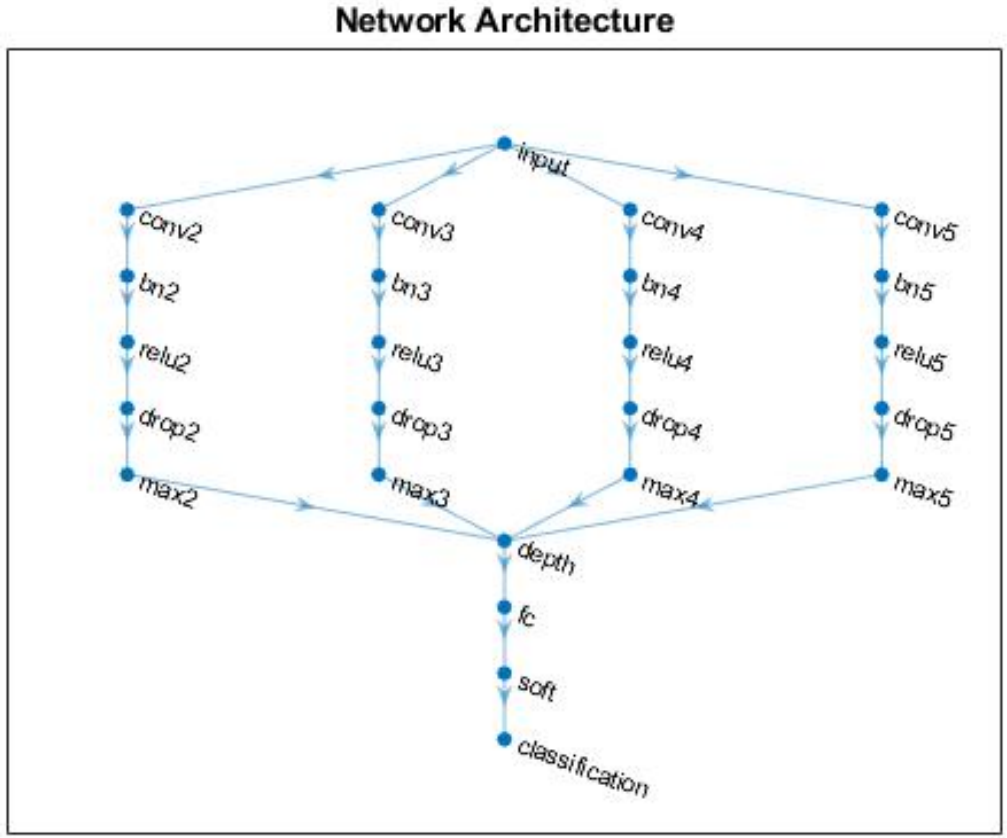
```
for j = 1:numBlocks
 N = ngramLengths(j);
 lgraph = connectLayers(lgraph, “max” + N, “深度/单位” + j); end
```

定义网络架构

图

图表（lgraph）

标题：“网络架构”



列车网络

指定训练选项：

- 使用最小批量大小为 128 的训练集进行训练。
- 请勿对数据进行洗牌，因为该数据存储不可洗牌。
- 显示训练进度图并隐藏详细输出内容。

miniBatchSize = 128;

每个训练周期的迭代次数 = 四舍五入后的观测值除以小批量大小；可选参数 = 训练选项（如‘adam’等）。

'MiniBatchSize',miniBatchSize, ...

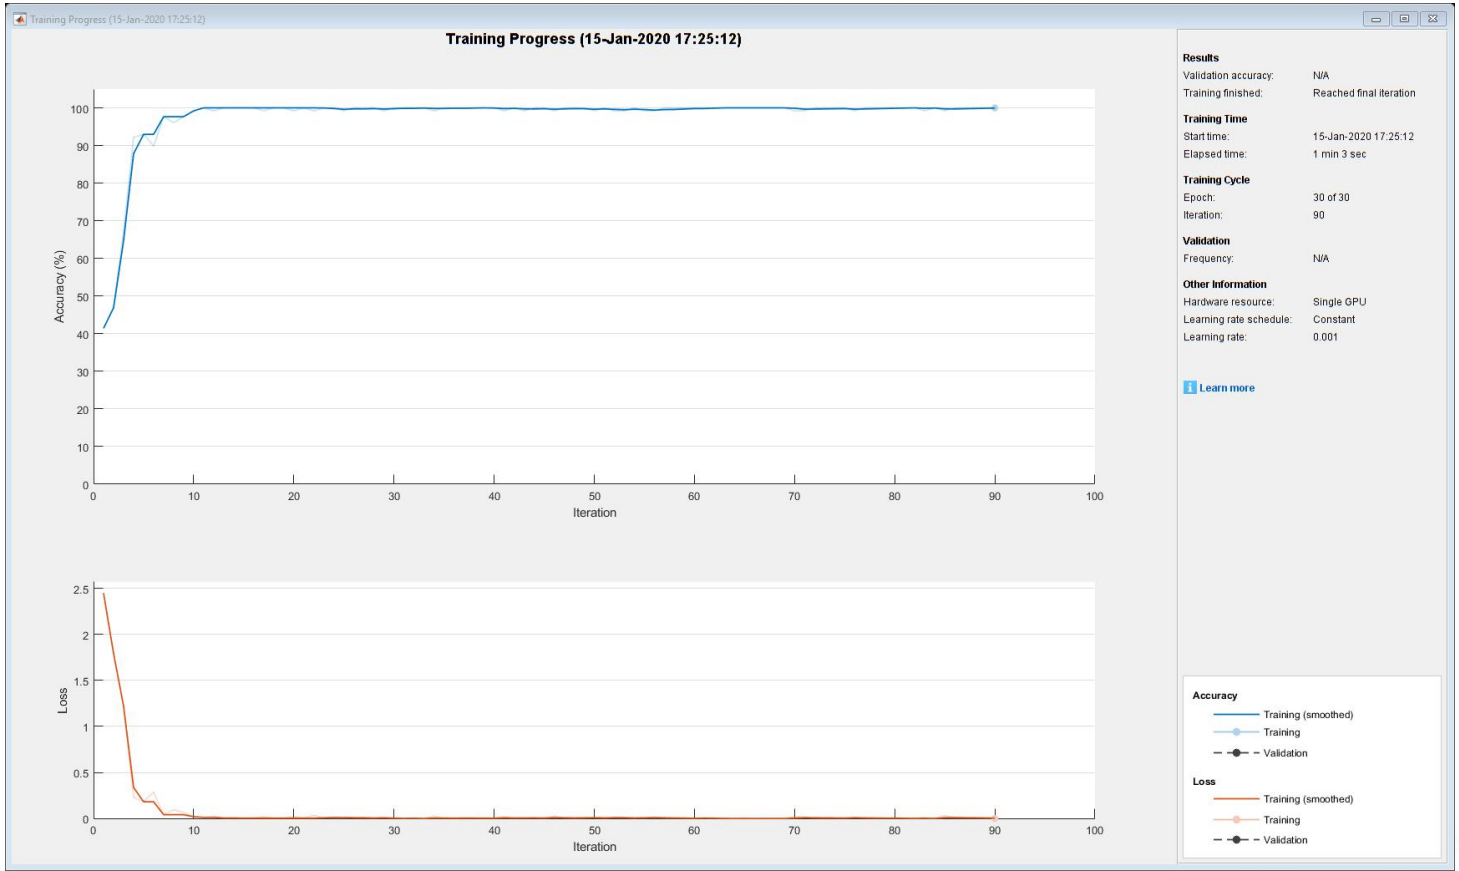
“随机排序”，“绝不”

“情节”、“训练进度”.....

“冗长的”，错误）；

Train the network using the trainNetwork function.

net = trainNetwork(tdsTrain,lgraph,options);



利用新数据进行预测

- 对三份新报告的事件类型进行分类，并创建一个包含这些新报告的字符串数组。

```
reportsNew = [
 冷却液在分选机下方积聚。
 启动时，Sorter会触发保险丝熔断。
 组装机发出了一些非常响亮的咔嗒声。
```

- 使用预处理步骤对文本数据进行预处理，并将其作为训练文档。

```
XNew = preprocessText(reportsNew,sequenceLength,emb);
```

利用新数据进行预测

- 使用训练好的 LSTM 网络对新序列进行分类。

标签新值 = 分类（网络数据集，XNew）

标签数量：3×1 个分类变量

（Leak）

电子故障；机械故障