# 文本处理深度学习模型——LSTM

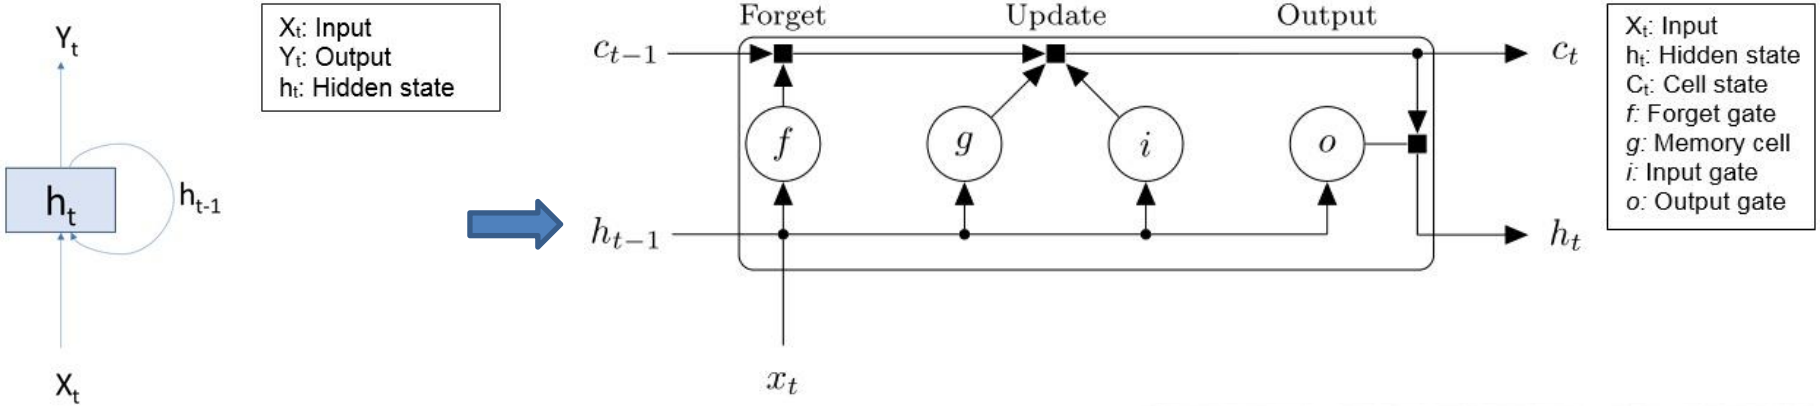
- 使用 LSTM 模型对文本进行分类

# 大纲；结构框架

- 关于 RNN 和 LSTM
- 长短期记忆网络
- 使用 LSTM 对文本数据进行分类

# RNN 与 LSTM

- 长短期记忆网络是一种循环神经网络（RNN）类型。LSTM在学习、处理和分类序列数据方面表现卓越，常见应用领域包括情感分析、语言建模、语音识别和视频分析。



# 长短期记忆网络

- 本节阐述如何利用长短期记忆（LSTM）网络处理序列数据和时间序列数据，以完成分类与回归任务。
- LSTM 网络是一种循环神经网络（RNN），能够学习序列数据中时间步之间的长期依赖关系。

# LSTM 网络架构

- LSTM 网络的核心组件包括序列输入层和 LSTM 层。序列输入层负责将序列数据或时间序列数据输入网络； LSTM 层则用于学习序列数据各时间步之间的长期依赖关系。

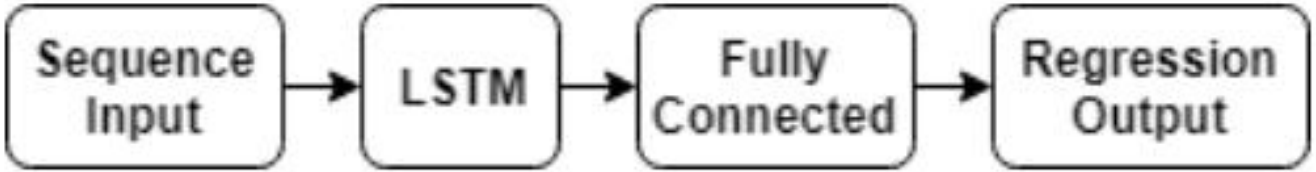
# LSTM 网络架构

- 该图展示了用于分类任务的简单 LSTM 网络架构。网络结构包括序列输入层、 LSTM 层、全连接层、softmax层以及分类输出层。



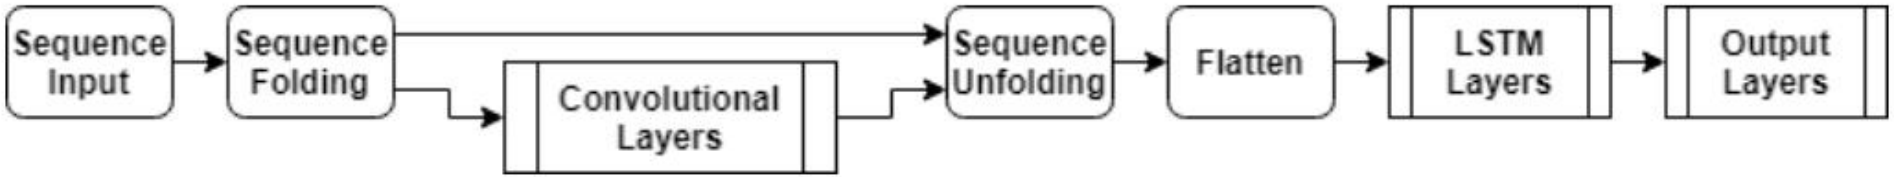
# LSTM 网络架构

- 该图展示了用于回归分析的简单 LSTM 网络架构。网络结构包括一个序列输入层、一个 LSTM 层，以及一个全连接层和一个回归输出层。



# LSTM 网络架构

- 该图展示了视频分类网络的架构：向网络输入图像序列时，需使用序列输入层；若采用卷积层提取特征，则需先使用序列折叠层，再接卷积层，最后使用序列展开层；若利用 LSTM 层从向量序列中学习，则需先使用展平层，再接 LSTM 层和输出层。



# 分类 LSTM 网络

- 为构建用于序列到标签分类的 LSTM 网络，需创建一个包含序列输入层、 LSTM 层、全连接层、softmax层及分类输出层的层结构数组。

- 将序列输入层的大小设置为输入数据的特征数量；将全连接层的大小设置为类别数量。无需指定序列长度。

- 对于 LSTM 层，请指定隐藏单元数量及输出模式“last”。

# 分类 LSTM 网络

```
numFeatures = 12;
numHiddenUnits = 100;
numClasses = 9;
层： [ ...
 sequenceInputLayer(numFeatures)
 LSTM层（隐藏单元数、输出模式、“最后”）
 fullyConnectedLayer(numClasses)
 softmaxLayer
 classificationLayer];
```

# 分类 LSTM 网络

- 要构建用于序列到序列分类的 LSTM 网络，可采用与序列到标签分类相同的架构，但需将 LSTM 层的输出模式设置为‘序列’。

```
numFeatures = 12;
numHiddenUnits = 100;
numClasses = 9;
层：[ ...
 sequenceInputLayer(numFeatures)
 LSTM层（隐藏单元数、输出模式、序列）
 fullyConnectedLayer(numClasses)
 softmaxLayer
 classificationLayer];
```

# 回归 LSTM 网络

- 要构建用于序列到单值回归的 LSTM 网络，请创建一个包含序列输入层、 LSTM 层、全连接层和回归输出层的层数组。

- 将序列输入层的大小设置为输入数据的特征数量；将全连接层的大小设置为响应数量。无需指定序列长度。

- 对于 LSTM 层，请指定隐藏单元数量及输出模式“last”。

# 回归 LSTM 网络

numFeatures = 12;

numHiddenUnits = 125;

numResponses = 1;

层：[ ...

序列输入层（特征数量）、LSTM层（隐藏单元数、输出模式、“末尾”）、全连接层（响应数量）、回归层;

# 回归 LSTM 网络

- 要创建用于序列到序列回归的 LSTM 网络，请采用与序列到单个回归相同的架构，但将 LSTM 层的输出模式设置为“序列”。

```
numFeatures = 12;
numHiddenUnits = 125;
numResponses = 1;
层：[ ...
 sequenceInputLayer(numFeatures)
 LSTM层（隐藏单元数、输出模式、序列）
 fullyConnectedLayer(numResponses)
 regressionLayer];
```

# 视频分类网络

- 为针对包含图像序列（如视频数据和医学影像）的数据构建深度学习网络，请使用序列输入层指定图像序列作为输入。
- 若要利用卷积层提取特征（即对视频的每一帧独立应用卷积操作），需先使用序列折叠层，再接卷积层，最后使用序列展开层；若要利用 LSTM 层从向量序列中学习，则需先使用展平层，再接 LSTM 层和输出层。

```
inputSize = [28 28 1];
filterSize = 5;
numFilters = 20;
numHiddenUnits = 200;
numClasses = 10;
layers = [ ...
 sequenceInputLayer(inputSize,'Name','input')
 sequenceFoldingLayer('Name','fold')
 convolution2dLayer(filterSize,numFilters,'Name','conv')
 batchNormalizationLayer('Name','bn')
 reluLayer('Name','relu')
 sequenceUnfoldingLayer('Name','unfold')
 flattenLayer('Name','flatten')
 lstmLayer(numHiddenUnits,'OutputMode','last','Name','lstm')
 fullyConnectedLayer(numClasses, 'Name','fc')
 softmaxLayer('Name','softmax')
 classificationLayer('Name','classification')];
```

# 视频分类网络

- 将各层转换为层图，并将序列折叠层的miniBatchSize输出连接至序列解折叠层的相应输入端。

```
lgraph = layerGraph(layers);
lgraph = connectLayers(lgraph,'fold/miniBatchSize','unfold/miniBatchSize');
```

# 更深层的 LSTM 网络

- 您可通过在 LSTM 层前添加输出模式为“序列”（sequence）的额外 LSTM 层来加深网络结构。为防止过拟合，可在 LSTM 层后插入丢弃层（dropout layers）。
- 对于序列到标签分类网络，最后一个 LSTM 层的输出模式必须设置为‘last’。

# Deeper LSTM Networks

```
numFeatures = 12;
numHiddenUnits1 = 125;
numHiddenUnits2 = 100;
numClasses = 9;
layers = [ ...
 sequenceInputLayer(numFeatures)
 lstmLayer(numHiddenUnits1,'OutputMode','sequence')
 dropoutLayer(0.2)
 lstmLayer(numHiddenUnits2,'OutputMode','last')
 dropoutLayer(0.2)
 fullyConnectedLayer(numClasses)
 softmaxLayer
 classificationLayer];
```

- 对于序列到序列分类网络，最后一个 LSTM 层的输出模式必须设为“sequence”。

```
numFeatures = 12;
numHiddenUnits1 = 125;
numHiddenUnits2 = 100;
numClasses = 9;
层：[ ...
 sequenceInputLayer(numFeatures)
 LSTM层（隐藏单元数1、输出模式、“序列”）
 dropoutLayer(0.2)
 LSTM层（隐藏单元数2、输出模式、“序列”）
 dropoutLayer(0.2)
 fullyConnectedLayer(numClasses)
 softmaxLayer
 classificationLayer];
```

# 序列填充、截断与分割

- LSTM 网络能够处理长度各异的输入数据。在数据通过网络传输时，软件会对序列进行填充、截断或分割处理，确保每个小批量中的所有序列均达到指定长度。您可通过 trainingOptions 中的 *SequenceLength* 和 *SequencePaddingValue* 名称-值对参数来指定序列长度及填充值。

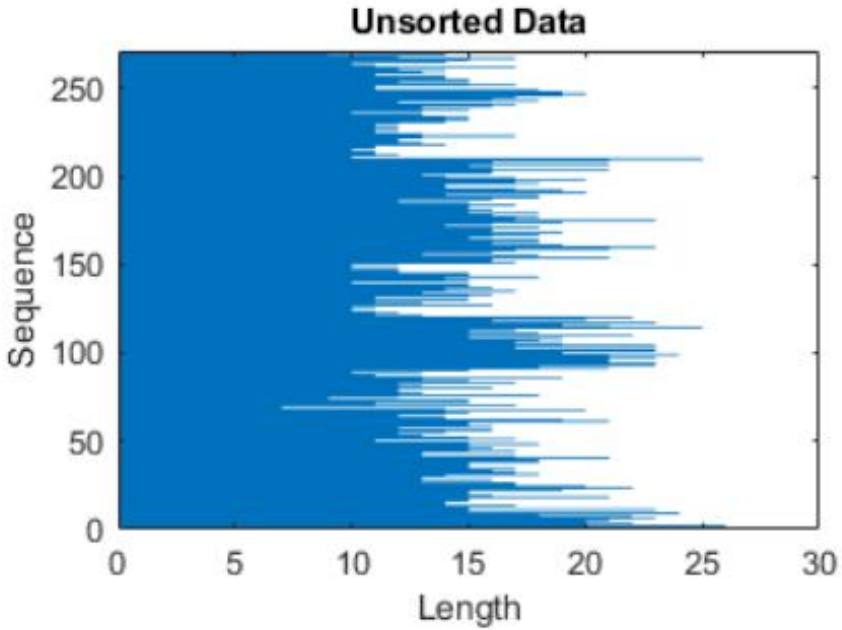
# 按长度对序列进行排序

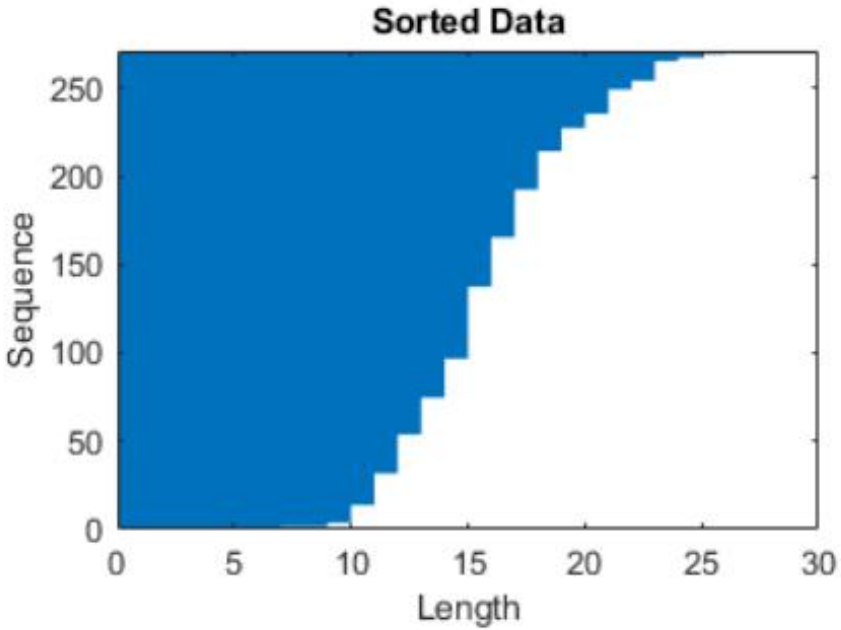
- 为减少序列填充或截断时产生的冗余数据或废弃数据，请按序列长度对数据进行排序。具体操作如下：首先使用`cellfun`函数对每个序列应用`size(X，2)`方法获取其列数；接着利用`sort`函数对序列长度进行排序，并根据第二次排序结果重新排列原始序列顺序。

```
sequenceLengths = cellfun(@(X) size(X,2), XTrain);
[sequenceLengthsSorted,idx] = sort(sequenceLengths);
XTrain = XTrain(idx);
```

# 按长度对序列进行排序

- 下图以柱状图形式展示了已排序与未排序数据的序列长度。



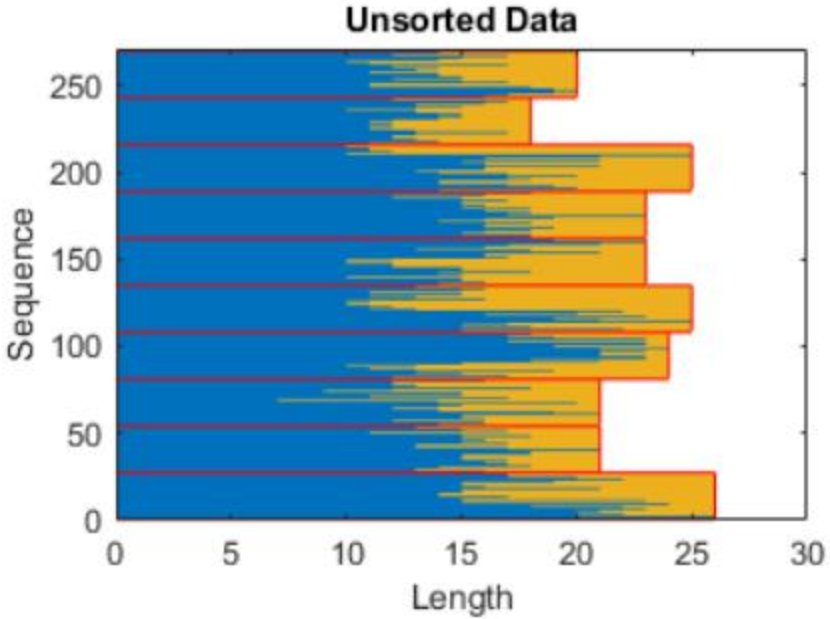



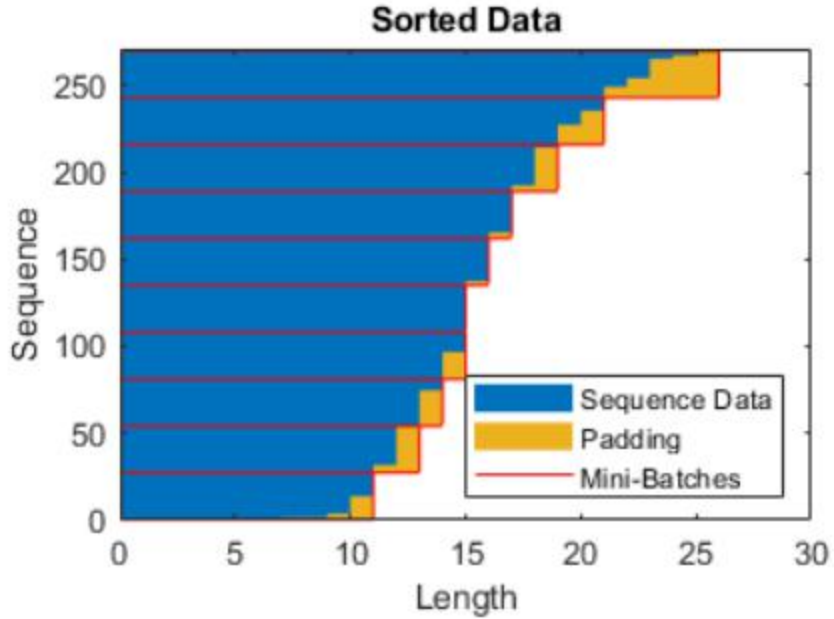
# 填充序列

- 若指定序列长度为“最长”，软件将对序列进行填充处理，使同一小批量中的所有序列长度均与该小批量中最长序列的长度一致。此选项为默认设置。

# 填充序列

- 下图展示了将‘SequenceLength’设置为‘最长’时产生的效果。



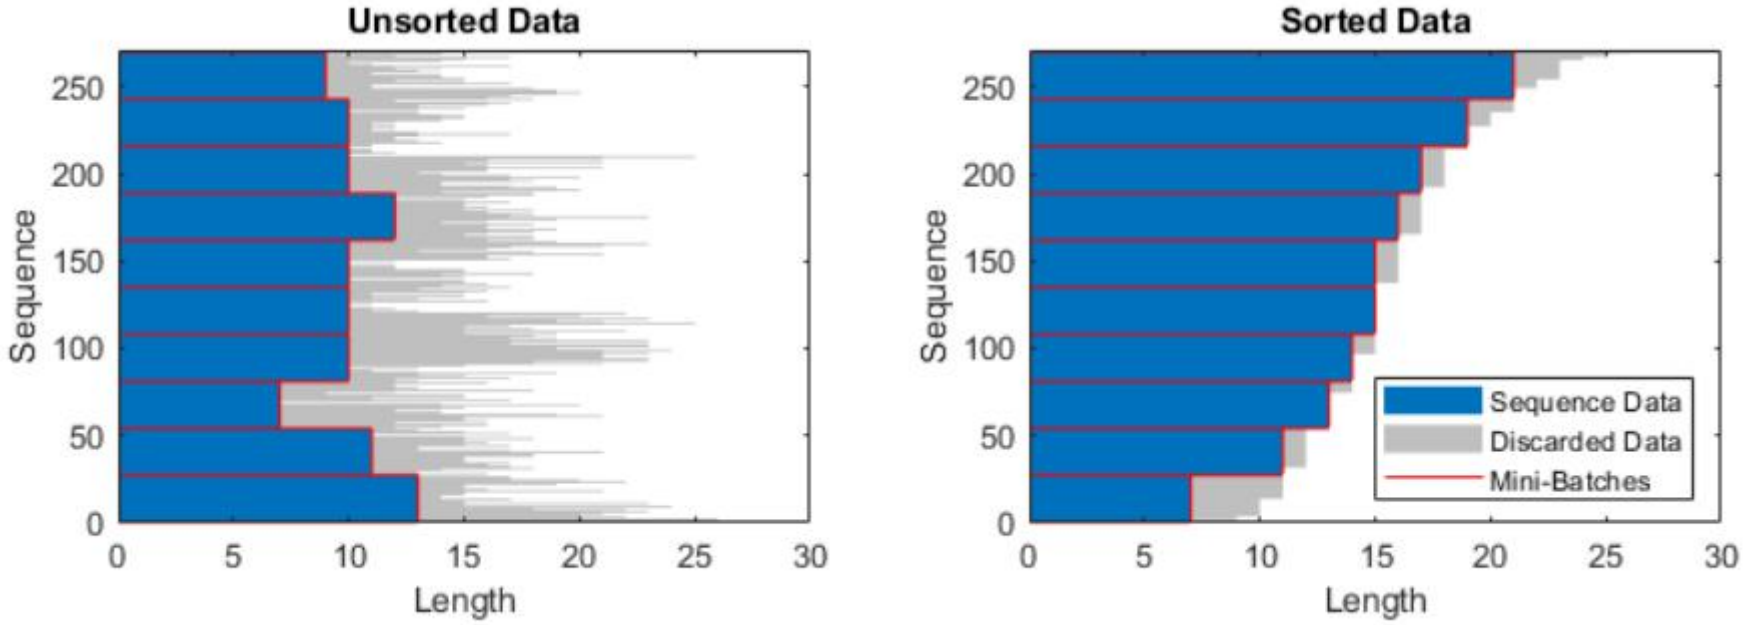



# 截断序列

- 若指定序列长度为“最短”，软件将对序列进行截断，使每个小批量中的所有序列长度均与该小批量中最短序列一致；序列中其余数据将被舍弃。

# 截断序列

- 下图展示了将‘SequenceLength’设置为‘最短’时产生的效果。



# 分裂序列

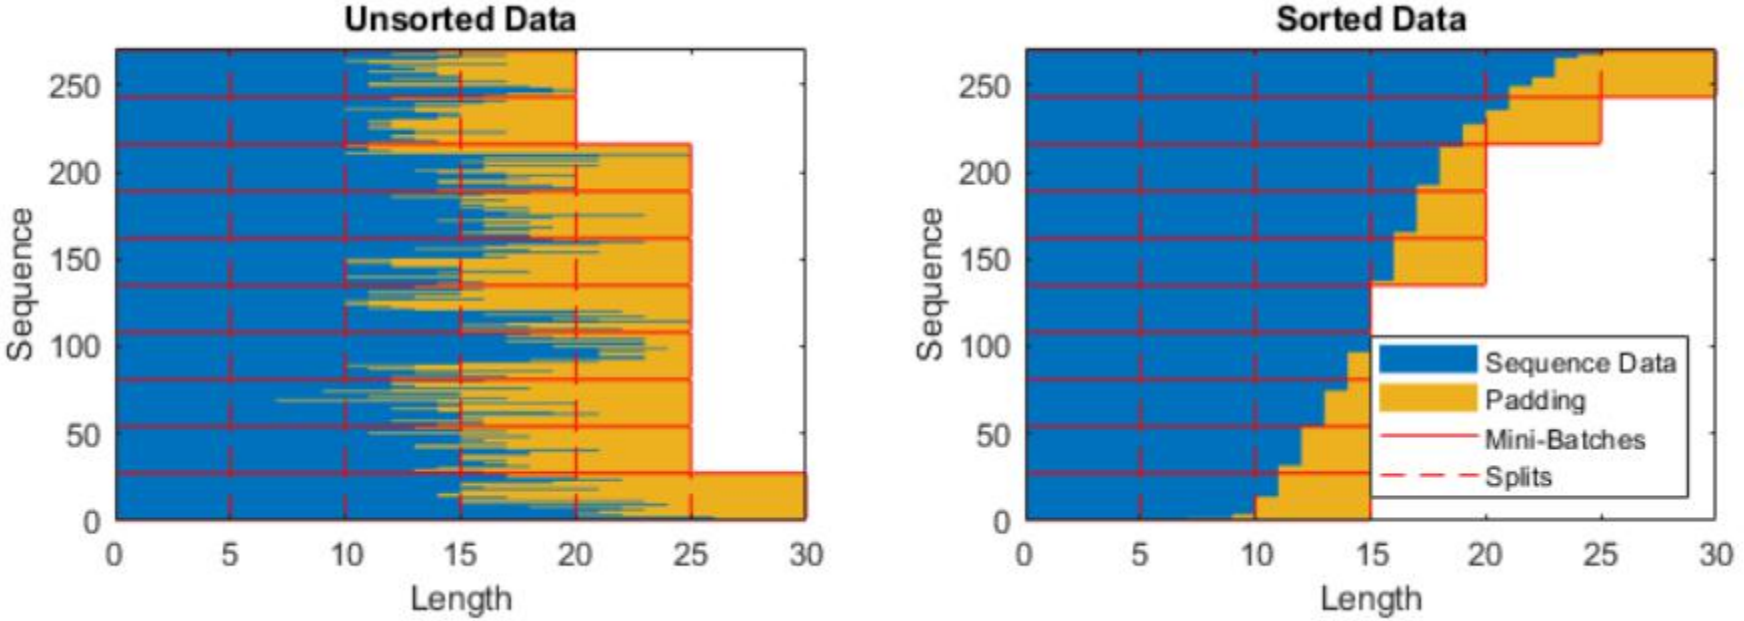
- 若将序列长度设置为整数值，软件会将迷你批次中的所有序列填充至指定长度的最近倍数（该倍数需大于迷你批次中最长序列的长度）；随后，软件会将每个序列分割为若干长度符合要求的小序列。若需要分割，则软件还会生成额外的迷你批次。

# 分裂序列

- 若完整序列无法完全容纳于内存中，请使用此选项。alternatively，您可将trainingOptions中的‘MiniBatchSize’选项设置为较低值以减少每个小批量处理的序列数量。
- 若将序列长度指定为正整数，则软件将在连续迭代中处理较短的序列。网络会在分割后的序列之间更新其状态。

# 分裂序列

- 下图展示了将‘SequenceLength’设置为5时产生的效果。



# 指定填充方向

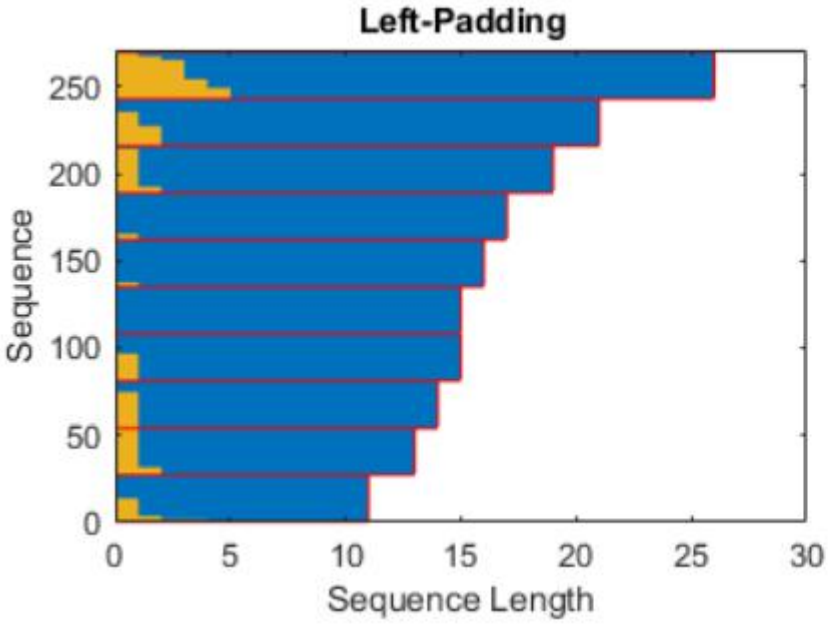
- 填充位置与截断位置的选择会影响训练效果、分类准确率及预测精度。请尝试将 `trainingOptions` 中的 ‘序列填充方向’ 选项设置为 ‘左’ 或 ‘右’，并确定哪种设置最适合您的数据。
- 由于 LSTM 层每次仅处理一个时间步长的序列数据，当该层的 OutputMode属性设置为 ‘last’ 时，最终时间步长中的填充数据可能对输出结果产生负面影响。若需在左侧对序列数据进行填充或截断，请将 ‘SequencePaddingDirection’ 选项设为 ‘left’ 。

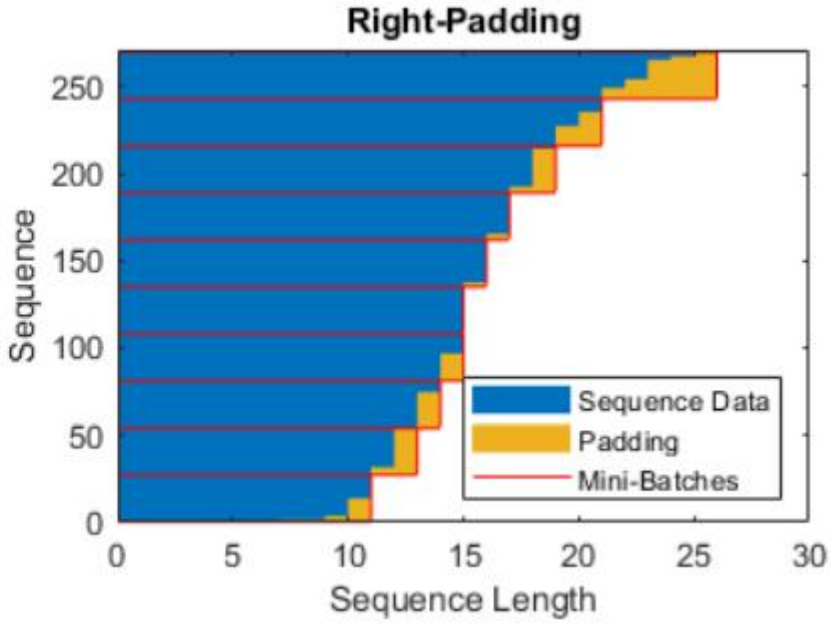
# 指定填充方向

- 对于序列到序列网络（当每个 LSTM 层的OutputMode属性均为‘sequence’时），首个时间步中的任何填充数据都可能对后续时间步的预测结果产生负面影响。若需在右侧对序列数据进行填充或截断，请将‘SequencePaddingDirection’选项设置为‘right’。

# 指定填充方向

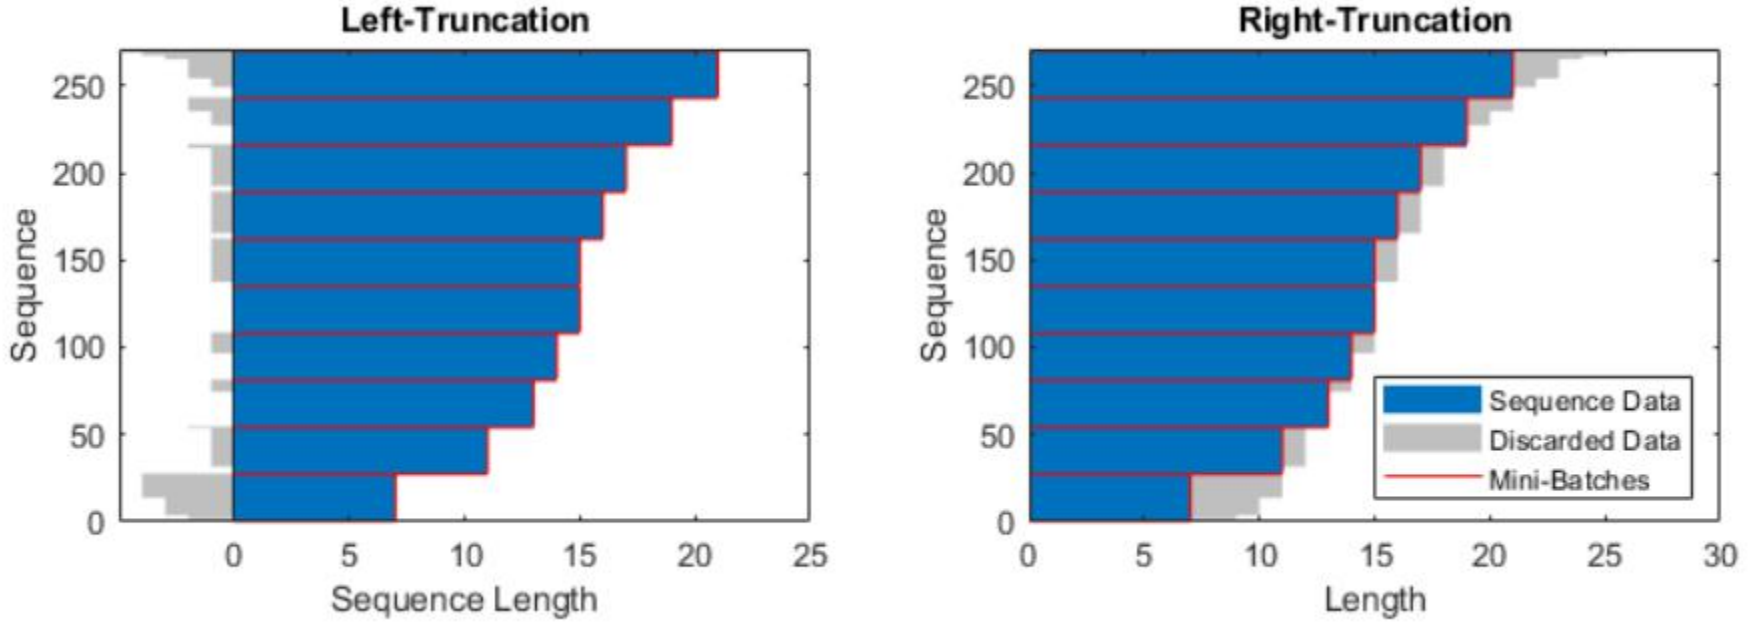
- 以下图示分别展示了左侧和右侧的填充序列数据。



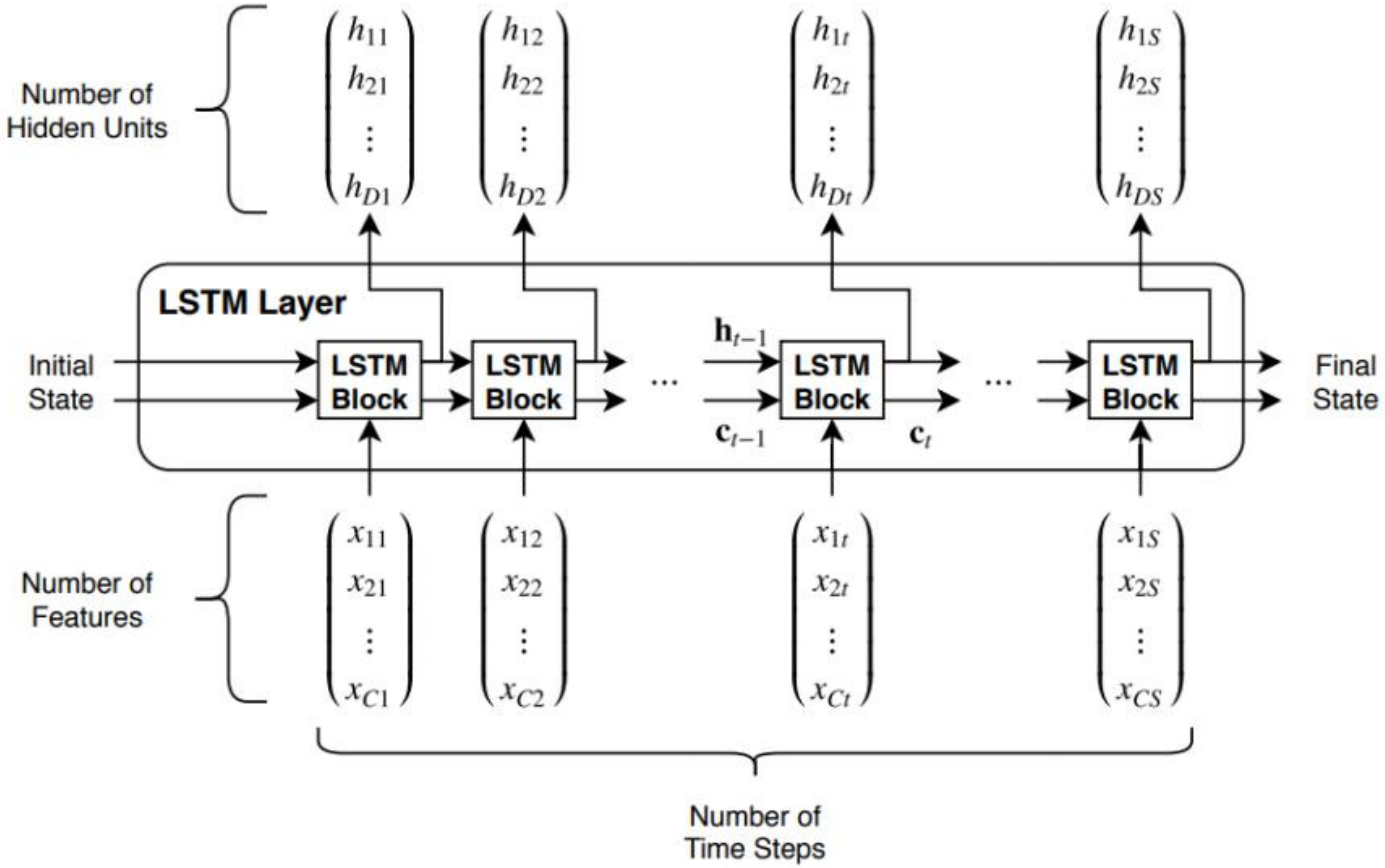



# 指定填充方向

- 以下图示分别展示了左侧和右侧的截断序列数据。

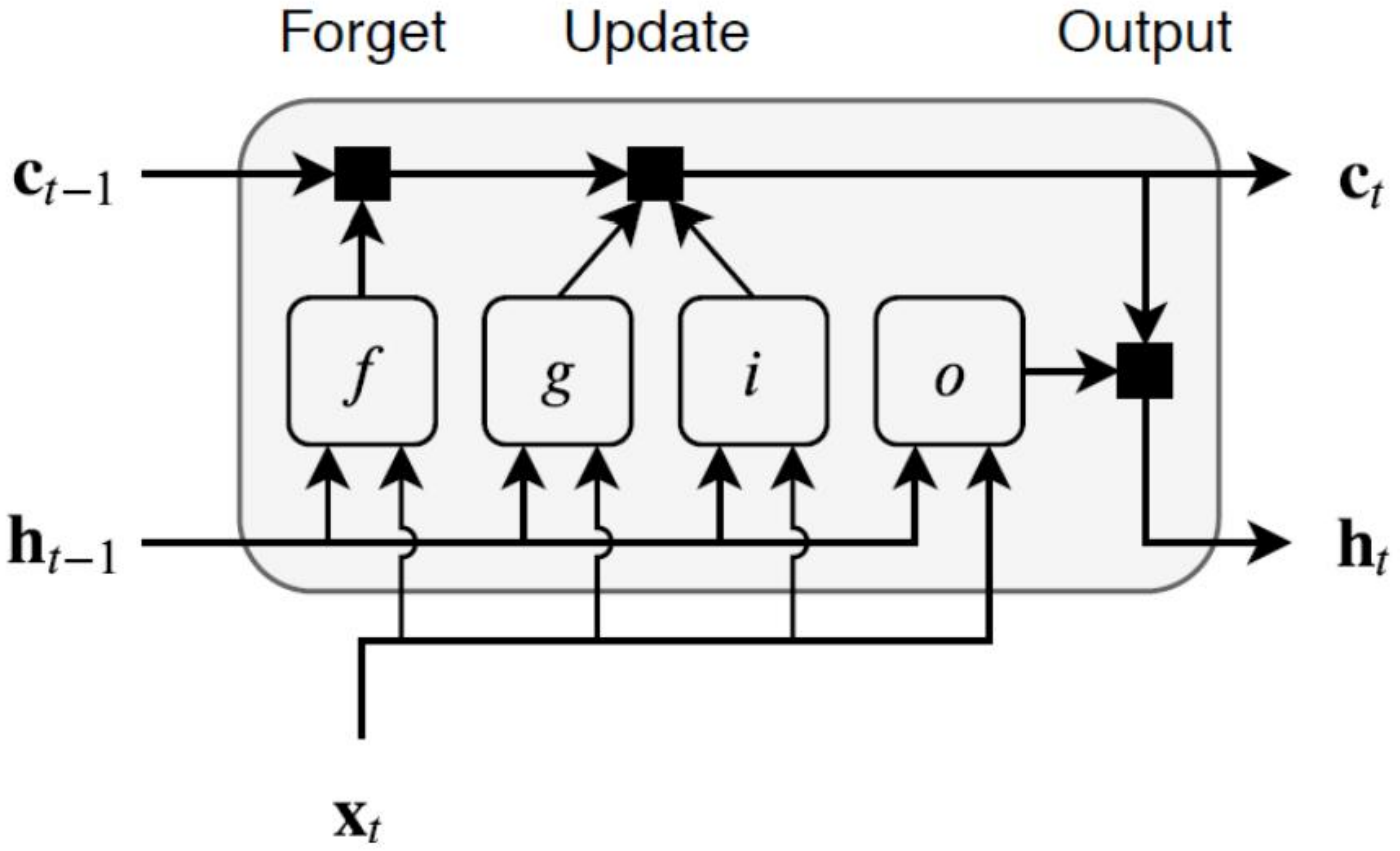


# LSTM 层架构




OF CHINA

# LSTM 层架构


Forget
Update
Output
$\mathbf{c}_{t-1}$
$\mathbf{c}_t$
$f$
$g$
$i$
$o$
$\mathbf{h}_{t-1}$
$\mathbf{h}_t$
$\mathbf{x}_t$

# LSTM 层架构

- LSTM 层的可学习权重包括输入权重W（InputWeights）、循环权重R（RecurrentWeights）以及偏置项b（Bias）。矩阵W、R和b分别对应各组件输入权重、循环权重及偏置项的拼接结果。

| Component | Formula |
| --- | --- |
| Input gate | $i_t = \sigma_g(W_i \mathbf{x}_t + \mathrm{R}_i \mathbf{h}_{t-1} + b_i)$ |
| Forget gate | $f_t = \sigma_g(W_f \mathbf{x}_t + \mathrm{R}_f \mathbf{h}_{t-1} + b_f)$ |
| Cell candidate | $g_t = \sigma_c(W_g \mathbf{x}_t + \mathrm{R}_g \mathbf{h}_{t-1} + b_g)$ |
| Output gate | $o_t = \sigma_g(W_o \mathbf{x}_t + \mathrm{R}_o \mathbf{h}_{t-1} + b_o)$ |

$$\mathbf{c}_t = f_t \odot \mathbf{c}_{t-1} + i_t \odot g_t, \qquad \mathbf{h}_t = o_t \odot \sigma_c(\mathbf{c}_t),$$

# 使用 LSTM 对文本数据进行分类

- 本示例展示了如何使用深度学习长短期记忆（LSTM）网络对文本数据进行分类。
- 文本数据本质上具有序列性。一段文本是由词语组成的序列，这些词语之间可能存在依赖关系。若要利用长期依赖关系对序列数据进行分类，应采用 LSTM 神经网络。 LSTM 网络是一种循环神经网络（RNN）的变体，能够学习序列数据中时间步之间的长期依赖关系。

# 使用 LSTM 对文本数据进行分类

- 要向 LSTM 网络输入文本，首先需将文本数据转换为数值序列。这可通过使用Word编码实现，该编码将文档映射为数值索引序列。为获得更优效果，建议在网络中加入Word嵌入层。Word嵌入将词汇表中的单词映射为数值向量而非标量索引；这些嵌入能捕捉词语的语义细节，使得意义相似的词语具有相似的向量特征；同时还能通过向量运算建模词语之间的关系。

# 使用 LSTM 对文本数据进行分类

在本示例中，训练和使用 LSTM 网络共包含四个步骤：

- 导入并预处理数据。
- 使用单词编码将这些单词转换为数值序列。
- 构建并训练一个包含词嵌入层的 LSTM 网络。
- 利用训练好的 LSTM 网络对新文本数据进行分类。

# 导入数据

- 导入工厂报告数据。该数据包含对工厂事件的带标签文本描述。

  若需将文本数据作为字符串导入，请指定文本类型为“string”。

```
filename = "factoryReports.csv";
```

数据 = 读取表（文件名，‘文本类型’，‘字符串’）；头部（数据）

答案：一个 8×5 的表格。

描述 类别 紧急程度 解决方案 成本

物品偶尔会卡在扫描仪滚筒中。 “机械故障” “介质” “重新调整机器” 45

# 导入数据

- 本示例的目标是根据类别中的标签对事件进行分类。
  列：要将数据划分为不同类别，请将这些标签转换为分类型数据。类别 = 分类型（数据.类别）；

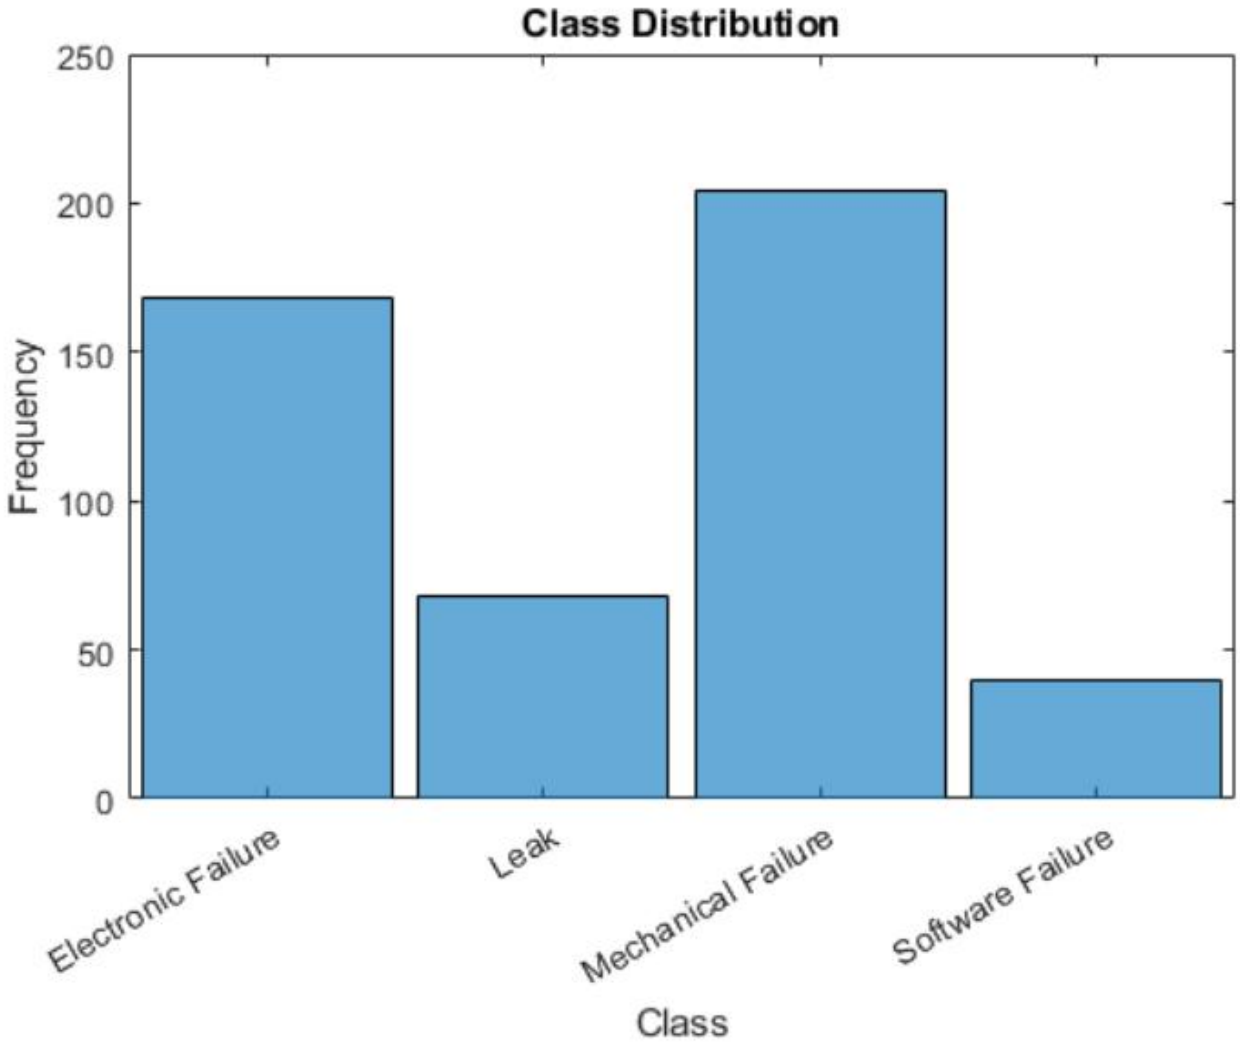
- 使用直方图查看数据中各类别的分布情况。

直方图（数据类别）； 横轴

标题（“类别”）

希腊字母（“频率”）

标题（“班级分布”）


Class Distribution
250
200
150
100
50
0
Frequency
Electronic Failure
Leak
Mechanical Failure
Software Failure
Class

OF CHINA

# 导入数据

- 下一步是将其划分为训练集和验证集。将数据分为训练集以及用于验证和测试的保留集，并指定保留比例为20%。

简历文件路径：cvp = cvpartition（数据集类别：“保留样本”，值为 0.2）；

```
dataTrain = data(training(cvp),:);
dataValidation = data(test(cvp),:);
```

# 导入数据

- 从分区表中提取文本数据及标签。

textDataTrain = dataTrain 的描述;

文本数据验证 = 数据验证。描述;

YTrain = dataTrain 的类别;

验证 = 数据验证。类别;

# 导入数据

- 为确认数据已正确导入，请使用词云图可视化训练文本数据。

图

wordcloud(textDataTrain);

标题：“训练数据”




CHINA

# 预处理文本数据

- 创建一个用于对文本数据进行分词和预处理的函数。示例末尾列出的preprocessText函数可执行以下步骤:

1 使用 tokenizedDocument 对文本进行分词处理。

2 使用lower函数将文本转换为小写。

3 使用erasePunctuation删除标点符号。

- 使用 preprocessText函数对训练数据和验证数据进行预处理。

```
documentsTrain = preprocessText(textDataTrain);
documentsValidation = preprocessText(textDataValidation);
```

# 将文档转换为序列

- 要将文档输入 LSTM 网络，请使用词编码将文档转换为数值索引序列。创建词编码时，请调用wordEncoding函数。

```
enc = wordEncoding(documentsTrain);
```

# 将文档转换为序列

- 下一步转换步骤是对文档进行填充和截断，使其长度一致。**trainingOptions**函数提供了自动填充和截断输入序列的选项。然而这些选项并不适用于词向量序列。因此，请手动对序列进行填充和截断。若对词向量序列进行左填充和截断，训练效果可能会有所提升。

# 将文档转换为序列

- 要对文档进行填充或截断处理，请先选择目标长度，然后截断超过该长度的文档，并对长度不足的文档进行左填充。为获得最佳效果，目标长度应尽可能短，同时避免丢弃大量数据。如需确定合适的目标长度，请查看训练文档长度的直方图分布。

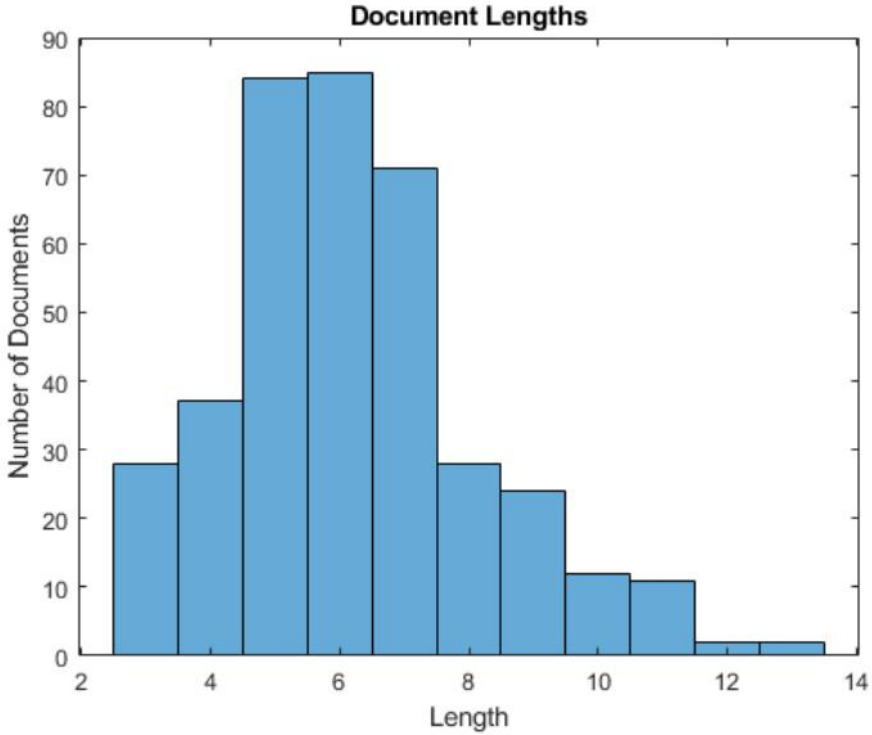
# 将文档转换为序列

文档长度 = doclength(documentsTrain)；图

表： 直方图 （documentLength

“文档长度”， 横轴标题为“长

希腊字母（“文档数量”）



# 将文档转换为序列

- 大多数训练文档的词数均少于10个。请以此作为截断和填充处理的目标长度。使用`doc2sequence`工具将文档转换为数值索引序列；若需将序列截断或左填至长度为10，请将“Length”选项设置为10。

```
sequenceLength = 10;
XTrain = doc2sequence(enc,documentsTrain,'Length',sequenceLength);
```

- 也将验证文档转换为序列。

```
XValidation = doc2sequence(enc,documentsValidation,'Length',sequenceLength);
```

# 创建并训练 LSTM 网络

- 定义 LSTM 网络架构：将序列数据输入网络时，需添加序列输入层并将输入维度设为1；随后加入维度为50、词嵌入维度与词编码数量相同的词嵌入层；接着配置 LSTM 层并设置隐藏单元数为80；若使用 LSTM 层进行序列到标签的分类任务，则需将输出模式设为“last”；最后添加与类别数量相同的全连接层、softmax层及分类层。

```
inputSize = 1;
embeddingDimension = 50;
numHiddenUnits = 80;
numWords = enc.NumWords;
numClasses = numel(categories(YTrain));
layers = [ ...
 sequenceInputLayer(inputSize)
 wordEmbeddingLayer(embeddingDimension,numWords)
 lstmLayer(numHiddenUnits,'OutputMode','last')
 fullyConnectedLayer(numClasses)
 softmaxLayer
 classificationLayer]
```

# 指定培训选项

指定训练选项:

- 使用 Adam 求解器训练模型。
- 指定小批量大小为 16。
- 在每个训练周期中随机打乱数据。
- 将“图表”选项设置为“training-progress”，即可监控培训进度。
- 使用“ValidationData”选项指定验证数据。
- 通过将“Verbose”选项设置为false来抑制冗长输出。

# 指定培训选项

- 默认情况下，如果可用GPU，trainNetwork会使用GPU；否则使用CPU。如需手动指定执行环境，请使用 trainingOptions 中的 ‘ExecutionEnvironment’ 名称-值对参数。在CPU上进行训练所需时间可能远长于在GPU上进行训练。

# 指定训练选项：options =

trainingOptions( ‘adam’ , ...

‘MiniBatchSize’ , 16, ...

'GradientThreshold',2, ...

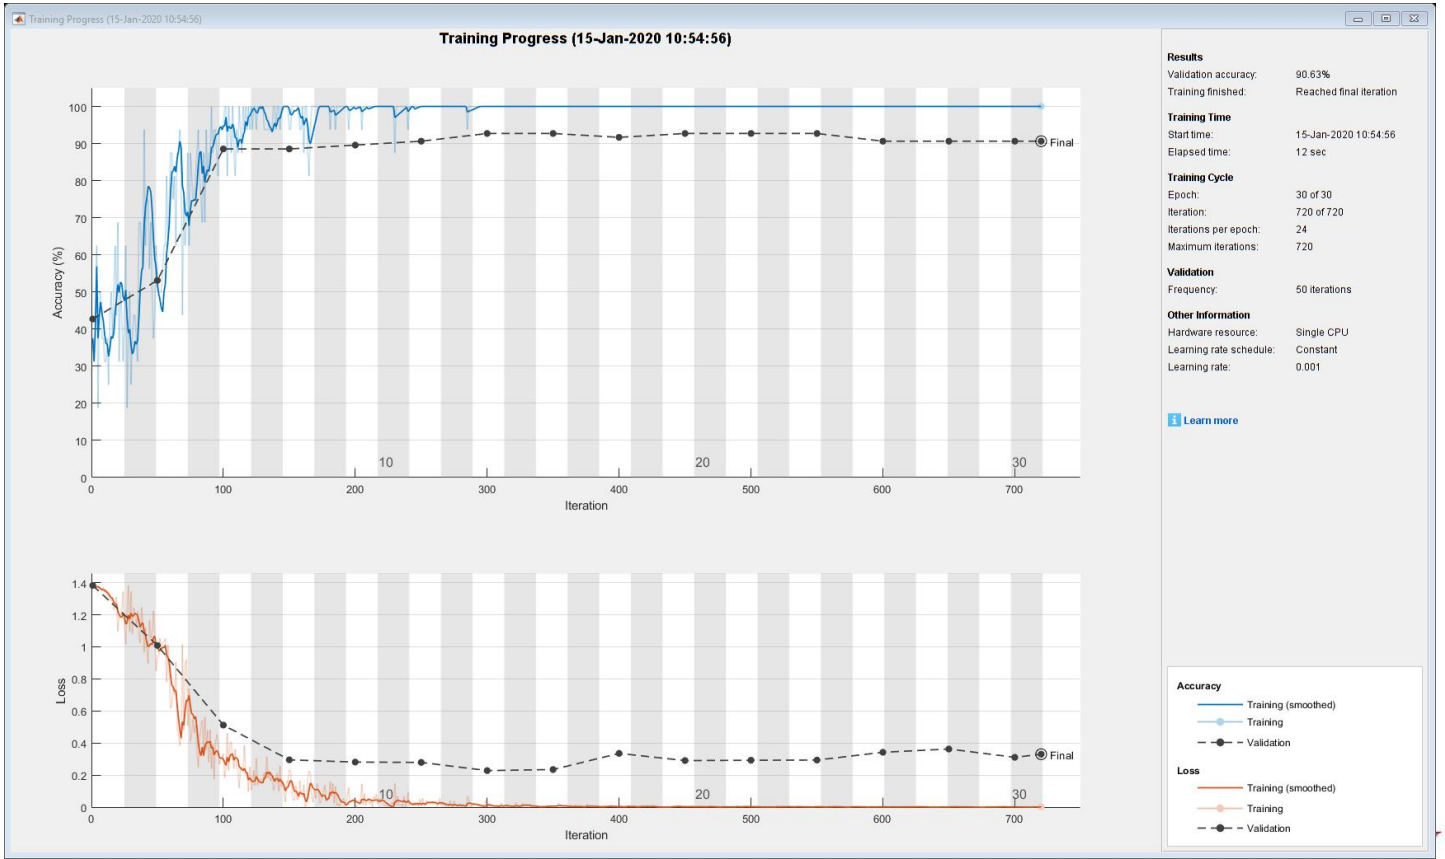
“随机播放”、“每期专属”.....

验证数据：{XValidation，YValidation}；绘图图表：‘训练进度’等

“冗长的”，错误）；

- Train the LSTM network using the trainNetwork function.

net = trainNetwork(XTrain,YTrain,layers,options);



# 利用新数据进行预测

- 对三份新报告的事件类型进行分类，并创建一个包含这些新报告的字符串数组。

```
reportsNew = [ ...
 冷却液在分选机下方积聚。
 启动时，Sorter会触发保险丝熔断。
 组装机发出了一些非常响亮的咔嗒声。
```

- 使用预处理步骤对文本数据进行预处理，并将其作为训练文档。

```
documentsNew = preprocessText(reportsNew);
```

# 利用新数据进行预测

- 使用与创建训练序列时相同的选项，通过doc2sequence将文本数据转换为序列。

```
XNew = doc2sequence(enc,documentsNew,'Length',sequenceLength);
```

- 使用训练好的 LSTM 网络对新序列进行分类。

标签新值 = 分类（网络数据集，XNew）

标签数量：3×1 个分类变量

（Leak）

电子故障；机械故障