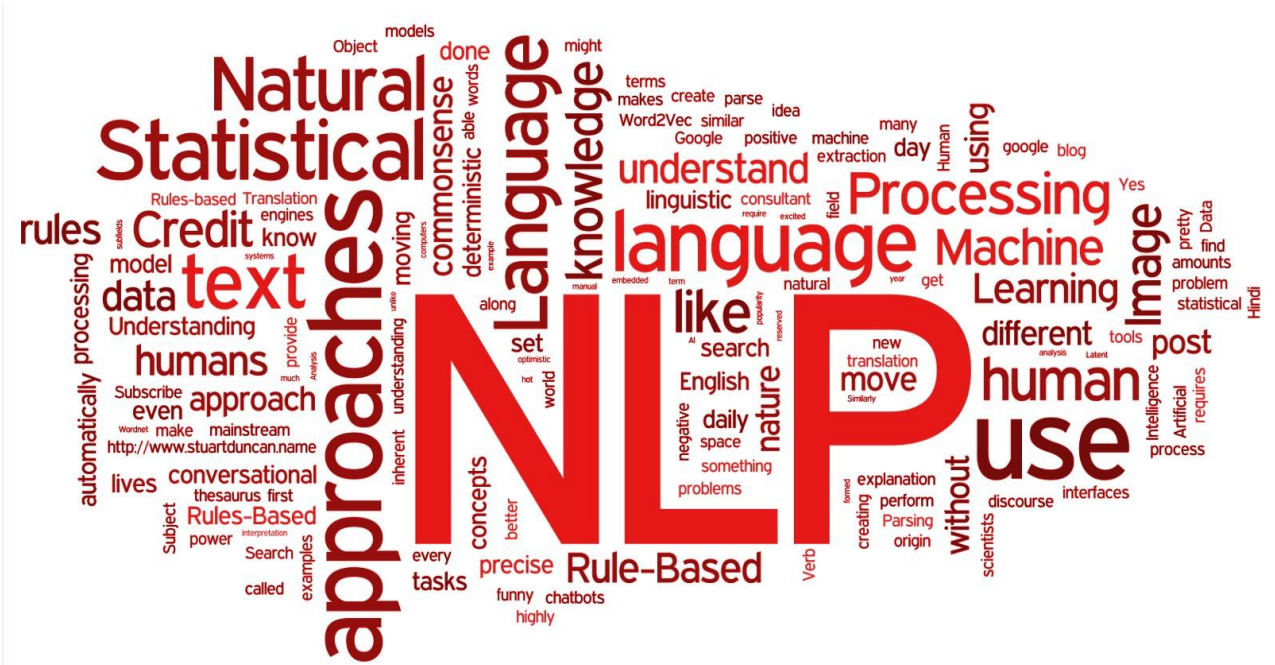
群聊：文本挖掘 26

该二维码7天内(6月12日前)有效，重新进入将更新

保存图片

文本挖掘



关于本课程

- 课程内容
- 参考书
- 班级项目
- 评分；等级评定

课程内容

- 文本挖掘与自然语言处理概述
- 深度学习模型
  - CNN、 RNN 与 LSTM 、自注意力机制、Transformer模型
- 预训练语言模型
  - BERT、GPT、T5
- 大型语言模型
  - Prompt Engineering、RAG、Agent型大语言模型（LLM）

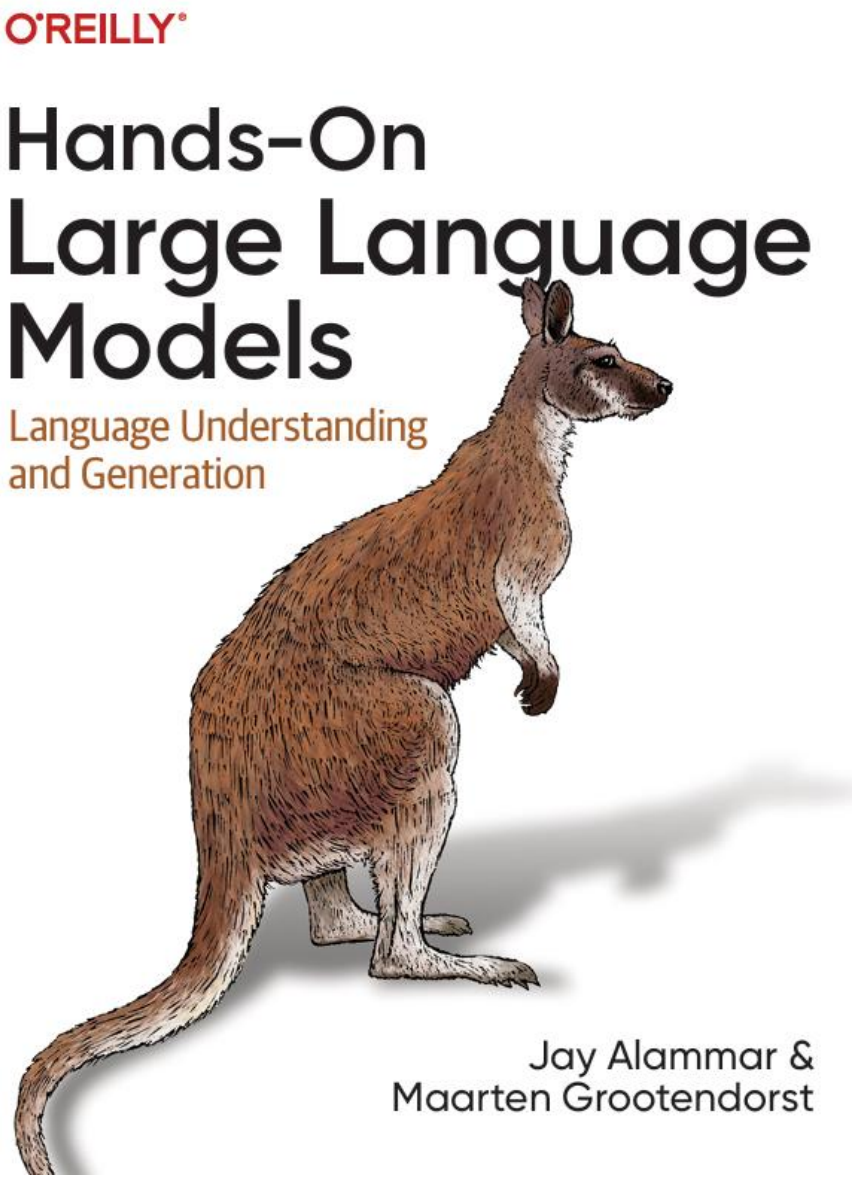
参考书

- BERT
- 中文应用



参考书

- LLM
- 训练&微调


O'REILLY
Hands-On
Large Language
Models
Language Understanding
and Generation
Jay Alammar &
Maarten Grootendorst

评分；等级评定

- 课堂作业纸
  - 加入 OverLeaf 的课堂论文项目。
  - 提案演示占比：30%（6.14）
  - 纸质材料占比为 70%（数量：7.12）

- 论文主题
  - https://openi.pcl.ac.cn/info-ruc/tm26projects

大纲；结构框架

- 文本挖掘与自然语言处理的发展历程
- 方法：规则制定、统计分析、神经网络
- 常见的自然语言处理任务
  - 文本与语音处理
  - 形态学分析
  - 句法分析
  - 词汇语义（指特定词语在具体语境中的含义）
  - 关系语义（单个句子的语义）
  - 话语（超越单个句子的语义）
  - 高级自然语言处理应用

关于文本挖掘

- **文本挖掘**、文本数据挖掘（TDM）或文本分析，是指从文本中提取高质量信息的过程。其核心在于“通过计算机自动从各类书面资源中提取信息，从而发现新的、此前未知的信息”。

- 文本挖掘通常包括对输入文本进行结构化处理、从结构化数据中提取模式，以及最终对输出结果进行评估与解读。

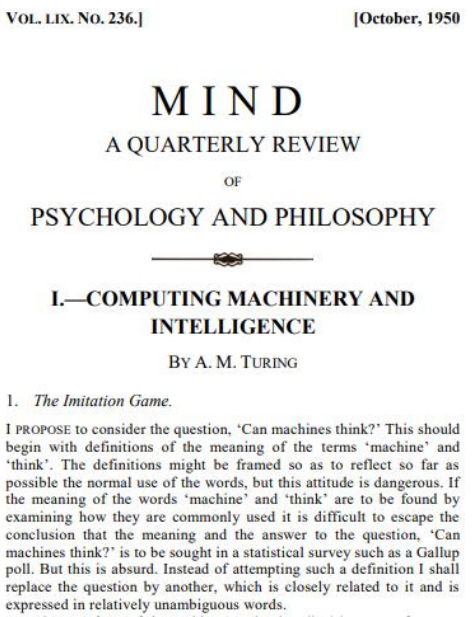
- 典型的文本挖掘任务包括文本分类、文本聚类、概念/实体抽取、细粒度分类体系构建、情感分析、文档摘要生成以及实体关系建模。

关于 NLP

- 自然语言处理（NLP）是语言学、计算机科学、信息工程及人工智能领域的子学科，专注于研究计算机与人类（自然）语言之间的交互关系，尤其是如何编写程序使计算机能够处理和分析海量自然语言数据。
- 自然语言处理领域的挑战通常涉及语音识别、自然语言理解以及自然语言生成。

历史

- 自然语言处理技术的历史可追溯至20世纪50年代。早在那时，1950年，艾伦·图灵发表了一篇题为《计算机器与智能》的文章，提出了如今被称为图灵测试的智能判定标准——该任务涉及自然语言的自动化解读与生成，但在当时并未被明确界定为独立于人工智能之外的问题。



VOL. LIX. NO. 236.] [October, 1950

MIND

A QUARTERLY REVIEW

OF

PSYCHOLOGY AND PHILOSOPHY

I.—COMPUTING MACHINERY AND INTELLIGENCE

BY A. M. TURING

1. *The Imitation Game.*

I PROPOSE to consider the question, 'Can machines think?' This should begin with definitions of the meaning of the terms 'machine' and 'think'. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words 'machine' and 'think' are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, 'Can machines think?' is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

历史——符号化自然语言处理（20世纪50年代至90年代初）

- 20世纪50年代：1954年乔治城大学开展的实验实现了将六十多条俄语句子完全自动翻译成英语。研究者声称，机器翻译问题将在三到五年内得到解决。然而实际进展远为缓慢；1966年 ALPAC 报告指出长达十年的研究未能达到预期目标后，机器翻译领域的资金支持被大幅削减。此后该领域几乎未再开展相关研究。

  20世纪80年代末，首批统计机器翻译系统应运而生。



历史——符号化自然语言处理（20世纪50年代至90年代初）

- 20世纪60年代：自然语言处理领域取得了一些显著成就。20世纪60年代开发的系统包括 SHRDLU ——一种在受限“模块化世界”及有限词汇范围内运行的自然语言系统；以及eliza——由约瑟夫·魏岑鲍姆于1964至1966年间编写、模拟罗杰式心理治疗师行为的程序。由于几乎不依赖人类思维或情感信息，eliza有时能提供令人惊讶的类人交互体验。当“患者”超出其极有限的知识库时，eliza可给出通用回应，例如对“我的头痛”回答“你为什么说你的头痛？”

历史——符号化自然语言处理（20世纪50年代至90年代初）

以下是 SHRDLU 的一个著名演示：

- 人物：拿起一块大红色的方块。
- 电脑：好的。
- 人员：掌握金字塔结构。
- 计算机：我不明白你指的是哪座金字塔。
- （改变主意的人）：找一个比你手中这个块更高的块，放入盒中。
- 计算机：说到“IT”，我猜您指的是那个比我手中的这个块更高的那个块。
- 电脑：好的。
- 人物：这个盒子里有什么？
- 计算机：蓝色金字塔与蓝色方块。

历史——符号化自然语言处理（20世纪50年代至90年代初）

```
 Welcome to
                EEEEEE  LL      IIII  ZZZZZZZ   AAAAA
                EE      LL       II       ZZ   AA   AA
                EEEEE   LL       II     ZZZ    AAAAAAA
                EE      LL       II    ZZ      AA   AA
                EEEEEE  LLLLLL  IIII  ZZZZZZZ  AA   AA

 Eliza is a mock Rogerian psychotherapist.
 The original program was described by Joseph Weizenbaum in 1966.
 This implementation by Norbert Landsteiner 2005.


ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:
```

历史——符号化自然语言处理（20世纪50年代至90年代初）

20世纪70年代：在这一时期，许多程序员开始编写“概念本体”，将现实世界的信息结构化为计算机可理解的数据形式。

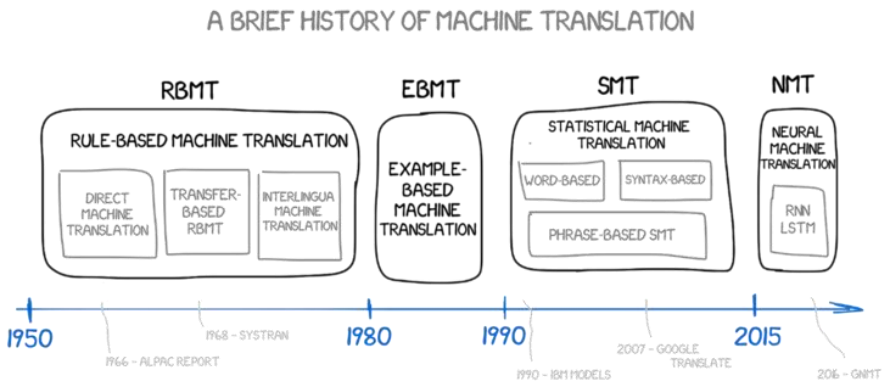
20世纪80年代至90年代初，符号方法在自然语言处理领域迎来了鼎盛时期。当时的重点研究方向包括基于规则的方法、形态学、语义学、指代机制以及其他自然语言理解领域；其他研究方向也持续发展，例如聊天机器人的开发。这一时期一个重要的进展（最终促成了90年代的统计学转向）便是定量评估方法的重要性日益凸显。

历史——统计自然语言处理（20世纪90年代至21世纪10年代）

直到20世纪80年代，大多数自然语言处理系统都依赖于复杂的手动编写规则集。然而自80年代末期起，随着机器学习算法在语言处理领域的应用，该领域发生了革命性变革。这一变化既得益于计算能力的持续提升（参见摩尔定律），也源于乔姆斯基语言学理论（如转换语法）主导地位的逐渐减弱——这些理论基础原本并不支持机器学习语言处理方法所依赖的语料库语言学研究路径。

历史——统计自然语言处理（20世纪90年代至21世纪10年代）

20世纪90年代：自然语言处理领域在统计方法方面取得的诸多重要早期成果均集中在机器翻译方向，这主要归功于IBM研究院的研究工作。这些系统能够充分利用现有的多语种文本语料库；然而，大多数其他系统则依赖专门为这些任务开发的专用语料库，这一局限性严重制约了其发展进程。因此，学界投入了大量研究精力来探索如何更有效地从有限数据中学习。
数据量。

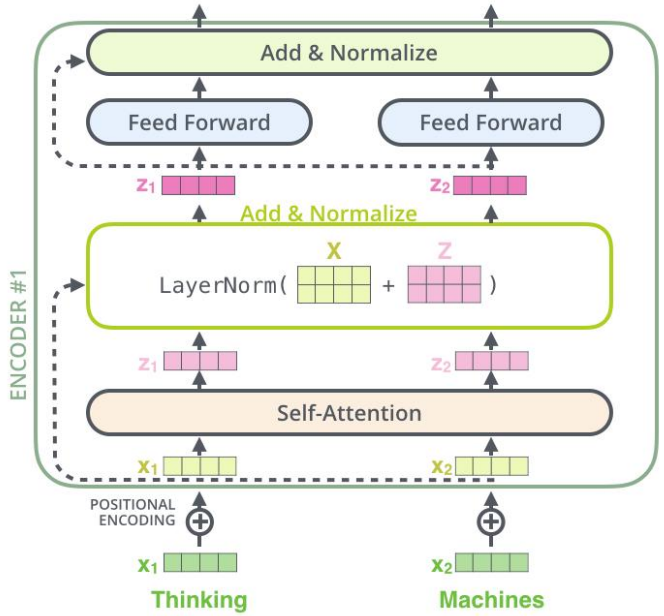


历史——统计自然语言处理（20世纪90年代至21世纪10年代）

21世纪初：随着互联网的蓬勃发展，自20世纪90年代中期以来，海量原始（未标注）语言数据不断涌现。因此，研究重点日益转向无监督学习和半监督学习算法。这类算法能够直接从未经人工标注的目标答案数据中学习，或结合使用标注与非标注数据进行训练。总体而言，在给定输入数据量的情况下，这类方法往往难以获得高精度结果。不过，目前可获取的非标注数据量极为庞大；只要算法设计足够实用，这些数据通常足以弥补预测结果的不足。

历史 - DL Neural NLP（当前版本）

2010年代，表征学习与深度神经网络风格的机器学习方法在自然语言处理领域得到广泛应用，这在很大程度上得益于一系列研究结果表明这些技术能够在语言建模、句法分析等诸多自然语言任务中取得最先进的性能。



方法：规则制定、统计分析、神经网络

在早期阶段，许多语言处理系统都是采用符号化方法设计的，即手动编写一组规则并结合词典查询：例如编写语法规则或制定用于词干提取的启发式规则。

基于机器学习算法的较新系统相较于人工制定的规则具有诸多优势：

- 机器学习过程中采用的学习流程会自动聚焦于最常见的案例；而手工编写规则时，往往难以明确应将精力集中于何处。

方法：规则制定、统计分析、神经网络

- 自动化学习方法可利用统计推断算法构建对未知输入及错误输入具有鲁棒性的模型。通常而言，通过手写规则优雅地处理此类输入，或更广泛地说，构建能够做出柔性决策的手写规则系统，均极具难度、易出错且耗时较长。
- 基于自动学习规则的系统只需提供更多输入数据即可提高准确性；而基于手写规则的系统则只能通过增加规则复杂度来提升准确性，这是一项更为困难的任务。

方法：规则制定、统计分析、神经网络

尽管机器学习在自然语言处理（NLP）研究中广受欢迎，
但符号化方法至今仍被广泛使用（2020年）。

- 当训练数据量不足以成功应用机器学习方法时（例如用于Apertium系统提供的低资源语言的机器翻译），
- 用于自然语言处理（NLP）流程中的预处理，例如分词
- 用于对自然语言处理（NLP）流程的输出结果进行后处理与转换，例如从句法解析中提取知识。

统计方法

自20世纪80年代末至90年代中期所谓的“统计革命”以来，大量自然语言处理研究都高度依赖机器学习。该机器学习范式主张通过分析包含典型现实案例的大型语料库（“corpus”的复数形式指一组文档，可能附有人类或计算机标注），利用统计推断自动学习相关规则。

统计方法

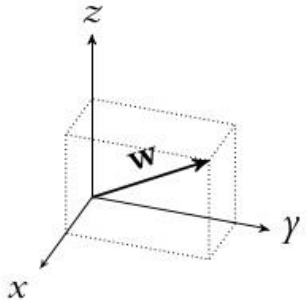
多种不同的机器学习算法已被应用于自然语言处理任务。这些算法以从输入数据中生成的大量“特征”作为输入参数。然而，近年来研究重点日益转向统计模型——这类模型通过为每个输入特征赋予实数值权重，从而做出软性、概率性的决策。此类模型的优势在于能够表达多种可能答案之间的相对确定性而非单一答案，当将其作为大型系统的一个组成部分时，能产生更可靠的结果。

统计方法

最早使用的机器学习算法（如决策树）所产生的硬性“如果-那么”规则体系，与现有的手工编写规则颇为相似。然而，词性标注技术的出现将隐马尔可夫模型引入自然语言处理领域；此后，研究重点逐渐转向统计模型——这类模型通过为输入数据中的特征赋予实数值权重，从而做出软性的概率性判断。如今众多语音识别系统所依赖的缓存语言模型，正是此类统计模型的典型代表。

神经网络

统计方法的一个主要缺点在于其需要复杂的特征工程处理。自2010年代初以来，该领域已基本摒弃统计方法，转而采用神经网络进行机器学习。常用技术包括使用词嵌入来捕捉词语的语义特性，以及加强针对高级任务（如问答系统）的端到端学习，而非依赖一系列独立的中间任务（如词性标注和依存关系分析）。
分析) .



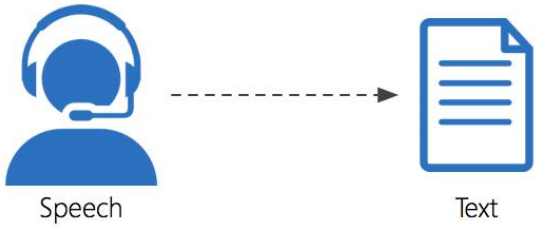
神经网络

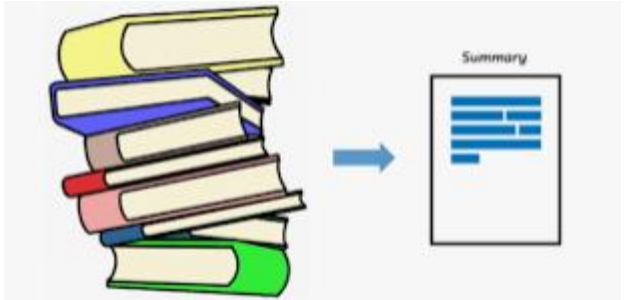
在某些领域，这种转变导致自然语言处理系统的设计方式发生重大变革，使得基于深度神经网络的方法可被视为一种不同于统计自然语言处理的新范式。例如，“神经机器翻译”（NMT）这一术语强调：基于深度学习的机器翻译方法能够直接实现序列到序列的转换，从而无需采用统计机器翻译（SMT）中使用的词对齐和语言建模等中间步骤。

常见的自然语言处理任务

以下是自然语言处理领域中一些最常被研究的任务列表。其中部分任务具有直接的实际应用价值，而其他任务则通常作为子任务，用于辅助解决更复杂的任务。

尽管自然语言处理任务相互紧密关联，但为便于分类可将其划分为不同类别。下文提供一个粗略的划分方案。







文本与语音处理 - 语音识别

给定一个人或多人的语音片段，需要提取其语音内容的文字表示。这与“文本转语音”任务完全相反，属于极其困难的问题之一（通常被称为“AI难题”）。在自然语音中，相邻词语之间几乎不存在停顿，因此语音分割是语音识别过程中不可或缺的一个子任务。此外，鉴于同一语言中的词汇由不同口音的人使用，语音识别软件必须能够将各种不同的输入内容在其文本等效性方面视为完全一致。

文本与语音处理 - 其他

语音分割

- 给定一段人说话的音频片段，请将其分离。
  转化为文字。这是语音识别的一个子任务，通常与之归为一类。

光学字符识别（OCR）

- 给定一张表示印刷文本的图像，确定其对应的文本内容。

文字转语音

- 给定一段文本，将其中的语音单元进行转换并生成语音输出。文本转语音技术可用于辅助视障人士。

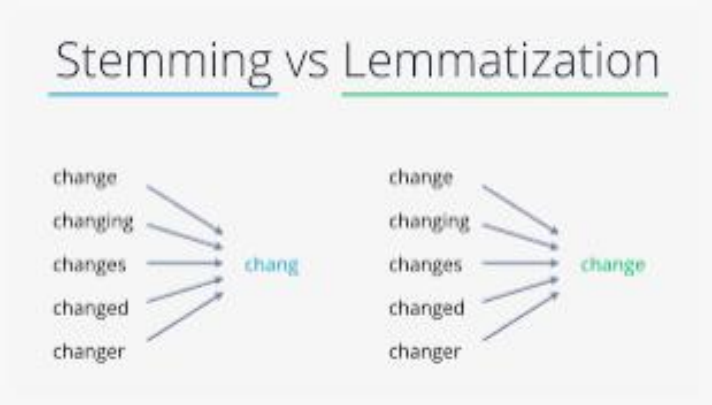
形态学分析

Stemming

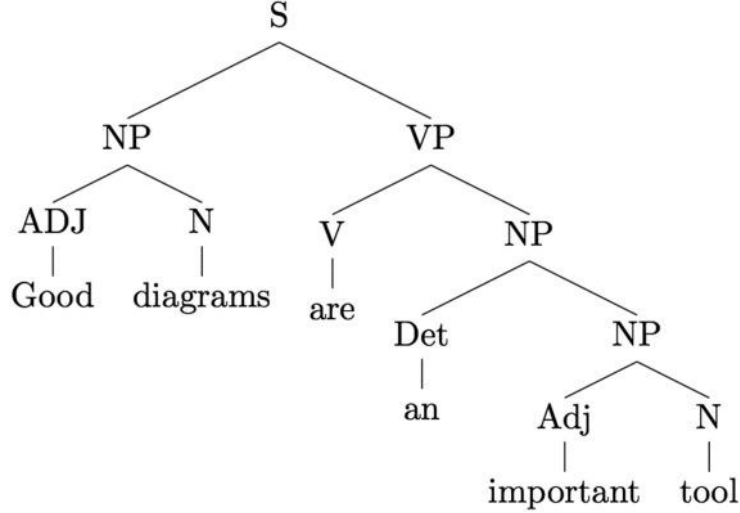
- 将屈折词（有时也包括派生词）还原为其词根形式的过程。（例如，“clos”即为“closed”、“closing”、“close”、“closer”等词的词根。）

Lemmatization

- 其任务仅是移除词形变化结尾，并恢复单词的基本词典形式，该形式亦称为词素。



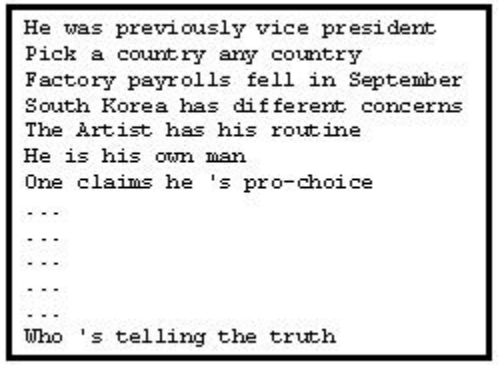
形态学分析

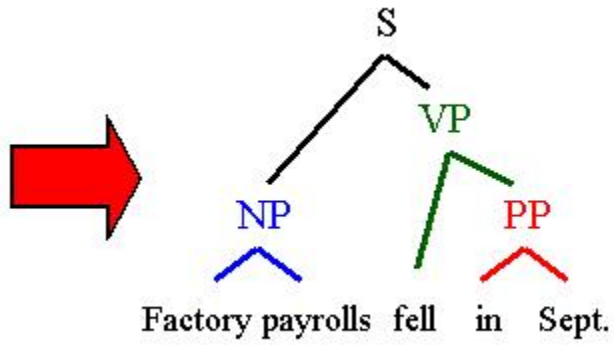


词性标注

- 给定一个句子，请确定其中每个词的词性（POS）。词语。许多词汇，尤其是常用词，可以充当多种词性。例如，“book”既可以作名词（“桌上的书”），也可以作动词（“预订航班”）；“set”可以作名词、动词或形容词；而“out”则至少能对应五种不同的词性。某些语言的这种歧义现象比其他语言更为普遍。像英语这样屈折形态变化较少的语言，尤其容易出现此类歧义。

句法分析





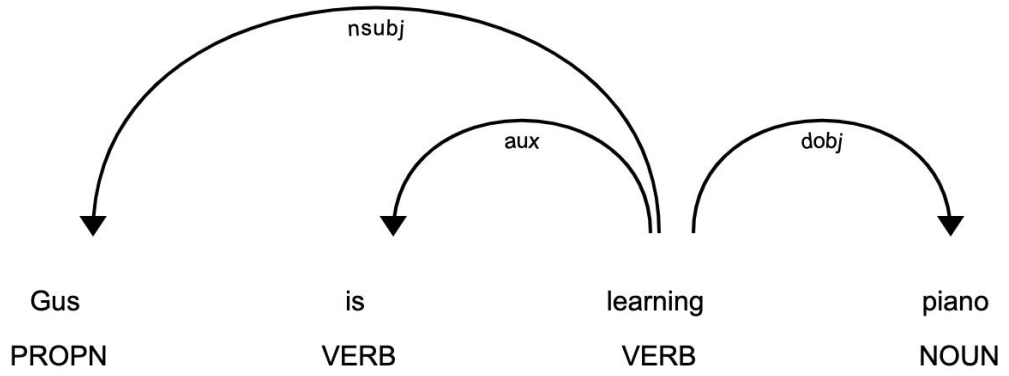
语法归纳

- 生成描述语言语法的正式文法。

句子分割

- 给定一段文本，需找出句子边界。句子边界通常由句号或其他标点符号标示，但这些字符亦可用于其他用途（例如标记缩写）。

句法分析



Parsing

- 确定给定文本的解析树（语法分析）
  句子。自然语言的语法具有歧义性，典型的句子可能存在多种不同的解析方式：令人惊讶的是，一个典型句子可能有数千种潜在解析结果（其中大多数对人类而言完全毫无意义）。解析主要分为两种类型：依存分析和成分分析。依存分析侧重于句中词语之间的关系（如确定主语和谓语），而成分分析则利用概率上下文无关文法（PCFG）构建解析树（另见随机文法）。

词汇语义（指特定词语在具体语境中的含义）

词汇语义学

- 在语境中，单个词语的计算意义是什么？分布语义学
- 我们如何从数据中学习语义表示？

情感分析（另见多模态情感分析）

- 通常从一组文档中提取主观信息，常利用在线评论来判断对特定对象的“倾向性”。该方法尤其适用于识别社交媒体上的公众意见趋势及营销分析。

词汇语义（指特定词语在具体语境中的含义）

术语提取

- 术语提取的目标是从给定语料库中自动提取相关术语。

词义消歧

- 许多词语具有多种含义；我们必须从中选择合适的含义。指在上下文中最为合理的含义。针对这一问题，我们通常会获得一组词语及其对应的Word义项列表（例如来自词典或Word Net等在线资源）。

词汇语义（指特定词语在具体语境中的含义）

命名实体识别（NER）

- 给定一段文本流，请确定其中哪些项应对应到何处。专有名词（如人名或地名）及其所属类型（例如：人物、地点、组织）。虽然大写形式有助于识别英语等语言中的命名实体，但该信息无法确定命名实体的具体类型，且往往不准确。不足的.

Gen. Jack Keane responded Monday, 23 Dec 2019 to threats of a possible "Christmas gift" missile launch from North Korea, as well as former national security adviser John Bolton's recent remark that President Trump was not exerting "maximum pressure" on North Korea during high-stakes nuclear talks.

Person Place Date

关系语义（单个句子的语义）

关系抽取

- 给定一段文本，识别其中命名实体之间的关系（例如谁与谁结婚）。

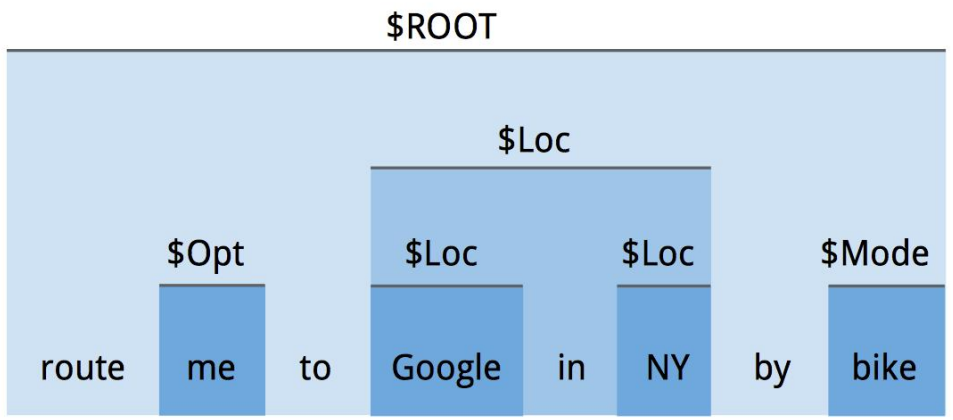
语义角色标注

- 给定一个句子，识别并消歧语义谓词（例如动词框架），随后识别并分类这些谓词。
  框架元素（语义角色）。

关系语义（单个句子的语义）

语义解析

- 给定一段文本（通常为一个句子），生成正式表述。
  对其语义的表示方式，既可采用图结构（如在AMR解析中），也可遵循逻辑形式体系（如在 DRT 解析中）。这一挑战通常涵盖多个基础自然语言处理任务中的语义相关方面（如语义角色标注、词义消歧），并可进一步扩展至完整的文



话语（超越单个句子的语义）

共指消解

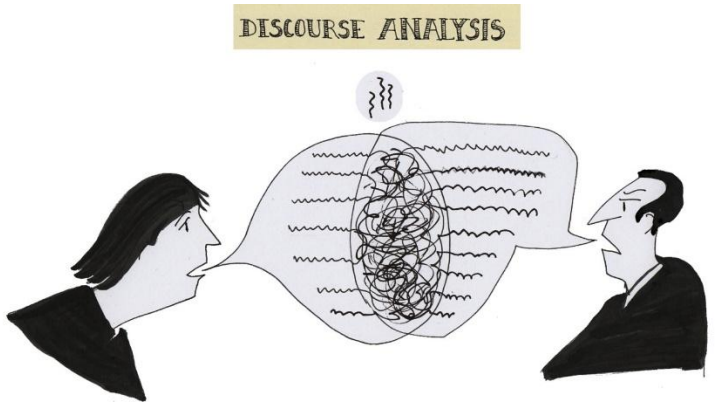
- 给定一个句子或较长的文本片段，请确定其中包含哪些单词。“提及”指代相同的对象（即“实体”）。指代匹配解析是该任务的一个具体实例，其核心在于将代词与其所指的名词或名称进行对应。更广泛的共指解析任务还包括识别涉及指称表达式的所谓“桥接关系”。例如，在句子“他通过前门进入约翰的家”中，“前门”所指的就是那扇前门。
约翰的房子。



话语（超越单个句子的语义）

话语分析

- 该评估标准包含若干相关任务。其中一项任务是话语解析，即识别连贯文本的话语结构，即句子之间的话语关系性质（如阐述、解释、对比等）；另一项可能的任务是识别并分类文本片段中的言语行为（例如是非疑问句、内容疑问句、陈述句等）。
  断言等）。



话语（超越单个句子的语义）

识别文本蕴含关系

- 给定两个文本片段，判断其中一个为真时是否必然导致另一个为真、是否必然导致另一个的否定成立，或是否允许另一个为真或为假。

主题分割与识别

- 给定一段文本，将其划分为多个段落，每个段落专注于一个特定主题，并识别该段落的主题。

高级自然语言处理应用

自动摘要（文本摘要）

- 生成一段文本的可读摘要。常用于对特定类型的文本（如研究论文或报纸财经版文章）进行概括。

对话管理

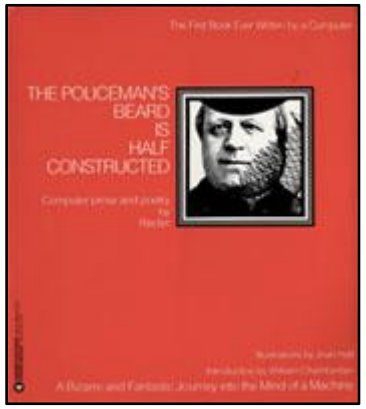
- 旨在与人类进行交互的计算机系统。机器翻译
- 自动将文本从一种人类语言翻译为另一种人类语言。
  这是最复杂的“AI完全”问题之一，即需要人类所具备的所有不同类型的知识（语法、语义、关于现实世界的事实等）才能正确解决。

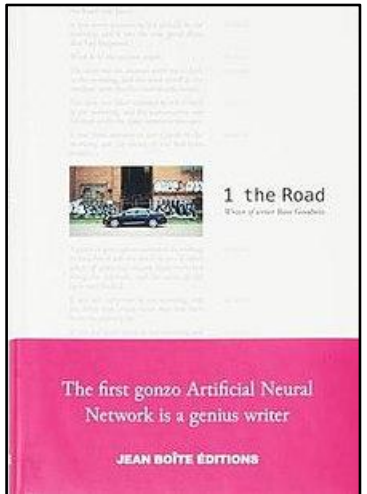
高级自然语言处理应用

书籍生成

- 虽然这并非严格意义上的自然语言处理任务，而是自然语言生成及其他NLP任务的延伸——即创作完整的书籍。首部机器生成书籍由基于规则的系统于1984年完成（**Racter，《警察的胡子是半成品》**）。首个由神经网络创作并出版的作品则出现在2018年。**《1号公路》**作为一部小说出版，全书共计六千万字。这两种语言模型本质上都是结构复杂但缺乏语义（即不考虑语义关系）的语言模型。首部由机器生成的科学著作于2019年问世（《Beta Writer》、《锂离子电池》、Springer出版社、Cham出版社）。与Racter和《1号公路》不同，该作品基于事实知识，并采用文本摘要技术构建而成。

高级自然语言处理应用

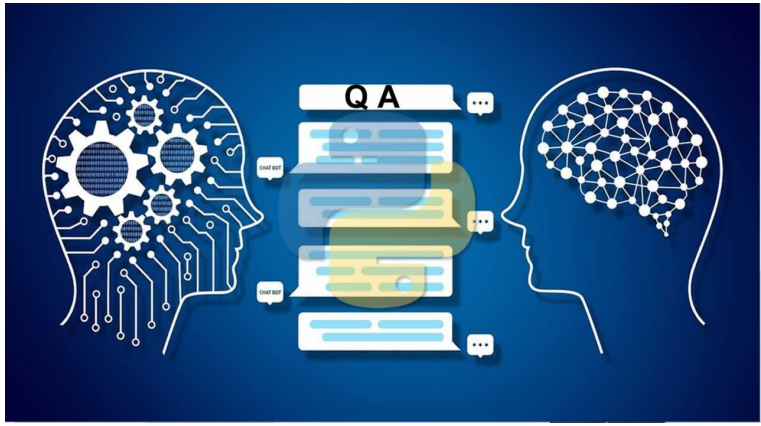




除本引言外，本书的所有文字均由计算机生成。该书已经过拼写校对，但除此之外完全未经人工编辑。计算机必须以某种方式向我们传达其运行状态——且通常通过英文编程指令实现这一功能——这一事实确实提示我们：或许可以编写相应的程序代码，使计算机能够“自主”地理解并运用一种通用语言……。

《1号公路》是一部由人工智能（AI）创作的实验性小说。为模仿杰克·凯鲁亚克的《在路上》，罗斯·古德温于2017年3月驾驶汽车从纽约前往新奥尔良，随车携带一台连接多种传感器的笔记本电脑；AI将传感器输出的数据转化为文字，并打印在收据纸上。该小说于2018年由让·博伊特出版社出版。古德温未对文本进行任何编辑——尽管他认为文笔“断断续续”且存在排版错误，但仍希望以原样呈现这段机器生成的文字供后世研究。故事开篇写道：“上午九点十七分，屋内显得格外沉闷。”

高级自然语言处理应用



问题回答

- 针对一个人类语言提出的问题，需确定其答案。典型问题通常具有明确的正确答案（例如“加拿大首都是什么？”），但有时也会考虑开放式问题（例如“生命的意义是什么？”）。近期研究甚至探讨了更为复杂的问题。

网络资源

班级项目提交:

https://github.com/info-ruc/tm26projects

实验环境

PyTorch

https://openi.pcl.ac.cn

Matlab

https://matlab.mathworks.com