# 文本内容分析

## 项目背景

最常见的分析方法是提取文本中的词语，并统计频率。频率能反映词语在文本中的重要性，一般越重要的词语，在文本中出现的次数就会越多。词语提取后，还可以做成词云，让词语的频率属性可视化，更加直观清晰。

## 一、分词

把要分析的文件，存为文本文件（txt 后缀），放到某个目录

1、装载自定义词库（这里的自定义词库，是根据分析文件中的某些特殊用词，自己编写的一个词库文件，其实也是一个文本文件，每行一个词。装自定义词库是为了准确进行分词。某些单词如果不设置为自定义词，那么分词的时候可能会分解成其他的词汇。

```
installDict(file.choose(),"mydict")
listDict()
loadDict(dictpath = getOption("dic.dir"))
```

2、分词后，会在分词文件的同一个目录生成一个”源文件名+.segment”的文本文件，就是分词的结果。Rwordseg 的特点是分词很快。

## 二、建立语料库

这部分是读入分词后的文件,然后进行整理,清洗,变换成用于分析的”语料库”。

1、读入分词后的文本

```
mydoc<-readLines(file.choose())
```

2、建立语料库（这里读取文本到变量，根据文本变量来建立语料库）

```
mydoc.vec<-VectorSource(mydoc)
mydoc.corpus<-Corpus(mydoc.vec)
```

3、删除停用词

```
data_stw=read.table(file=file.choose(),colClasses="character")
stopwords_CN=c(NULL)
for(i in 1:dim(data_stw)[1]){
  stopwords_CN=c(stopwords_CN,data_stw[i,1])}
mydoc.corpus<-tm_map(mydoc.corpus,removeWords,stopwords_CN)
```

## 三、进行内容分析

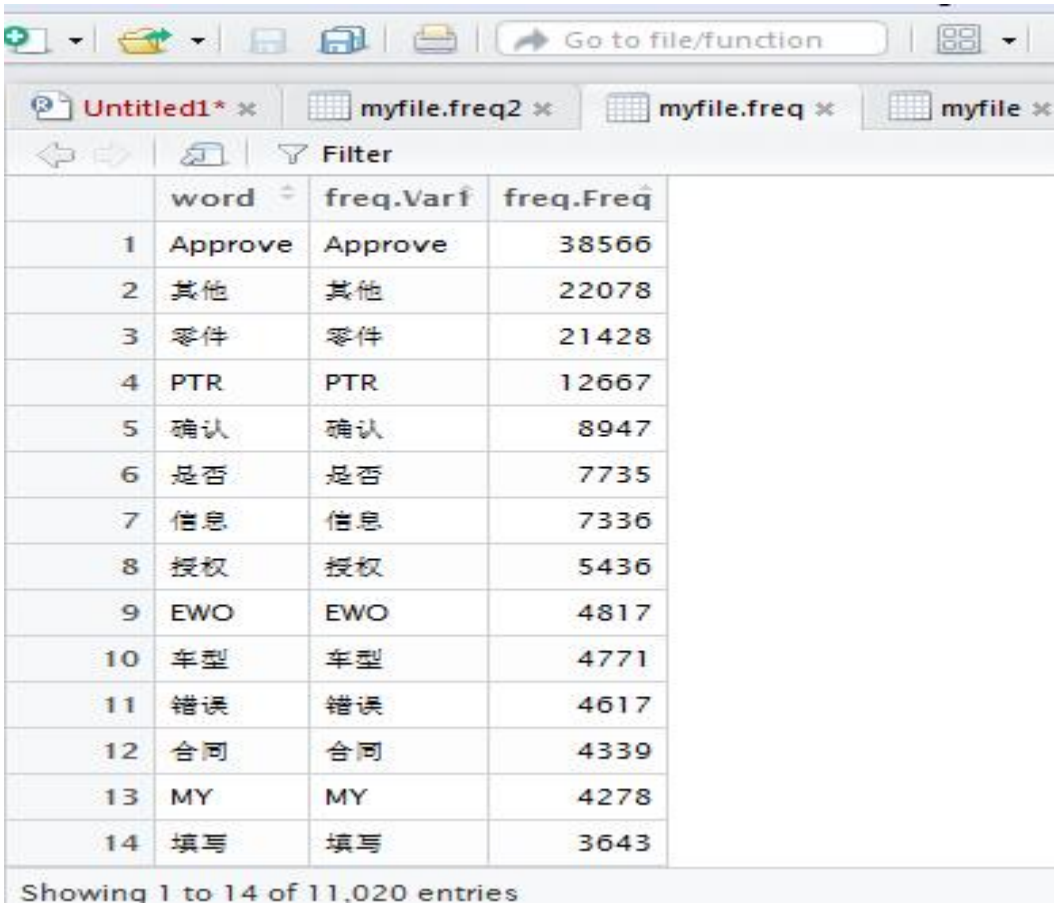
建立 TDM 矩阵：在一份给定的文件里，词频（term frequency, TF）指的是某一个给定的词语在该文件中出现的次数。这个数字通常会被归一化，以防止它偏向长的文件。（逆向文件频率（inverse document frequency, IDF）是一个词语普遍重要性的度量。某一特定词语的 IDF，可以由总文件数目除以包含该词语之文件的数目，再将得到的商取对数得到。

某一特定文件内的高词语频率，以及该词语在整个文件集合中的低文件频率，可以产生出高权重的 TF-IDF。因此，TF-IDF 倾向于保留文档中较为特别的词语，过滤常用词。

词云：

```
library(wordcloud)
m<-as.matrix(mydoc.tdm)
wordfred<-sort(rowSums(m),decreasing=T)
set.seed(375)
op = par(bg = "lightgrey")
wordcloud(words=names(wordfred),freq=wordfred,
min.freq=2,random.order=F,col = rainbow(length(wordfred)))
par(op)
```

实验结果：




| | word | freq.Var1 | freq.Freq |
|---|---|---|---|
| 1 | Approve | Approve | 38566 |
| 2 | 其他 | 其他 | 22078 |
| 3 | 零件 | 零件 | 21428 |
| 4 | PTR | PTR | 12667 |
| 5 | 确认 | 确认 | 8947 |
| 6 | 是否 | 是否 | 7735 |
| 7 | 信息 | 信息 | 7336 |
| 8 | 授权 | 授权 | 5436 |
| 9 | EWO | EWO | 4817 |
| 10 | 车型 | 车型 | 4771 |
| 11 | 错误 | 错误 | 4617 |
| 12 | 合同 | 合同 | 4339 |
| 13 | MY | MY | 4278 |
| 14 | 填写 | 填写 | 3643 |

Showing 1 to 14 of 11,020 entries