一、项目目标：通过 NLP 工具对小说类数据构建模型，通过模型生成词向量判断小说中的人物关系紧密程度。

二、项目技术：

（1）jieba 分词技术

（2）基于 gensim 实现 word2vec 模型

三、项目实现

（1）读取数据并使用 jieba 进行中文分词

```
with open("shuihuzhuan.txt", 'r', encoding='utf-8') as f:    # 读入文本
    lines = []
    for line in f:    # 分别对每段分词
        temp = jieba.lcut(line)    # 结巴分词 精确模式
        words = []
        for i in temp:
            # 过滤掉所有的标点符号
            i = re.sub("[\s+\.\!\/_,$%^*(+\"\'”“《》]+|[+——！，。？、~@#￥%……&*（）：；‘]+", "", i)
            if len(i) > 0:
                words.append(i)
        if len(words) > 0:
            lines.append(words)
```

（2）分词之后使用 gensim 库中的 word2vec 构建模型

```
from gensim.models import Word2Vec
# 调用 Word2Vec 训练 参数：size: 词向量维度；window: 上下文的宽度，min_count 为考虑计算的单词的最低词频阈值
model = Word2Vec(lines,vector_size = 20, window = 2 , min_count = 3, epochs=7, negative=10,sg=1)
```

（3）根据输入人物名称验证结果

```
print("\n 和武松相关性最高的前 20 个词语：")
model.wv.most_similar('武松', topn = 20)# 与武松最相关的前 20 个词语
```

输出如下：

和武松相关性最高的前 20 个词语：

[('武大', 0.9159631133079529), ('李逵', 0.9126640558242798), ('智深', 0.9061545729637146), ('史进', 0.9007703065872192), ('王婆', 0.8968600034713745), ('林冲', 0.8924708962440491), ('那婆子', 0.8894446492195129), ('动', 0.8876190185546875), ('李固', 0.8818626999855042), ('小二哥', 0.8767825365066528), ('燕青', 0.8737136721611023), ('杨雄', 0.8714655637741089), ('何九叔', 0.8702340126037598), ('老儿', 0.8674899339675903), ('那汉', 0.865023136138916), ('石秀', 0.8636547327041626), ('李小二', 0.8632025718688965), ('王进', 0.8593494296073914), ('贺太守', 0.8589684367179871), ('扯住', 0.8576358556747437), ('众军', 0.8563530445098877), ('鲁达', 0.8554097414016724), ('假意', 0.8549312949180603), ('时迁', 0.8532587885856628), ('王庆', 0.8527480959892273), ('一杯', 0.8525522351264954), ('潘公', 0.8525198101997375), ('薛霸', 0.8510876893997192), ('石秀便', 0.850543737411499)]

从结果中我们看出，与武松相关性最高的是武大、李逵、智深、史进，也符合小说中的角色关系。

四、类比关系实验，

（1）鲁智深关系关联最多的有哪几位？

（2）在三国演义中，孔明是玄德的军师，那么曹操的军师是谁呢？曹操跟魏国的关系很近，那么跟蜀国关系最近的谁呢？

（3）在红楼梦中，林黛玉、王熙凤、薛宝钗分别和那些人关联性最紧密？