CNN-NLP-舆情新闻分类任务-经验分享

姓名：姜吉阳　　资格证号：231017000153

- **相关背景**
  - 因为工作会接触到一些舆情，再结合课程相关内容
  - 于是想开发一个小项目，用于舆情新闻的分类
  - 由于工作与 AI 相关性不高，且未系统深入地学习过相关知识
  - 因此这个项目实现的过程中，大量使用了 ChatGPT 工具
- **准备工作**
  - 询问 ChatGPT，获取项目所需的相关条件
  - 购买阿里云 ECS 虚拟主机，下载安装 anaconda
  - 新建并切换虚拟环境，下载项目所需的相关包
  - 使用 Fleet 远程连接云主机
  - 寻找网站，采集数据，整理数据，存储数据
- **实现步骤**
  - 整合项目的关键点，询问 ChatGPT，获得一个基本模型
  - 再进一步询问每个步骤的细节，获得对整个流程和各步骤细节的基本认识
  - 询问 ChatGPT，获取一个基本的代码模型
  - 拷贝代码到云主机，替换自己的数据集，解决各种报错问题
  - 调试代码，直到能正常跑通，并解决欠拟合或过拟合问题
- **项目结论**
  - 构建的模型，在训练集、测试集和验证集上，都有相对统一的结果
- **不足之处**
  - 精确度，较统一，但偶尔存在 80%-96%之间的波动
- **需改善处**
  - 增加数据集的数量
  - 寻找更高质量的数据来源，确保标签的准确度

- **项目样例**
  - 部分数据集

```
tag,content
科技,原标题迄今最大全基因组测序数据公布科技日报北京月日电记者张梦然经过历时年超万小时的基因组测
科技,原标题中国科技评估发展报告发布科技日报重庆月日电记者雍黎日第七届全国科技评估机构协作发展座
科技,原标题控制食欲的脑细胞找到了科技日报北京月日电记者张梦然最新自然杂志上发表的动物实验确定了
科技,原标题黑科技让残障人士开启无碍生活观众在杭州拱墅运河体育公园体育场大厅体验电子导盲犬小西杭
科技,原标题我专家团队揭示细胞感应氨基酸新机制科技日报讯任萱记者王春细胞如何感知胞内营养物质尤其
科技,原标题国家时间频率计量中心挂牌成立科技日报北京月日电记者华凌近日在国家市场监督管理总局中国
科技,原标题带电作业现场勘查技术在任城获突破科技日报讯记者王延斌通讯员陈志浩东海月日记者从山东省
科技,原标题家单位联手助推大豆振兴战略实施科技日报讯记者金凤月日全国大豆生物育种产教融合创新联盟
科技,柴人杰在实验室工作受访者供图据估计全球约有亿人患有致残性听力损失在中国残疾性听力损失患者约
```

  - 部分停用词

```
原标题
责编
分享
让
更多人
看到
一下
一些
一切
一则
```

  - 部分代码

```python
# 将标签转换为numpy数组并进行独热编码【消除标签的数值大小影响】
labels = to_categorical(np.array(labels))

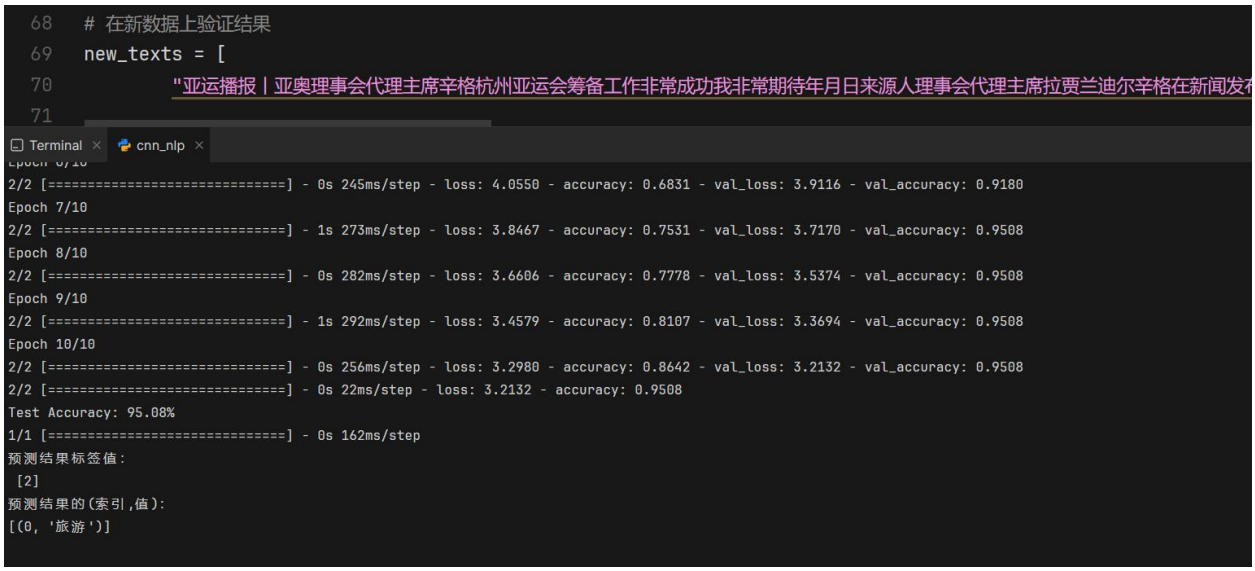
# 划分训练集和测试集
x_train, x_test, y_train, y_test = train_test_split(*arrays: data, labels, test_size=0.2, random_state=42)

# 构建CNN模型【】
model = Sequential()
model.add(Embedding(len(tokenizer.word_index) + 1, output_dim: 128, input_length=maxlen))  # 嵌入层，将输入的整数序列转换
model.add(Conv1D(filters: 128, kernel_size: 5, activation='relu', kernel_regularizer=l2(0.01)))  # 添加第一个一维卷积层，
model.add(MaxPooling1D(5))  # 池化层，窗口为5
model.add(Conv1D(filters: 128, kernel_size: 5, activation='relu', kernel_regularizer=l2(0.01)))  # 添加第二个一维卷积层，
model.add(GlobalMaxPooling1D())  # 全局最大池化层
model.add(Dense(units: 128, activation='relu', kernel_regularizer=l2(0.01)))  # 全连接层
model.add(Dropout(0.5))  # Dropout层，减少过拟合
model.add(Dense(len(labels[0]), activation='softmax'))  # 激活函数为softmax，多分类任务

# 编译深度学习模型，其中包括了损失函数、优化器和评估指标的设置【交叉熵损失函数，Adam优化器，准确率评估指标】
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

```

- 训练结果


68 # 在新数据上验证结果
69 new_texts = [
70 "亚运播报丨亚奥理事会代理主席辛格杭州亚运会筹备工作非常成功我非常期待年月日来源人理事会代理主席拉贾兰迪尔辛格在新闻发
71
Terminal
cnn_nlp
2/2 [==============================] - 0s 245ms/step - loss: 4.0550 - accuracy: 0.6831 - val_loss: 3.9116 - val_accuracy: 0.9180
Epoch 7/10
2/2 [==============================] - 1s 273ms/step - loss: 3.8467 - accuracy: 0.7531 - val_loss: 3.7170 - val_accuracy: 0.9508
Epoch 8/10
2/2 [==============================] - 0s 282ms/step - loss: 3.6606 - accuracy: 0.7778 - val_loss: 3.5374 - val_accuracy: 0.9508
Epoch 9/10
2/2 [==============================] - 1s 292ms/step - loss: 3.4579 - accuracy: 0.8107 - val_loss: 3.3694 - val_accuracy: 0.9508
Epoch 10/10
2/2 [==============================] - 0s 256ms/step - loss: 3.2980 - accuracy: 0.8642 - val_loss: 3.2132 - val_accuracy: 0.9508
2/2 [==============================] - 0s 22ms/step - loss: 3.2132 - accuracy: 0.9508
Test Accuracy: 95.08%
1/1 [==============================] - 0s 162ms/step
预测结果标签值:
[2]
预测结果的(索引,值):
[(0, '旅游')]