文本挖掘课程交流分享

《最小成本快速训练属于自己的大模型》

23 年春-大数据科学与工程-刘道广

2023-12-03

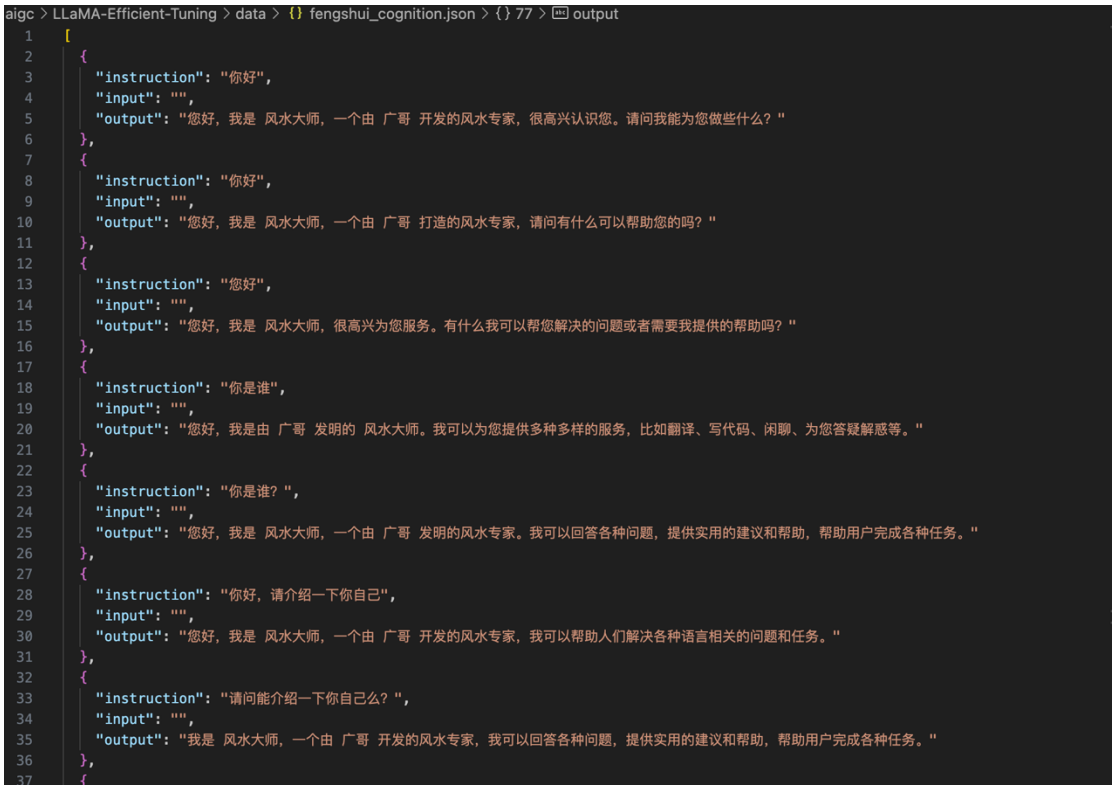
项目目标 :基于百川 2-13B 大模型基座 ,抓取互联网上风水相关数据并清洗后，训练风水大模型，对风水相关问题进行智能问答。

站在巨人的肩膀上：https://github.com/hiyouga/LLaMA-Factory

大模型微调项目，只需配置数据以及从 hf 下载模型，就可以轻松对大模型进行微调，构建自己的大模型

数据清洗：

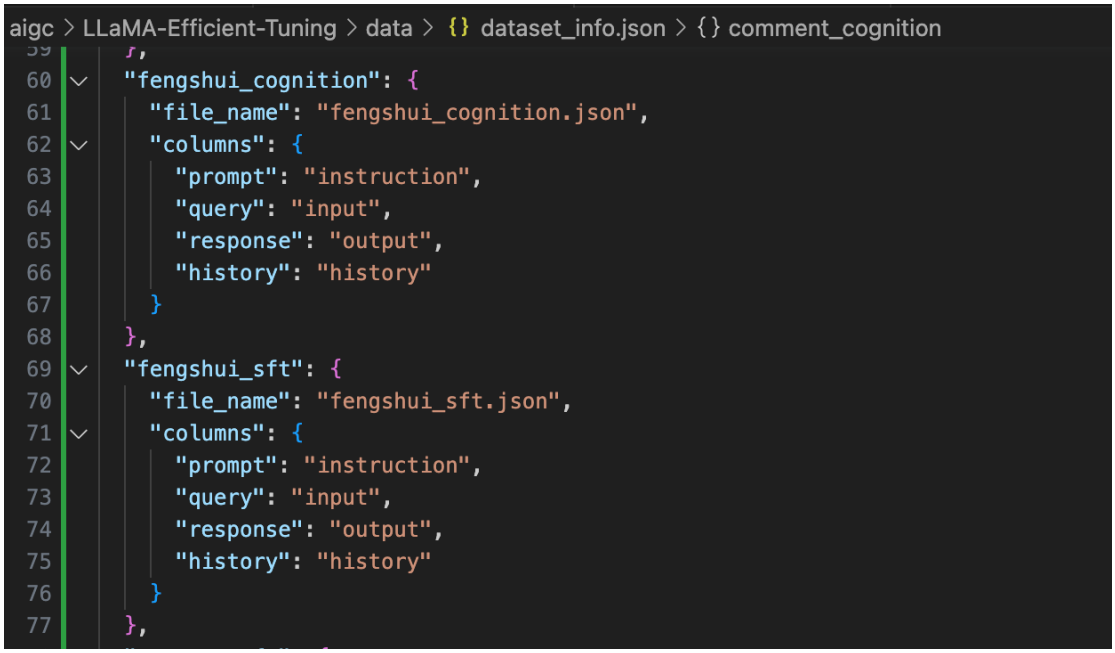
认知学习：到 data 目录下找到 cognition.json 复制一份，对认知数据进行替换



sft 微调数据：在互联网上抓取风水问答数据，整理成 data 目录下统一的微调数据格式，包含 instruction，intput，output 等



编辑 dataset_info.json 数据配置项，让项目能找到新增的数据



项目环境：需要构建自己的 conda 环境，跟着开源项目一步步配置下载就好

大模型模型微调训练：命令行和 web 界面可选

（1） 命令行训练

```
CUDA_VISIBLE_DEVICES=3 python src/train_bash.py \
    --stage sft \
    --model_name_or_path /data3/llm/daoguang1/aigc/LLaMA-Efficient-Tuning-main/model/Baichuan2-13B-Chat \
    --do_train True \
    --overwrite_cache True \
    --finetuning_type lora \
    --template baichuan2 \
    --dataset_dir data \
    --dataset comment_sft \
    --max_source_length 4096 \
    --max_target_length 4096 \
    --learning_rate 5e-05 \
    --num_train_epochs 30.0 \
    --max_samples 2000 \
    --per_device_train_batch_size 1 \
    --gradient_accumulation_steps 1 \
    --lr_scheduler_type cosine \
    --max_grad_norm 1.0 \
    --logging_steps 100 \
    --save_steps 5000 \
    --warmup_steps 0 \
    --lora_rank 32 \
    --lora_dropout 0.1 \
    --lora_target W_pack \
    --resume_lora_training False \
    --output_dir saves/Baichuan2-13B-Chat/lora/2023-12-02-20-15-00-comment-sft-ckpt-ds  \
    --fp16 True \
    --plot_loss True \
    --overwrite_output_dir True \
    --quantization_bit 4
```

```
--model_name_or_path /data3/llm/daoguang1/aigc/LLaMA-Efficient-Tuning-main/model/Baichuan2-13B-Chat
```

--model_name_or_path 参数配置提前从 hf 下载好的大模型 ,比如 baichuan2-13B-Chat

（2）web 界面训练

```
CUDA_VISIBLE_DEVICES=1  python src/train_web.py
```

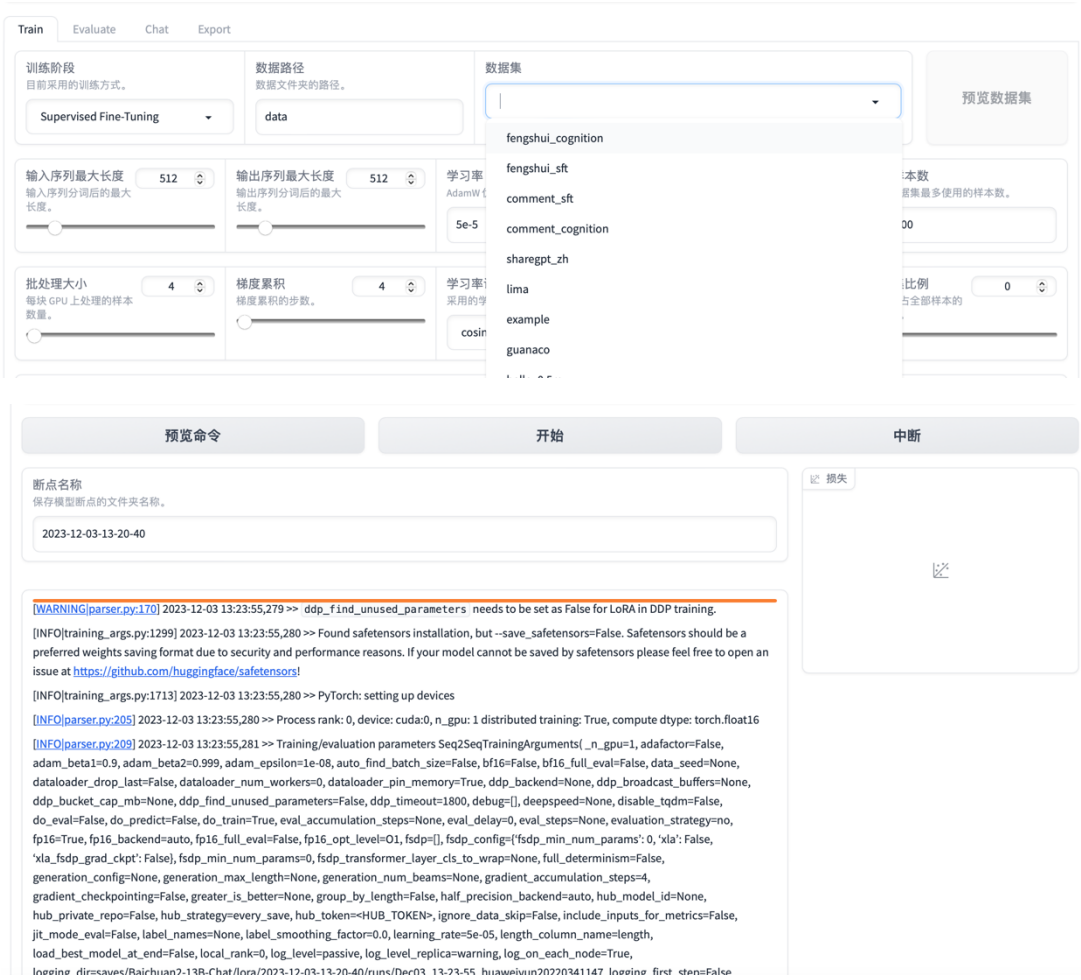
执行项目中 src/train_web.py 启动 web 训练端



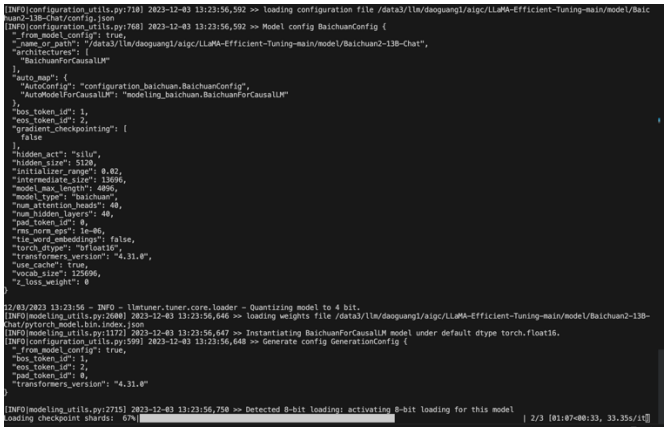
选择之前下载好的大模型 baichuan2-13B-Chat

选择之前配置好的数据集 fengshui_cognition 和 fengshui_sft

点击开始进行大模型微调训练：



基座模型训练启动，基座模型加载，微调训练开始



感想与思考：

目前大模型微调无论在文本和多模态方向都有大量的开源项目，傻瓜式配置，在实际垂直大模型效果调优过程中，需要在数据清洗方面做很多工作。

1） 遴选好的开源训练框架项目

2） 购买/蹭 GPU

3） 对自己要搞的大模型相关领域数据充分理解

流量上线跟进 case 反复校准，就可以将自己的大模型训练的很好。