一 项目背景

我们处于信息爆炸时代，每天被大量新闻包围。因此，利用文本挖掘技术对新闻文本进行分类，比如娱乐新闻、财经新闻、科技新闻等，便于读者阅读。

二 项目路线

1 利用 jiebaR 进行切词，jiebaR 有一个自己的词典库，如果 jiebaR 自带的词典库无法涵盖一些关键词汇，将通过增加新的词汇表进一步对词汇进行优化提取。同时利用增加停止词，去掉“了”“的”及语气词等词汇。

2 利用 jiebaR vector_keywords 关键词函数进行主题提取。

3 利用 TF-IDF 进行词频统计

4 利用词云对关键词进行可视化处理

5 利用 kmeans 及其它技术（待定）对新闻文本进行聚类分析，最终将数据集中的新闻按照不同类别进行分类。