基于大预言模型的摘要生成

（22殷慧敏）

一、项目背景

工作中需要经常性阅读大量文件，并且对信息快速进行响应，由于全文阅读完时间较长，希望通过大模型能够对文件进行分析，生成摘要信息，让用户快速了解整体文件内容，并且通过摘要确定优先阅读重点。

二、解决思路（实现步骤）

1. 自己创建一个基础脚本，能够调用大预言模型，实现摘要的基础功能；
2. 能够实现从终端直接上传一个文件，而不是简单输入文本，从而可以支持多类型文件分析；
3. 根据自己的使用需求，对大预言模型进行微调，生成一些个性参数集，对生成的摘要更加精准（关键是训练数据集）

三、技术选型

1. 技术环境：基于魔塔社区https://modelscope.cn/提供的个人学习环境；注册账户后拥有一个CPU和GPU的环境，基于python3.8，pytorch2.0.1和ModelScope的lib。
2. 大预言模型：基于魔塔社区的提供的开源LLM信息，做了一些简单的测试后选择“通义千问-7B-Chat-Int4”

四、具体实现

1. 进入modelscope，在notebook打开python文件，进行脚本编辑；
2. 首先导入lib

```
from modelscope import AutoTokenizer, AutoModelForCausalLM
```

3. 采用Qwen-7B-Chat-Int4模型来生成tokenizer和model

```
tokenizer = AutoTokenizer.from_pretrained("qwen/Qwen-7B-Chat-Int4", trust_re
model = AutoModelForCausalLM.from_pretrained(
    "qwen/Qwen-7B-Chat-Int4",
    device_map="auto",
    trust_remote_code=True
).eval()
```

4. 获取待解析文本。当前从命令行接收，并存入临时变量

```
str = input("请输入要提炼摘要的原始文档内容：(单行#号结束)")
fullStr = str
while str != "#" :
    fullStr = fullStr + str
    str = input("")
```

5. 设置摘要的prompt内容，调用model解析后输出摘要内容

```
fullStr = "给出如下文章的摘要，至少300字以上: \n" + fullStr
response, history = model.chat(tokenizer, fullStr, history=None)
print('文本摘要结果:\n' + response)
```

6. 继续接收新的文档，并输出。

```
# 循环执行，等待新的文本输入，直到只输入
while fullStr != "#" :
    str = input("请继续输入新的文档内容：(单行#号结束 ) ")
    while str != "#" :
        fullStr = fullStr + str
        str = input("")

    if len(fullStr) > 0 :
        fullStr = "给出如下文章的摘要，至少300字以上: \n" + fullStr
        response, history = model.chat(tokenizer, fullStr, history=history)
        print('文本摘要结果:\n' + response)
        fullStr = ""
        str = ""
    else :
        print("再见！")
        fullStr = "#"
```

最后保存代码为test.py

五、执行摘要结果

打开terminal终端窗口，在脚本目录下，执行命令：

```
root@xxxx:/mnt/workspace#python test.py
```

在提示词后

```
请输入要提炼摘要的原始文档内容：(单行#号结束 )
```

输入内容（复制入到终端窗口中）：

> 三）深化数字政府系统建设（牵头单位：省政府办公厅）
>
> 以数字化手段推进政府治理全方位、系统性、重塑性变革，
>
> 打造整体智治、高效协同的数字政府综合应用，构建整体高效的
>
> 政府运行体系，优质便捷的普惠服务体系，公平公正的执法监管
>
> ……
>
> 10．打造生态环境保护综合协同管理应用。深入践行“绿水
>
> 青山就是金山银山”理念，集成地表水水质预测预警、大气环境
>
> 监测预报预警、固废治理数字化应用、河湖库保护、农地土壤改

> 良服务、农村生活垃圾分类回收和资源化利用等系统，完善生态环境全要素态势感知、污染源数字化档案、污染防治攻坚战指挥协同、生态环境治理应用服务、碳排放监测应用服务等模块，运用环境质量、污染源自动监控、排污许可、河湖库保护、农地土
> — 23 —
> 壤改良等大数据分析，构建地上地下、陆海统筹的生态环境数字治理体系和生态环境质量评价体系，提升生态环境治理智能化水平，打造美丽中国先行示范区。

模型输出的摘要内容：

> 这篇文章主要讨论了数字政府系统的建设，旨在通过数字化手段推进政府治理的全方位、系统性和重塑性变革。该系统将采用一体化智能化公共数据平台，建设数字政府综合应用，并通过集成多个业务系统和数据源来实现政务、经济调节、市场监管、生态环境治理、应急管理等多个领域的全局化管理和智能化处理。通过该系统，可以更好地进行数据分析和预测，提高政府决策效率和公共服务水平。同时，也将进一步完善实践体系、理论体系和制度规范体系，打造一个“整体智治、唯实惟先”的现代政府。

输出结果基本上比较贴合原文内容，字数也比较合适（大概300字左右）。

六、不同模型结果比较

在使用“Qwen-7B-Chat-Int4”通用模型之前，先尝试了“PolyLM-Qwen-7B-多语言预训练模型”来测试，但是摘要结果不太理想。可能是该模型和我们测试使用的文档不太匹配，模型预训练并不适合等原因。

使用“PolyLM-Qwen-7B-多语言预训练模型”的代码（summary1.py）：

```
from modelscope.pipelines import pipeline
from modelscope.utils.constant import Tasks
from modelscope.outputs import OutputKeys

str = input("请输入文档内容：")
fullStr = str
while str != "#" :
    fullStr = fullStr + str
    str = input("")

text_summary = pipeline(Tasks.text_generation, model='damo/nlp_polylm_qwen_7
result = text_summary(fullStr)
print('文本摘要结果:\n' + result[OutputKeys.TEXT])
fullStr = ""

```

```
str = input("请继续输入文档内容：(单行#号结束 ) ")
while str != "#" :
    fullStr = fullStr + str
    str = input("")

if len(fullStr) > 0 :
    result = text_summary(fullStr)
    print('文本摘要结果:\n' + result[OutputKeys.TEXT])
else :
    print("再见！")

```

使用相同的输入文档的摘要结果：

```
2023-12-03 15:27:08,966 - modelscope - INFO - initiate model from /mnt/workspace/.cache/modelscope/damo/nlp_palm2.0_text-generation_chi
2023-12-03 15:27:08,966 - modelscope - INFO - initiate model from location /mnt/workspace/.cache/modelscope/damo/nlp_palm2.0_text-gener
2023-12-03 15:27:08,967 - modelscope - INFO - initialize model from /mnt/workspace/.cache/modelscope/damo/nlp_palm2.0_text-generation_c
2023-12-03 15:27:22.111345: I tensorflow/core/platform/cpu_feature_guard.cc:182] This TensorFlow binary is optimized to use available C
To enable the following instructions: AVX2 FMA, in other operations, rebuild TensorFlow with the appropriate compiler flags.
2023-12-03 15:27:23.877694: W tensorflow/compiler/tf2tensorrt/utils/py_utils.cc:38] TF-TRT Warning: Could not find TensorRT
文本摘要结果：
深化数字政府系统建设(图)
请继续输入文档内容：(单行#号结束) #
再见！
root@eais-bjc9fh99bp6nip7ryhs1-65bf86684f-cszrb:/mnt/workspace#
```

> 文本摘要结果:
>
> 深化数字政府系统建设(图)

对比之前的模型输出结果

```
#
文本摘要结果：
这篇文章主要讨论了数字政府系统的建设，旨在通过数字化手段推进政府治理的全方位、系统性和重塑性变革。该系统将采用一体化智能
化公共数据平台，建设数字政府综合应用，并通过集成多个业务系统和数据源来实现政务、经济调节、市场监管、生态环境治理、应急管
理等多个领域的全局化管理和智能化处理。通过该系统，可以更好地进行数据分析和预测，提高政府决策效率和公共服务水平。同时，也
将进一步完善实践体系、理论体系和制度规范体系，打造一个“整体智治、唯实惟先”的现代政府。
请继续输入新的文档内容：(单行#号结束)
```

可以看到此模型输出的摘要结果过于简单，可能只获取了文档标题，要进一步进行训练后再看是否有所改观

七、下一步优化

1. 解决文件上传问题
2. 解决大字数量文件优化问题
3. 优化训练