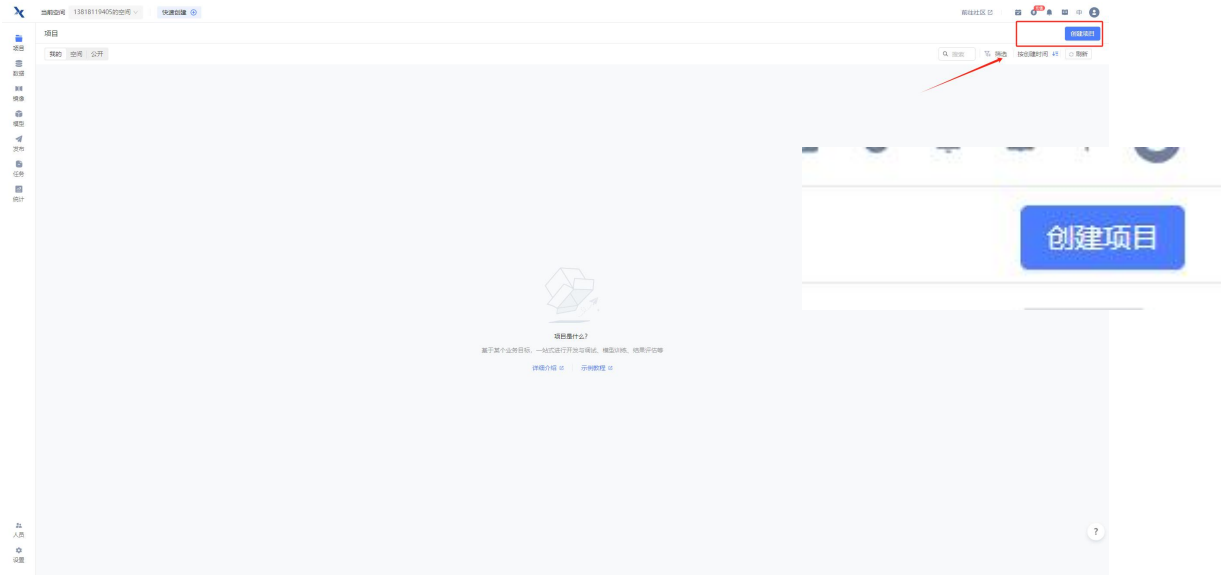
小白如何部署大模型，然后发可体验链接给其他人看。
未来云平台会越来越傻瓜化的操作趋势。
https://growthdata.virtaicloud.com，我随便用了机构给我的能免费用的平台，注册，登录

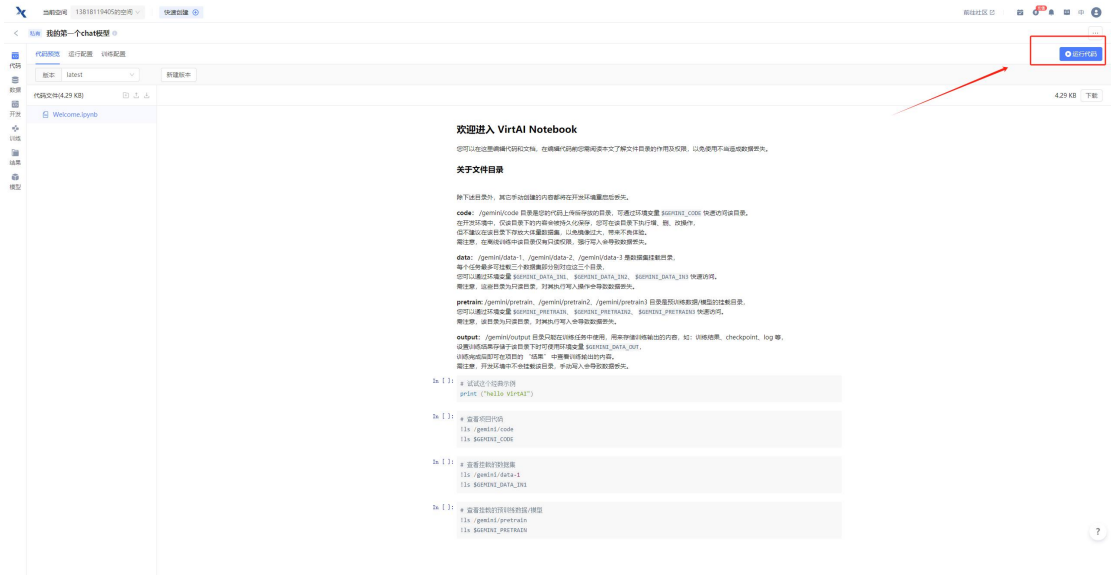


按下图选，选完右下角点创建，选择暂不上传

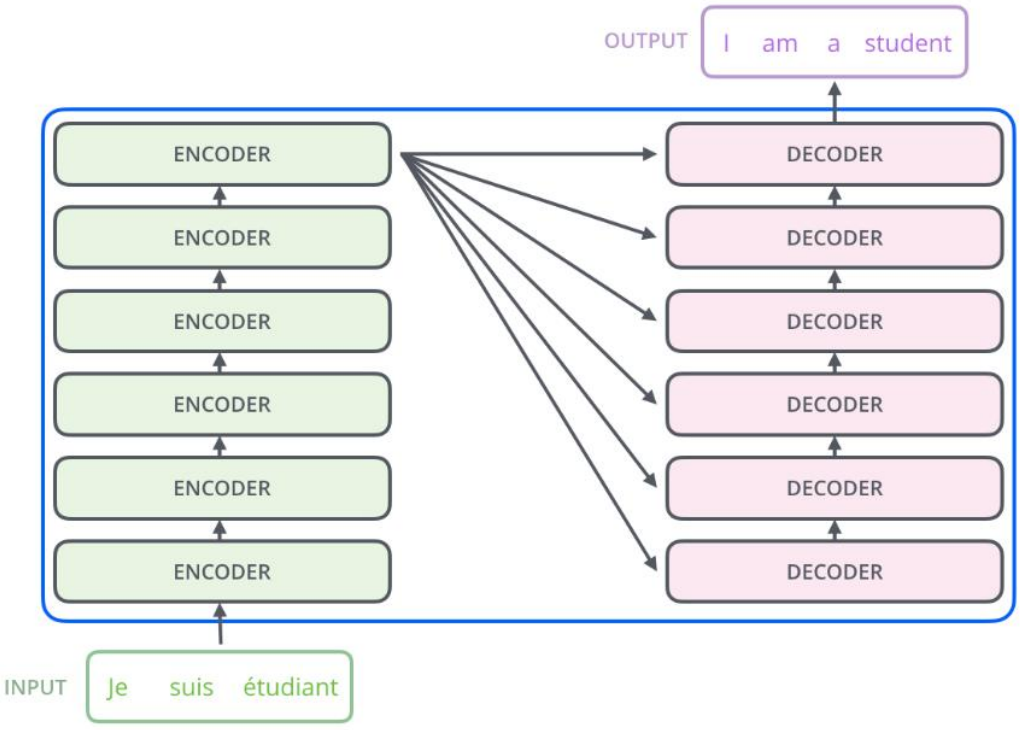




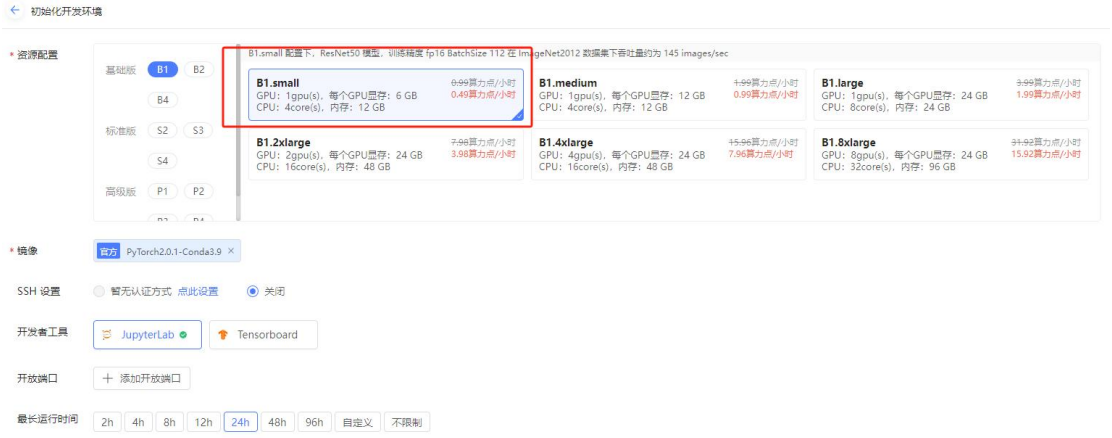
这个时候系统会自动加载完毕代码，你继续点右上角运行代码



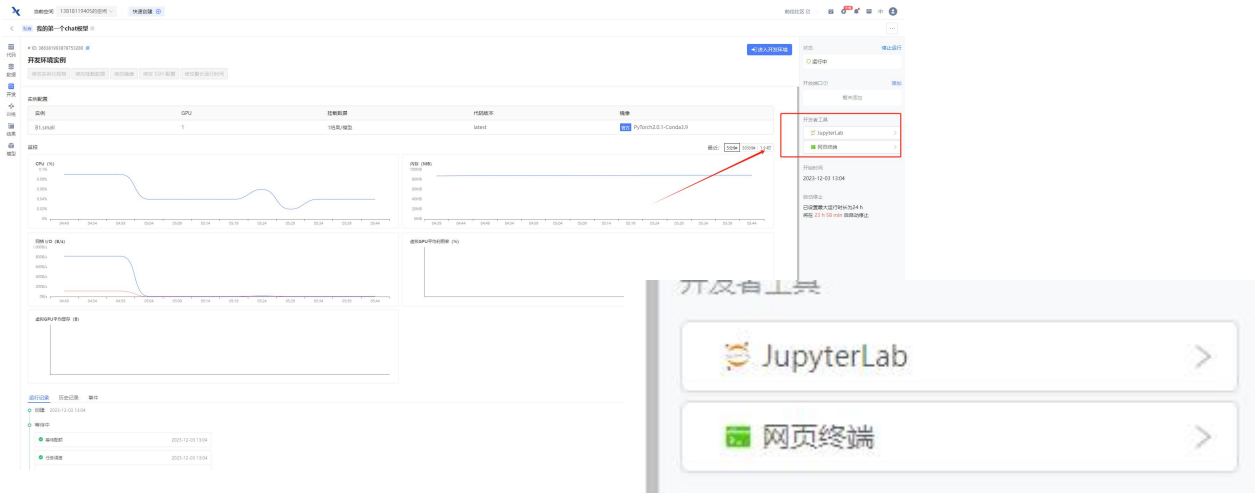
按照国际惯例，标准大模型都会分小杯，中杯，大杯，超大杯等等，就是参数量区别，本质上就是卷积层多一点，Transform 模型里面 decoder 多叠几遍，比如下图叠了 6 遍，可能就是小杯，你来个 100 遍就是大杯



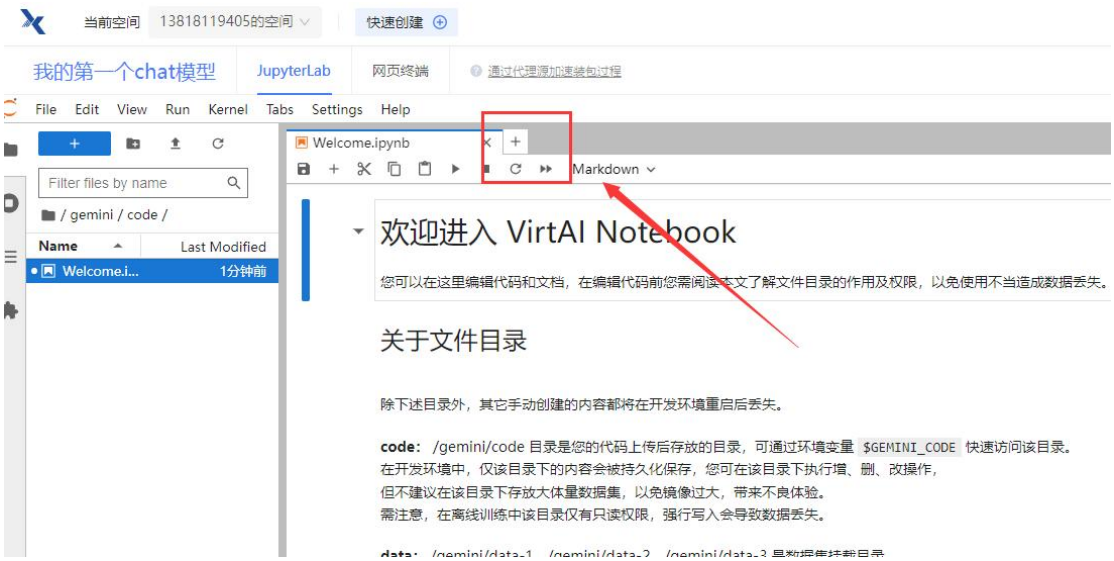
测试我们就选最小就好，继续按创建



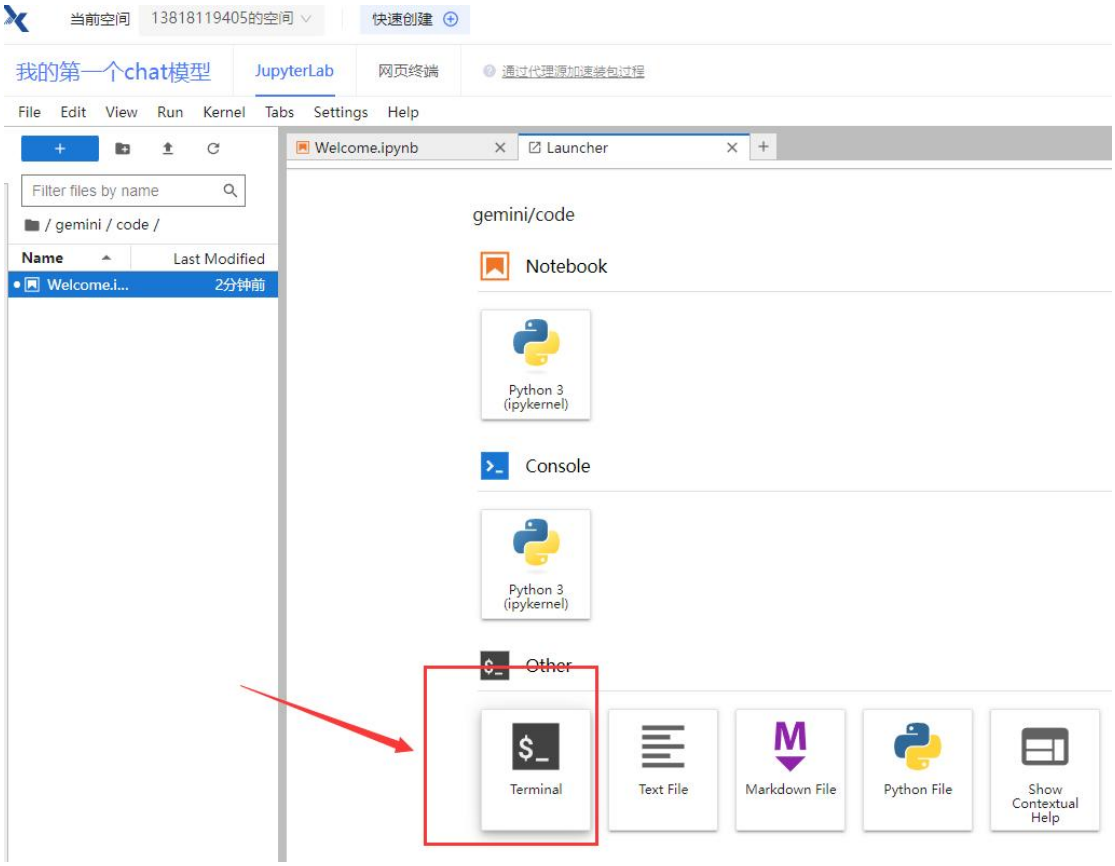
等待加载完毕后，点击右边



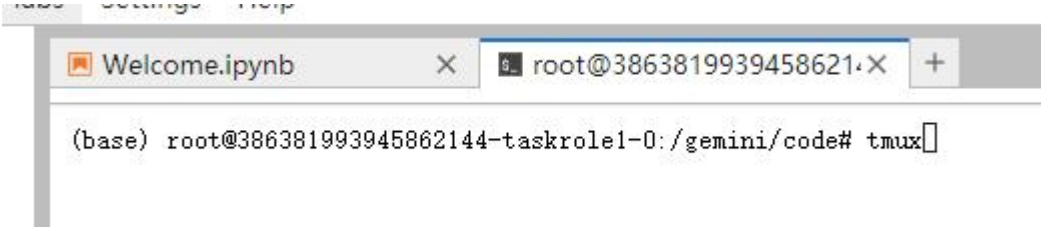
点击加号


当前空间
13818119405的空间
快速创建
我的第一个chat模型
JupyterLab
网页终端
File Edit View Run Kernel Tabs Settings Help
Filter files by name
/ gemini / code /
Name
Last Modified
Welcome.i...
1分钟前
Welcome.ipynb
Markdown
欢迎进入 VirtAI Notebook
关于文件目录
除下述目录外，其它手动创建的内容都将在开发环境重启后丢失。
code: /gemini/code 目录是您的代码上传后存放的目录，可通过环境变量 $GEMINI_CODE 快速访问该目录。
在开发环境中，仅该目录下的内容会被持久化保存，您可在该目录下执行增、删、改操作，
但不建议在该目录下存放大体量数据集，以免镜像过大，带来不良体验。
需注意，在离线训练中该目录仅有只读权限，强行写入会导致数据丢失。

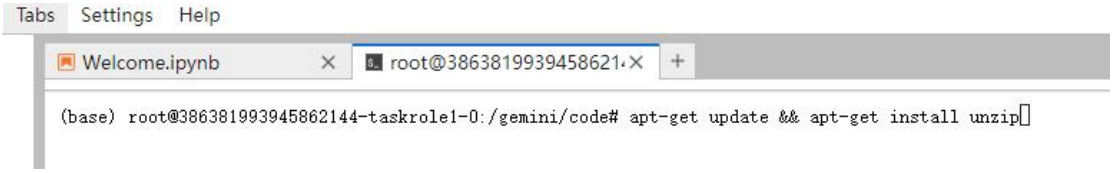
选这个终端


当前空间
13818119405的空间
快速创建
我的第一个chat模型
JupyterLab
网页终端
File Edit View Run Kernel Tabs Settings Help
Filter files by name
/ gemini / code /
Name
Last Modified
Welcome.i...
2分钟前
Welcome.ipynb
Launcher
gemini/code
Notebook
Python 3 (ipykernel)
Console
Python 3 (ipykernel)
Other
Terminal
Text File
Markdown File
Python File
Show Contextual Help

打开窗口后输入 tmux，系统会打开一个新窗口



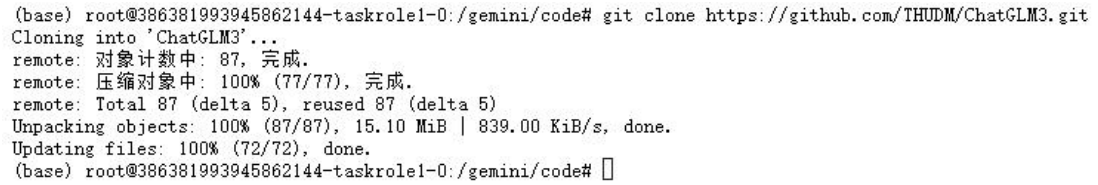
输入 apt-get update && apt-get install unzip，等待下载解压工具



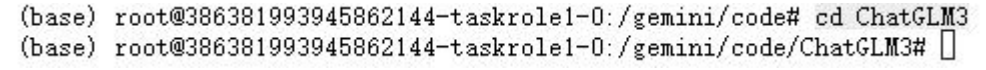
继续依次输入 git config --global url."https://gitclone.com/".insteadOf https://
pip config set global.index-url https://mirrors.ustc.edu.cn/pypi/web/simple
python3 -m pip install --upgrade pip
会有警告提示，不用管，显示 sucessfully 就行



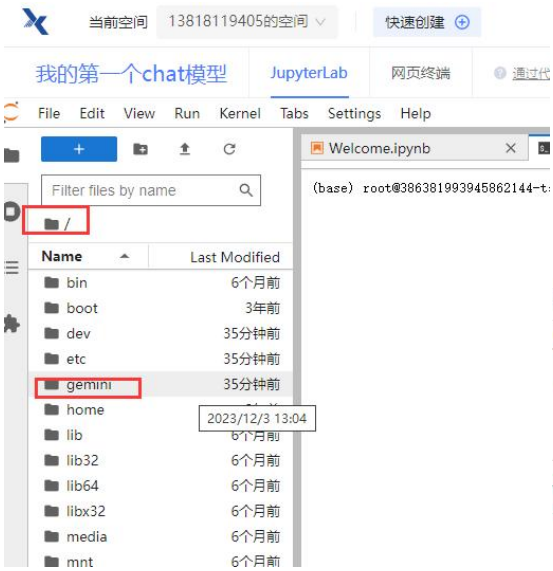
输入 git clone https://github.com/THUDM/ChatGLM3.git
克隆清华大学出的中文大模型，目前是最好的

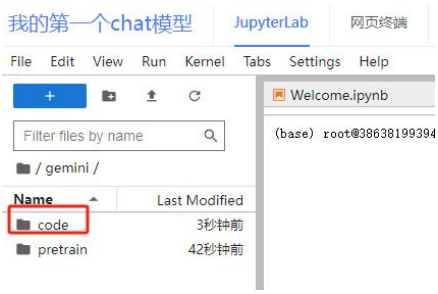


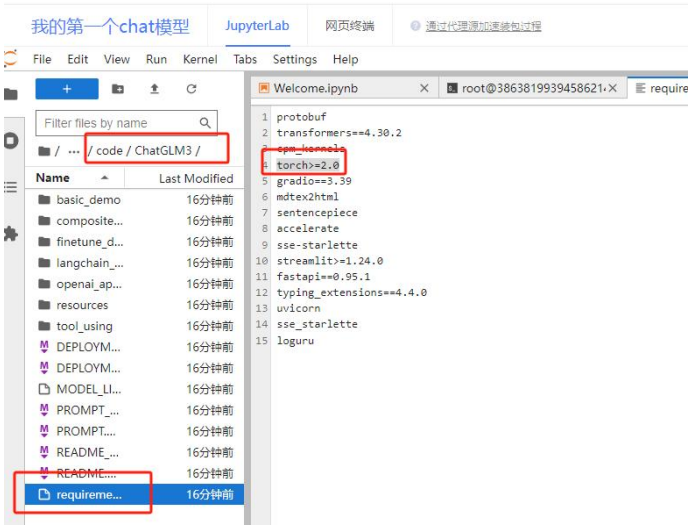
输入 cd ChatGLM3，进入模型 存放文件夹



在左侧找到 requirements.txt,删除 torch，因为我们已经安装了
万一点错了，可以按照下图路径找到
打开文档，删除图示字段，按×，选 save 即可





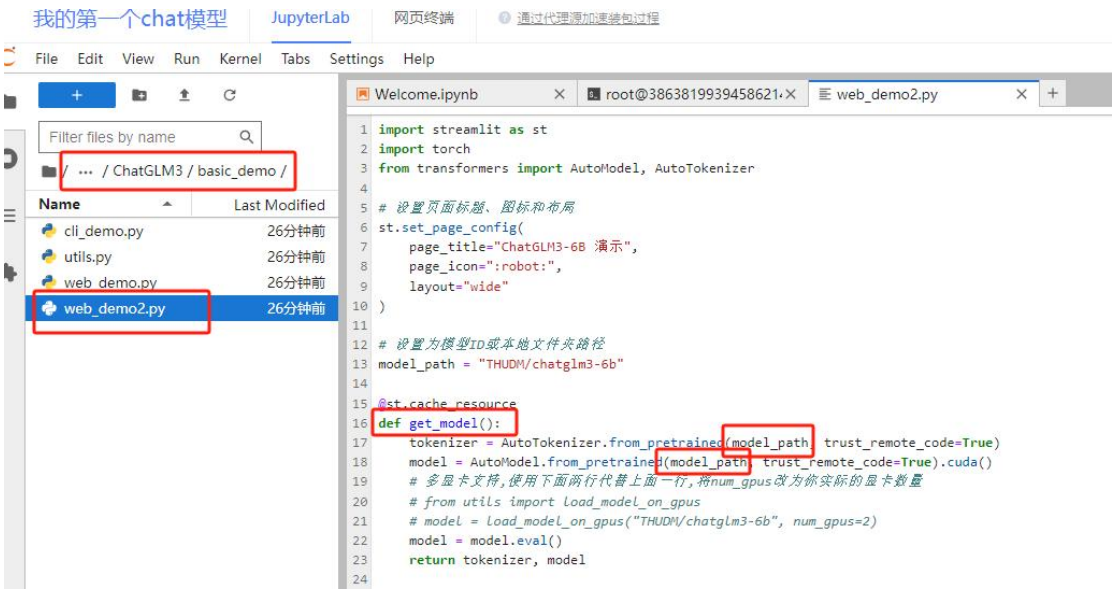


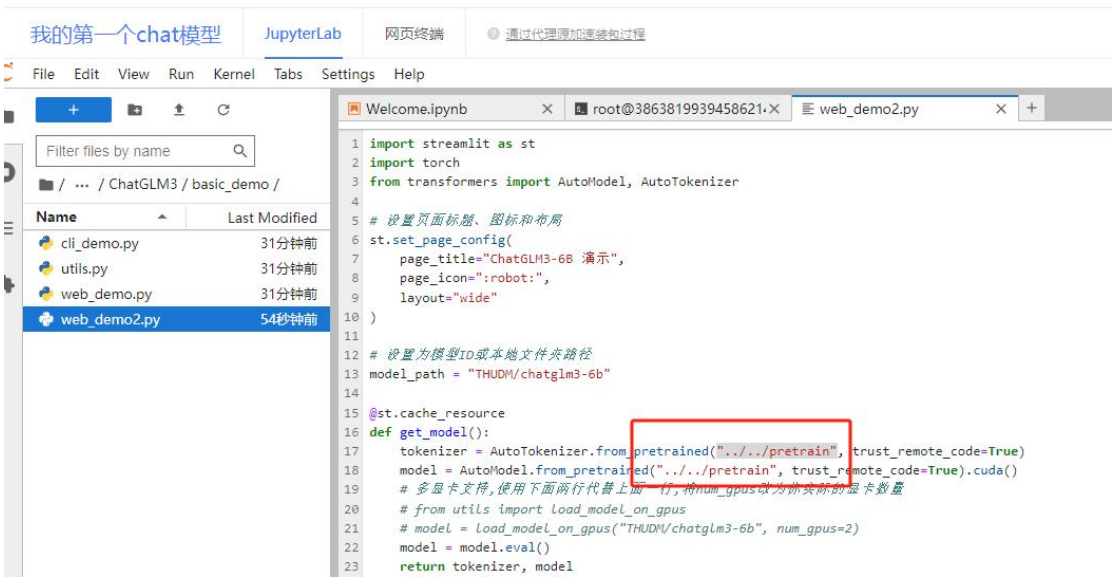
安装刚改好环境部署工具，输入 pip install -r requirements.txt

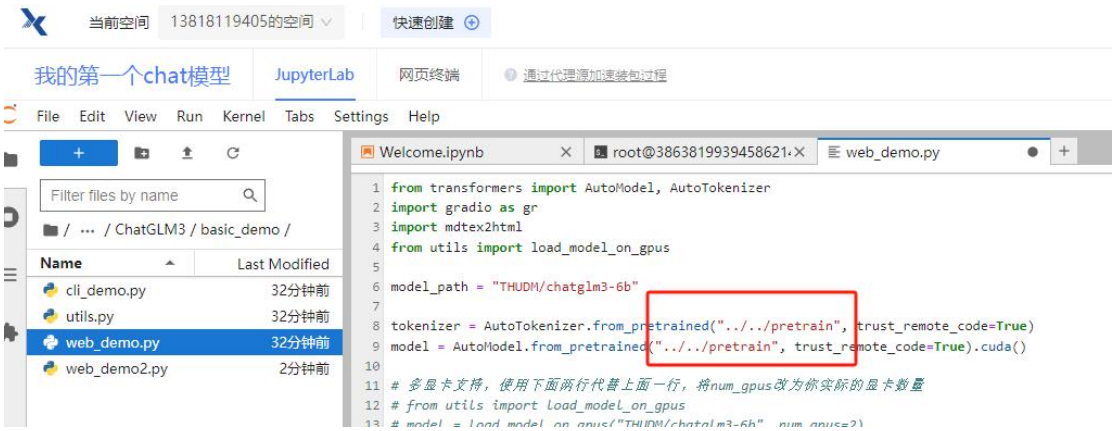
```
(base) root@386381993945862144-taskrole1-0:/# cd gemini
(base) root@386381993945862144-taskrole1-0:/gemini# cd code
(base) root@386381993945862144-taskrole1-0:/gemini/code# cd ChatGLM3
(base) root@386381993945862144-taskrole1-0:/gemini/code/ChatGLM3# pip install -r requirments.txt
ERROR: Could not open requirements file: [Errno 2] No such file or directory: 'requirments.txt'
(base) root@386381993945862144-taskrole1-0:/gemini/code/ChatGLM3# pip install -r requirements.txt
Looking in indexes: https://mirrors.ustc.edu.cn/pypi/web/simple
Requirement already satisfied: protobuf in /root/miniconda3/lib/python3.9/site-packages (from -r requirements.txt (line 1)) (4.23.2)
Collecting transformers==4.30.2 (from -r requirements.txt (line 2))
  Downloading https://mirrors.bfsu.edu.cn/pypi/web/packages/5b/0b/e45d26ccd28568013523e04f325432ea88a442b4e3020b757cf4361f0120/transfo
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 7.2/7.2 MB 19.6 MB/s eta 0:00:00
Collecting cpm_kernels (from -r requirements.txt (line 3))
  Downloading https://mirrors.bfsu.edu.cn/pypi/web/packages/af/84/1831ce6ffa87b8fd4d9673c3595d0fc4e6631c0691eb43f406d3bf89b951/cpm_ker
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 416.6/416.6 kB 95.2 MB/s eta 0:00:00
Collecting gradio==3.39 (from -r requirements.txt (line 4))
  Downloading https://mirrors.bfsu.edu.cn/pypi/web/packages/82/5f/c815ae438b63ca8b7418acf470369493bac5aa267192702c8601ca67966b/gradio-
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 19.9/19.9 MB 9.5 MB/s eta 0:00:00
```

按照下图找到这个 web_demo.py 与 web_demo2.py 文件，把模型设置里模型地址 model_path，改为"../../pretrain"

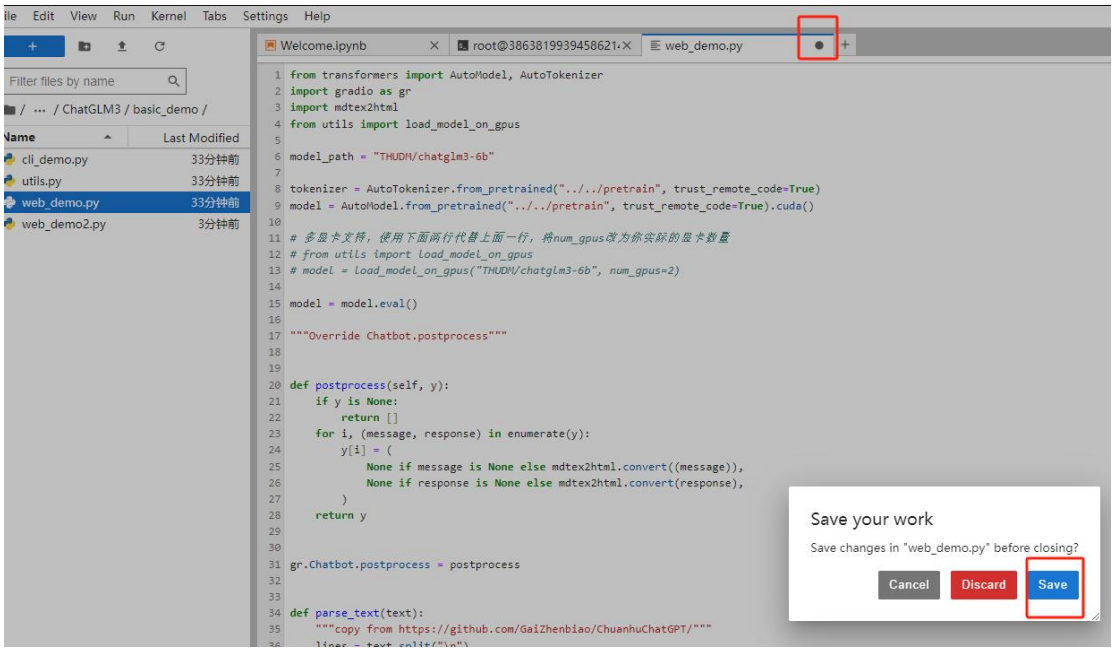
路径，文件，改的地方见下图框







在 web_demo.py 中，除了上述修改，还需要在下图所示处（最底部）改为
demo.queue().launch(share=False, server_name="0.0.0.0",server_port=7000)
按 x 后，save 一下



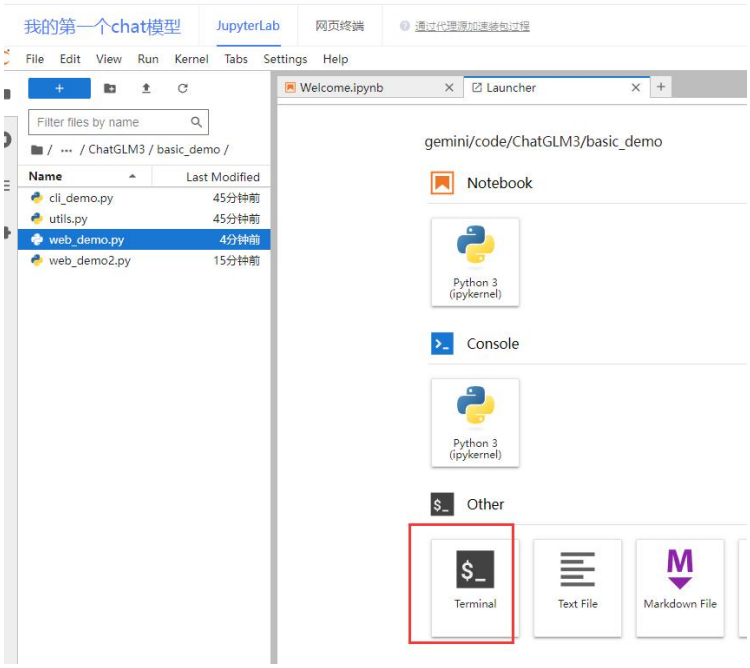
点击右边，端口信息下的，添加按钮



填上端口号，系统代码中已经包含了 gradio 调用测试功能，对小白很友好。



下面回到终端，输入 python web_demo.py




```
(base) root@386381993945862144-taskrole1-0:/gemini/code/ChatGLM3/basic_demo# python web_demo.py
```

加载完毕后，找到右边的外部访问，然后复制地址，用浏览器打开就行



复制这个地址 direct.virtaicloud.com:42486
在浏览器中打开就行啦

ChatGLM3-6B


Chatbot
你好👋！我是人工智能助手 ChatGLM3-6B，很高兴见到你，欢迎问我任何问题。
okk
您好！请问有什么问题我可以帮您解答吗？
晚饭吃什么呢？
晚饭可以吃一些清淡易消化的食物，例如粥、面条、炖菜等。同时，可以根据自己的口味和营养需求进行选择。如果您喜欢肉类，可以考虑炖一些鱼或鸡肉。另外，搭配一些蔬菜和豆腐等蛋白质丰富的食材，可以使您的晚餐更加均衡。

Input...
Clear History
Maximum length
8192
Top P
0.8
Temperature
0.6
提交