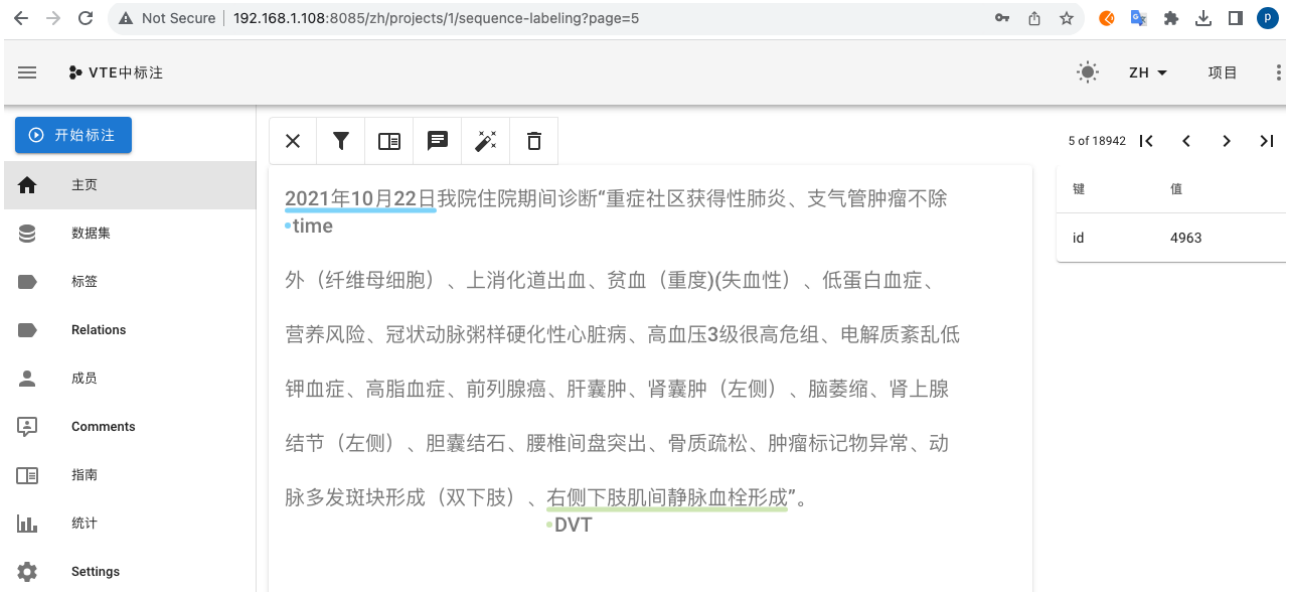
电子病历NER识别（李昌振、陈娟、武玮、丁雨聪）

- 团队：
  - 李昌振 231017000010
  - 陈娟 231017000036
  - 武玮
  - 丁雨聪
- 业务目标：从电子病历识别患者是否患有DVT或PE以及对应的时间，本质为NER识别
  - DVT的样例：双下肢深静脉血栓、左侧小腿多条肌间静脉血栓、右侧小腿肌间静脉血栓、右侧髂静脉血栓形成
  - PE的样例：肺栓塞、肺动脉栓塞、慢性血栓栓塞性肺动脉高压
  - 时间的样例：2022-09-02、1年多前、2020年、2022年1月3日
- 处理流程：
  - 准备数据集
    - 提取原始电子病历文档，进行句子拆分
    - 通过正则表达式进行初步识别，简化人工标注工作量
    - 机器标注结果上传到文本标注平台(Doccano平台)
    - 人工审核与标注
    - 导出标注结果，转换为模型输入格式
  - 模型定义：使用开源框架DeepKE
  - 模型训练与调参
  - 测试
- 数据集和NLP标注： 标注样例如图所示：



标注数据集导出如图所示：


```
10分钟，无出冷汗，无明显胸痛，曾于我院门诊查心脏冠脉CT，诊断冠心病明确，故考虑诊断冠状动脉粥样硬化性心脏病不稳定型心绞痛，需与以下疾病鉴别：（1）急性肺栓塞：可有胸痛、咳嗽、呼吸困难与休克，但右心负荷加重，如紫绀、肺动脉瓣区第二音亢进、颈静脉充盈、肝肿大、下肢水肿等可资鉴别。", "label": [[72, 77, "time"]]}
{"text": "特征性心电图改变（右心室肥厚）是肺动脉栓塞的一大特征。", "label": []}
{"text": "呼吸短促与胸痛同时发生而无肺水肿的证据提示肺动脉栓塞。", "label": []}
{"text": "超声心动图有助于摒除MI所引起的室壁动作异常和判断右心室劳损的存在，后者是肺动脉栓塞病人溶血栓治疗的一个指征。", "label": []}
{"text": "化验及特殊检查(2022-10-1912:04，本院)全血细胞分析（静脉血）等(静脉血)：红细胞比积38.7%，凝血酶时间.42.0s；2022年10月24日我院超声：右下肢深静脉血栓形成。", "label": [[8, 18, "time"], [68, 78, "time"]]}
{"text": "3、肺栓塞（双肺）", "label": [[2, 5, "PE"]]}
{"text": "9、双下肢肌间静脉血栓", "label": [[2, 11, "DVT"]]}
{"text": "患者于2022年1月3日于我科诊断“肺栓塞（双肺）”，经抗凝治疗后好转出院，现序贯利伐沙班抗凝治疗，后续治疗的推荐剂量为20mg1日，复查心脏超声肺动脉压未见明显异常。", "label": [[3, 11, "time"], [18, 21, "PE"]]}
{"text": "既往史：患者于2022年1月3日于我科诊断“肺栓塞（双肺）”，经抗凝治疗后好转出院，现序贯利伐沙班抗凝治疗，后续治疗的推荐剂量为20mg1日，复查心脏超声肺动脉压未见明显异常。", "label": [[7, 15, "time"], [22, 25, "PE"]]}
{"text": "(2022-06-1017:46，本院)行超声(其它)检查提示：左侧下肢动脉多发斑块形成；左侧小腿肌间静脉血栓形成。", "label": [[1, 11, "time"], [45, 57, "DVT"]]}
{"text": "3、肺栓塞（双肺）；", "label": [[2, 5, "PE"]]}
{"text": "9、双下肢肌间静脉血栓；", "label": [[2, 11, "DVT"]]}
{"text": "2、患者既往有肺栓塞病史，入院血管B超提示：左侧下肢动脉多发斑块形成；左侧小腿肌间静脉血栓形成；右侧下肢动脉多发斑块形成；右侧下肢深静脉未见明显异常，因此启动药物预防：依诺肝素40mg，皮下注射，112h。", "label": [[7, 10, "PE"], [35, 47, "DVT"]]}
```

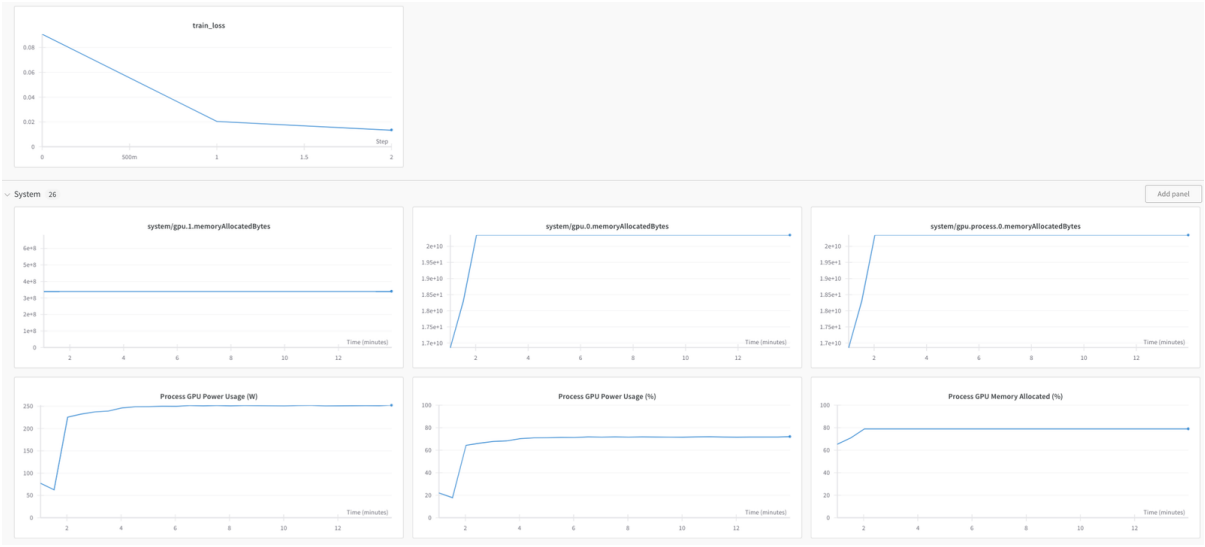

导出的jsonl转换为模型输入的BIO格式

```
动 O
脉 O
多 O
发 O
斑 O
块 O
伴 O
股 O
浅 O
动 O
脉 O
多 O
节 O
段 O
狭 O
窄 O
左 B-DVT
侧 I-DVT
小 I-DVT
腿 I-DVT
肌 I-DVT
间 I-DVT
静 I-DVT
脉 I-DVT
```

```
血 I-DVT
栓 I-DVT
形 I-DVT
成 I-DVT
```

- 数据集情况说明：
    - 总句子数：18942个句子，其中
        - "DVT"类型标注7701个实体
        - "PE"类型标注3747个实体
        - "TIME"类型标注7444个实体
    - 训练集：1399985 字符
    - 测试集：53838字符
    - 验证集: 154010 字符
- 模型描述：
    - 基于开源DeepKE框架，进行NER识别
    - 基于bert的模型关键超参数(conf/hydra/model/bert.yaml)
        - bert_model: "bert-base-chinese"
        - do_lower_case: True
        - fp16: False
        - fp16_opt_level: "01"
        - local_rank: -1
        - loss_scale: 0.0
        - max_grad_norm: 1.0
        - max_seq_length: 512 # 初始默认为128
- 模型训练：
    - 训练环境：NVIDIA Geforce RTX 3090
    - (deepke) root@ubuntu:/home/deploy/vte-nlp-ner/DeepKE-2.1.0/example/ner/standard# python run_bert.py
        - 说明：若服务器网络不好的话，运行bert需要先从huggingface下载bert-base-chinese模型到本地，在配置文件中对应的bert_model: "bert-base-chinese"改为本地保存模型的目录

- 训练过程可以通过wandb进行监控：



- 模型运行结果(bert)

	precision	recall	f1-score	support
DVT	0.9091	0.9390	0.9238	426
PE	0.9074	0.9378	0.9224	209
TIME	0.9962	0.9962	0.9962	263
micro avg	0.9336	0.9555	0.9444	898
macro avg	0.9376	0.9577	0.9474	898
weighted avg	0.9342	0.9555	0.9447	898