代码相似度评估研究

分享人：马琼

背景需求：

在平时工作中，需要评估两段代码的相似度。

思路：

本研究提出了一种简易的评估模型，使用 pytorch 实现对两段代码进行分析，并给出了评估值计算表达式。

操作步骤：

对输入的数据进行清洗，并字典化，结合 pytorch 余弦相似度计算方法，评估出代码的相似度。

评估指标：

$$S = \max(f(x,y), g(x,y))$$

其中，f(x,y)为字典评估值，g(x,y)为余弦相似度评估值，x 与 y 分别代表比对的代码输入，取两者（f 和 g）的最大值为最终评估结果 S。

若结果 S 为 1，则完全相同，否则，比 1 小，且值越小，不相同度越高。

效果：

In [12]:
```
#result
x = "int sum(int x,int y){return (x + y);}"
y = "int summary(float z){return z;}"
s = max(f(x,y), g(x,y))
print(s)
```

```
['int', 'sum', 'int', 'x', 'int', 'y', 'return', 'x', 'y']
['int', 'summary', 'float', 'z', 'return', 'z']
0.4444444444444444
0.3333333333333333
diction:
['return', 'int', 'y', 'sum', 'z', 'float', 'x', 'summary']
kv:
{'return': 0.1111111111111111, 'int': 0.2222222222222222, 'y': 0.3333333333333333, 'sum': 0.4444444444444444, 'z':
0.5555555555555556, 'float': 0.6666666666666666, 'x': 0.7777777777777778, 'summary': 0.8888888888888888}
6
[0.2222222222222222, 0.4444444444444444, 0.2222222222222222, 0.7777777777777778, 0.2222222222222222, 0.333333333333
3333]
[0.2222222222222222, 0.8888888888888888, 0.6666666666666666, 0.5555555555555556, 0.1111111111111111, 0.555555555555
5556]
tensor(0.8661)
```

In [13]:
```
#result
x = "int sum(int x,int y){return (x + y);}"
y = "int sum(int x,int y){return (x + y);}"
s = max(f(x,y), g(x,y))
print(s)
```

```
['int', 'sum', 'int', 'x', 'int', 'y', 'return', 'x', 'y']
['int', 'sum', 'int', 'x', 'int', 'y', 'return', 'x', 'y']
1.0000000000000002
1.0000000000000002
diction:
['return', 'int', 'y', 'sum', 'x']
kv:
{'return': 0.16666666666666666, 'int': 0.3333333333333333, 'y': 0.5, 'sum': 0.6666666666666666, 'x': 0.833333333333
3334}
9
[0.3333333333333333, 0.6666666666666666, 0.3333333333333333, 0.8333333333333334, 0.3333333333333333, 0.5, 0.1666666
6666666666, 0.8333333333333334, 0.5]
[0.3333333333333333, 0.6666666666666666, 0.3333333333333333, 0.8333333333333334, 0.3333333333333333, 0.5, 0.1666666
6666666666, 0.8333333333333334, 0.5]
1.0000000000000002
```

收获：

通过查阅相关资料，熟悉了部分 pytorch 接口的使用方法，熟悉了字典编码原理和基础开发流程。

不足之处：

暂时只能处理英文代码；

由于时间有限，没有合适的数据集，暂未使用训练生成模型的方法评估。