中国人民大學 RENMIN UNIVERSITY OF CHINA

第2讲 大数据思维与分析

余力 博士

教授、博士生导师

大数据分析与智能决策实验室

buaayuli@ruc.edu.cn

目录

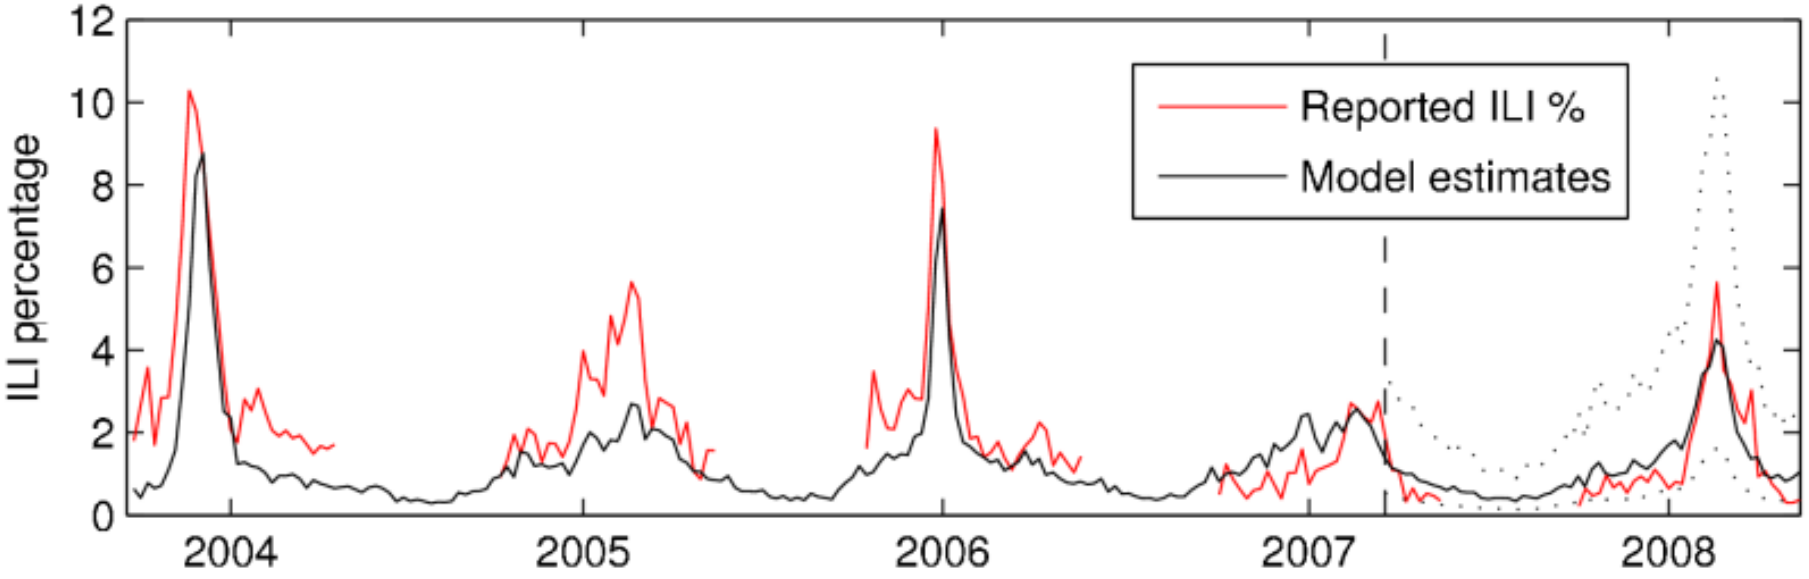
1. 几个实例
2. 大数据时代背景
3. 什么是大数据
4. 大数据思维
5. 大数据分析



1. 几个例子

例1：预测流感

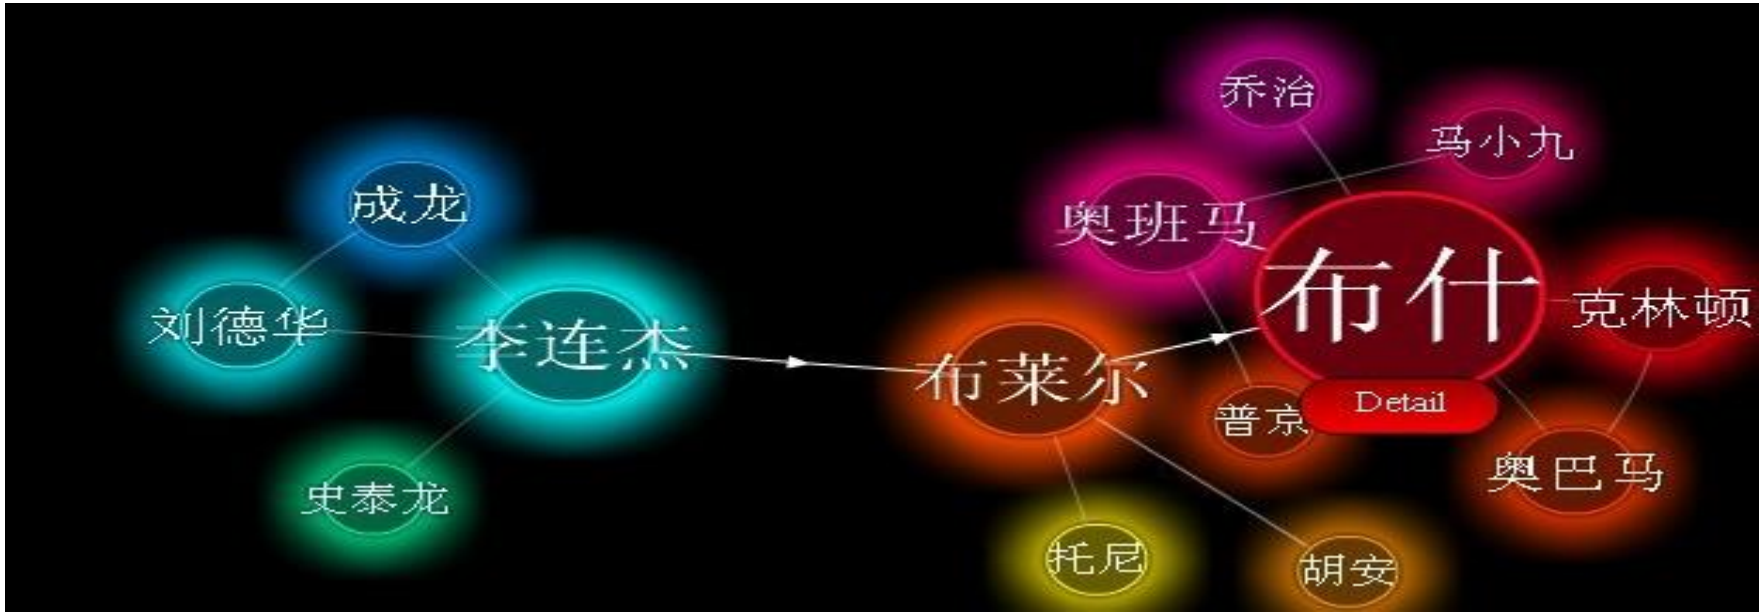




Detecting influenza epidemics using search engine query data, Nature 457, 1012-1014 (2009)

例2：人立方


Beta
人立方
Renlifang关系搜索


乔治
马小九
奥班马
布什
克林顿
成龙
刘德华
李连杰
布莱尔
普京
Detail
奥巴马
史泰龙
托尼
胡安

例3：Akinator

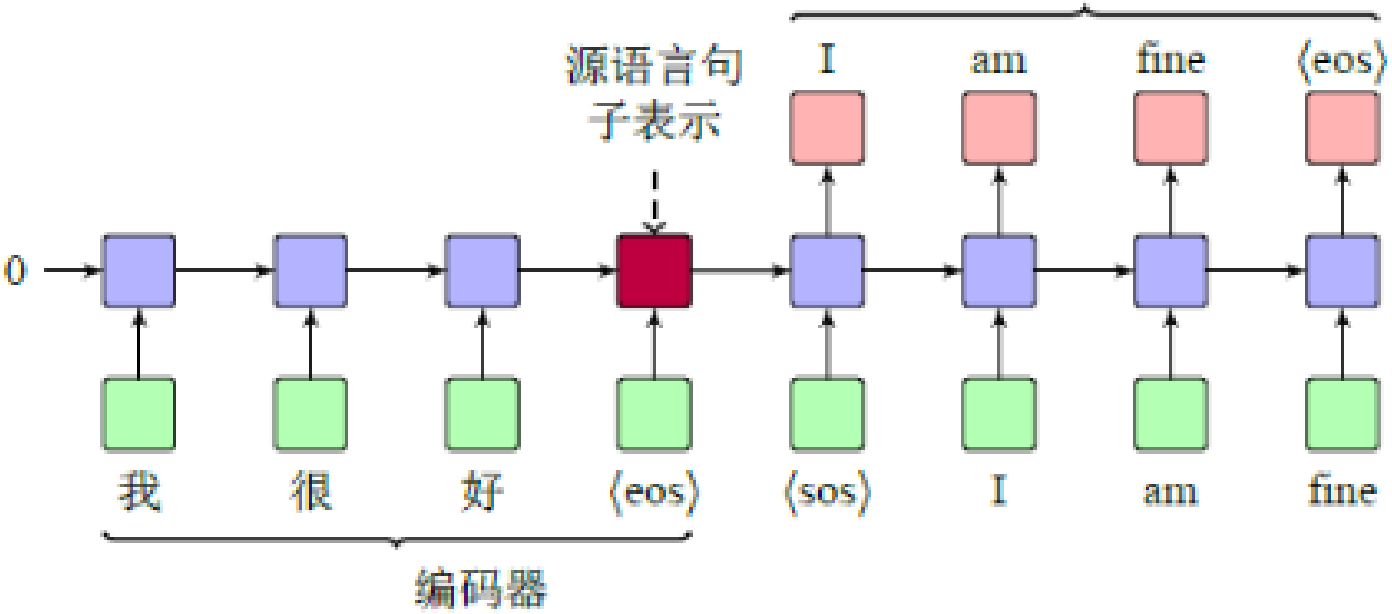


http://cn.akinator.com

https://www.silvergames.com/en/akinator

例4：机器翻译


Bai du 翻译
文本翻译
文档翻译
PRO
智能翻译
人工翻译
AI同传
翻译API
课程优选
企业服务
检测到中文(简体)
英语
NEW
通用领域
立即翻译
AI翻译
中国人民大学
6/5000
Renmin University of China
笔记


源语言句子表示
I
am
fine
⟨eos⟩
0
我
很
好
⟨eos⟩
⟨sos⟩
I
am
fine
编码器

机器翻译困难

自动化研究所取得的成就

词法歧义

- 自动化/研究所/取得/的/成就/。
- 自动化/研究/所/取得/的/成就/。

Achievements made by the Institute of Automation

上大学子烛光追思钱伟长

新词汇

- University sub candlelight memorial chang
- On the big students qian wei-chang candlelight memorial
- Shanghai University students mourn Qian Weichang with the candlelight

基于大数据的翻译方法

- 她买了一本计算机语言入门书。

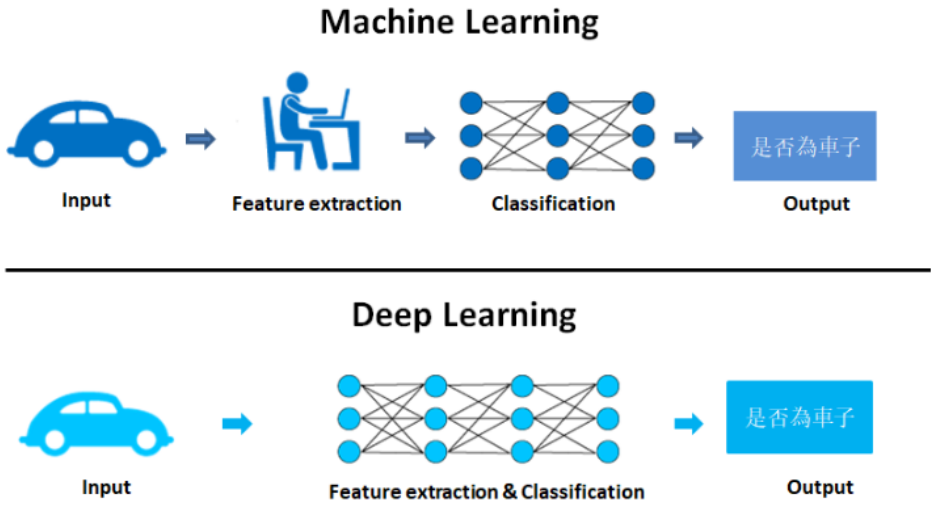
语料库

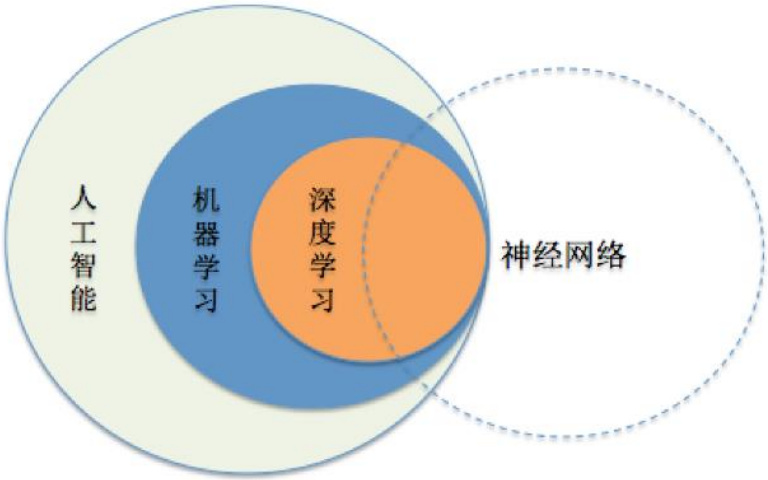
- 她买了一件时髦的夹克衫。
  - She bought a sharp jacket.
- 他正在读一本计算机语言入门书。
  - He is reading a book on introduction to computational linguistics.

例5：Chatgpt

- GPT-3数据主要来自CommonCrawl、新闻、帖子、书籍及各种网页，原始数据规模达45TB





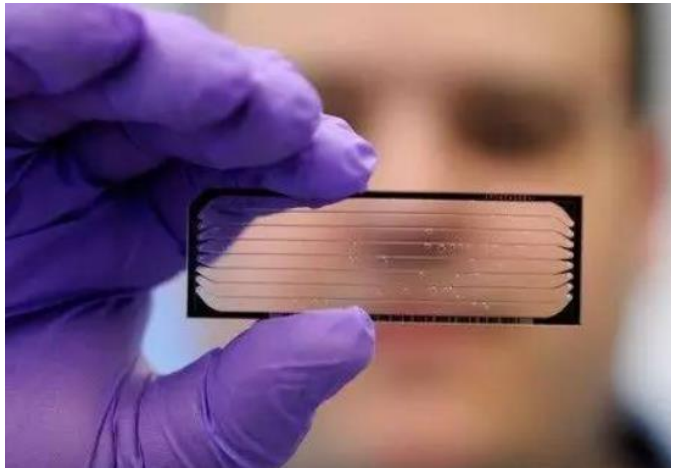


例6： AlphaGo

- 基于23万个人类棋谱，收录了6000个近代围棋史上主要的开局变化，有两万多个分支变化，三十七万步棋组成
- alphago 每天能下三百万盘棋



其他



大数据与乔布斯癌症治疗



淘宝指数进行市场分析



奥巴马大选连任成功



啤酒与尿布

为什么能工作

- 预测流感
- 人立方
- Akinator
- 机器翻译
- Chatgpt
- 微软小冰
- Alphago

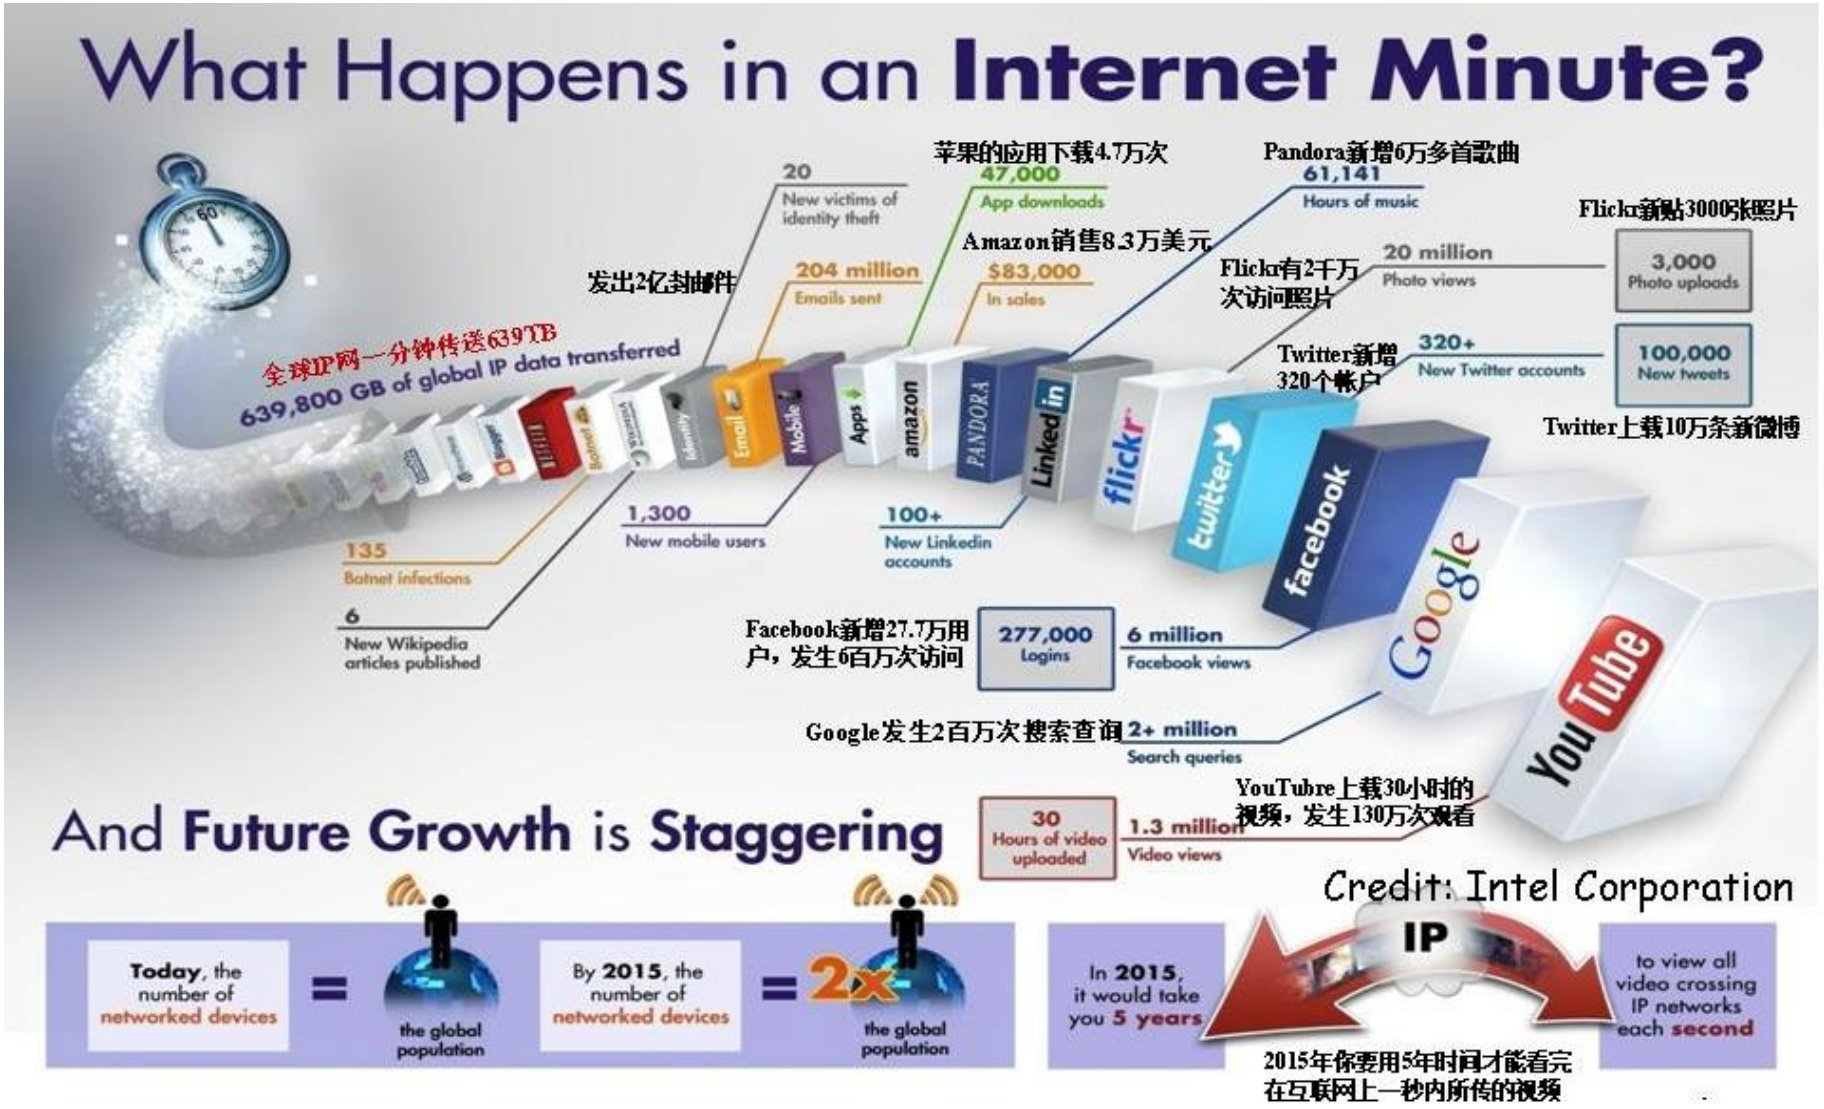






2. 大数据的背景

网上1分钟，人间1万年


What Happens in an Internet Minute?
全球IP网一分钟传送639TB
639,800 GB of global IP data transferred
发出2亿封邮件
20
New victims of identity theft
204 million
Emails sent
苹果的应用下载4.7万次
47,000
App downloads
Amazon销售8.3万美元
$83,000
In sales
Pandora新增6万多首歌曲
61,141
Hours of music
Flickr有2千万次访问照片
20 million
Photo views
Flickr新贴3000张照片
3,000
Photo uploads
Twitter新增320个帐户
320+
New Twitter accounts
100,000
New tweets
Twitter上载10万条新微博
135
Botnet infections
1,300
New mobile users
100+
New Linkedin accounts
6
New Wikipedia articles published
Facebook新增27.7万用户，发生6百万次访问
277,000
Logins
6 million
Facebook views
Google发生2百万次搜索查询
2+ million
Search queries
YouTubre上载30小时的视频，发生130万次观看
30
Hours of video uploaded
1.3 million
Video views
And Future Growth is Staggering
Today, the number of networked devices = the global population
By 2015, the number of networked devices = 2x the global population
In 2015, it would take you 5 years
IP
to view all video crossing IP networks each second
2015年你要用5年时间才能看完在互联网上一秒内所传的视频
Credit: Intel Corporation

数据信息的认识史就是人类的发展史








社会的进步是一部信息储存和传播方式变革的历史。

迎接大数据时代的到来

- 硬件成本的降低
- 网络带宽的提升
- 云计算的兴起
- 智能终端的普及
- 互联网模式的发展
- 电子商务、社交网络
- 物联网











3. 什么是大数据

大数据的特征


数据容量和复杂性使传统工具和技术已无法处理
Volume 巨量
增长速度快
处理速度快
Velocity 高速
人对人
人对机器
机器对机器
Variety 多样
创造价值高
价值密度低
Value 价值

大数据的意义1：知著见微

- 知著见微：大数据的“大弹性”
- 知著----天文望远镜
  - 传统采样和定位（平均、去噪声）
  - 社会计算、计算广告、情感分析
- 见微----显微镜
  - 从细分到微分、微分到个人







大数据的意义2：当下皆明

- 当下皆明：快思考也要深分析
- 当下
  - 刻舟求剑、人口普查
  - 实时推荐 聊天机器人
- 皆明
  - 描述性分析：过去，现在
  - 预测性分析：票房预测
  - 处方性分析：草船借箭





大数据的意义3：辨讹晓意

- 辨讹晓意：从真相窥探思想
- 辨讹
  - 看到真相
  - 美国德克萨斯州的数据新闻报道说，能够把这个州的很多政府雇员的工资都做到数据库里面供人们查询
- 晓意
  - 机器能够逐步窥探人的思想境界
  - 情感分析、价值观分析



4. 大数据思维

大数据思维

“更多” —— 不是随机样本，而是全体数据！

“更杂” —— 不是精确性，而是混杂性！

“更好” —— 不是因果关系，而是相关关系！

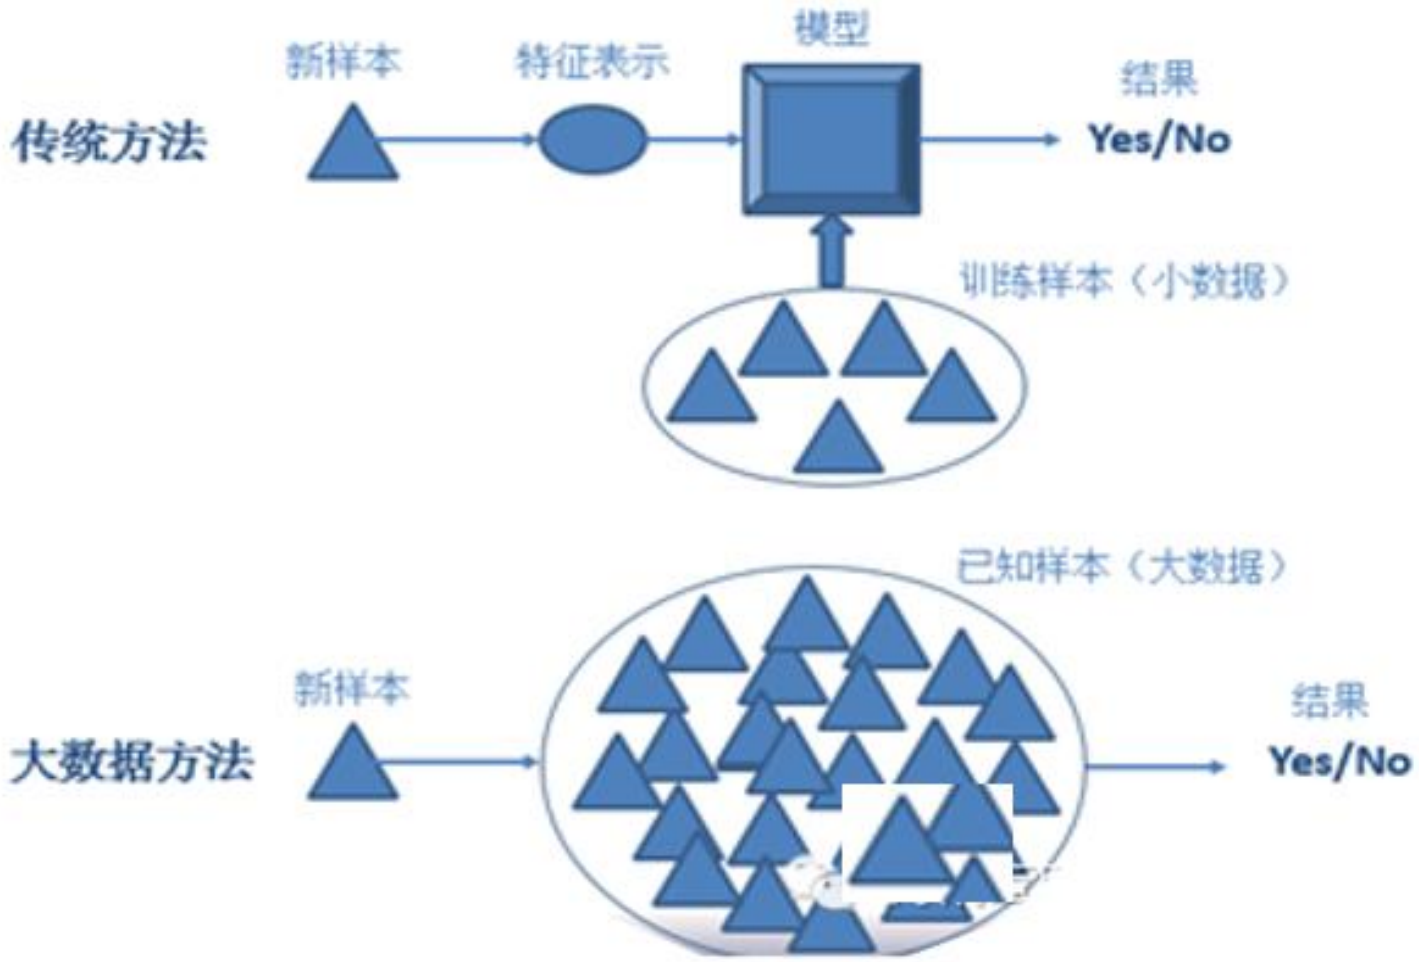
大数据时代的新经验主义

- **传统：** 理性分析>主观经验
- **今天：** 经验主义>理性主义
- 大数据 = 经验
- 数据>模型
- 简单计算超越复杂计算

流感预测

机器翻译

传统方法与大数据方法



简单计算超越复杂计算

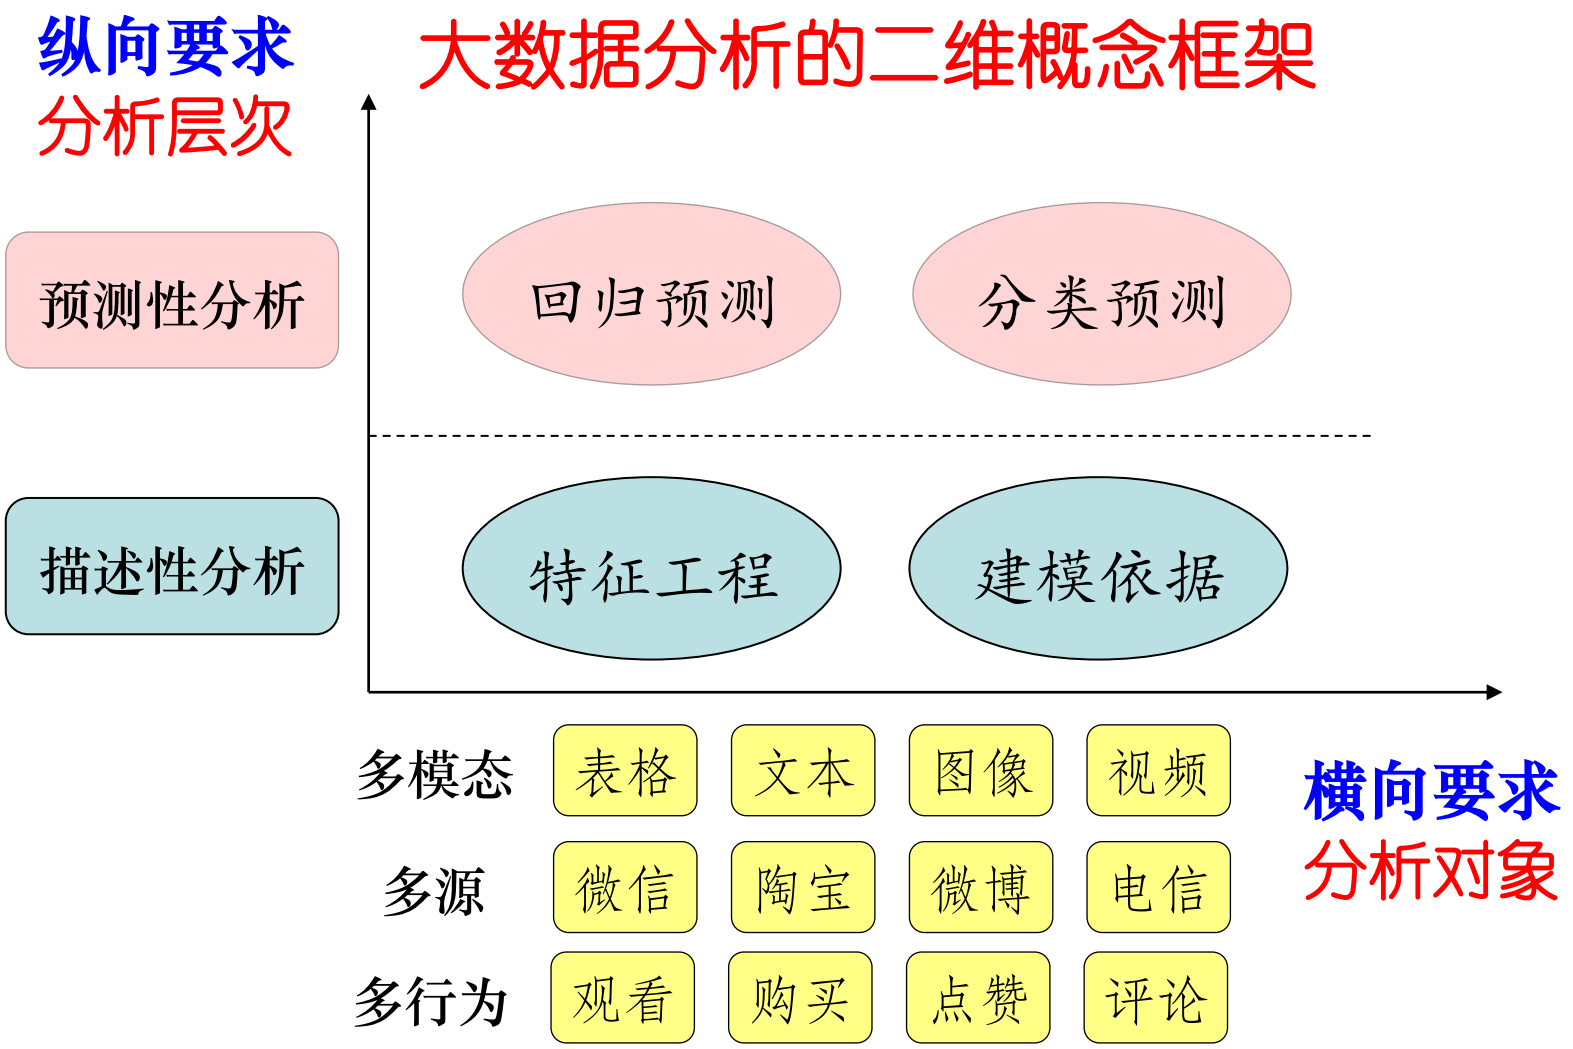
如何认识世界

- 改变认识论：理论认识世界、数据认识世界 ？
- 白天鹅+黑天鹅 （1697） 经验知识也许是可怕的！
- 认识者获得的不是对象本身绝对映像，而是离开对象，从对象中抽象出、关于其运动轨迹的数据
- 数据反映的是具有同构关系的两个序列的关系信息，一个对象的运动轨迹，通过另一个序列的载体编码来表达。
- 同构关系是大数据的数理哲学基础



5. 大数据分析

大数据分析


纵向要求
分析层次
大数据分析的二维概念框架
预测性分析
回归预测
分类预测
描述性分析
特征工程
建模依据
多模态
表格
文本
图像
视频
多源
微信
陶宝
微博
电信
多行为
观看
购买
点赞
评论
横向要求
分析对象

研究范式



预测性分析

（机器学习）

描述性分析

（统计图、云图）

预测

推荐

模拟

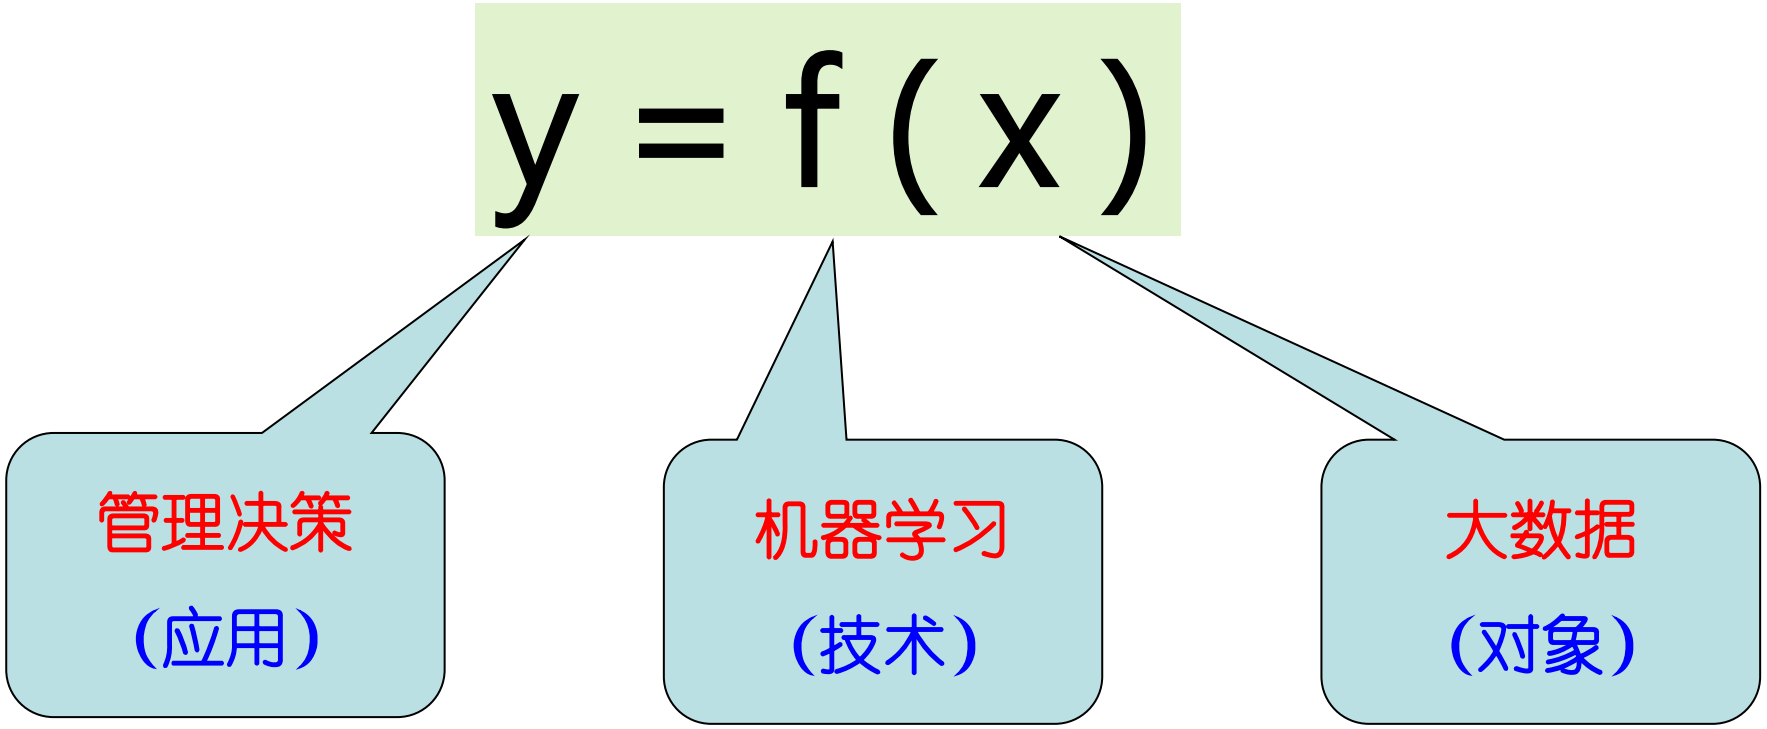
仿真

大数据

分析

管理决策

大数据驱动的管理决策-科学问题范式

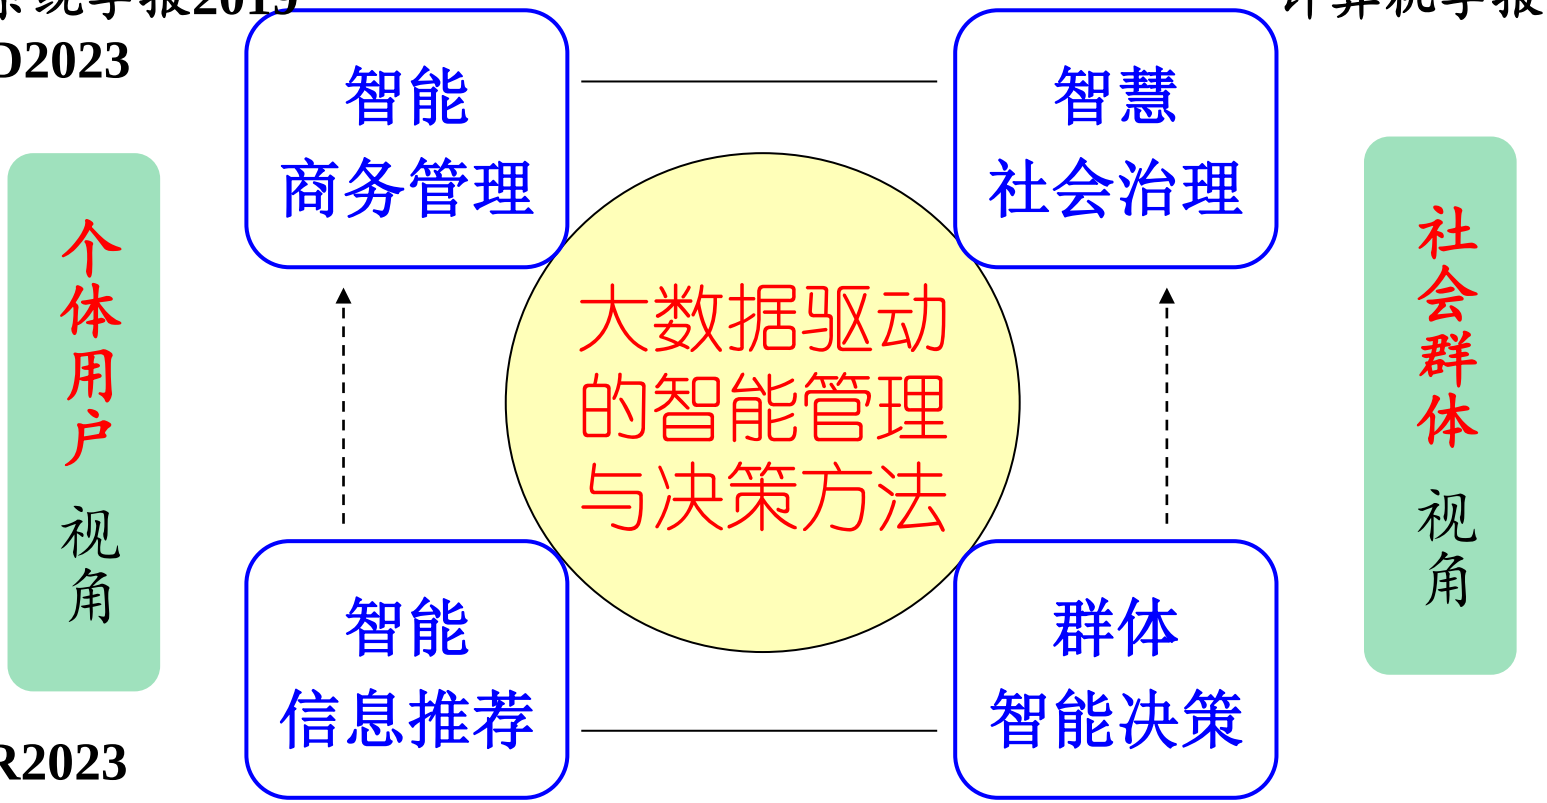


大数据驱动的智能决策

ICIS2012 PACIS2014
信息系统学报2012
信息系统学报2019
TKDD2023

行业应用范式

I&M2021
ICASSP2022
计算机学报2022



SIGIR2023
TKDD2022 InfoSci2023
DSAFAA2020
ICASSP2022 ICME2022

建模技术方法

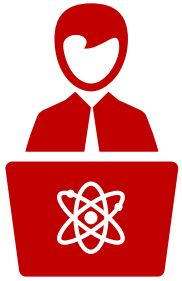
DSS2023 DS2020
InfoSci2022 PR2022
系统工程2017

总结

- 大数据出现
- 大数据概念
- 大数据思维

大数据并不是一个充斥着算法和机器的冰冷世界，人类的作用依然无法被完全替代。大数据为我们提供的不是最终答案，只是参考答案，帮助是暂时的，而更好的方法和答案还在不久的未来！！

中国人民大学
RENMIN UNIVERSITY OF CHINA



谢谢大家！

