中国人民大學 RENMIN UNIVERSITY OF CHINA

第1讲 个性化推荐

余力 博士

教授、博士生导师

大数据分析与智能决策实验室

buaayuli@ruc.edu.cn

目录

1. 个性化推荐概述

2. 经典推荐方法

3. 深度学习推荐

4. 高级推荐方法

中国人民大学
RENMIN UNIVERSITY OF CHINA



1. 概述

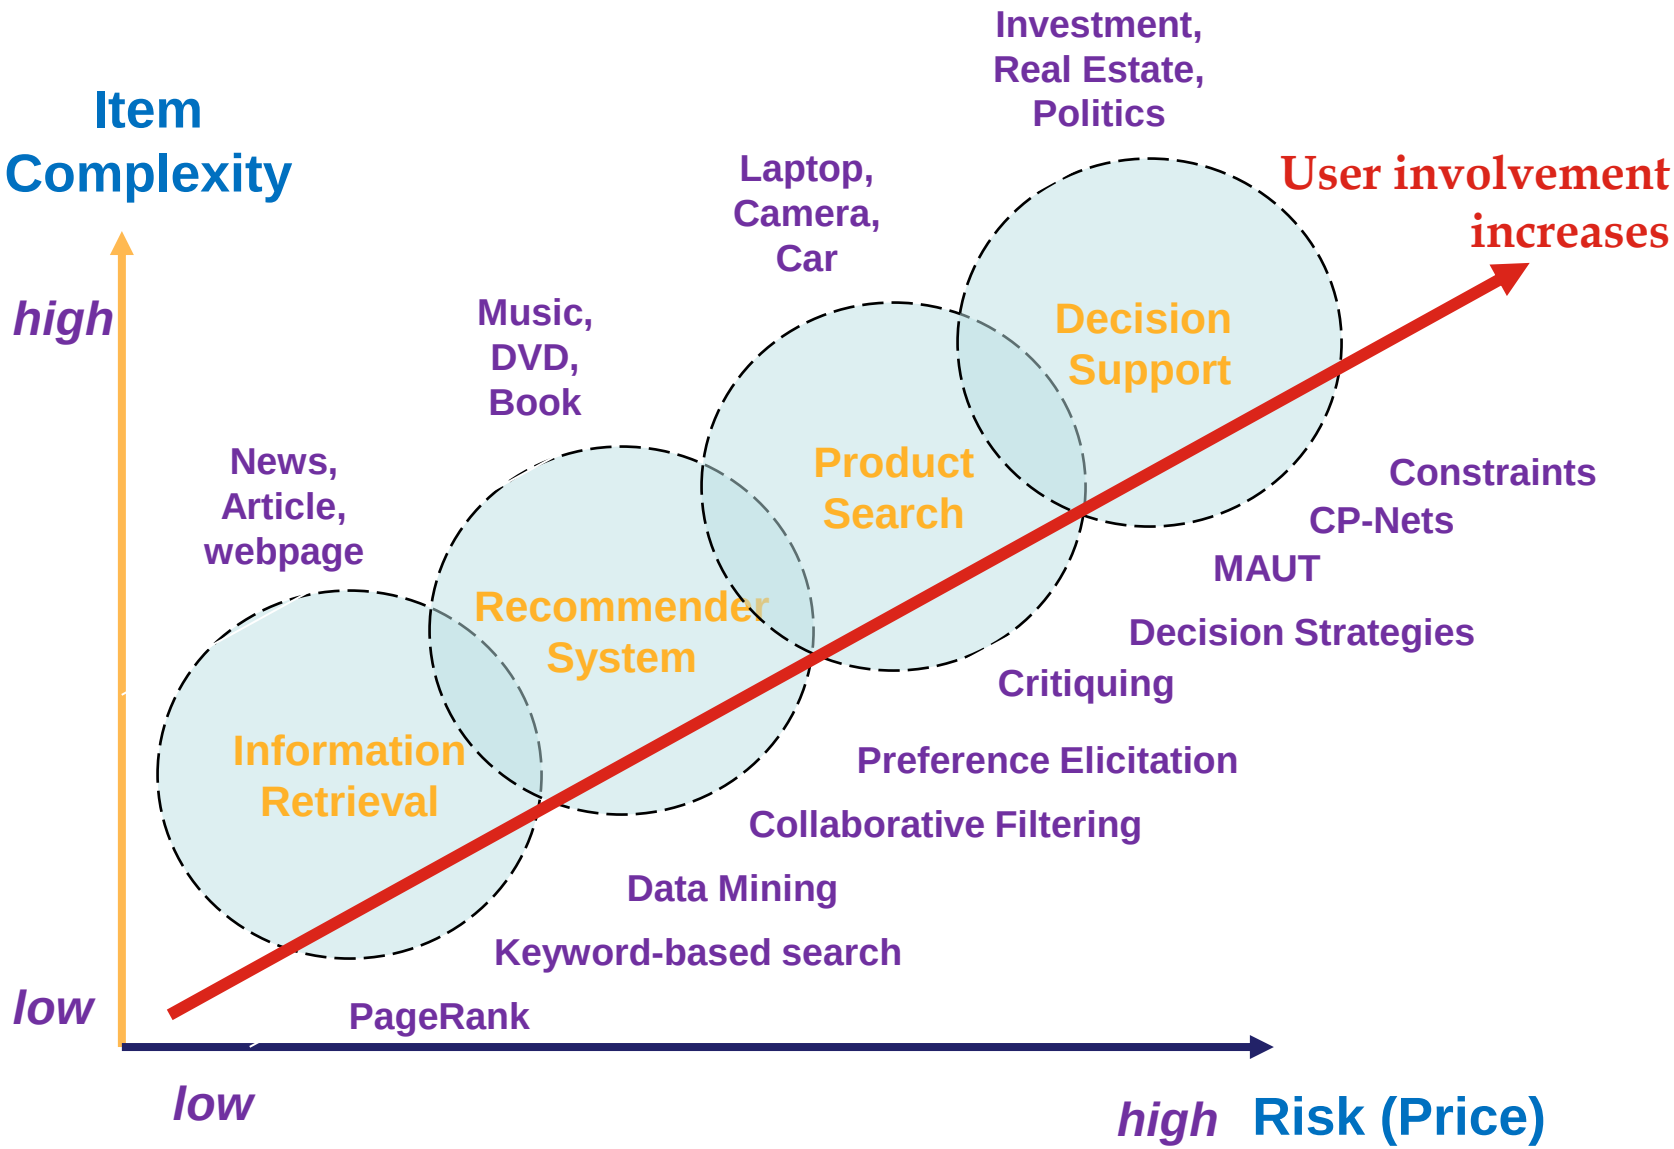
个性化推荐


女博士直播健身引争议
关注
推荐
热搜
抗疫
军事
北京
央视新闻
迎接党的二十大建言献策
央视新闻
“湘沪”帮助 这是最美逆行
央视网
乌军反攻首战大败，东部大战正式打响！数百公里战线炮声不断
利刃时刻 1.8万播放
乒乓球商业赛场笑面郎君攻如太极防如铁，战场低调战斗难缠的李晟
一登乒道 6204播放
俄方再次呼吁亚速钢铁厂守军放下武器
界面新闻 9评论
界面快报
百度
视频
惠生活
我的


北京
关注
推荐
4月22日进京往返最新消息
北京市 | 北务服务区 请问
@喜悦推荐
好消息，没有通勤证也可以进京，返回给社区打电话即可#燕郊 #京冀通勤 #北三县
Not Gonna Stop—NC MU
2812
344
379
967
首页
朋友
来赚钱
消息
我


首页
附近
笔记本电脑
推荐
电脑办公
男装
手机
生鲜
食品三分类
品/质/好/生/活
臧家阿哥肉干肉脯
质优价廉
京东空调
超级品类日
以旧换新补贴300元起 GO>
TCL
Haier
京东超市
京东电器
京东服饰
免费水果
京东到家
生活·缴费
领京豆
领券
借钱
PLUS会员
京东秒杀
16点场 01:03:32
京东直播
健康瘦身日
超值好物
¥48 预估价
¥99 预估价
排行榜
金榜发京豆
大家都在买
发现好货
潮流好物
美好新生活
首页
新品
购物车
我的

相关方法


Item Complexity
high
low
low
high Risk (Price)
User involvement increases
Investment, Real Estate, Politics
Laptop, Camera, Car
Music, DVD, Book
News, Article, webpage
Decision Support
Product Search
Recommender System
Information Retrieval
Constraints
CP-Nets
MAUT
Decision Strategies
Critiquing
Preference Elicitation
Collaborative Filtering
Data Mining
Keyword-based search
PageRank



2. 经典推荐方法

个性化推荐的背景



如何实现个性化推荐？

核心技术：个性化推荐方法

基于内容的推荐

协同过滤的推荐

基于模型的推荐

核心思路

你喜欢什么推荐什么

基于内容的推荐

用户
喜欢
什么









这是
什么
商品

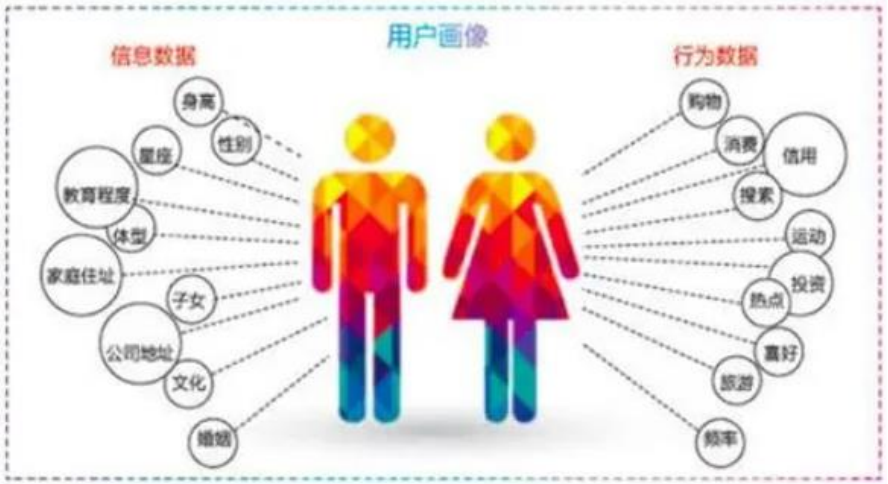
用户画像

Item表示

用户（画像）建模

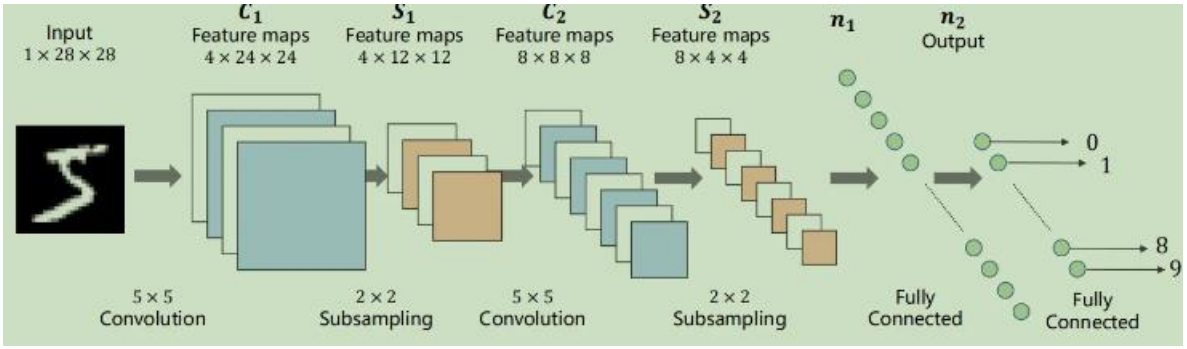
- 个人基本特征属性（**静态**）
- 用户行为大数据（**动态**）
  - 交互大数据
    - 浏览、点击、加入购物车
    - 评论、观看
  - 交易大数据
    - 历史购买
    - 多个平台购买
- 多模态行为数据
  - 表格、文本、视频、音频





数据建模

- 结构化数据
  - 淘宝商品
  - 表格型数据



- 非结构化数据
  - 文本数据：新闻、科技论文等
  - 网页：HTML、XML
  - 多媒体数据：图像、视频、图形、音频

非结构化数据 → **结构化数据**

词袋模型

'it was the worst of times'=[1, 1, 1, 0, 1, 1, 1, 0, 0, 0]

'it was the age of wisdom'=[1, 1, 1, 0, 1, 0, 0, 1, 1, 0]

'it was the age of foolishness'=[1, 1, 1, 0, 1, 0, 0, 1, 0, 1]



TF-IDF模型



计算机科学文档集

“计算机” “科学” “商务”

该文档集中的全部重要词项

- 文档D包含三个词 (a, b, and c):
  - freq(a,D)=3, freq(b,D)=2, freq(c,D)=1
- 假设有10000个文档:
  - N_a=50, N_b=1300, N_c=250

$$d_{t_i} = \left(0.5 + 0.5\frac{tf_i}{tf_{max}}\right)\left(\log\frac{n}{df_i}\right)$$

- 则对于D文档:
  - a: tf = 3/3; idf = log(10000/50) = 5.3; tf-idf = 5.3
  - b: tf = 2/3; idf = log(10000/1300) = 2.0; tf-idf = 1.3
  - c: tf = 1/3; idf = log(10000/250) = 3.7; tf-idf = 1.2

文本向量空间模型

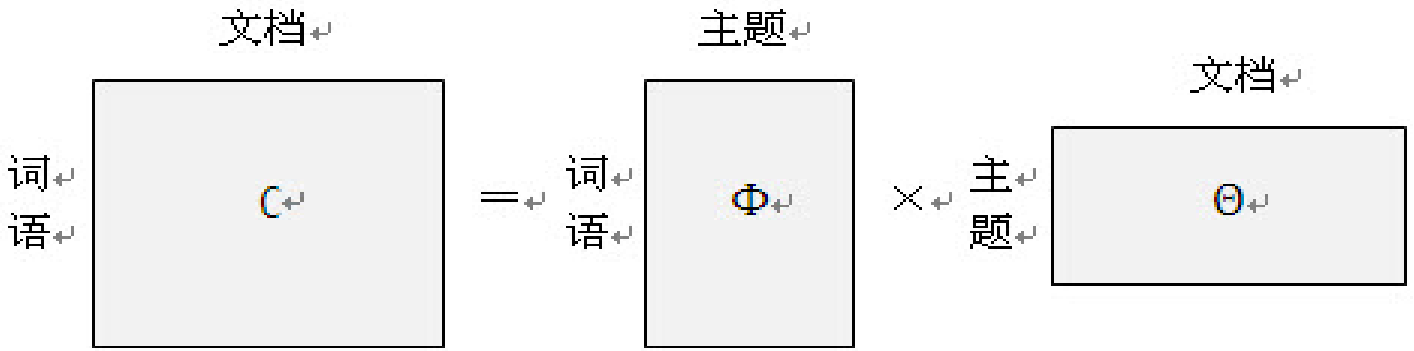
“乔布斯离我们而去了。”

“苹果价格会不会降？”



LDA(Latent Dirichlet Allocation)

$$p(\text{词语}|\text{文档}) = \sum_{\text{主题}} p(\text{词语}|\text{主题}) \times p(\text{主题}|\text{文档})$$

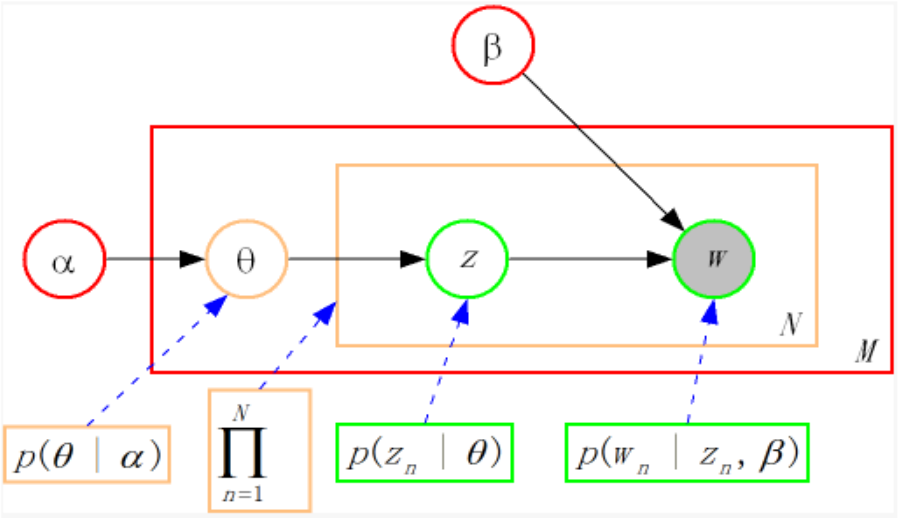


- 主题模型是通过左边矩阵进行训练，学习出右边两个矩阵

在 LDA 模型中，一篇文档生成的方式如下：

- 从狄利克雷分布α中取样生成文档 i 的主题分布θ_i
- 从主题的多项式分布θ_i中取样生成文档 i 第 j 个主题$z_{i,j}$
- 从狄利克雷分布β中取样生成主题$z_{i,j}$对应的词语分布$\phi_{z_{i,j}}$
- 从词语的多项式分布$\phi_{z_{i,j}}$中采样最终生成词语$w_{i,j}$

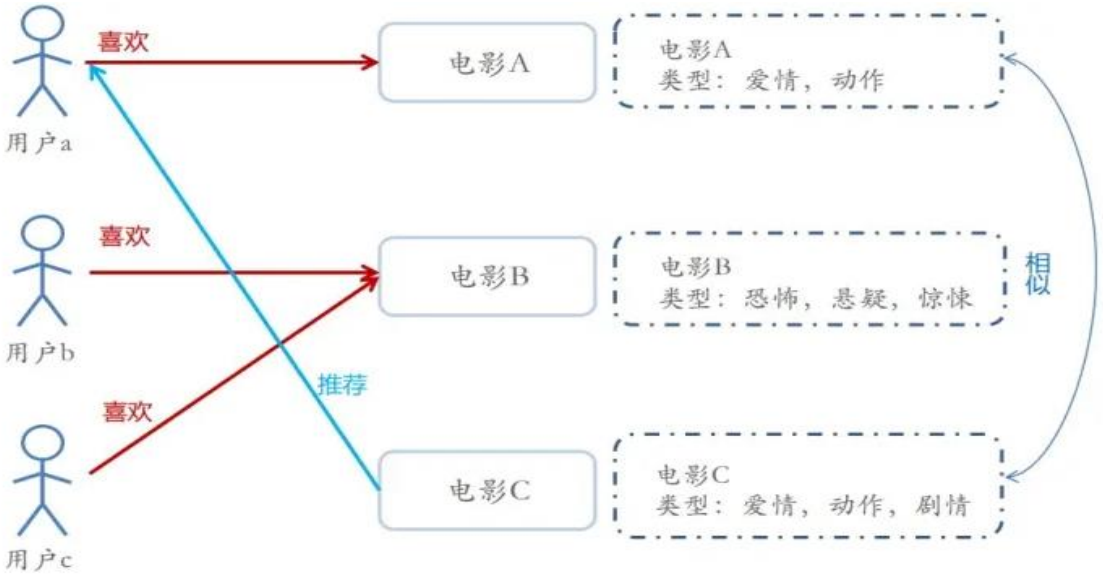
$$p(\theta, \mathbf{z}, \mathbf{w} \mid \alpha, \beta) = p(\theta \mid \alpha) \prod_{n=1}^{N} p(z_n \mid \theta) p(w_n \mid z_n, \beta)$$



LDA应用

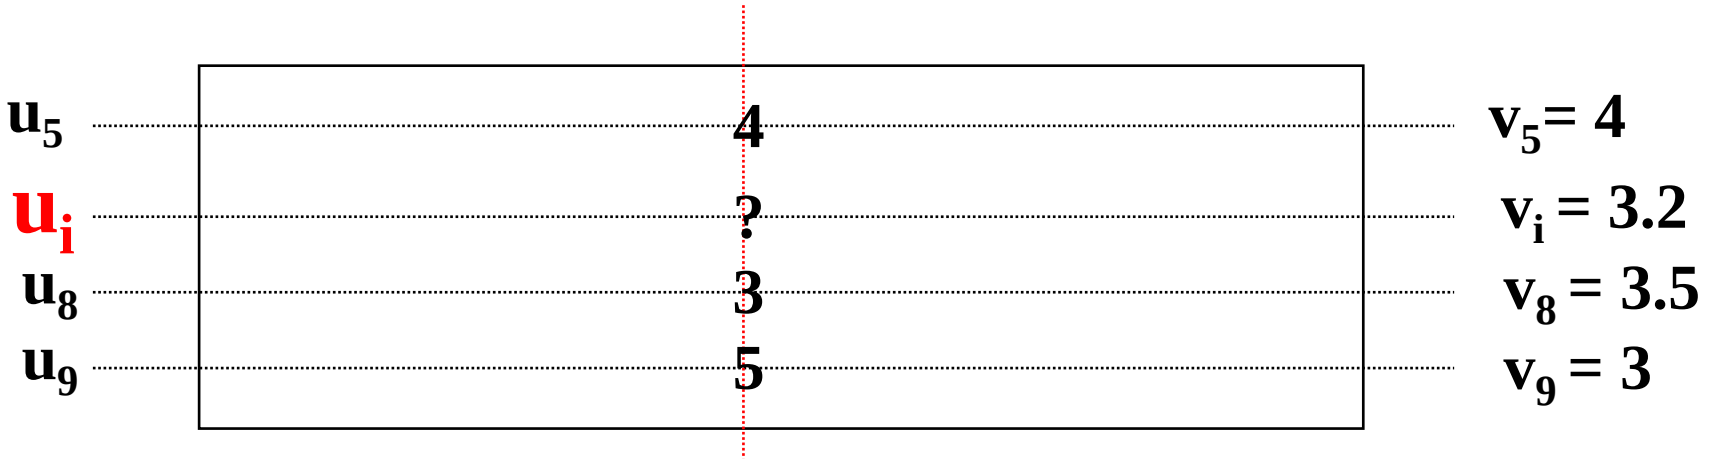
- **theta文件**（doc—>topic），**phi文件**（topic—>word）
- 相似文档的计算
- 文本打标签
  - 读取theta文件找出每篇文章概率最大的主题，获取其编号
  - 读取phi文件里每个主题下word概率，读入内存。
  - 找出该文章最大主题下的最大概率的n个词作为文章标签。
- 文本推荐：
  - 方法一：基于Topic用户建模的方法
  - 方法二：LDA与LR(逻辑斯蒂回归)进行新闻推荐

协同过滤推荐



4	?	?	5	1	?	?
5	5	4				
			2	4	5	
	3					3

基于用户的协同过滤推荐



Users' similarities: $u_{i5} = 0.5$, $u_{i8} = 0.5$, $u_{i9} = 0.8$

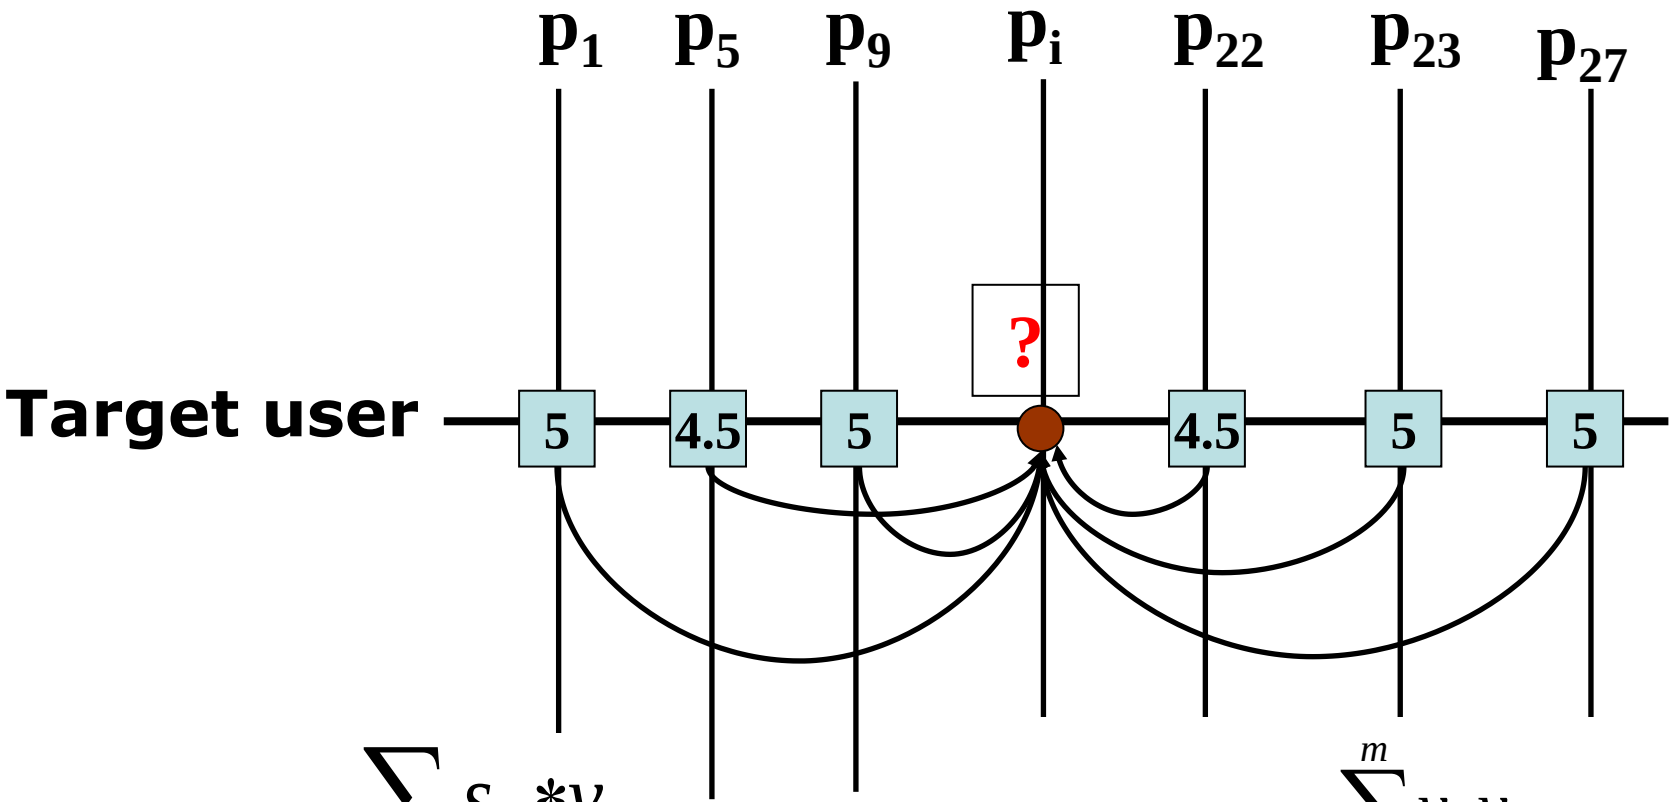
$$v_{ij}^{*} = v_i + K\sum_{v_{kj} \neq ?} u_{ik}\,(v_{kj} - v_k)$$

$$u_{ik} = \frac{\sum_j (v_{ij} - v_i)(v_{kj} - v_k)}{\sqrt{\sum_j (v_{ij} - v_i)^2 \sum_j (v_{kj} - v_k)^2}}$$

v^*_{ij} = 3.2 + 1/(0.5+0.5+0.8) * [0.5 (4 -4) + 0.5 (3 – 3.5) + 0.8 (5 -3)

= 3.2 + 1/1.8 * [0 - 0.25 + 1.6] = 3.2 + 0.75 = 3.95

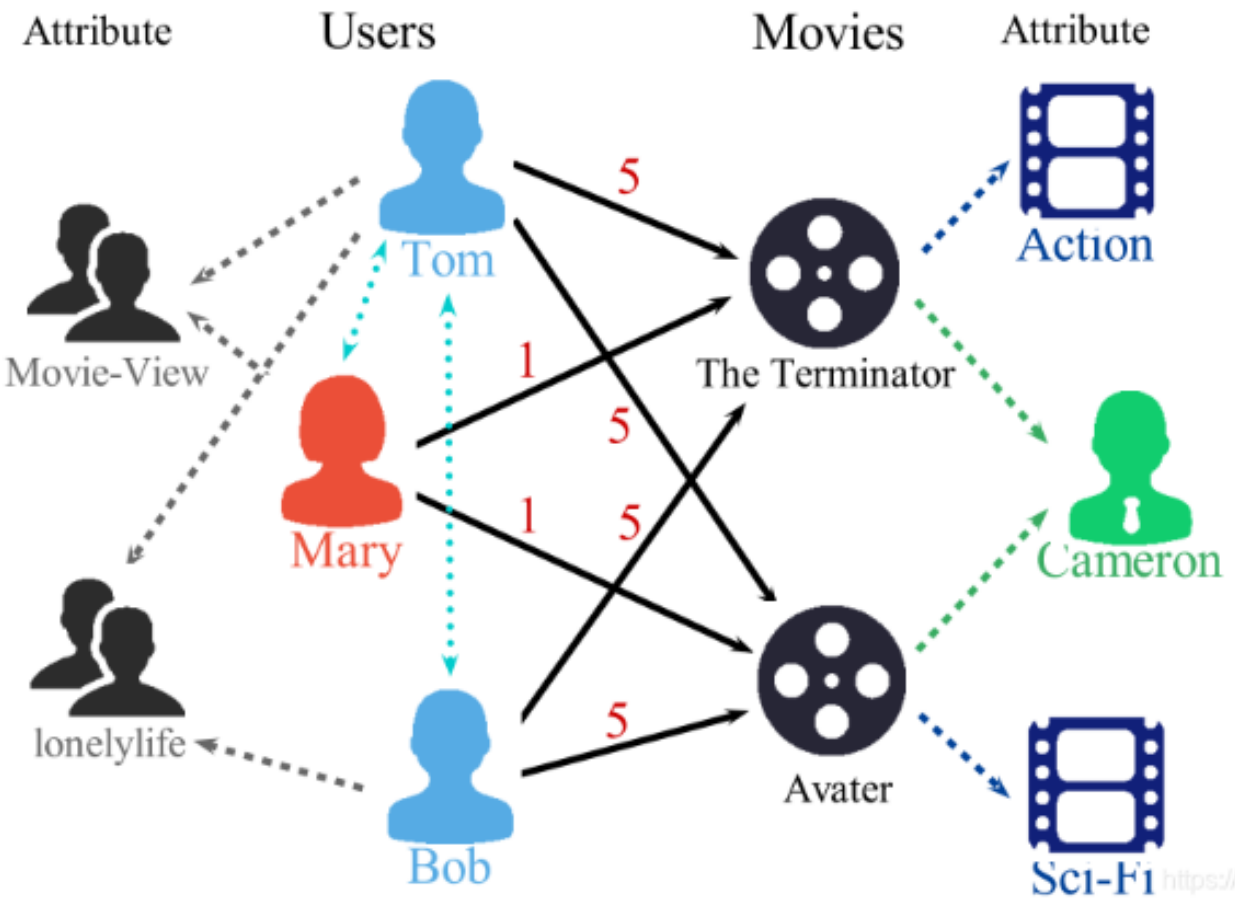
基于项目的协同过滤推荐



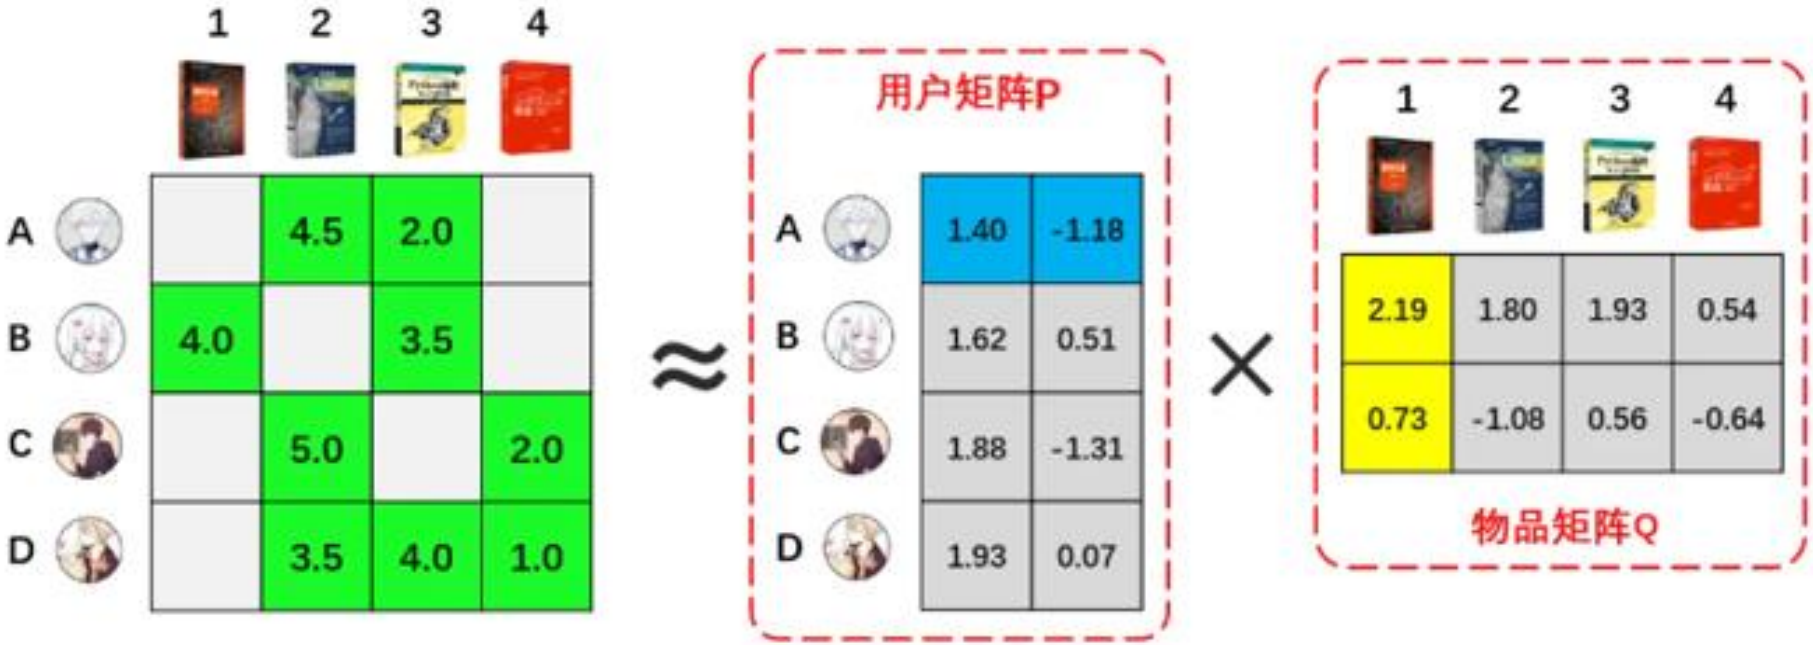
$$v_{ui}^{*} = \frac{\sum_{j} s_{ij} * v_{uj}}{\sum_{j} s_{ij}}$$

$$\cos(p_i, p_j) = \frac{\sum_{k=1}^{m} v_{ki} v_{kj}}{\sqrt{\sum_{k=1}^{m} v_{ki}^2 \sum_{k=1}^{m} v_{kj}^2}}$$

基于图神经网络的推荐


Attribute
Users
Movies
Attribute
Movie-View
Tom
5
Action
1
The Terminator
5
Mary
1
5
Cameron
lonelylife
5
Avater
Bob
Sci-Fi

基于模型的推荐（矩阵分解MF）



假如可得到：$R_{U\times I} = P_{U\times K} Q_{K\times I}$

进行预测：$\hat{r}_{ui} = p_u^T q_i$

$$\text{SSE} = \sum_{u,i} {e_{ui}}^2 = \sum_{u,i} \left(r_{ui} - \sum_{k=1}^{K} p_{uk} q_{ki} \right)^2$$

关键：训练P、Q

$$e_{ui} = r_{ui} - \hat{r}_{ui}$$

$$e_{ui} = r_{ui} - \hat{r}_{ui} = r_{ui} - p_u^T q_i = r_{ui} - \sum_{k=1}^{K} p_{uk} q_{ki}$$

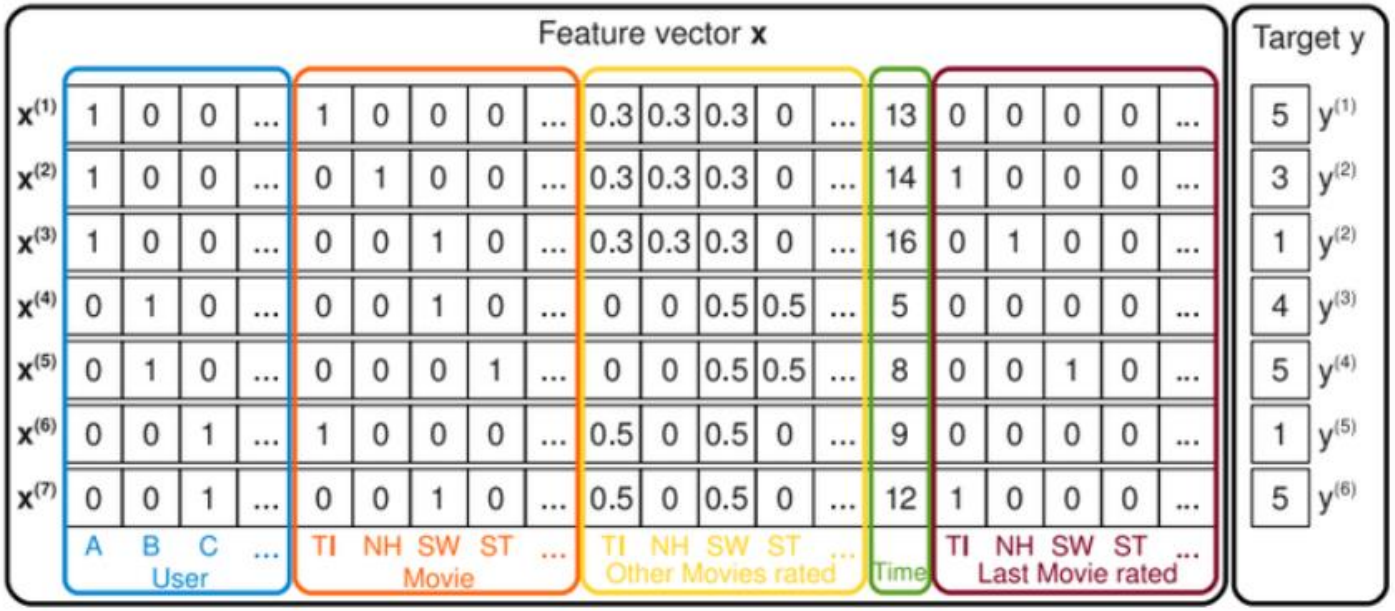
$$\text{SSE} = \sum_{u,i} {e_{ui}}^2 = \sum_{u,i} \left(r_{ui} - \sum_{k=1}^{K} p_{uk} q_{ki} \right)^2$$

$$\frac{\partial}{\partial p_{uk}} SSE = \frac{\partial}{\partial p_{uk}} \left({e_{ui}}^2 \right) = 2 e_{ui} \frac{\partial}{\partial p_{uk}} e_{ui} = -2 e_{ui} q_{ki}$$

$$p_{uk} := p_{uk} - \eta(-e_{ui} q_{ki}) := p_{uk} + \eta e_{ui} q_{ki}$$

$$q_{ki} := q_{ki} - \eta(-e_{ui} p_{uk}) := q_{ki} + \eta e_{ui} p_{uk}$$

基于模型的推荐（因子分解机FM）



$$\hat{y}(\mathbf{x}) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

$$= w_0 + \sum_{i=1}^{n} w_i x_i,$$

$$\langle \mathbf{v}_i, \mathbf{v}_j \rangle := \sum_{f=1}^{k} v_{i,f} \cdot v_{j,f}$$

Interaction between variables

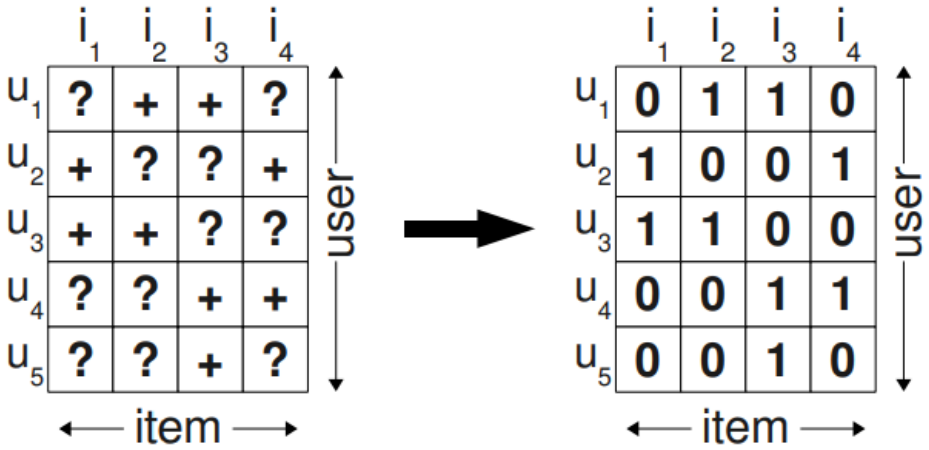
$$y(\mathbf{x}) = w_0 + \sum_{i=1}^{n} w_i x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} w_{ij} x_i x_j$$

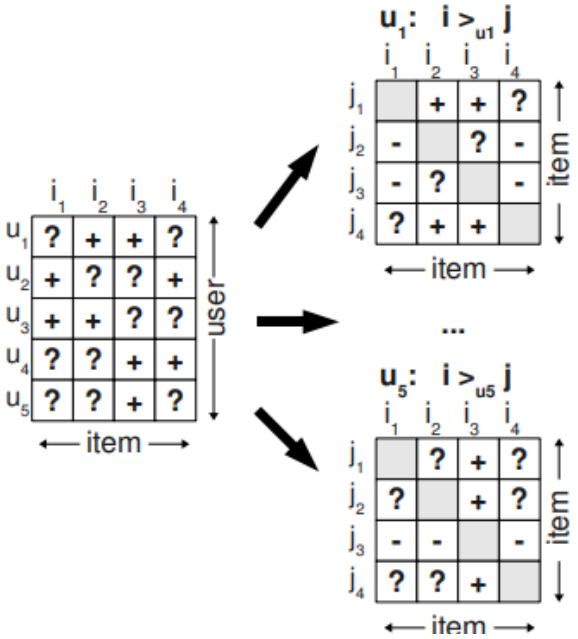
Machine　　Factorization

$$\hat{y}(\mathbf{x}) := w_0 + \sum_{i=1}^{n} w_i x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} < \mathbf{v}_i, \mathbf{v}_j > x_i x_j$$

Fast Context-aware Recommendations with Factorization Machines (SIGIR2011)

基于模型的推荐（贝叶斯排序BPR）





$$p(\Theta|>_u) \propto p(>_u|\Theta)\,p(\Theta)$$

$$\prod_{u\in U} p(>_u|\Theta) = \prod_{(u,i,j)\in U\times I\times I} p(i>_u j|\Theta)^{\delta((u,i,j)\in D_S)} \cdot (1-p(i>_u j|\Theta))^{\delta((u,j,i)\notin D_S)}$$

$$\delta(b) := \begin{cases} 1 & \text{if } b \text{ is true,} \\ 0 & \text{else} \end{cases}$$

$$p(i>_u j|\Theta) := \sigma(\hat{x}_{uij}(\Theta)) \qquad \sigma(x) := \frac{1}{1+e^{-x}}$$

$$\begin{aligned} \text{BPR-OPT} &:= \ln p(\Theta|>_u) \\ &= \ln p(>_u|\Theta)\,p(\Theta) \\ &= \ln \prod_{(u,i,j)\in D_S} \sigma(\hat{x}_{uij})\,p(\Theta) \\ &= \sum_{(u,i,j)\in D_S} \ln\sigma(\hat{x}_{uij}) + \ln p(\Theta) \\ &= \sum_{(u,i,j)\in D_S} \ln\sigma(\hat{x}_{uij}) - \lambda_\Theta||\Theta||^2 \end{aligned}$$

BPR: Bayesian Personalized Ranking from Implicit Feedback (UAI2009)



3. 深度学习推荐

推荐系统引入深度学习

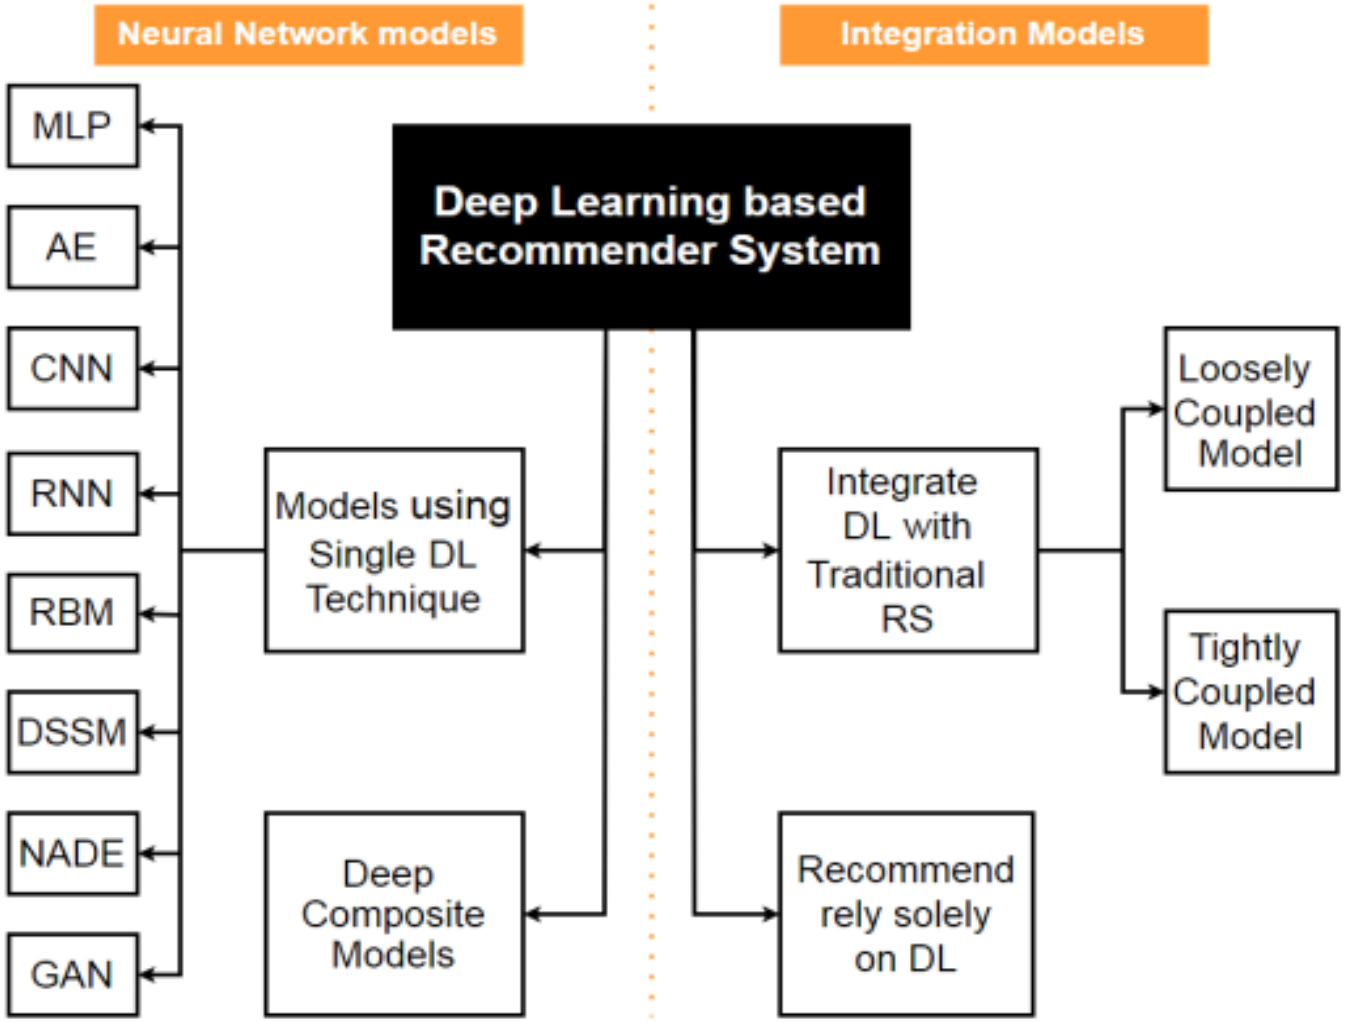
（1）深度学习特征表示、复杂非线性映射机制；

（2）集成各种数据源（文本，图片，视频，音频等）通过提取更高质量的特征表示来丰富推荐算法用户偏好建模；

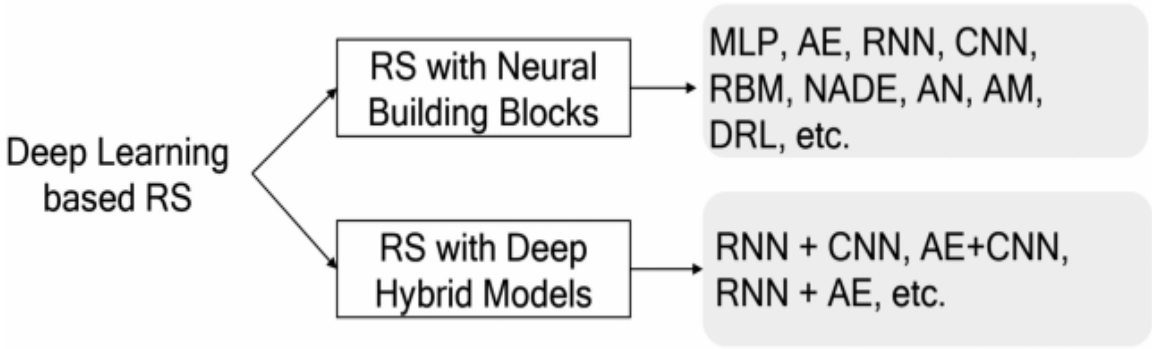
（3）深度学习有可能对用户偏好进行直接建模。不再依赖于协同过滤，新用户的冷启动问题得到了解决；

（4）为推荐系统中的关键问题提供了丰富的解决方案，传统的机器学习限制矩阵分解MF、LDA中，深度学习DAE、RNN、LSTM等广泛应用。

Deep Learning based Recommender System



Shuai Zhang, Lina Yao, and Aixin Sun. 2017. Deep Learning based Recommender System: A Survey and New Perspectives. ACM J. Comput. Cult. Herit. 1, 1, Article 35 (July 2017).



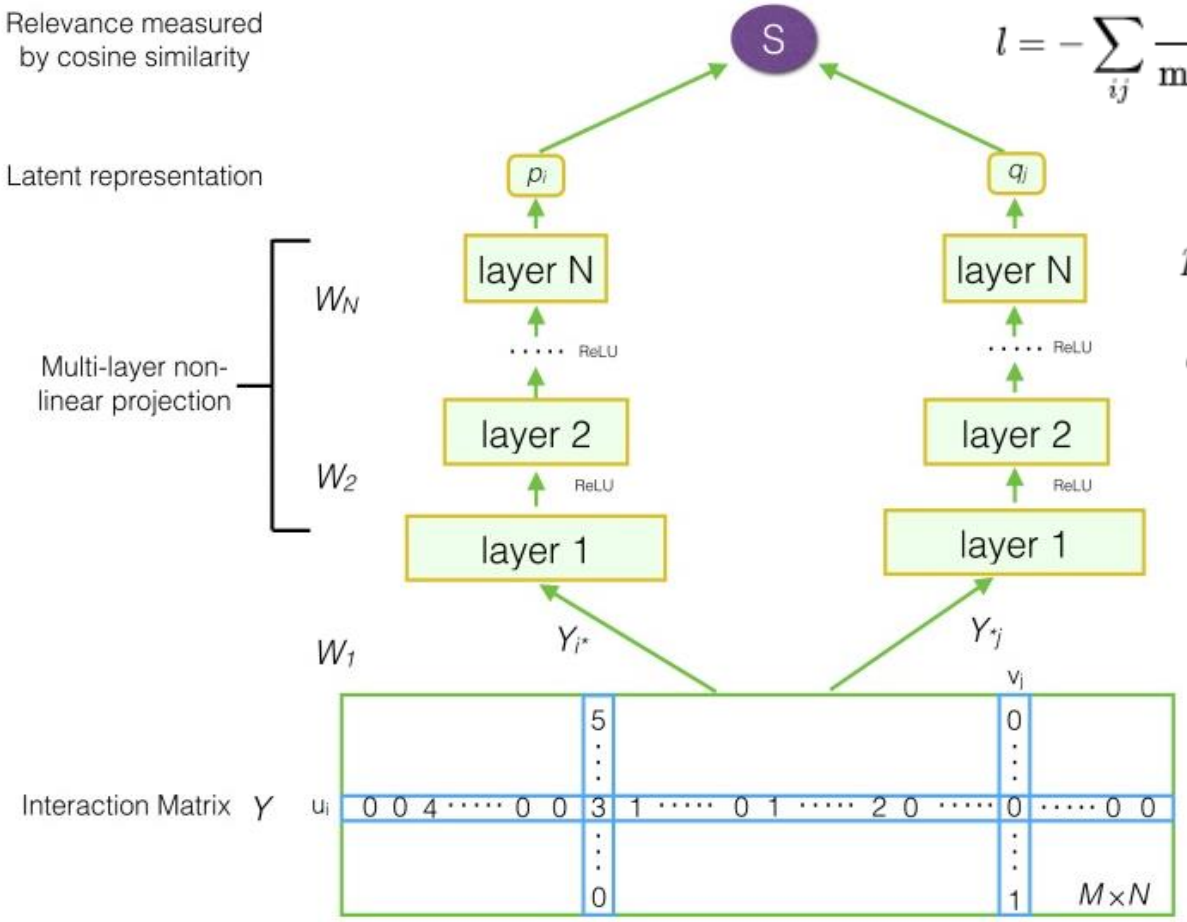
Categories	Publications
MLP	[2, 13, 20, 27, 38, 47, 53, 54, 66, 92, 95, 158, 167, 186], [12, 39, 93, 112, 135, 155, 183, 184]
Autoencoder	[34, 88, 89, 114, 116, 126, 137, 138, 141, 160, 178, 188, 208], [4, 10, 32, 94, 151, 152, 159, 171, 172, 189, 197, 209, 210]
CNNs	[25, 49, 50, 75, 76, 99, 105, 128, 131, 154, 166, 173, 203, 207], [6, 44, 51, 83, 110, 127, 144, 149, 170, 191, 192]
RNNs	[5, 28, 35, 56, 57, 73, 78, 90, 118, 133, 140, 143, 175–177], [24, 29, 33, 55, 68, 91, 108, 113, 134, 142, 150, 174, 180]
RBM	[42, 71, 72, 101, 124, 168, 181]
NADE	[36, 204, 205]
Neural Attention	[14, 44, 70, 90, 100, 103, 128, 146, 170, 190, 195, 206], [62, 147, 194]
Adversary Network	[9, 52, 163, 165]
DRL	[16, 21, 107, 169, 199–201]
Hybrid Models	[17, 38, 41, 82, 84, 87, 119, 136, 161, 193, 194]

Data Sources/Tasks	Notes
Sequential Information	w/t User ID
	Session based w/o User ID
	Check-In, POI
Text	Hash Tags
	News
	Review texts
	Quotes
Images	Visual features
Audio	Music
Video	Videos
Networks	Citation Network
	Social Network
	Cross Domain
Others	Cold-start
	Multitask
	Explainability

Shuai Zhang, Lina Yao, Aixin Sun, and Yi Tay. 2019. Deep Learning Based Recommender System: A Survey and New Perspectives. *ACM Comput. Surv.* 52, 1, Article 5 (February 2019), 38 pages.

Deep Matrix Factorization(DMF)
(IJCAI2017)

$$\hat{Y}_{ij} = F^{DMF}(u_i, v_j|\Theta) = cosine(p_i, q_j) = \frac{p_i^T q_j}{\|p_i\| \, \|q_j\|}$$



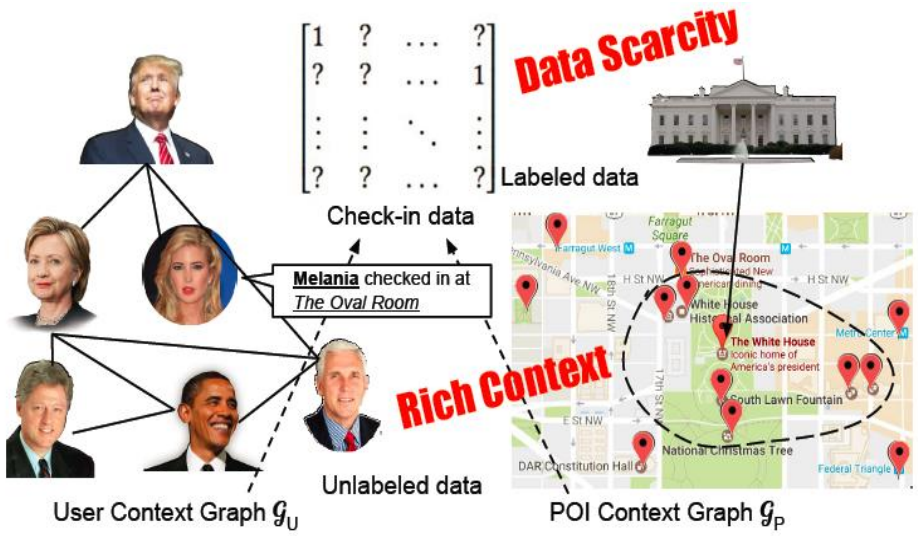
$$l = -\sum_{ij} \frac{Y_{ij}}{\max(R)} \log \hat{Y}_{ij} + (1 - \frac{Y_{ij}}{\max(R)}) \log(1 - \hat{Y}_{ij})$$

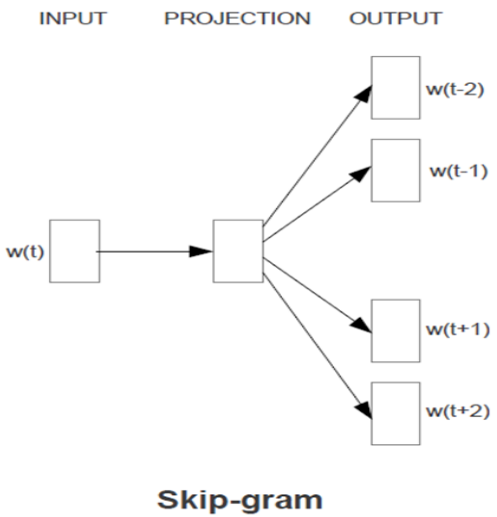
$$p_i = f_{\theta_N^U}(...f_{\theta_3^U}(W_{U2} f_{\theta_2^U}(Y_{i*} W_{U1}))...)$$

$$q_j = f_{\theta_N^I}(...f_{\theta_3^I}(W_{V2} f_{\theta_2^I}(Y_{*j}^T W_{V1}))...)$$

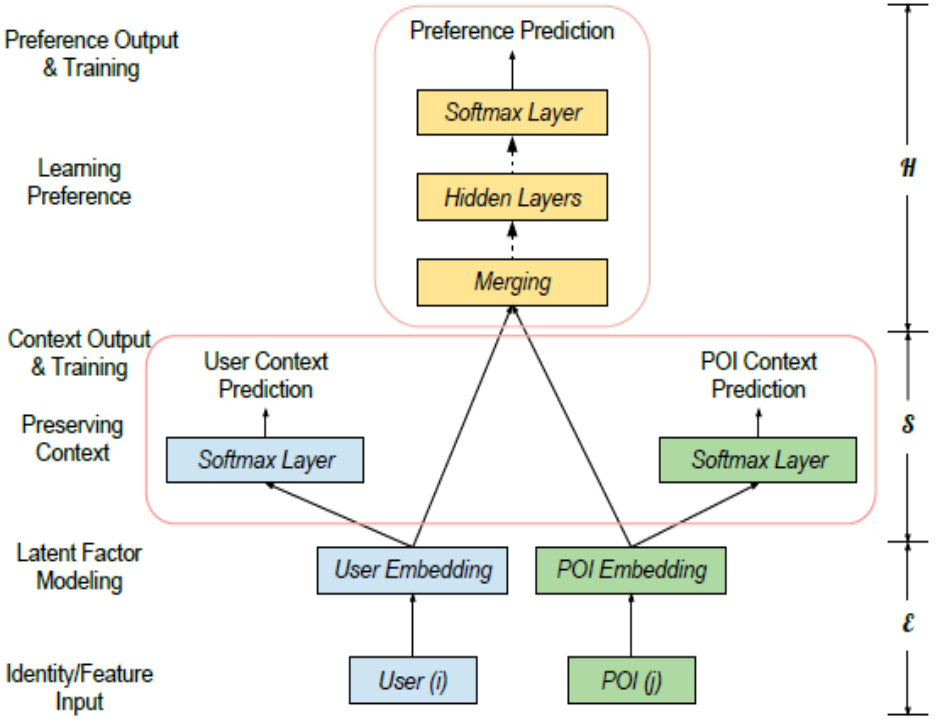
$$l_1 = W_1 x$$
$$l_i = f(W_{i-1} l_{i-1} + b_i), i = 2, ..., N-1$$
$$h = f(W_N l_{N-1} + b_N)$$

Preference and Context Embedding(PACE)
(KDD2017)





一个用户用他周围的朋友来表示



$$\mathcal{J}_P = \log p(\mathcal{L}|\Theta_e, \Theta_h)$$
$$= -\sum_{(u_i,p_j)\in\mathcal{L}^+} \log \hat{y}_{ij} - \sum_{(u_i,p_j)\in\mathcal{L}^-} \log(1-\hat{y}_{ij})$$
$$= -\sum_{(u_i,p_j)\in\mathcal{L}} y_{ij}\log \hat{y}_{ij} + (1-y_{ij})\log(1-\hat{y}_{ij})$$

多信息集成

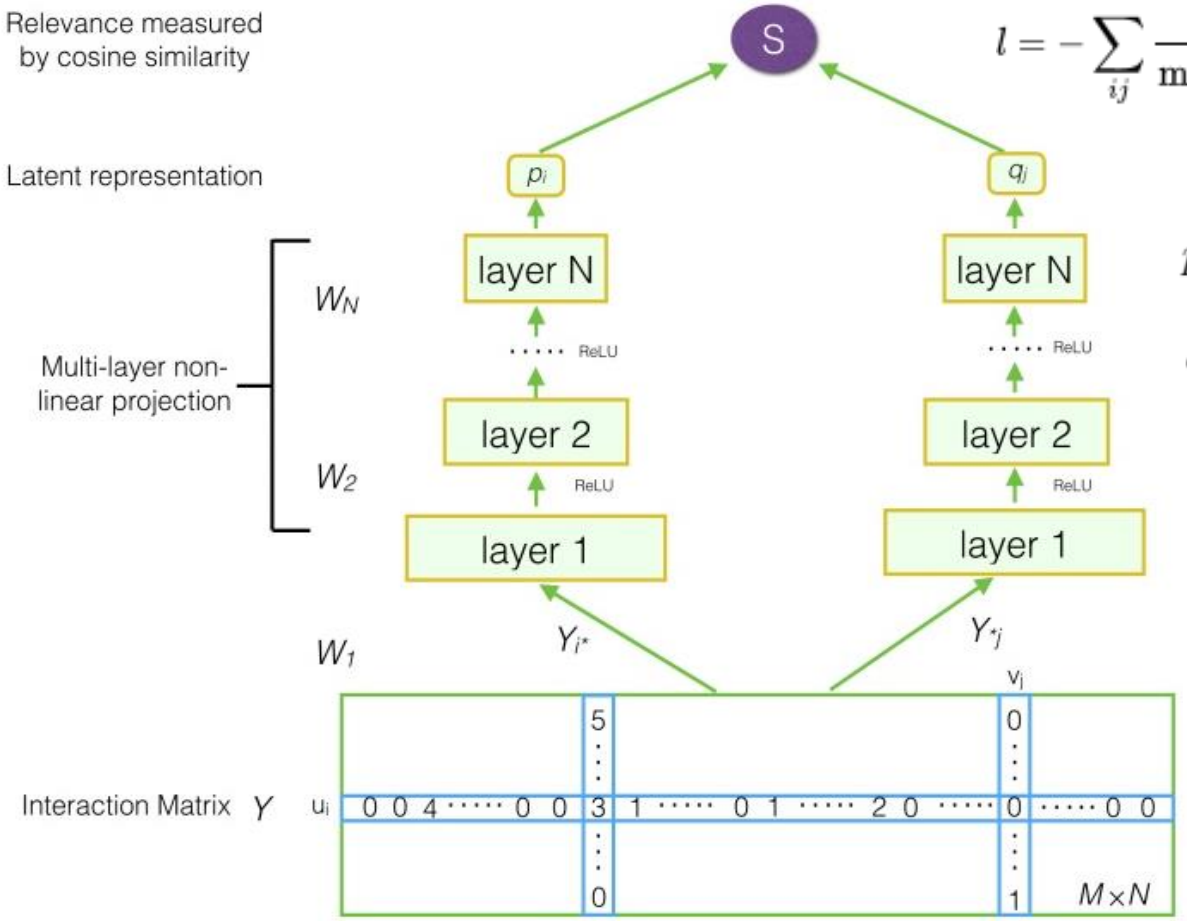
多目标优化

$$\mathcal{J} = \mathcal{J}_P + \lambda_1 \mathcal{J}_{C_u} + \lambda_2 \mathcal{J}_{C_p}$$

Bridging Collaborative Filtering and Semi-Supervised Learning: A Neural Approach for POI Recommendation(KDD2017)

Deep Matrix Factorization(DMF)
(IJCAI2017)

$$\hat{Y}_{ij} = F^{DMF}(u_i, v_j|\Theta) = cosine(p_i, q_j) = \frac{p_i^T q_j}{\|p_i\| \, \|q_j\|}$$



$$l = -\sum_{ij} \frac{Y_{ij}}{\max(R)} \log \hat{Y}_{ij} + (1 - \frac{Y_{ij}}{\max(R)}) \log(1 - \hat{Y}_{ij})$$

$$p_i = f_{\theta_N^U}(...f_{\theta_3^U}(W_{U2} f_{\theta_2^U}(Y_{i*} W_{U1}))...)$$

$$q_j = f_{\theta_N^I}(...f_{\theta_3^I}(W_{V2} f_{\theta_2^I}(Y_{*j}^T W_{V1}))...)$$

$$l_1 = W_1 x$$
$$l_i = f(W_{i-1} l_{i-1} + b_i), i = 2, ..., N-1$$
$$h = f(W_N l_{N-1} + b_N)$$



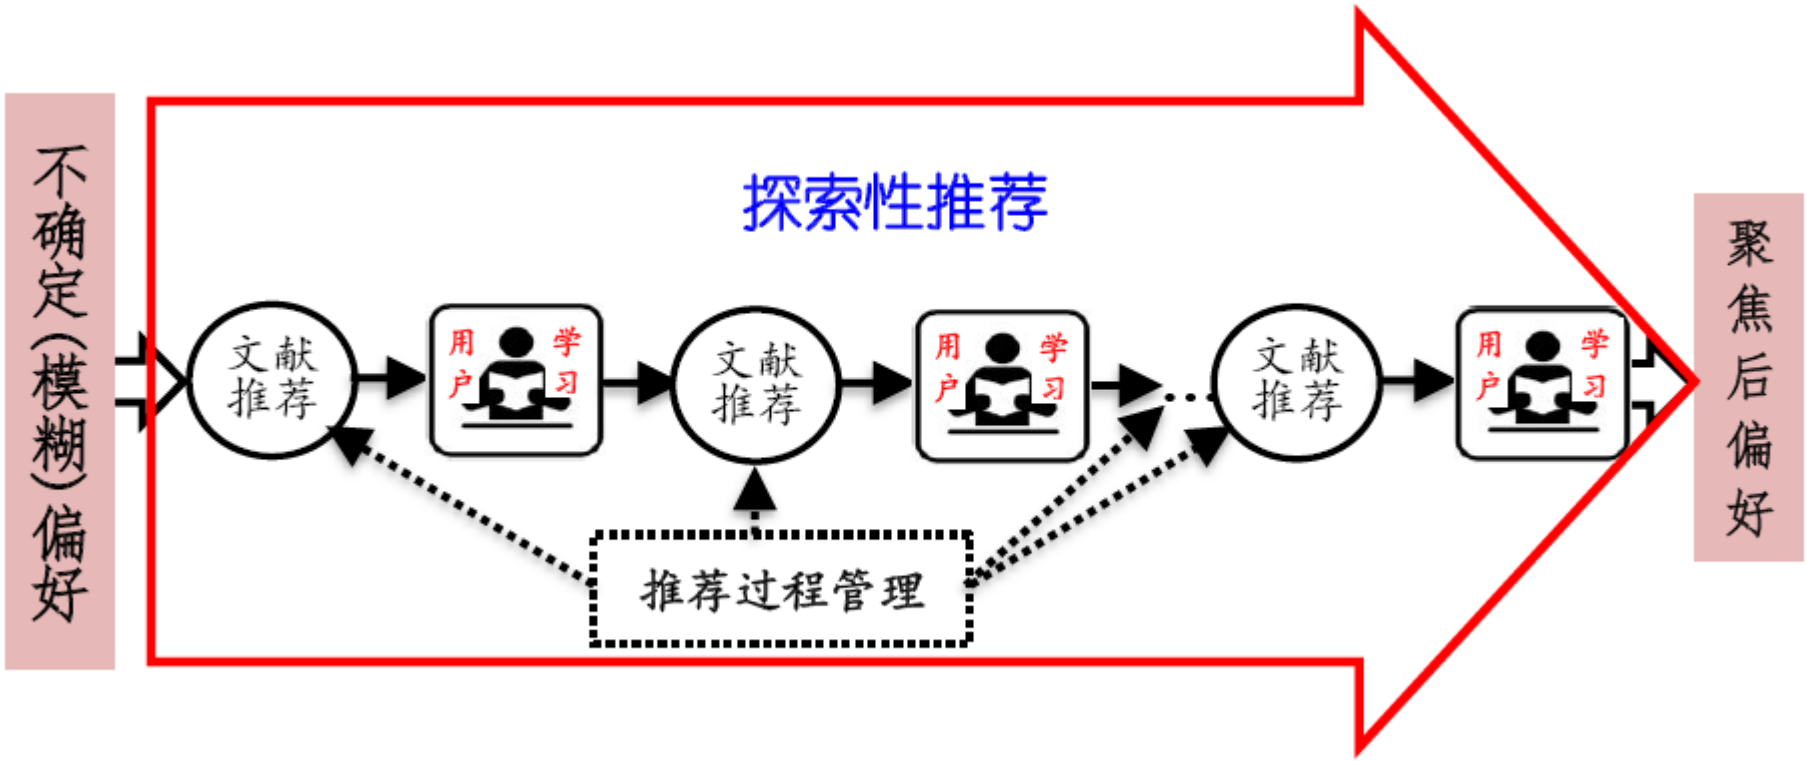
4. 高级推荐系统

why

- 用户偏好清楚
  - 能表达
  - 不能表达 (太复杂、不断变化)
- 用户偏好不清晰
- 有责任帮助用户挖掘需求

探索性推荐

- 推荐依据
  - 基于偏好？ 探索性质？



自适应测试

试题组1

试题组2

试题组3

试题组4

试题组5

精准化评估

知识点1 - 95

知识点2 - 60

知识点3 - 30

学习资源1

学习资源2

学习资源3

学习资源4

学习资源5

个性化推荐

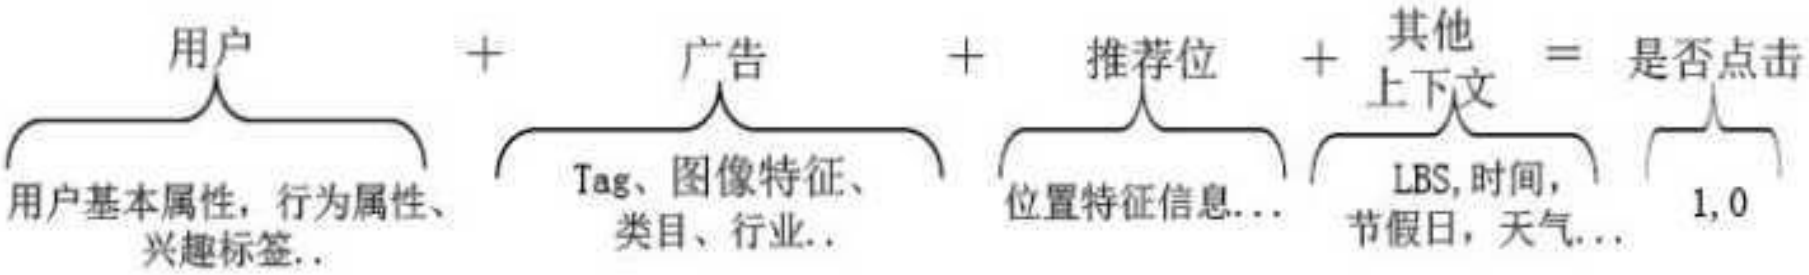




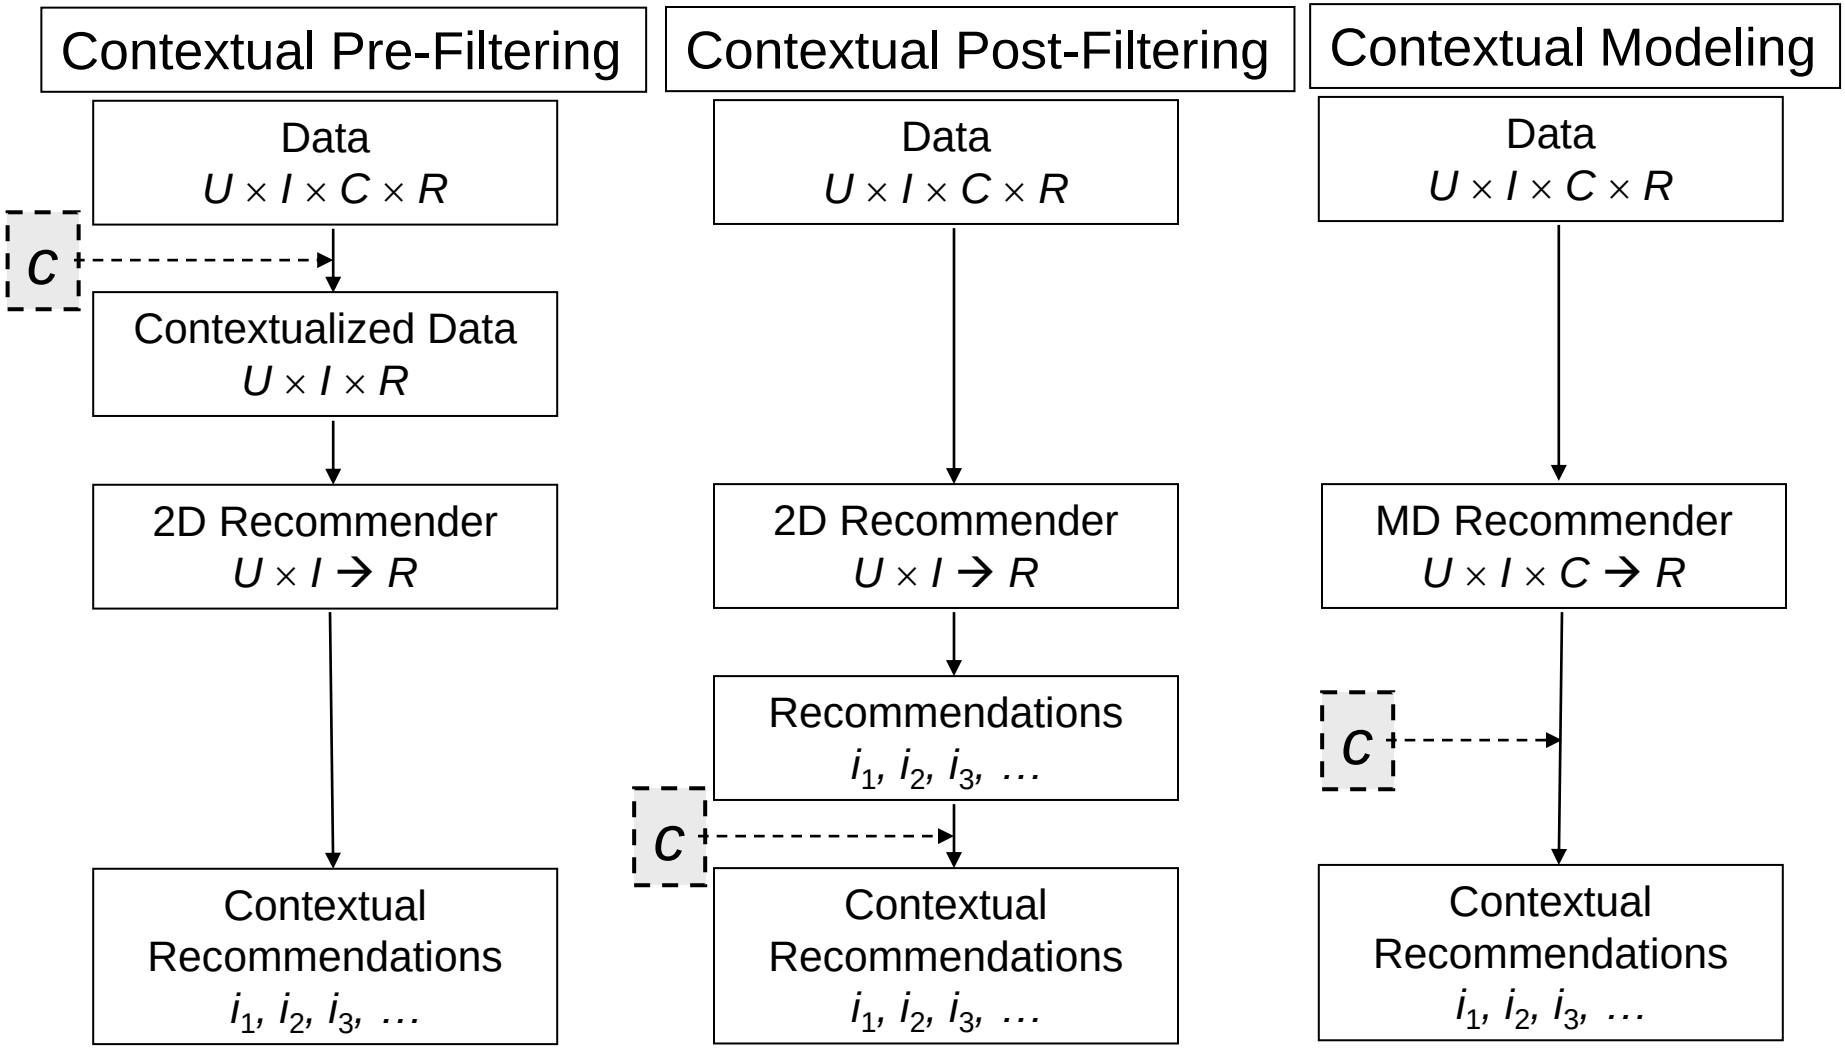
针对性学习

Context Dependent Recommendations

- Recommend a vacation
  - Winter vs. summer
- Recommend a purchase (e-retailer)
  - Gift vs. for yourself
- Recommend a movie
  - To a student who wants to see it on Saturday night with his girlfriend in a movie theater.

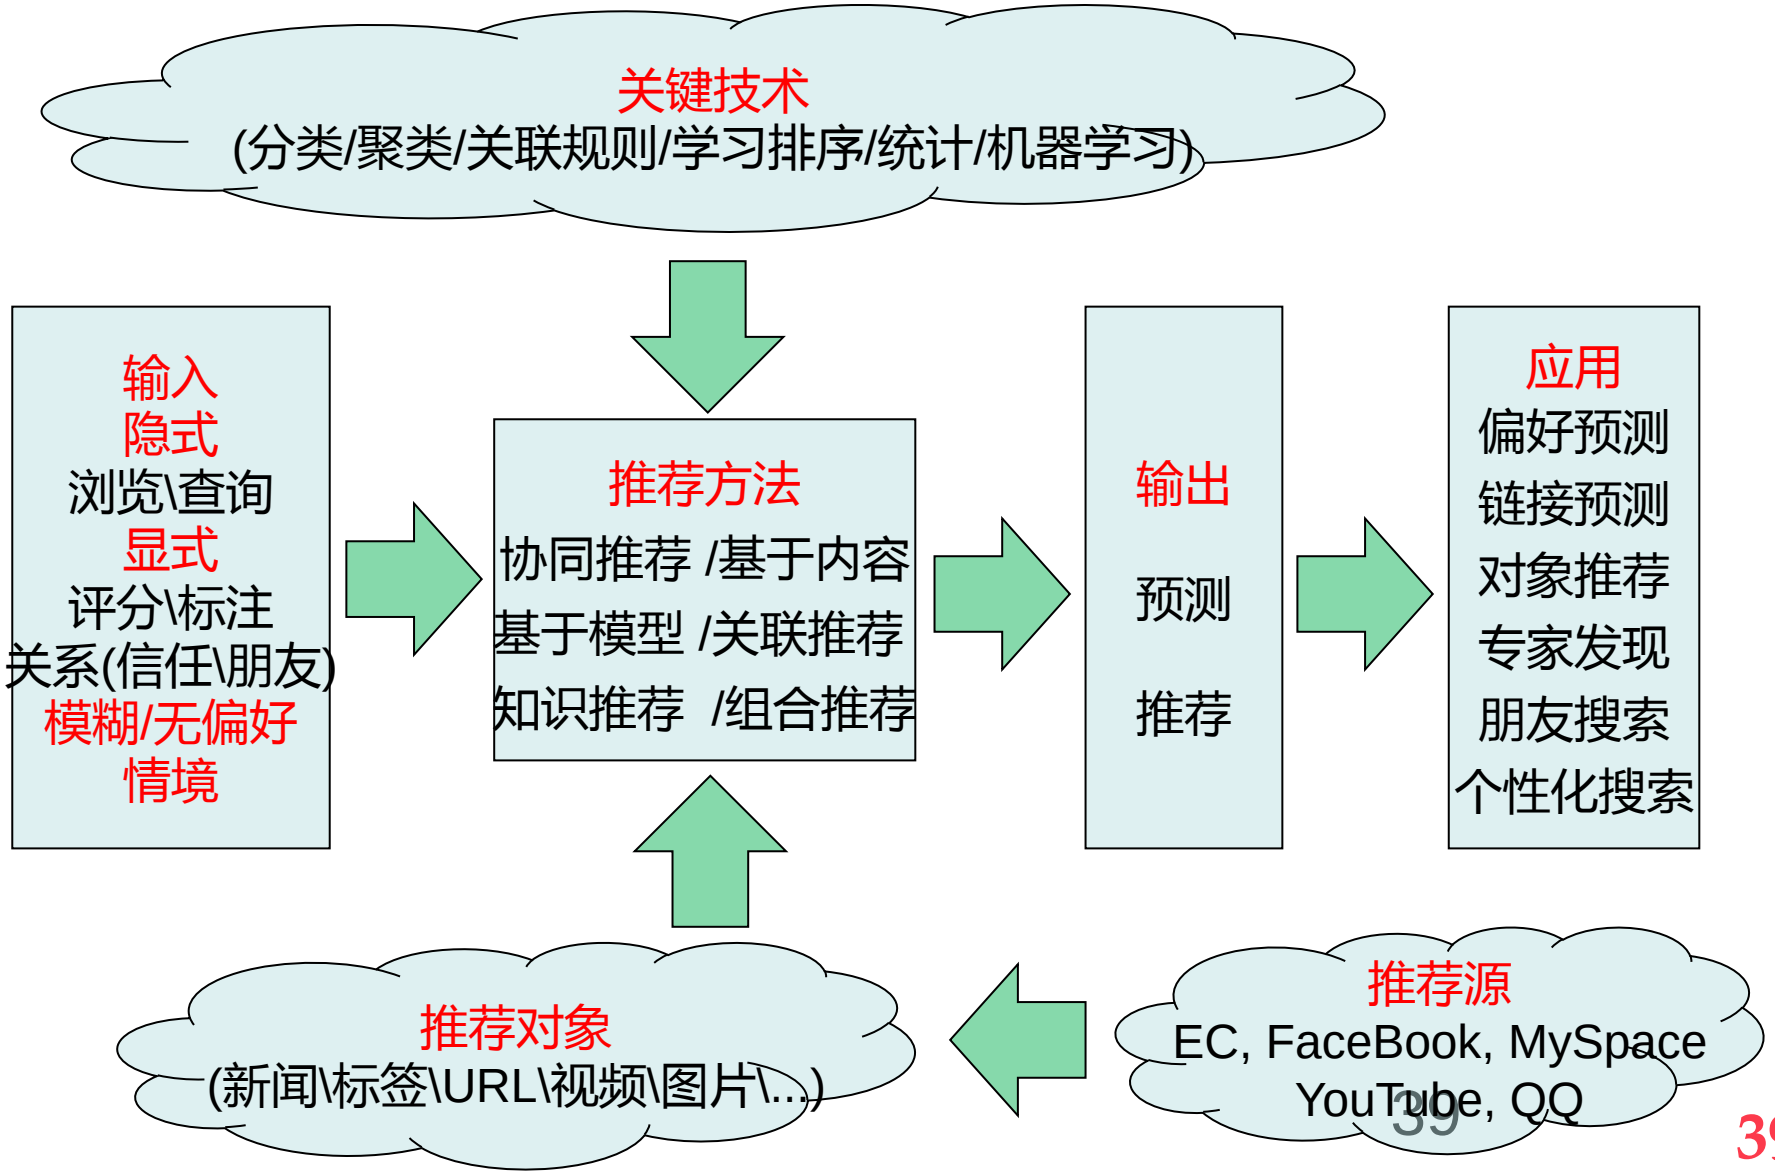


Incorporating Context in RecSys



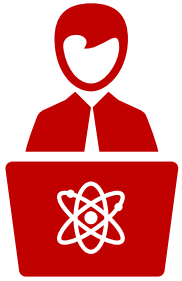
[Adomavicius and Tuzhilin 2008]

Conclusions



39

中国人民大学
RENMIN UNIVERSITY OF CHINA



谢谢大家！