中国人民大学
RENMIN UNIVERSITY OF CHINA

高级社会网络分析

主讲教师：杜玮 副教授
中国人民大学 信息学院
ahduwei@ruc.edu.cn

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

汇报大纲

- 高级社会网络挖掘算法
- 知识图谱
- 社会网络分析前沿
- 课程小结

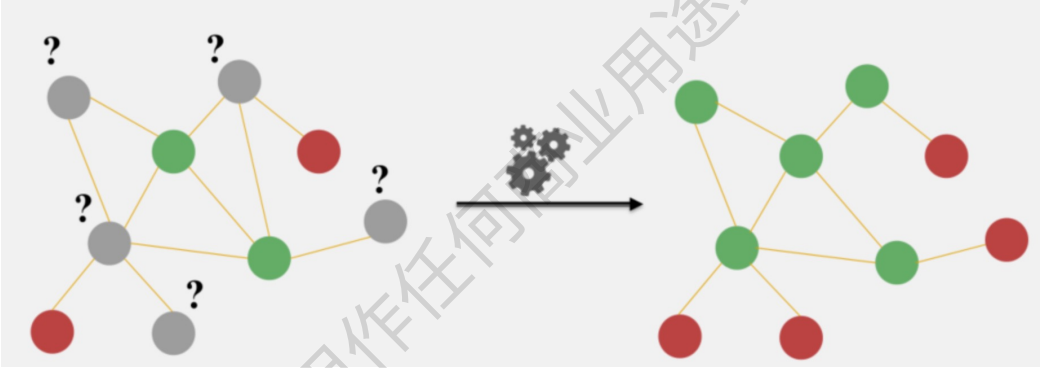
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

一、高级社会网络挖掘算法

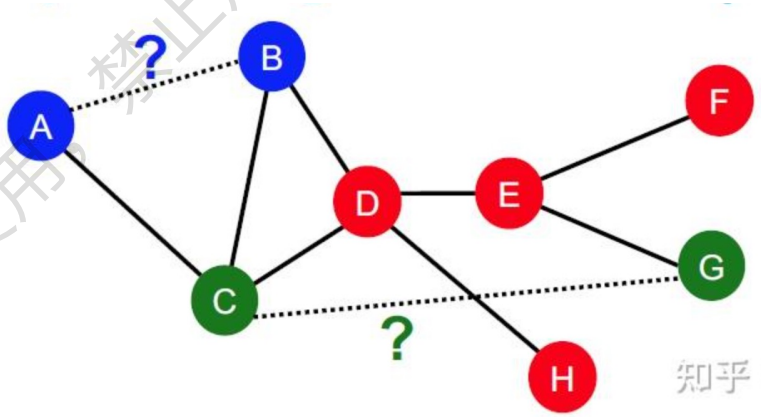
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘任务

- 节点分类/预测 （node classification）
  - 分类：信用评级
  - 异常检测：反欺诈；风险预警



- 链接预测（link prediction）
  - 推荐：电影推荐；商品推荐；合作者推荐；论文引用推荐

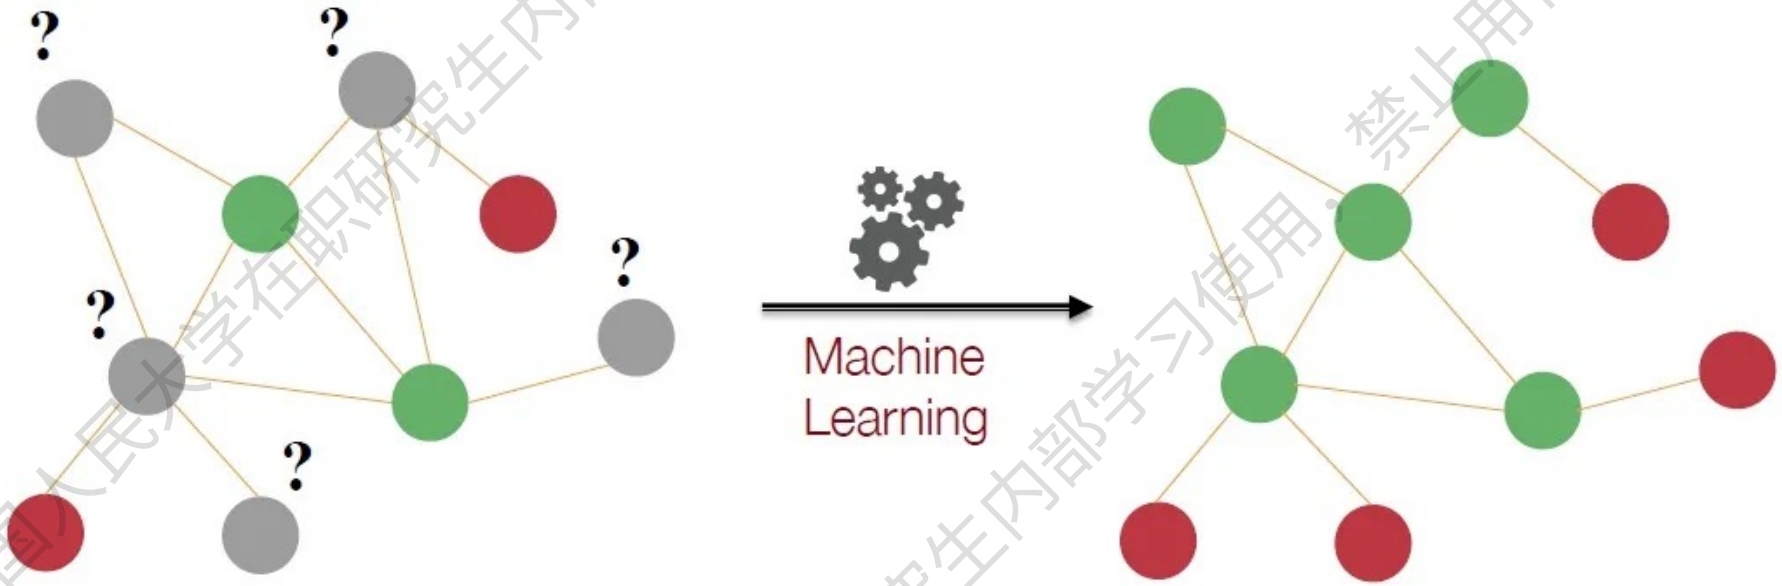


- 其他任务：社区检测；路径抽取等

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘任务-传统方法

- 网络特征抽取→机器学习模型（SVM、RF等）→分类/预测 结果



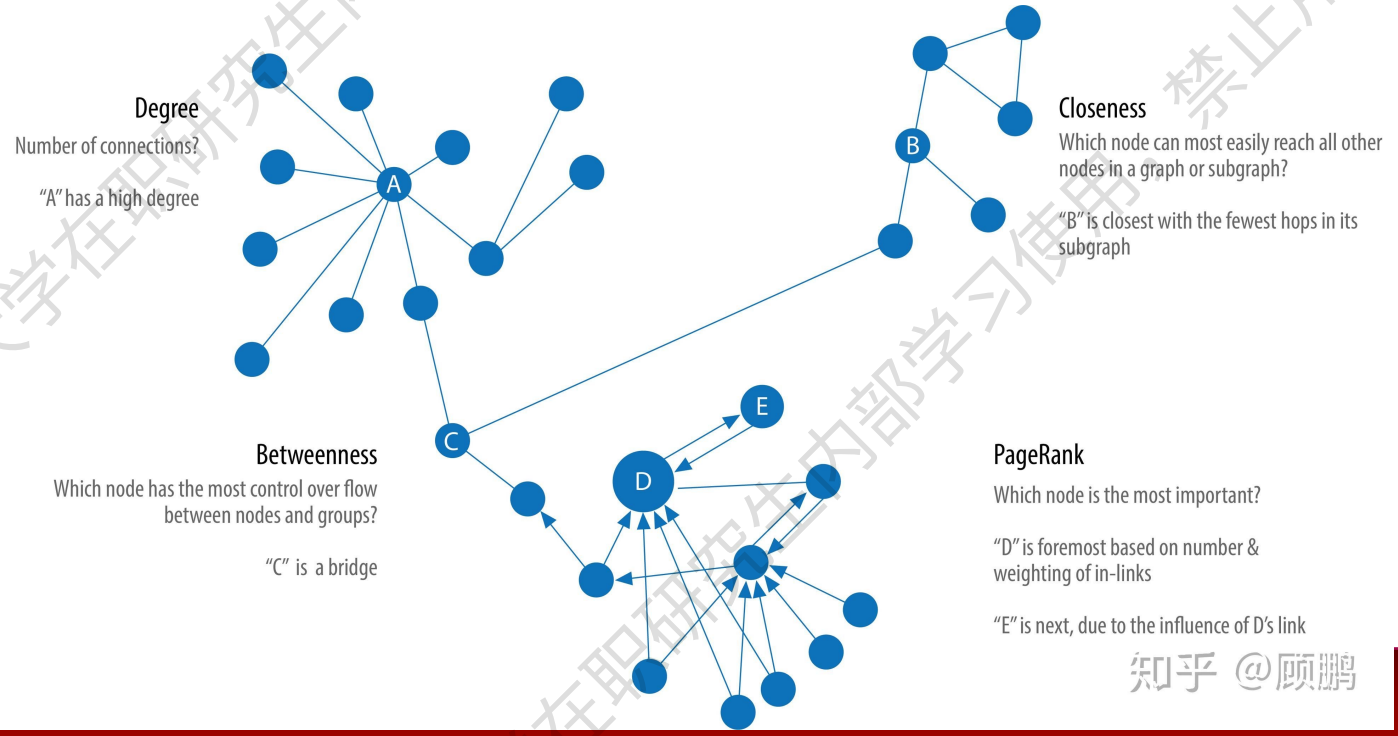
Node classification

知乎 @缓缓飘落的枫叶

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘任务–传统方法

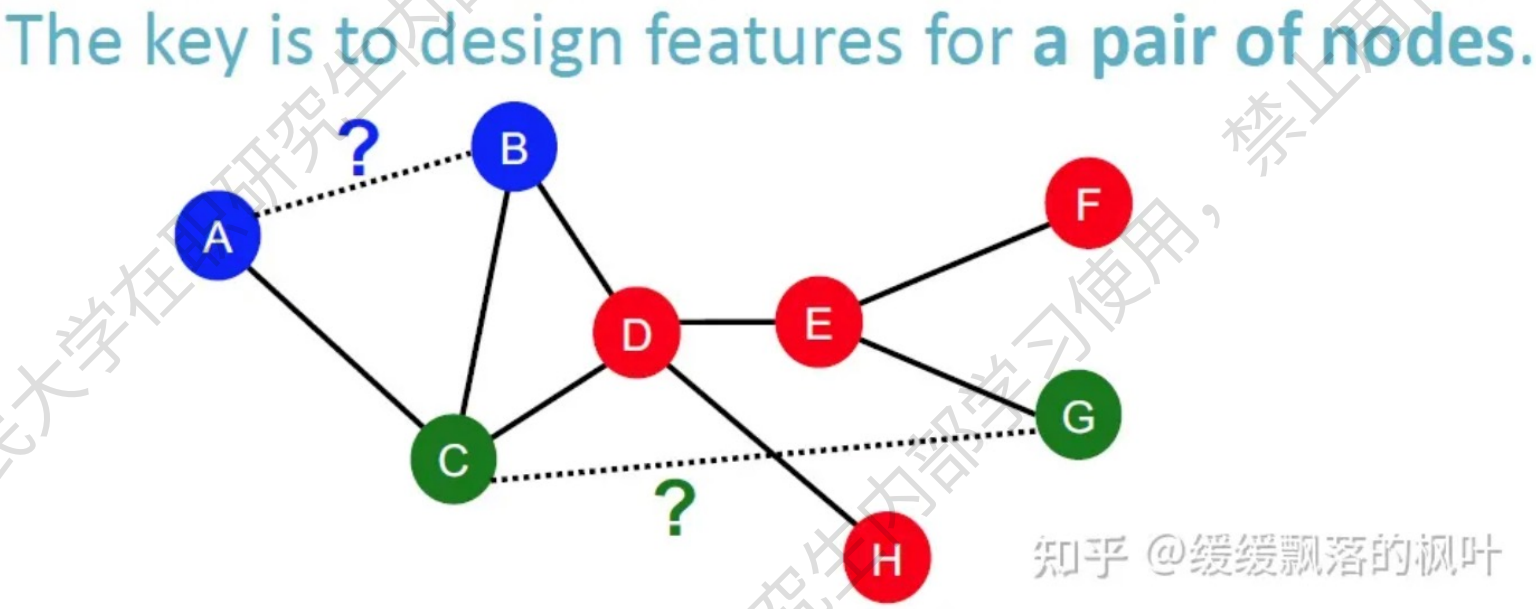
- 节点分类/预测 （node classification）
  - 节点特征提取
    - 节点的重要性/结构：e.g., degree, eigenvector centrality, betweenness centrality, and closeness centrality



知乎 @顾鹏

社会网络挖掘任务–传统方法

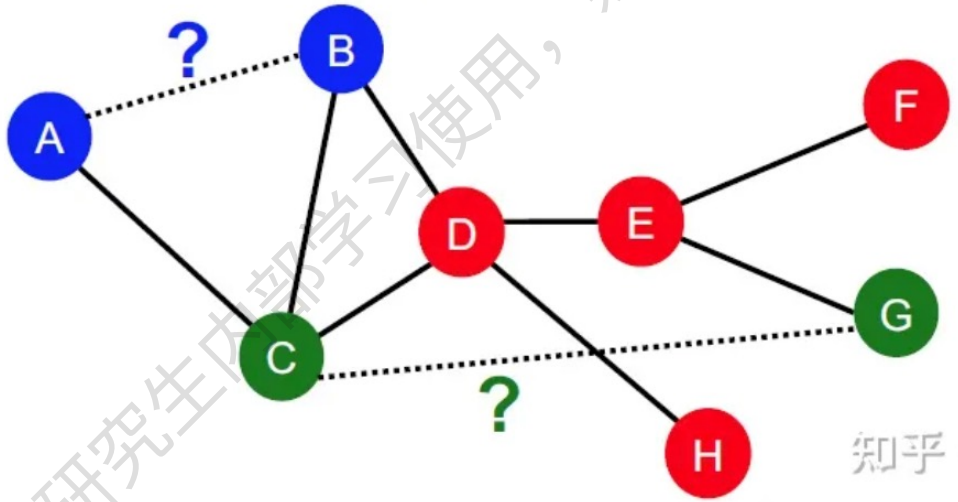
- 链接预测（link prediction）
  - 链接特征提取（or“节点对”特征）



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘任务-传统方法

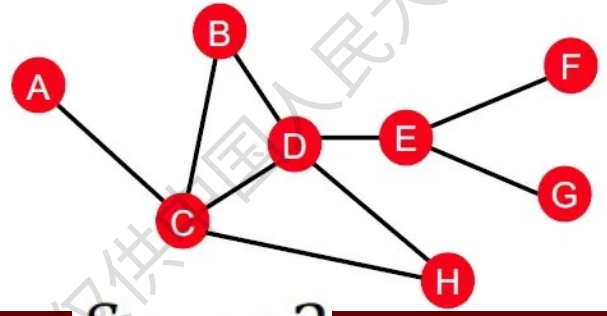
The key is to design features for **a pair of nodes**.



知乎 @缓缓飘落的枫叶

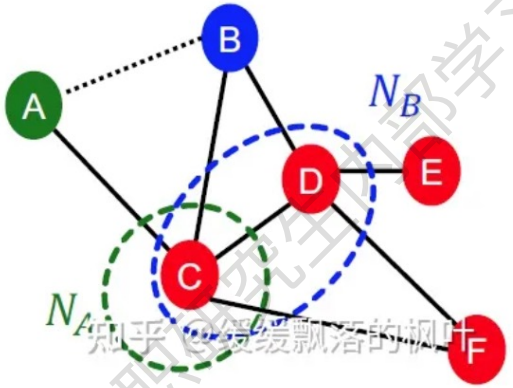
1. 基于距离的特征

Example:



$S_{AB} = 2$

2. 局部邻居重叠特征



知乎 @缓缓飘落的枫叶

3. 全局邻居重叠特征

给定一个节点对，计算节点对上所有的路径及其路径的长度。

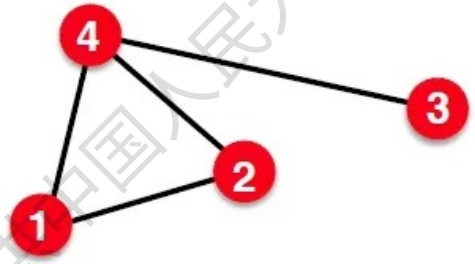
- A-C-B
- A-C-D-B
- A-C-F-D-B
- …

社会网络挖掘任务–传统方法

如何找到节点对之间的所有路径？使用邻接矩阵的幂次方。

Computing #paths between two nodes

- **Recall:** $A_{uv} = 1$ if $u \in N(v)$
- Let $P_{uv}^{(K)}$ = #paths of length K between u and v
- We will show $P^{(K)} = A^k$
- $P_{uv}^{(1)}$ = #paths of length 1 (direct neighborhood) between u and $v = A_{uv}$



$$P_{12}^{(1)} = A_{12}$$

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix}$$

知乎 @缓缓飘落的枫叶

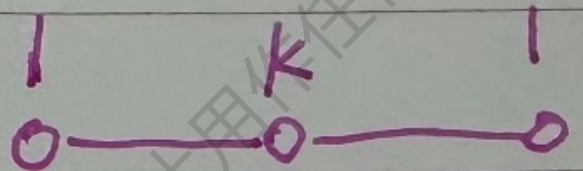


动手算一下！并想一想为什么

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{pmatrix}$$

$$A^2(1,1) = \sum_{k=1}^{4} a_{1k} \cdot a_{k1}$$



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

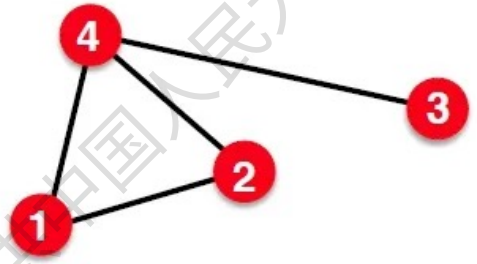
社会网络挖掘任务–传统方法

如何找到节点对之间的所有路径？使用邻接矩阵的幂次方。

Computing #paths between two nodes

- **Recall:** $A_{uv} = 1$ if $u \in N(v)$
- Let $P_{uv}^{(K)}$ = #paths of length K between u and v
- We will show $P^{(K)} = A^k$
- $P_{uv}^{(1)}$ = #paths of length 1 (direct neighborhood) between u and $v = A_{uv}$

$P_{12}^{(1)} = A_{12}$



$$A = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix}$$

知乎 @缓缓飘落的枫叶

A^2=

2	1	1	1
1	2	1	1
1	1	1	0
1	1	0	3

A^3=

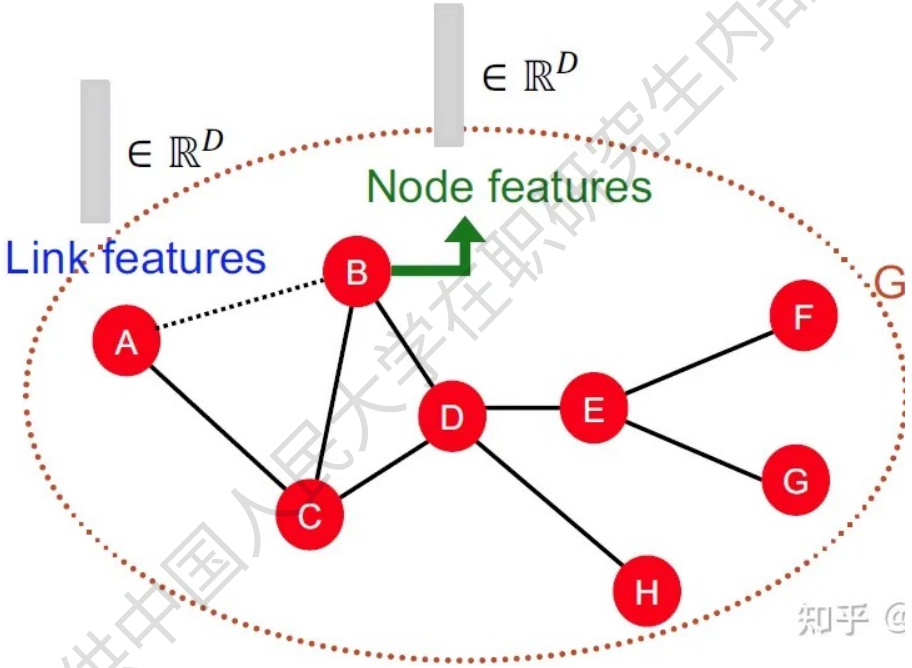
2	3	1	4
3	2	1	4
1	1	0	3
4	4	3	2

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘任务-传统方法

– 节点特征（中心性指标，聚集系数等）

– 链接（节点对）特征（距离、邻居重叠等）



机器学习方法

SVM、DT、RF、NB etc.

- 信用评级
- 欺诈预警
- 好友推荐
- 商品推荐

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

传统机器学习的缺陷





连翘&迎春花

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

传统机器学习的缺陷



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

社会网络挖掘算法

- 传统算法
  - 人工设计特征→机器学习模型
  - 特征工程：专业知识；特征不全面；费时费力

- 高级社会网络挖掘算法
  - 基础特征→模型学习复杂特征
  - 图神经网络算法（GNN）
    - GNN, GCN, GAT, GraphSAGE, rGCN, HeteGCN

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图image和图graph

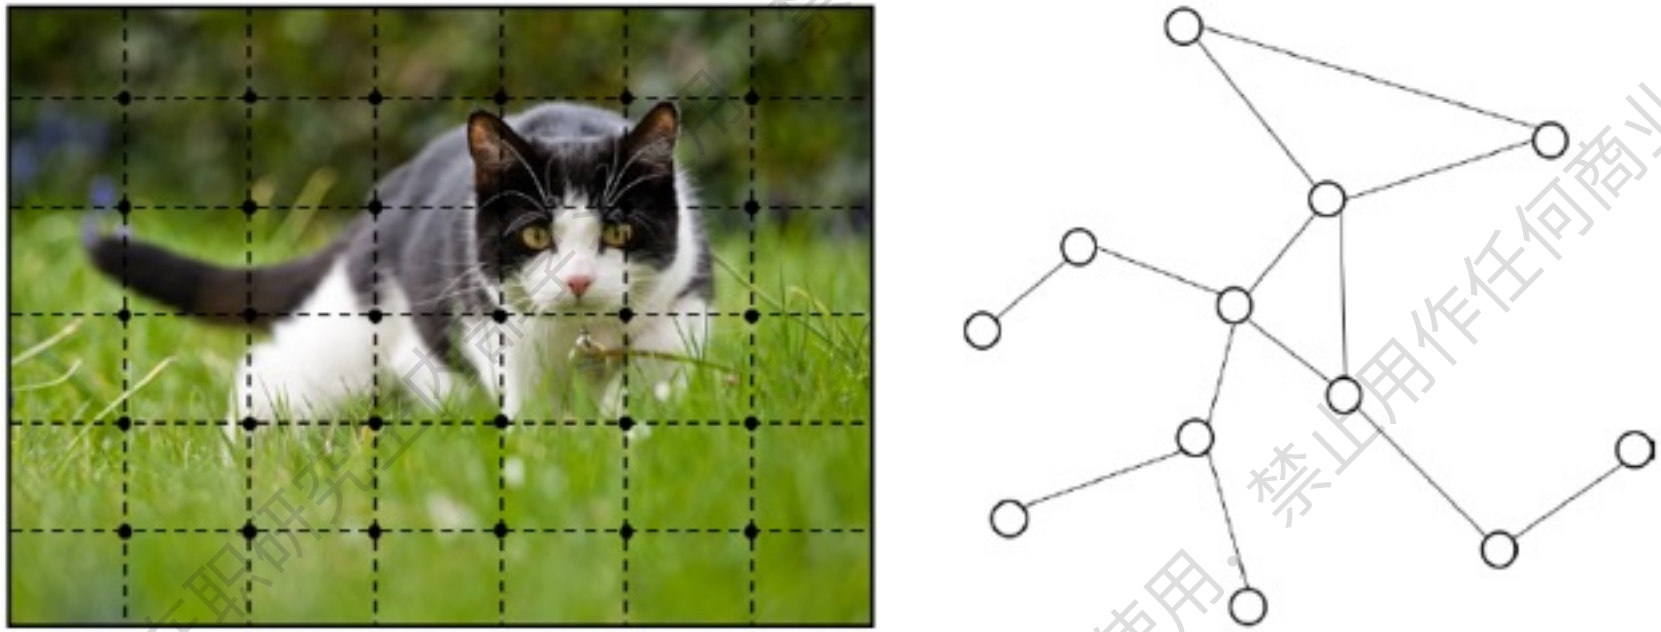


Fig. 1. Left: image in Euclidean space. Right: graph in non-Euclidean space

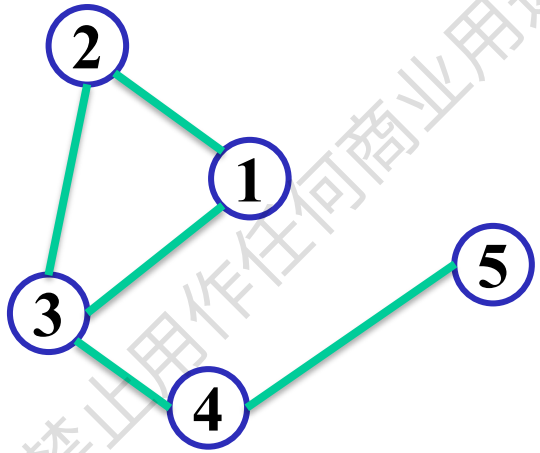
图论中的图(Graph)，它是一种由若干个结点(Node)及连接两个结点的边(Edge)所构成的图形，用于刻画不同结点之间的关系。

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

特征表示

- 图的表示：节点特征矩阵$A \in \mathcal{R}^{n \times f}$

Node	Feature1	Feature2	Feature3	Feature4	Feature5
1	1	1	1	0	0
2	1	1	1	0	0
3	1	1	1	1	0
4	0	0	1	1	1
5	0	0	0	1	1



缺点：

1. 当节点数量多时，大量0值，n维特征向量
2. 难以反映节点间的高阶关联，如节点2和节点5

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

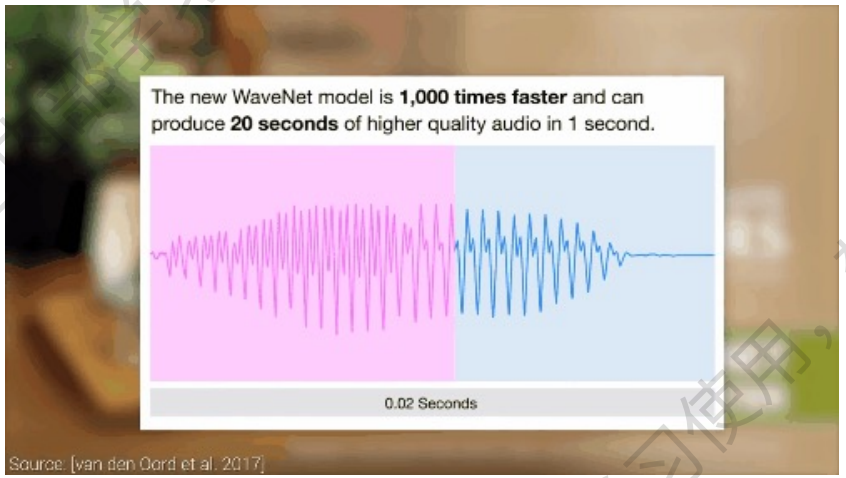
图神经网络

- 深度学习→Graph

深度学习在语音、图像、文本（序列or网格数据）处理上取得了重要进展

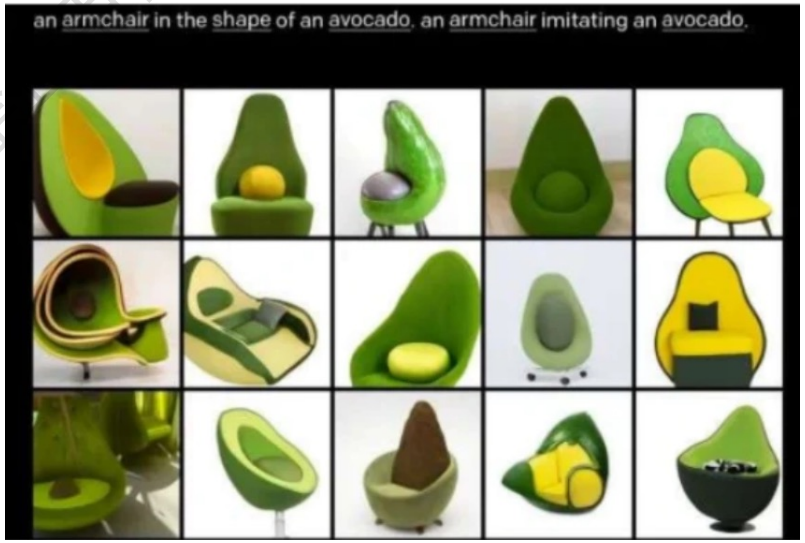


2015年，微软提出的深度学习算法在ImageNet2012数据集上分类错误达4.94%（人眼识别：5.1%）



2017年6月发布的WaveNet语音合成系统，文本到语音环节最好的生成模型

https://openai.com/blog/dall-e/

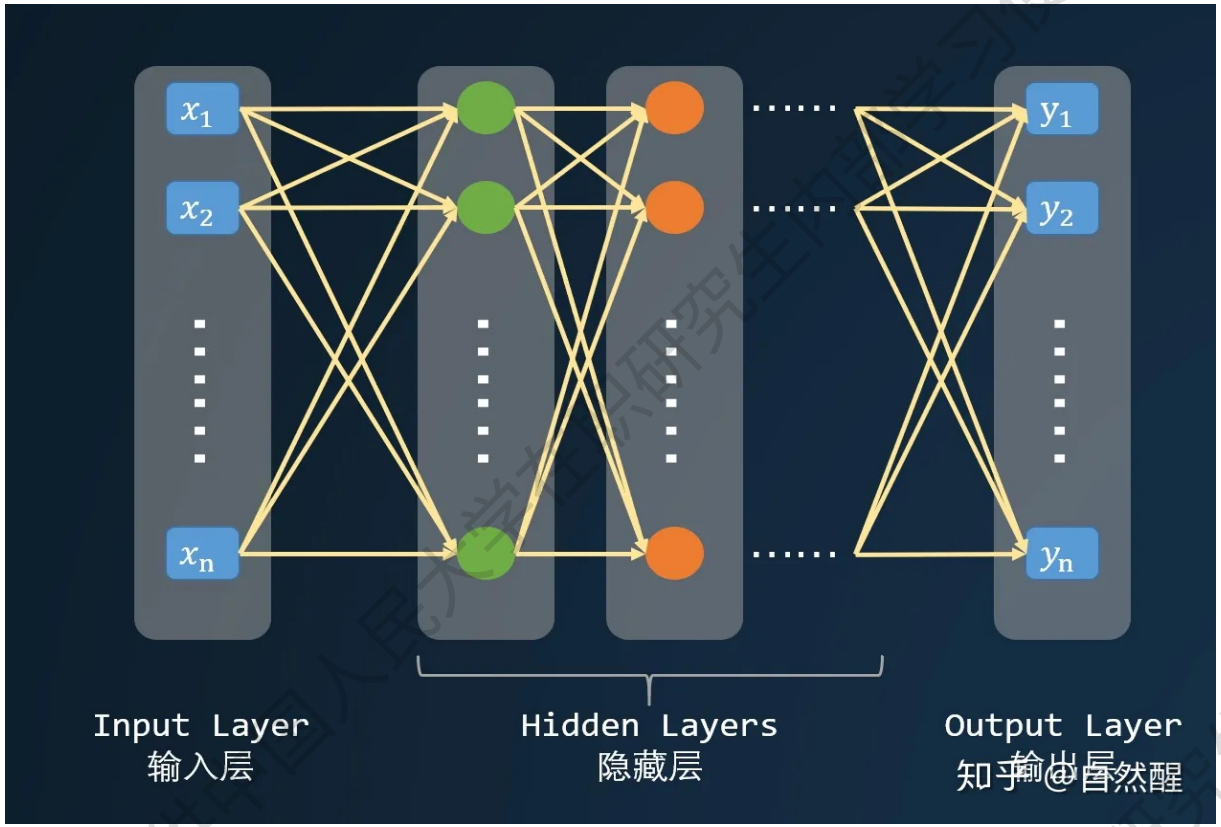


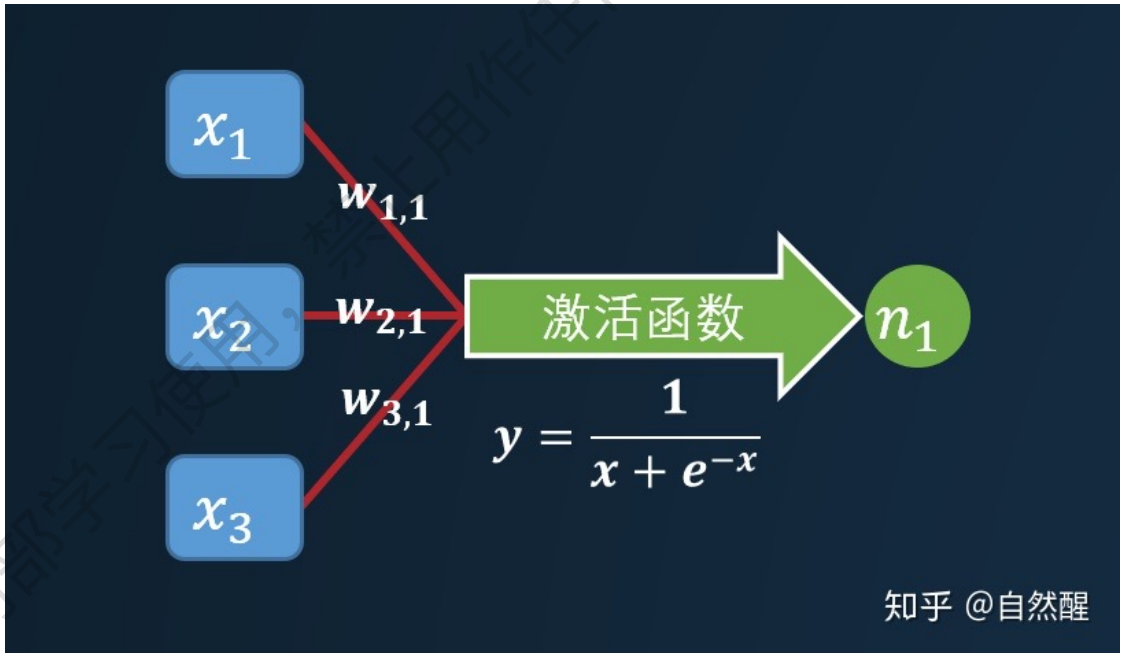
OpenAI的语言模型GPT-2超越BERT，2020年的GPT-3在多个NLP任务上达到最优性能

仅供中国人民大学在职研究生课堂学习使用，禁止用作任何商业用途或传播

深度学习背景-DNN

- Deep neural network深度神经网络

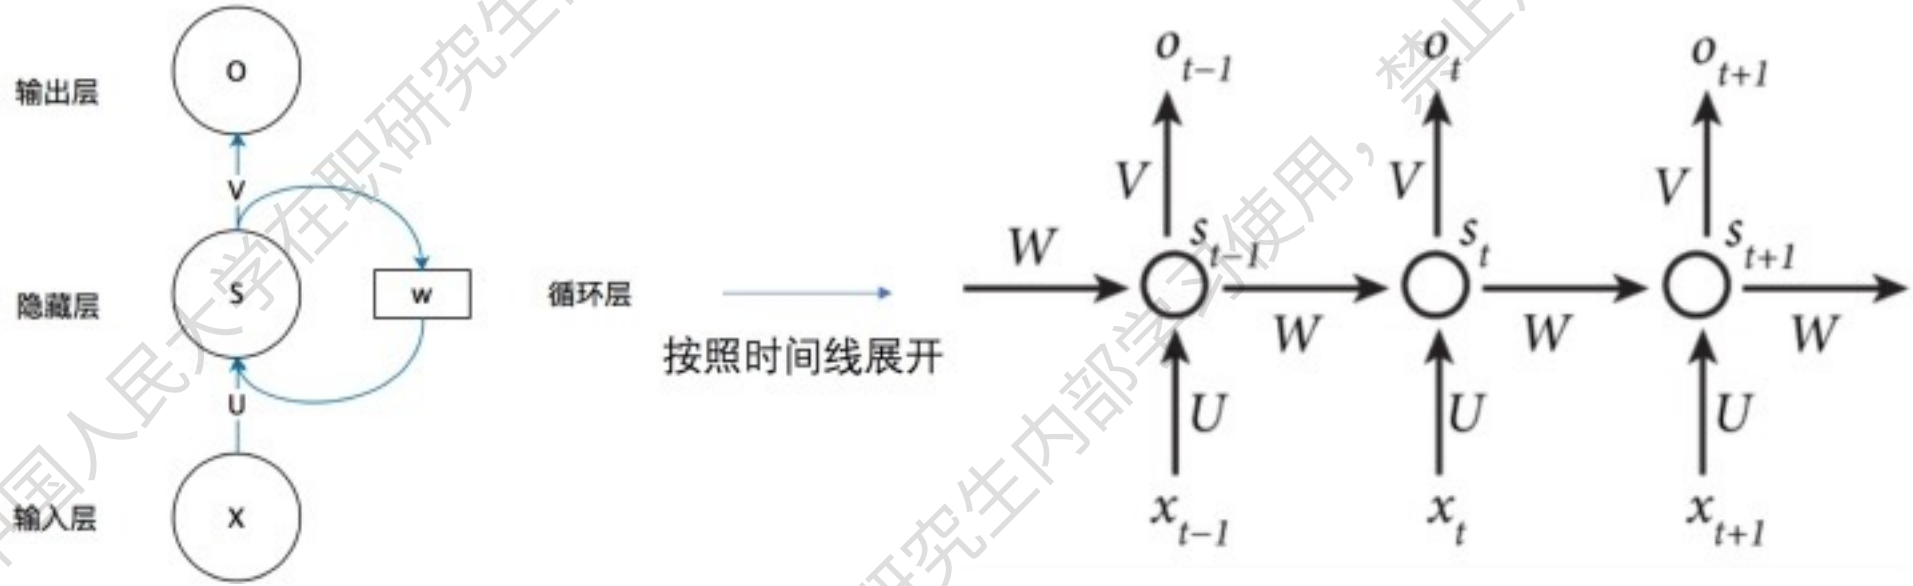




激活函数： 引入非线性因素

深度学习背景- RNN

- Recurrent neural network循环神经网络-处理时间/空间序列数据
  - 自然语言处理：上下文
  - 时间序列预测



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

深度学习背景-CNN

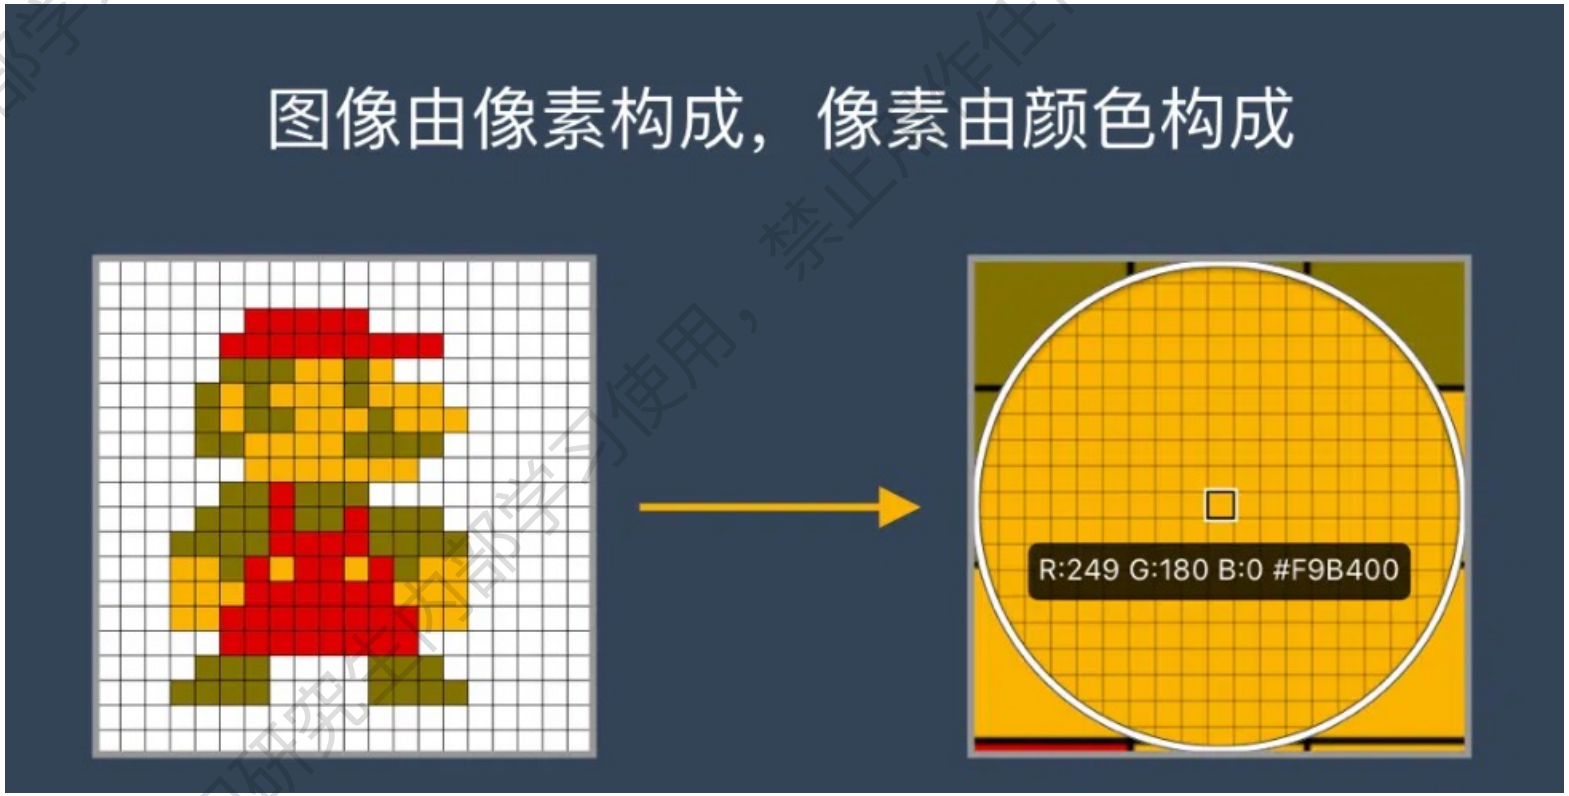
- Convolutional neural network卷积神经网络
  - 处理图像image

DNN直接处理大尺寸图像具有三个明显的缺点：

（1）首先将图像展开为向量会丢失空间信息；

（2）其次参数过多效率低下，训练困难；

（3）同时大量的参数也很快会导致网络过拟合



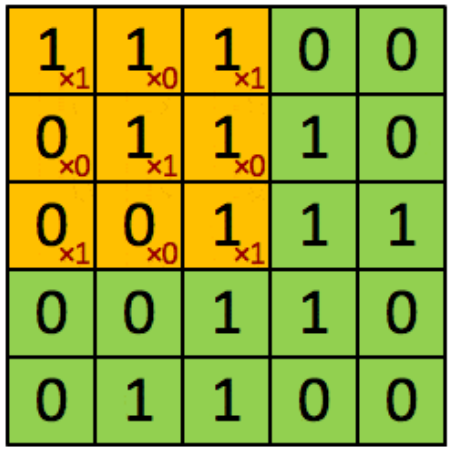
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

深度学习背景-CNN

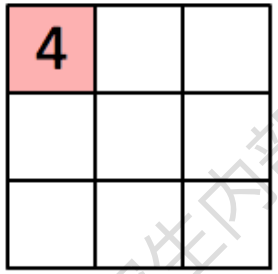
Step 1.卷积-提取特征

Step 2.池化-下采样，数据降维

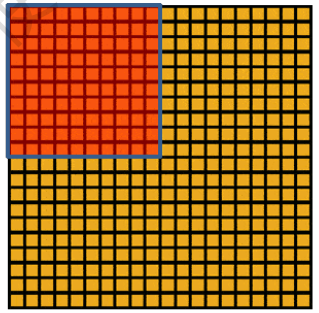
Step 3.全连接层-输出结果



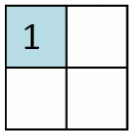
Image



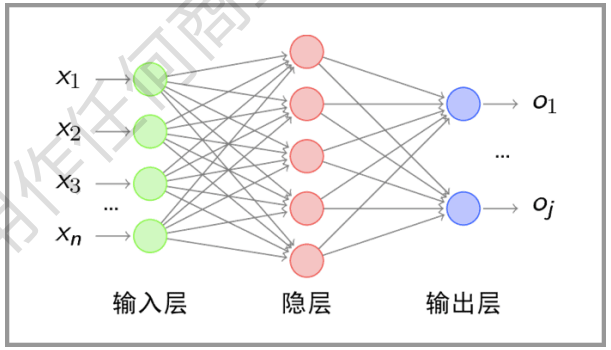
Convolved Feature



Convolved feature



Pooled feature



2x2 pooling, stride 2

9	3	5	3
10	32	2	2
1	3	21	9
2	6	11	7

Max pooling

32	5
6	21

Average pooling

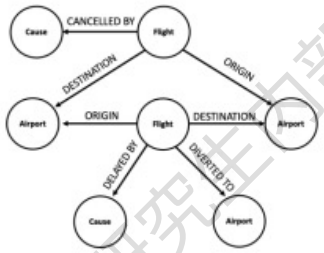
18	3
3	12

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播
知乎 @秋枫
https://blog.csdn.net/mrjkzhangma

图神经网络

- 深度学习→Graph

如何处理非结构化图数据？

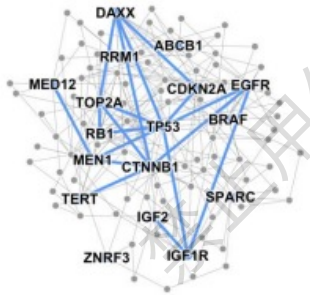


Event Graphs



Image credit: SalientNetworks

Computer Networks



Disease Pathways

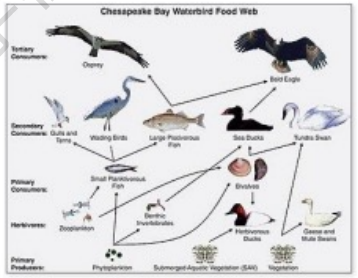


Image credit: Wikipedia

Food Webs



Image credit: Pinterest

Particle Networks



Image credit: visitlondon.com

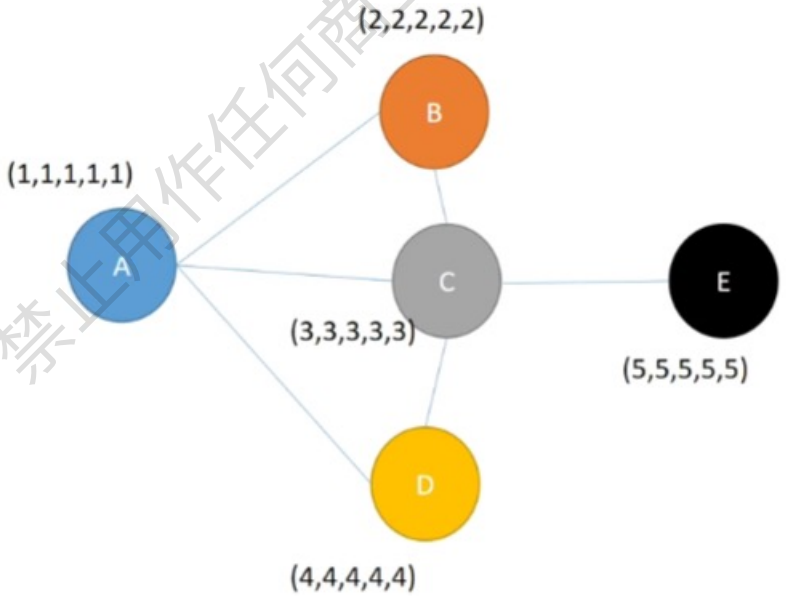
Underground Networks

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络原理-简单版

- 聚合信息
  - 对于A点其邻居信息 $N = a * (2,2,2,2,2) + b * (3,3,3,3,3) + c * (4,4,4,4,4)$

- 更新信息
  - A的信息=$\sigma(W((1,1,1,1,1) + \alpha * N))$



- 多层循环传播信息
  - 经过一次聚合更新之后，A中含有B,C,D的信息，C中有A,B,D,E的信息…
  - 第二次聚合时，以A节点为例，此时A可以获得二阶邻居E点的特征
  - 最终得到节点表示

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络原理

- 给定一张图 G，用$\mathbf{x}_v$表示结点v的特征，用$\mathbf{x}(u,v)$ 表示结点u与结点v之间边的特征
- **GNN的学习目标：**获得每个结点的图感知的隐藏状态 $\mathbf{h}_v$ (state embedding)，对于每个节点，它的隐藏状态包含了来自邻居节点的信息。

那么，如何让每个结点都感知到图上其他的结点呢？

GNN通过迭代式更新所有结点的隐藏状态来实现，在t+1时刻，结点v的隐藏状态按照如下方式更新：

$$\mathbf{h}_v^{t+1} = f(\mathbf{x}_v, \mathbf{x}_c o[v], \mathbf{h}_n^t e[v], \mathbf{x}_n e[v]),$$

f：隐藏状态的状态更新函数　　$\mathbf{x}_n e[v]$：结点v的邻居节点的特征

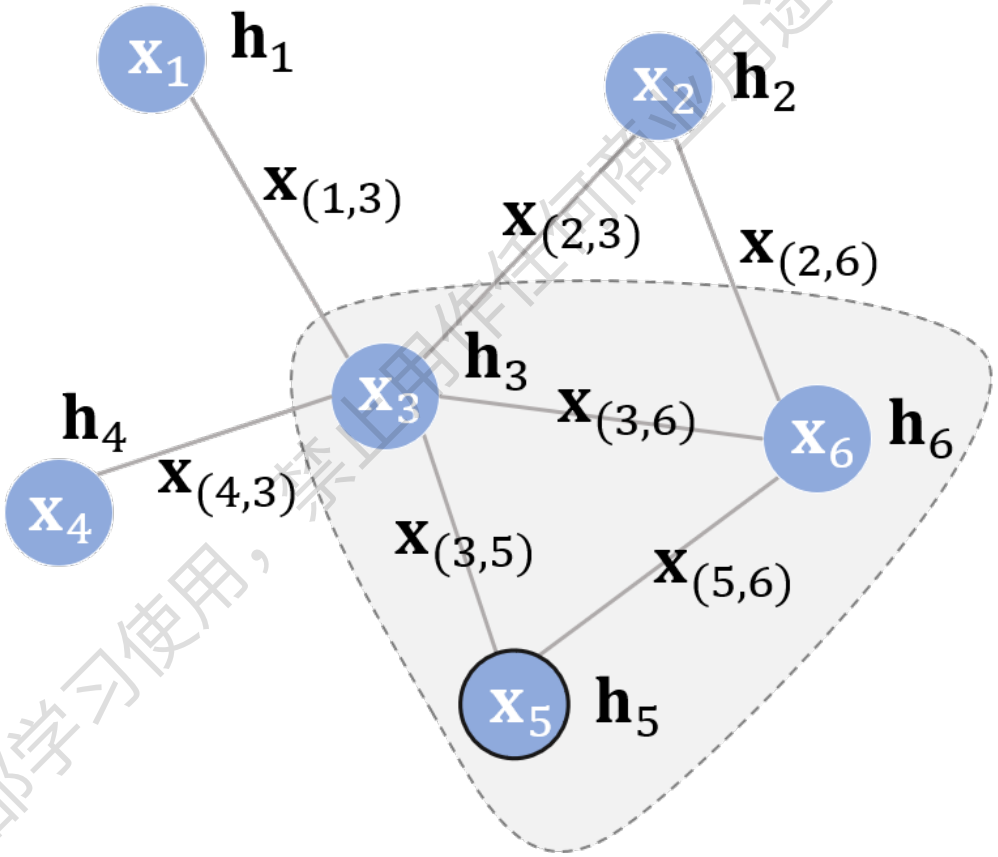
$\mathbf{x}_c o[v]$：与结点v相邻的边的特征　　$\mathbf{h}_n^t e[v]$：邻居节点在t时刻的隐藏状态

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络原理

- 假设结点5为中心结点，其隐藏状态的更新函数如图所示。
- 这个更新公式表达的思想自然又贴切：

不断地利用当前时刻邻居结点的隐藏状态作为部分输入来生成下一时刻中心结点的隐藏状态，直到每个结点的隐藏状态变化幅度很小，整个图的信息流动趋于平稳。

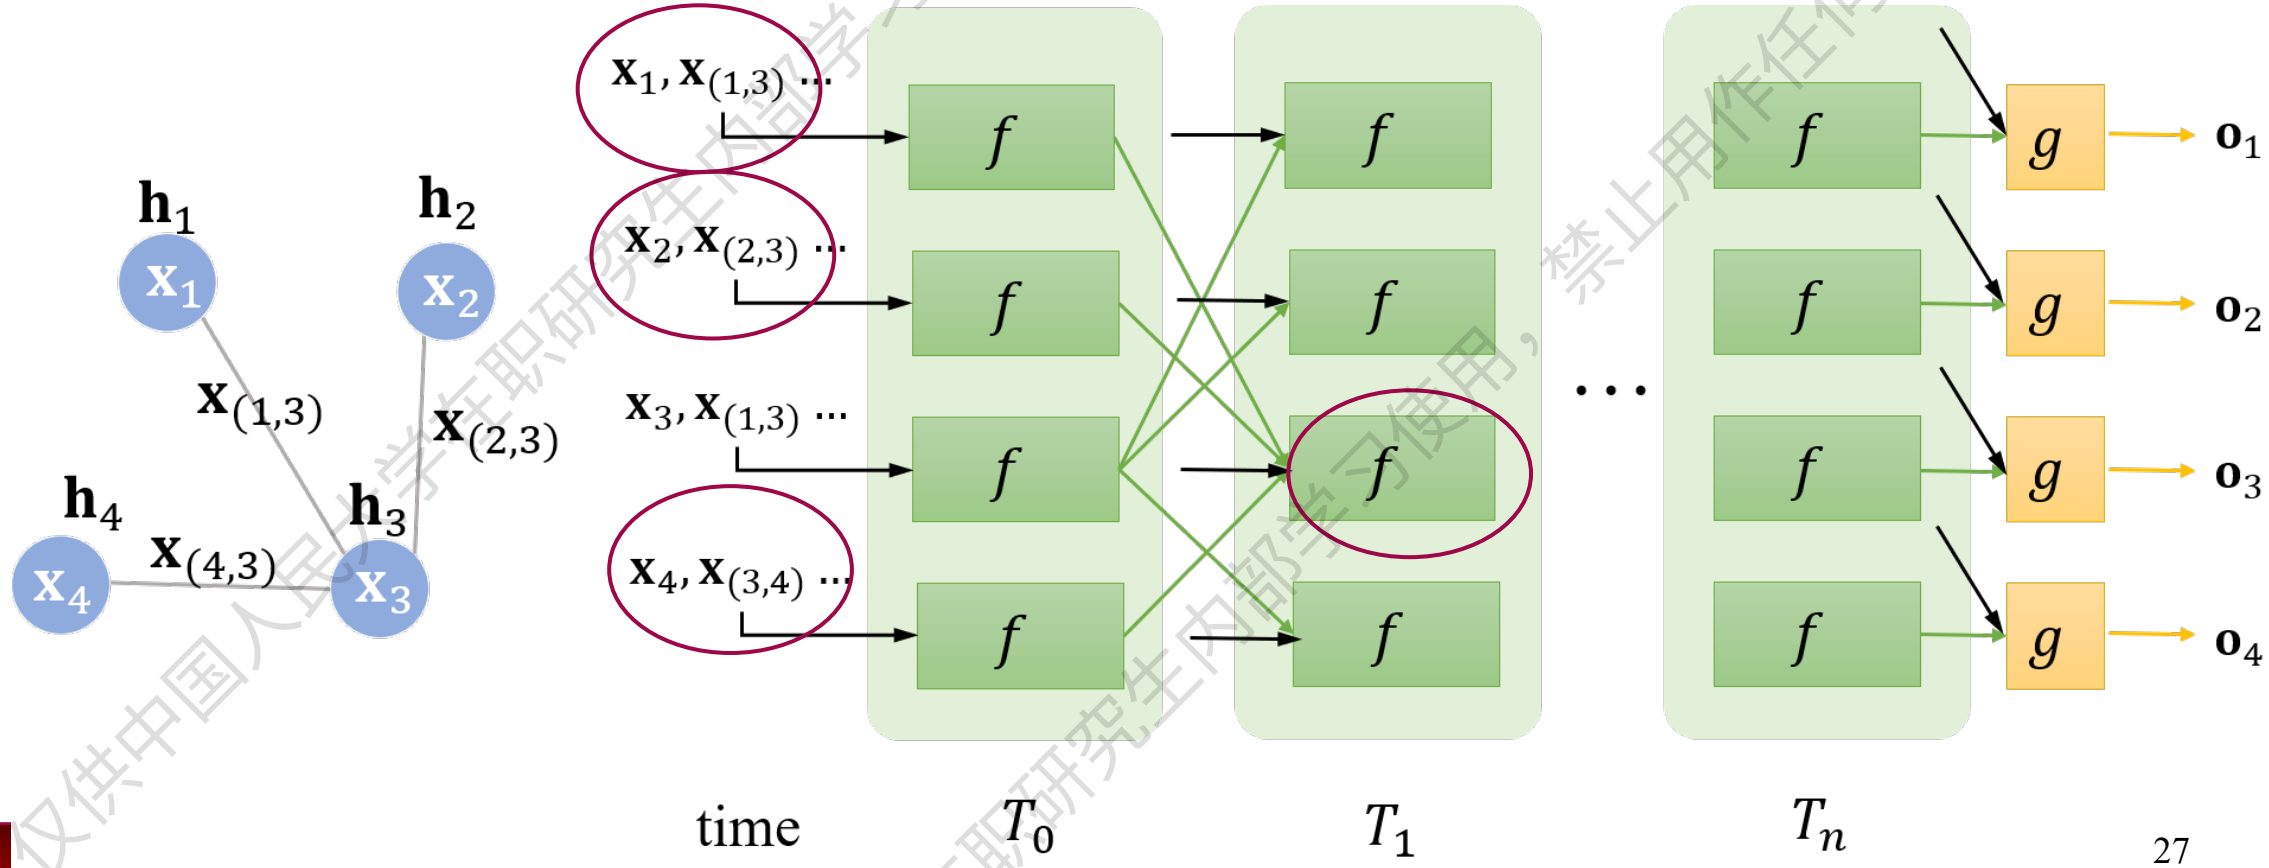


$$\mathbf{h}_5 = f\left(\mathbf{x}_5, \mathbf{x}_{(3,5)}, \mathbf{x}_{(5,6)}, \mathbf{h}_3, \mathbf{h}_6, \mathbf{x}_3, \mathbf{x}_6\right)$$

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络原理

- f是对所有结点都成立的，是一个全局共享的函数，利用神经网络(Neural Network)来拟合这个复杂函数 f



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络&图卷积网络

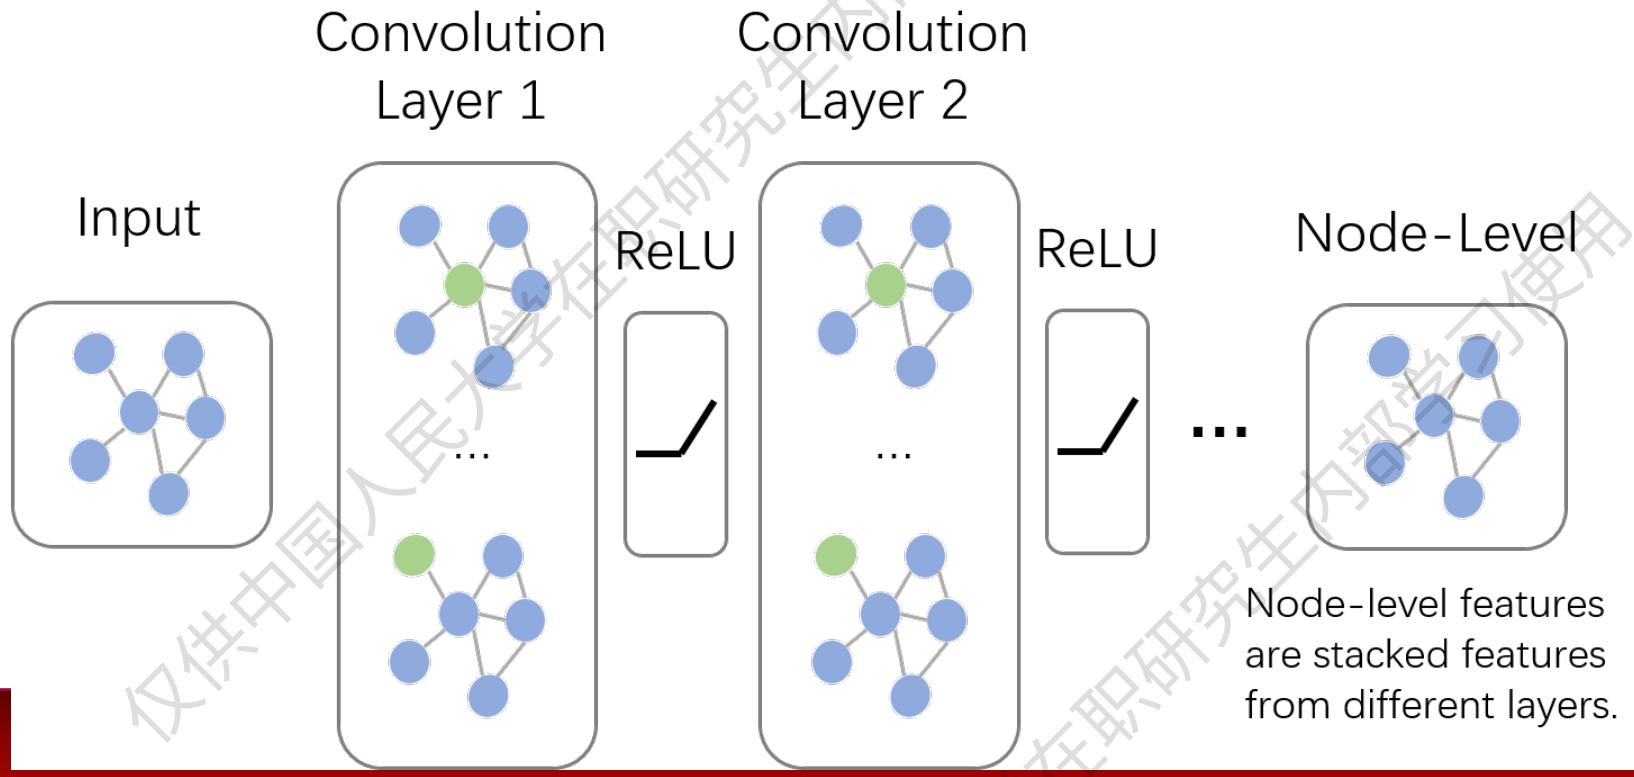
- **DNN→GNN:**
  - GNN可以看作是对现有的神经网络的扩展，关注处理图(graph) 中表示的数据。

- **CNN→GCN:**
  - GCN希望将卷积操作应用在图结构数据上，可以视作CNN的扩展

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图卷积网络（Graph Covolutional Networks ,GCN）

- 输入的是整张图，在Convolution Layer 1里，对每个结点的邻居都进行一次卷积操作，并用卷积的结果更新该结点；
- 然后经过激活函数如ReLU，然后再过一层卷积层Convolution Layer 2与一层激活函数；
- 反复上述过程，直到层数达到预期深度。

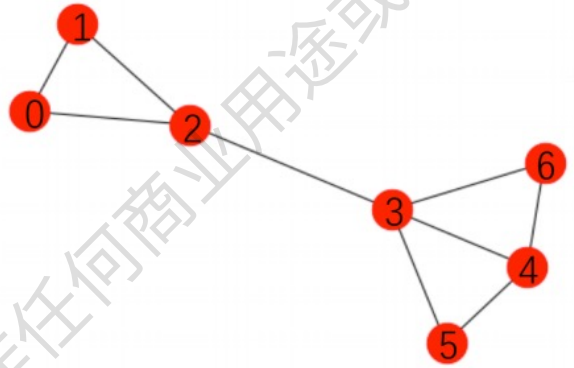


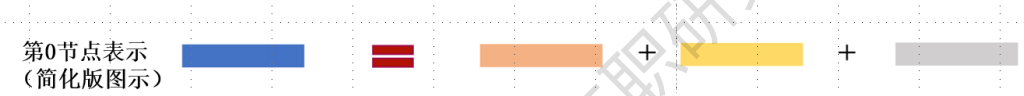
- GCN中通过级联的层捕捉邻居的消息，层与层之间的参数不同
- GNN通过级联的时间来捕捉邻居的消息，全局共享参数

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

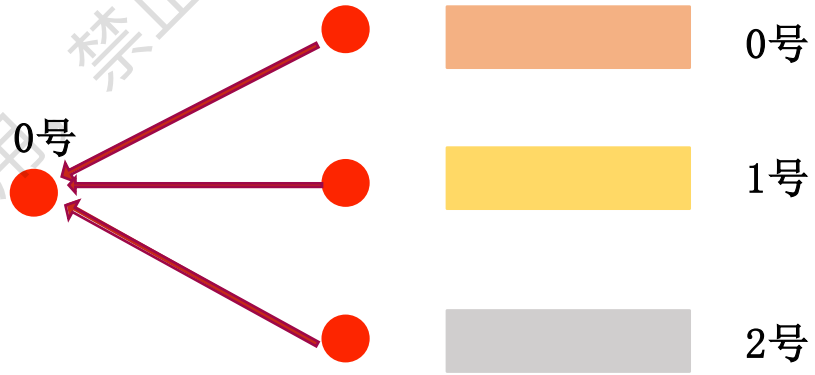
图卷积网络

- 消息传递机制(Message Passing)
  - 边上的源节点，往目标节点发送特征
  - 目标节点对收到的特征进行聚合





消息传递



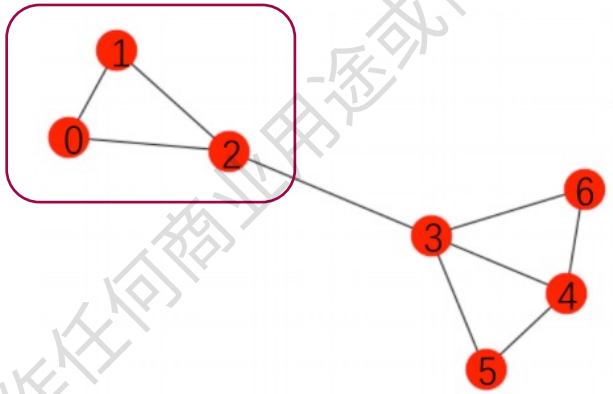
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

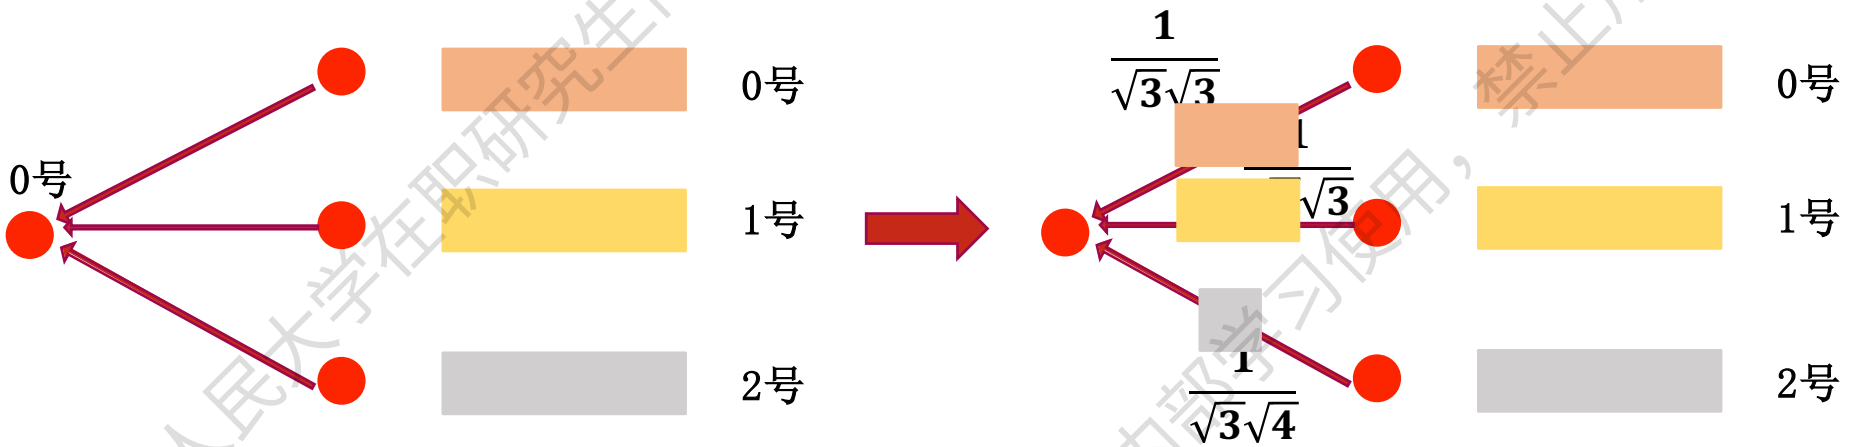
图卷积网络

给边加权

$$AH^{(l)} \Rightarrow D^{-\frac{1}{2}}AD^{-\frac{1}{2}}H^{(l)}$$

d越大，信息量越小，$\boldsymbol{d^{-\frac{1}{2}}}$越小



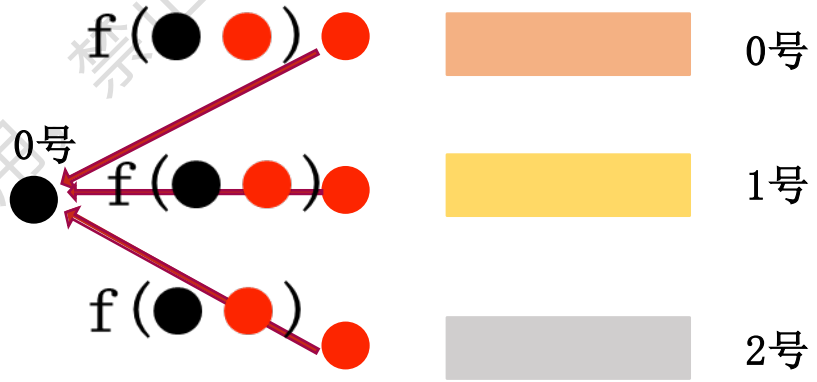


仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图注意力网络（Graph Attention Network，GAT）

- GCN中边的权重：
  - 与节点的度相关
  - 不可学习

- GAT中边的权重：f(● ●)
  - 权重变成节点间的函数
  - 权重与两个节点相关性有关
  - 可学习



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

Graph Sample and Aggregate（GraphSage）

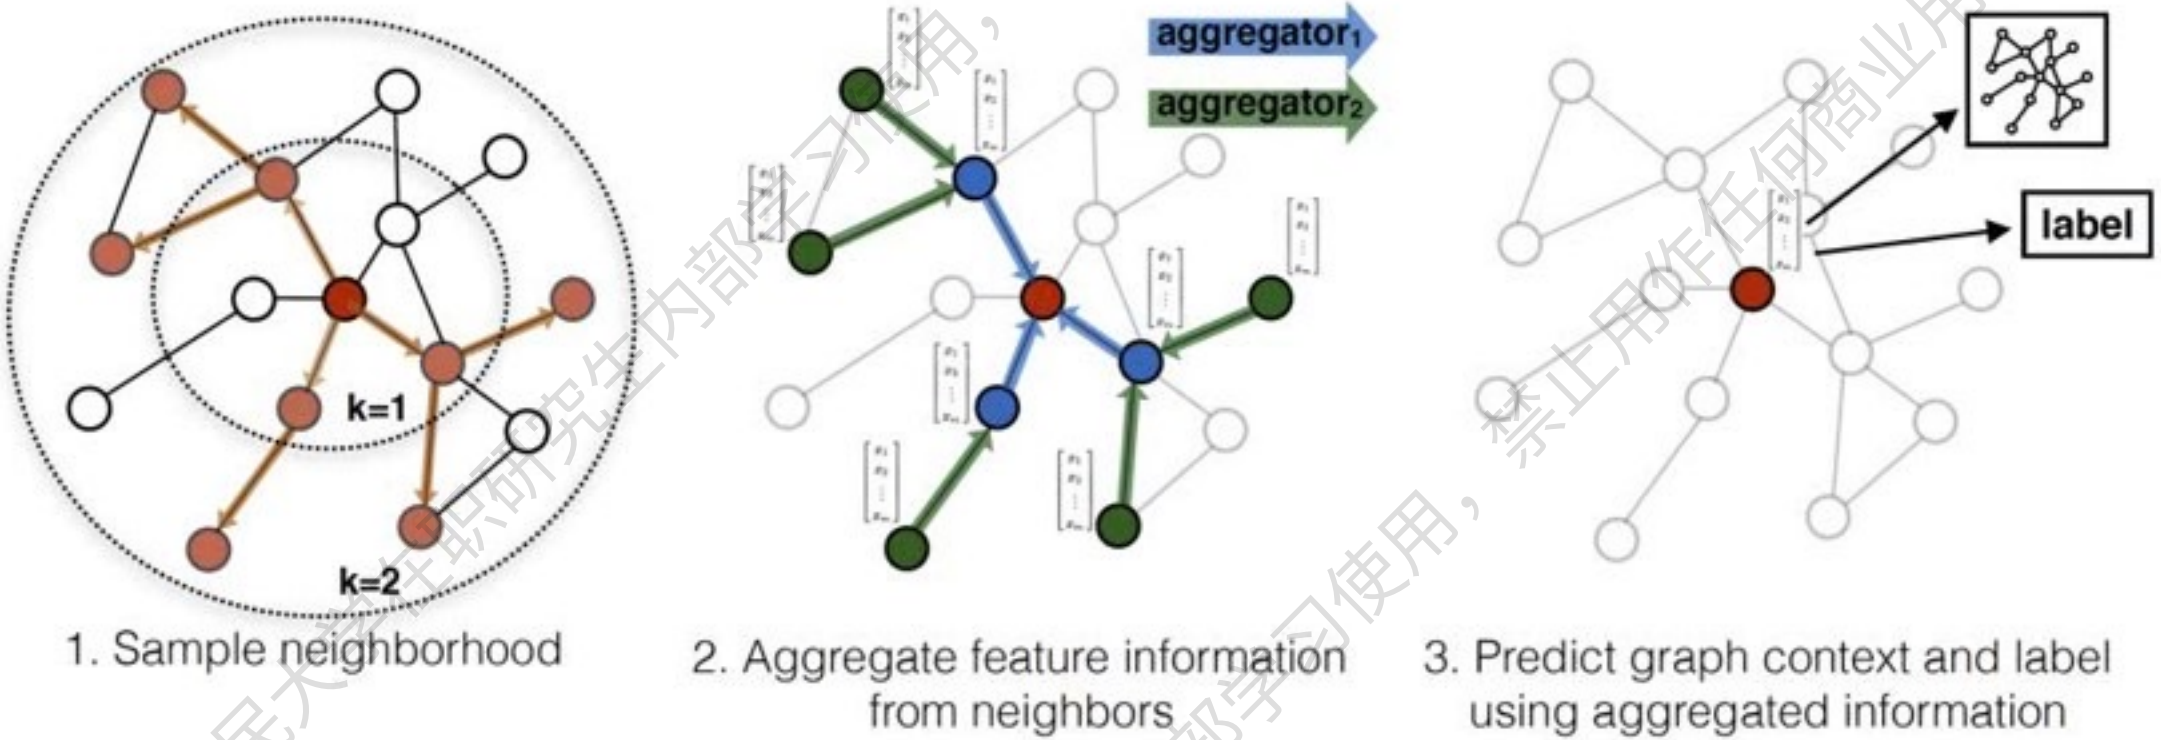
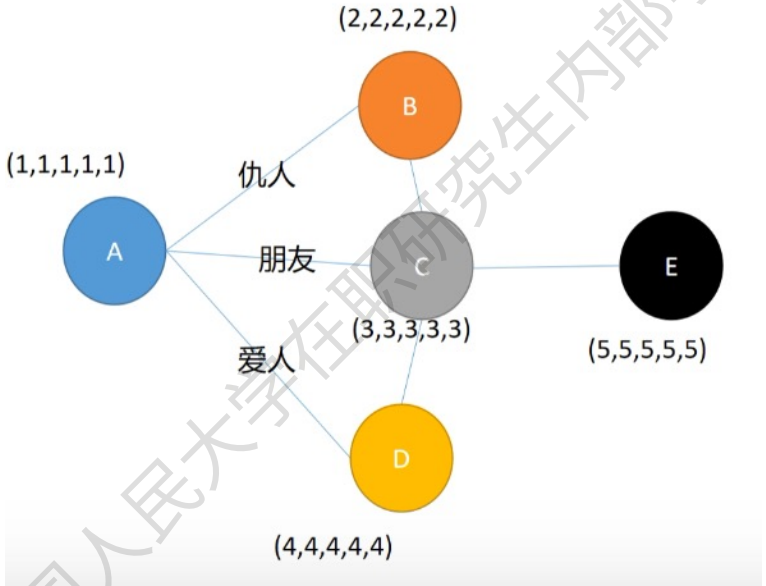


Figure 1: Visual illustration of the GraphSAGE sample and aggregate approach.

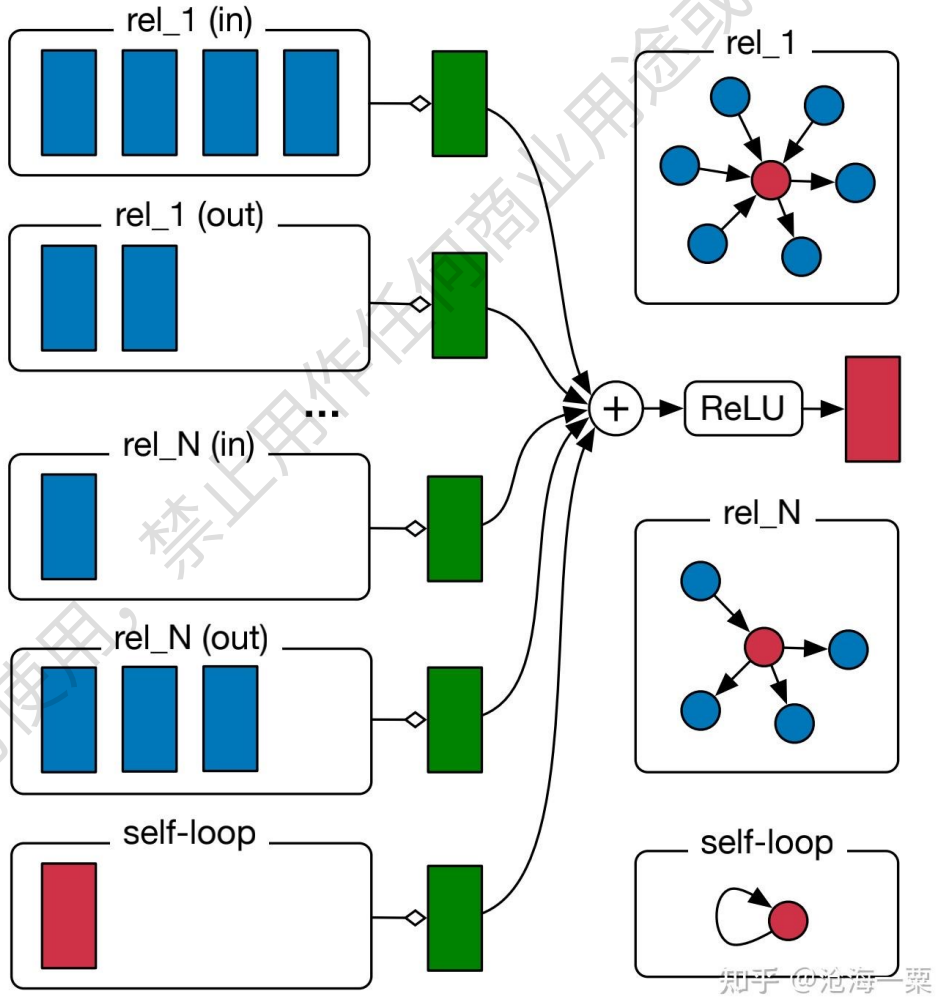
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

Relational GCN(R-GCN)

$$\mathbf{h}_v^{(l+1)} = \sigma\left(\sum_{r\in R}\sum_{u\in N_v^r}\frac{1}{c_{v,r}}\mathbf{W}_r^{(l)}\mathbf{h}_u^{(l)} + \mathbf{W}_0^{(l)}\mathbf{h}_v^{(l)}\right)$$



实例

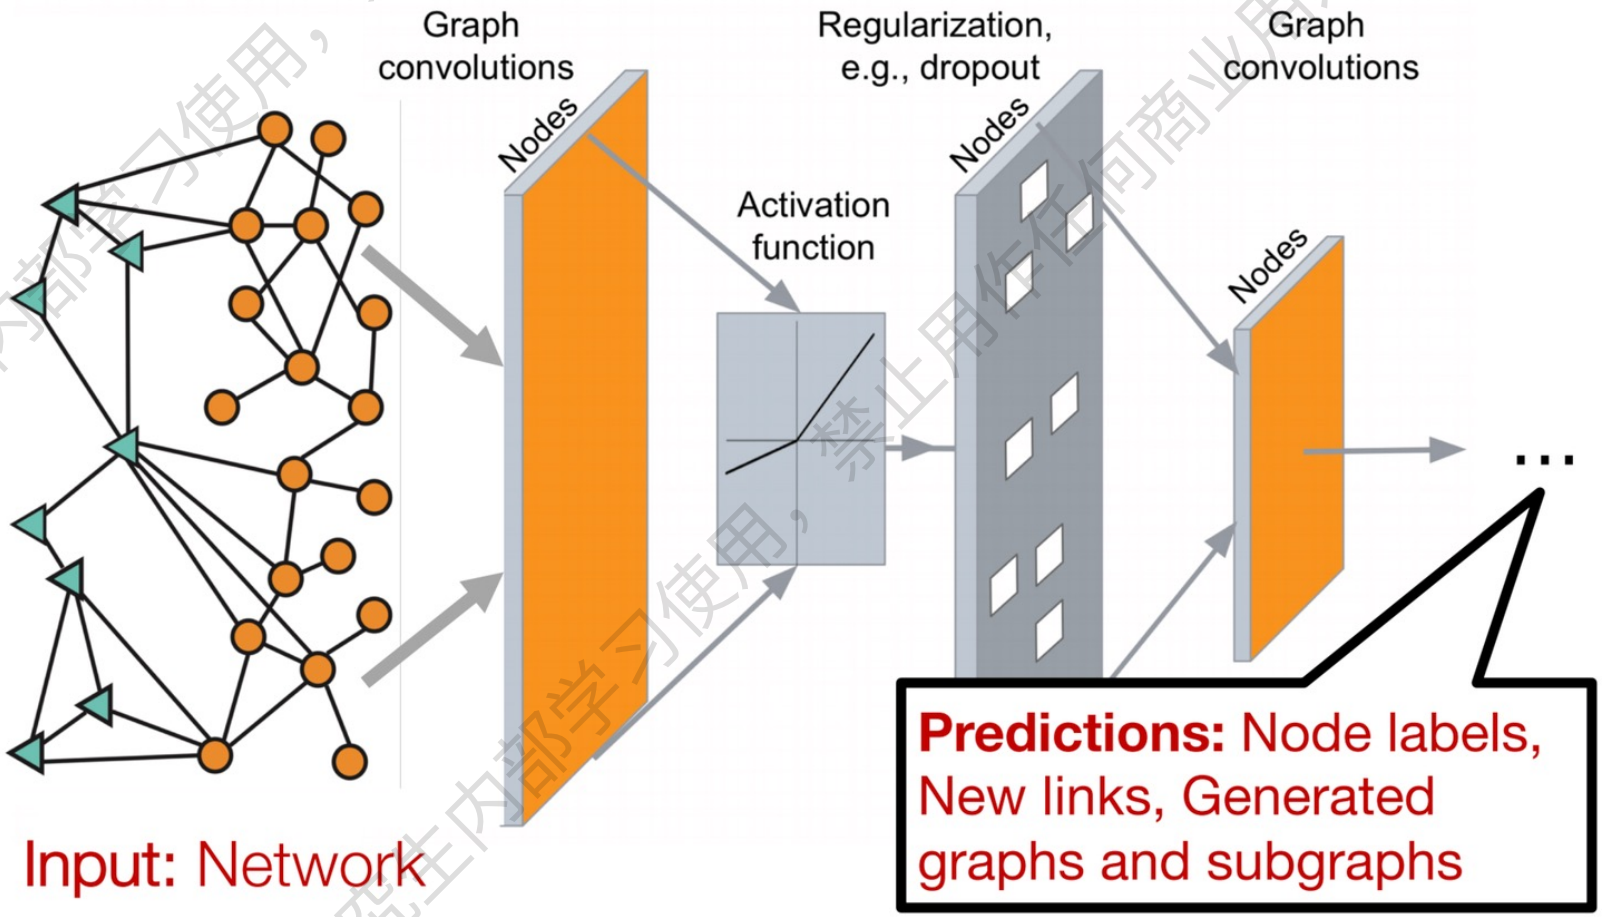


R-GCN模型图

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

图神经网络应用

- Node embedding
- Link: node pair



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

小结

- 一般算法：GNN GCN
- 区分节点作用：GAT
- 大规模图：GraphSAGE
- 异构图：RGCN

其他，参见：Zhou, Jie, et al. "Graph neural networks: A review of methods and applications." *AI open* 1 (2020): 57-81.

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

作业：社会网络案例分析

- 假设你现在正在承担某银行大数据风控建模工作，针对借款人进行信贷评估，目前可以获得借款人的工作地址、姓名、身份证、单位、IP 地址、联系人手机号等信息，请尝试采用社会网络分析方法解决该问题
  - 请描述该社会网络的节点和边，并画出该网络
  - 请阐述什么网络特征可用于解决信贷评估问题，为什么

线上同学请扫码作答

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

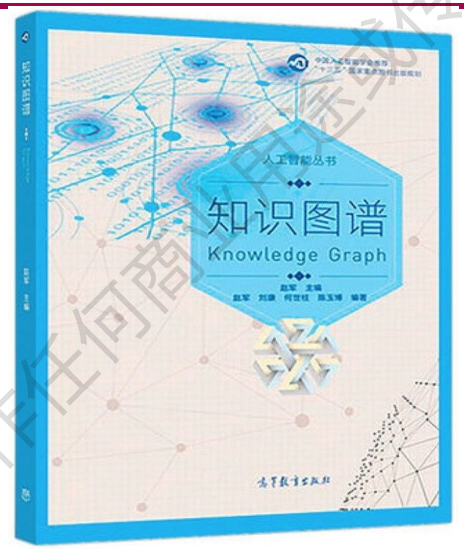


二. 知识图谱

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

扩展阅读

- 赵军 主编，《知识图谱》
- 王昊奋 等主编，《知识图谱：方法、实践与应用》
- 邵浩等著，《从零构建知识图谱：技术、方法与案例》
- 网络资源
  - https://download.csdn.net/download/baijinswpu/10715397
  - CSDN





仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

1. 什么是知识图谱？

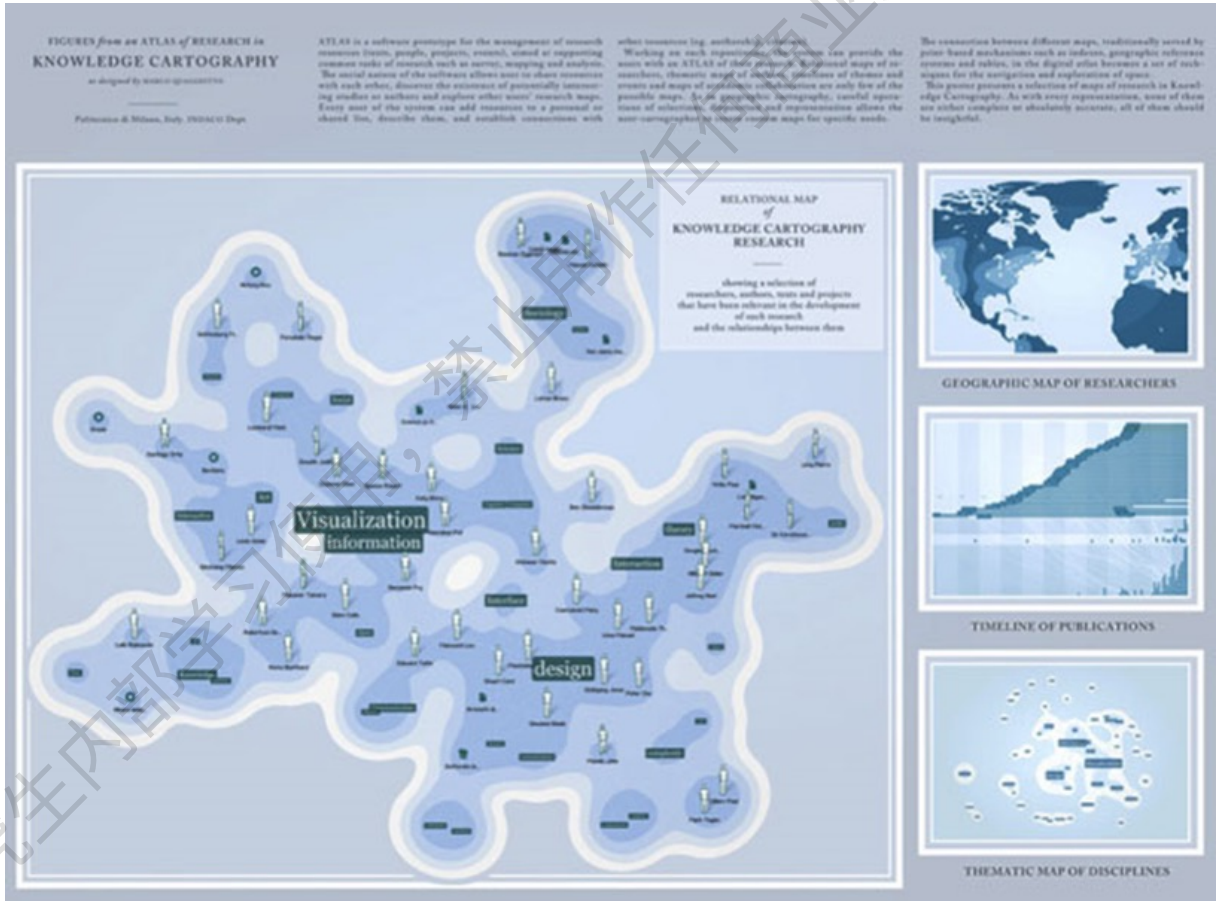
- 知识图谱辨别
  - 知识地图-knowledge map
  - 知识术语-glossary
  - 科学知识图谱（绘制）-mapping knowledge domains

- 知识图谱-knowledge graph

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识地图（knowledge map）

- 地理学领域
- 以二维/三维空间形式显示地形和人类活动及相关特征



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

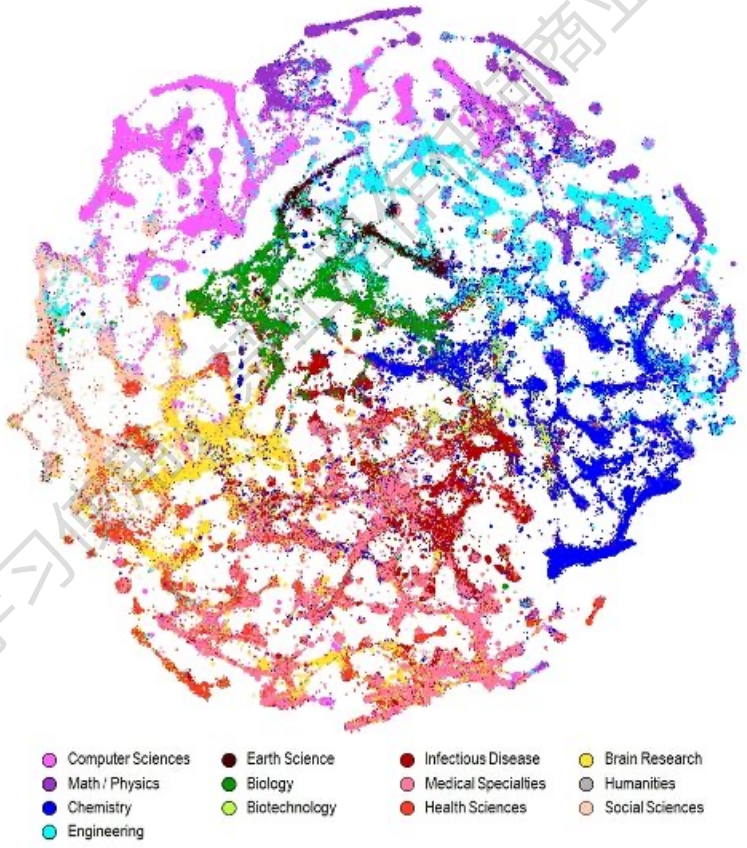
知识术语/词典-Glossary



仅供中国人民大学在职研究生课程学习使用，禁止用作任何商业用途或传播

科学知识图谱（绘制）-mapping knowledge domains

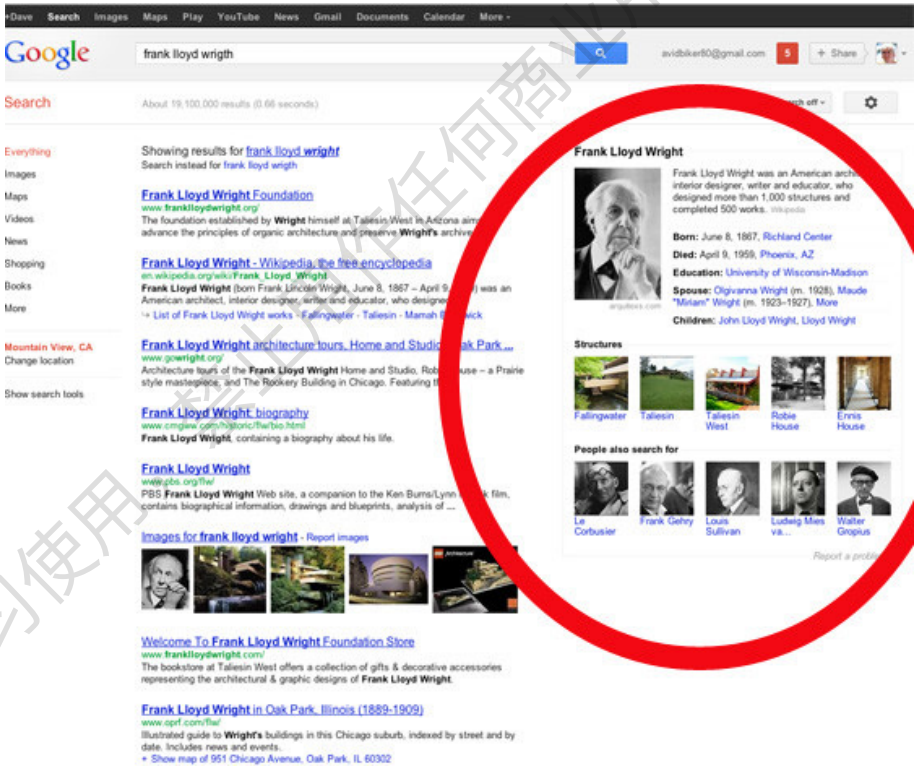
- 科学计量学（Scientometrics），研究学科领域发展规律
- 社会网络分析图谱；学术群体及代表人物知识图谱



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱-knowledge graph

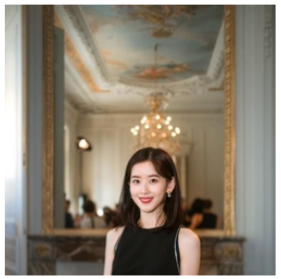
- 2012年5月，Google在其官博上发表了一篇博文：Introducing the Knowledge Graph: things, not strings 首次提出知识图谱概念。
- **智能搜索：**借助知识图谱，搜索引擎实现了从strings到Things的飞跃，机器会理解关键词所代表的实际含义



刘强东的妻子 百度一下

网页 资讯 视频 图片 知道 文库 贴吧 采购 地图 更多»

百度为您找到相关结果约4,690,000个 搜索工具



刘强东妻子：

章泽天

章泽天，1993年11月18日出生于南京，网络红人。2009年因一张手捧奶茶的照片走红网络，被称为“奶茶妹妹”。2011年，章泽天就读清华大学。2014年4月14日，章泽天与刘强东... 详情>>

来自百度百科

刘强东的毕业学校 百度一下

网页 资讯 视频 图片 知道 文库 贴吧 地图 采购 更多

百度为您找到相关结果约1,260,000个 搜索工具



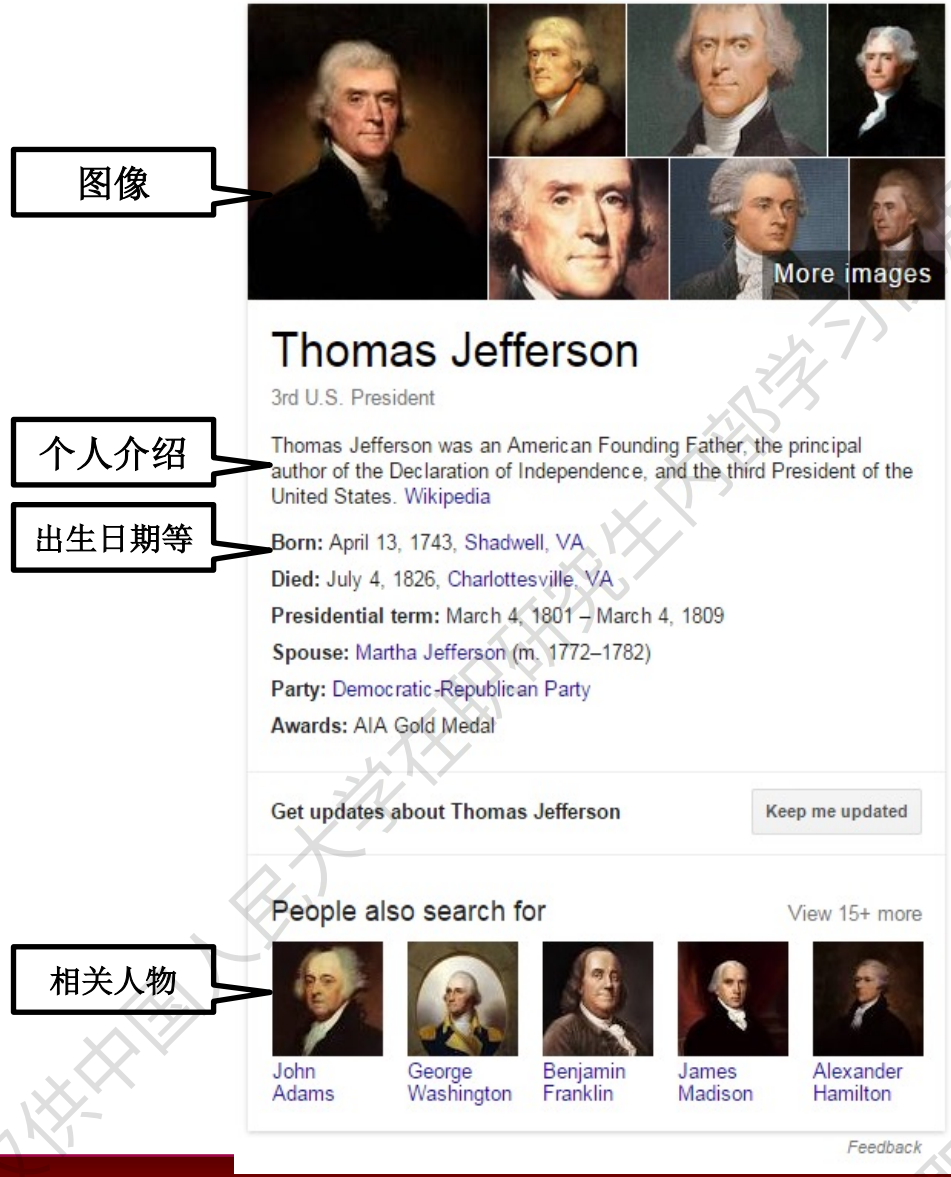
刘强东毕业院校：

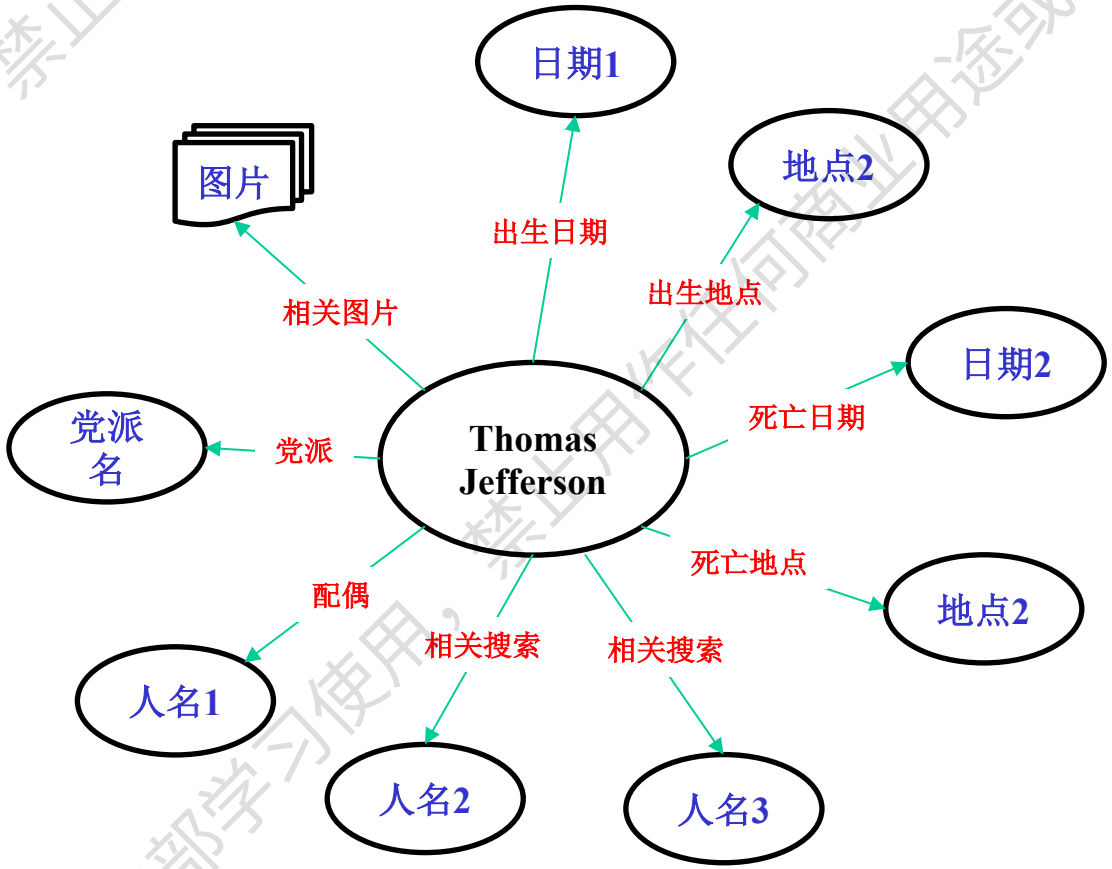
来自百度百科

中国人民大学

刘强东，男，汉族，1974年2月14日生，江苏宿迁人，祖籍湖南湘潭。京东集团董事局主席兼首席执行官，本科毕业于中国人民大学，民建会员，河北省阜平县平石头村名誉村主任。1998年6月18日，... 详情 >

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播





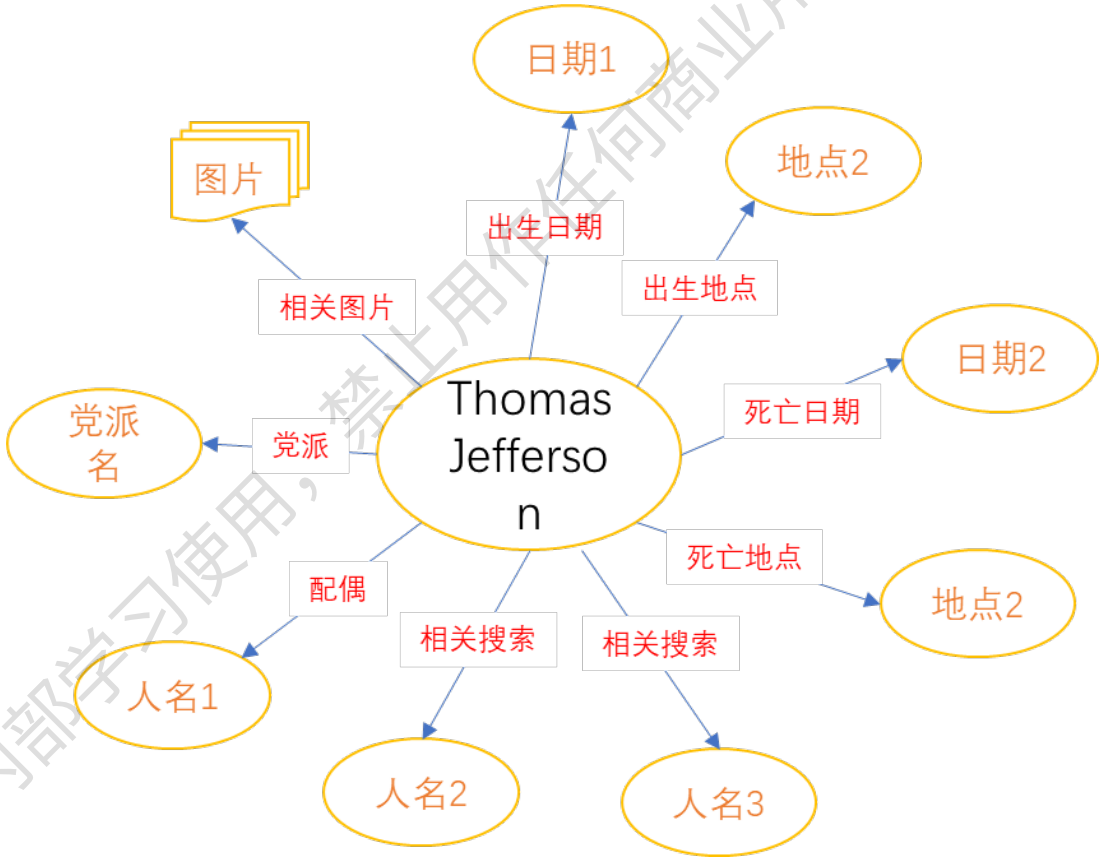
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

Google搜索页面

知识图谱

直观感受

- 知识图谱是一种具有图结构的知识库，通过边将节点连接在一起
- 知识图谱可以看做一类语义网络（semantic network)
- 在搜索引擎中，知识图谱可以提高用户搜索体验
  - Google背后的知识图谱：freebase [2016年5月关闭]

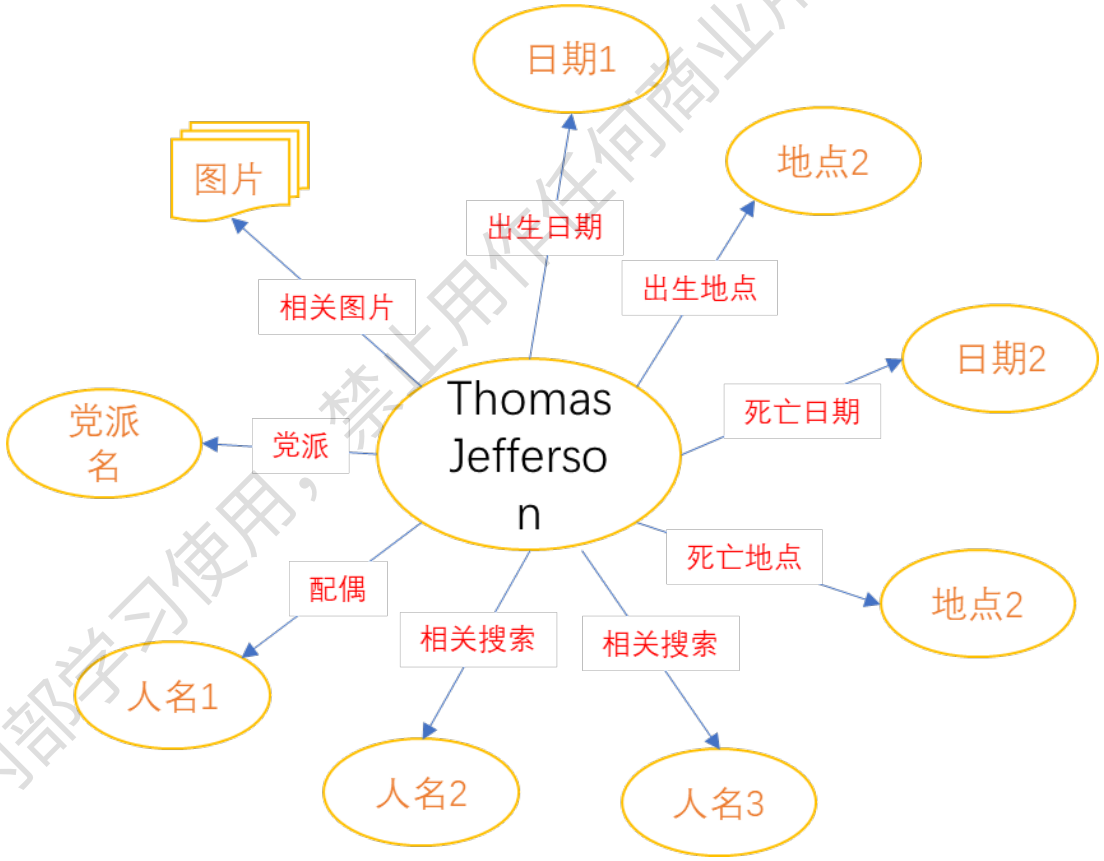


知识图谱样例

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱的定义

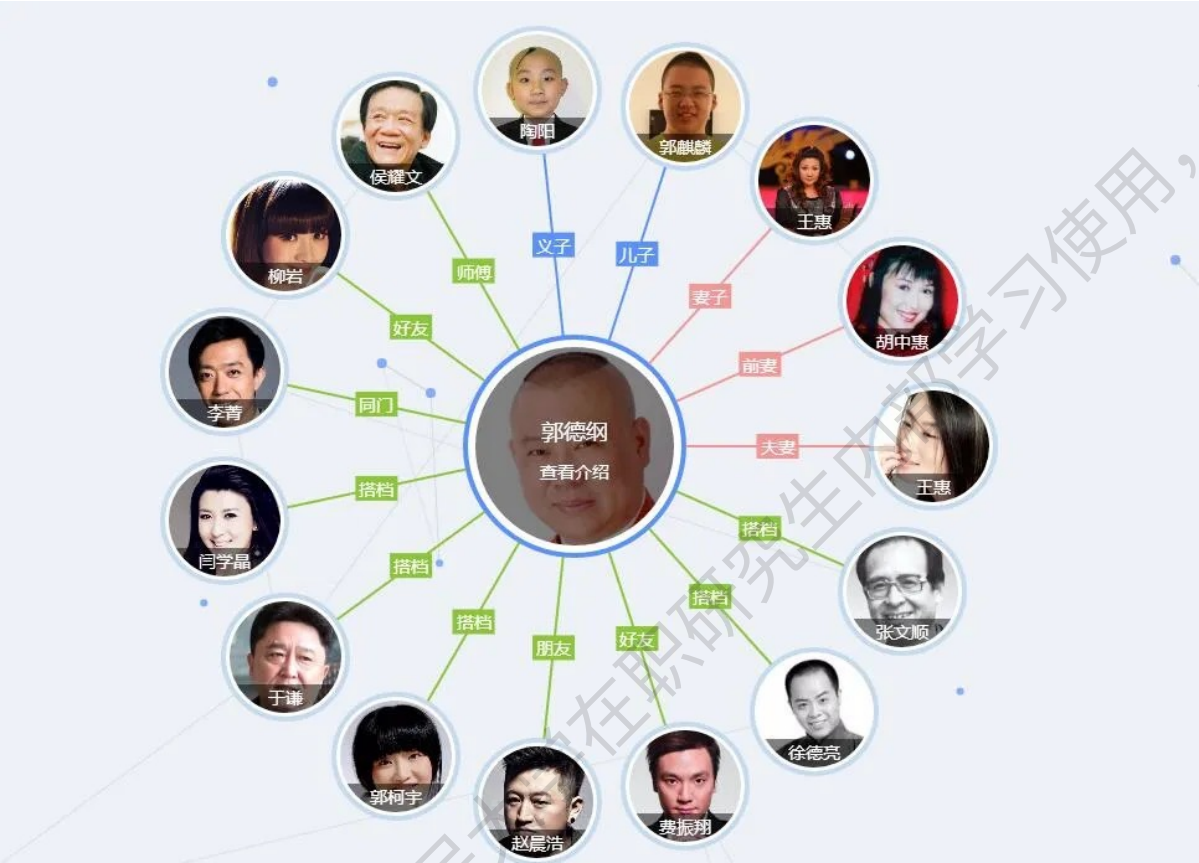
- 什么是知识图谱？
- 知识图谱就是用图的形式将知识表示出来。图中的结点代表语义实体或概念，边代表结点间的各种语义关系



知识图谱样例

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

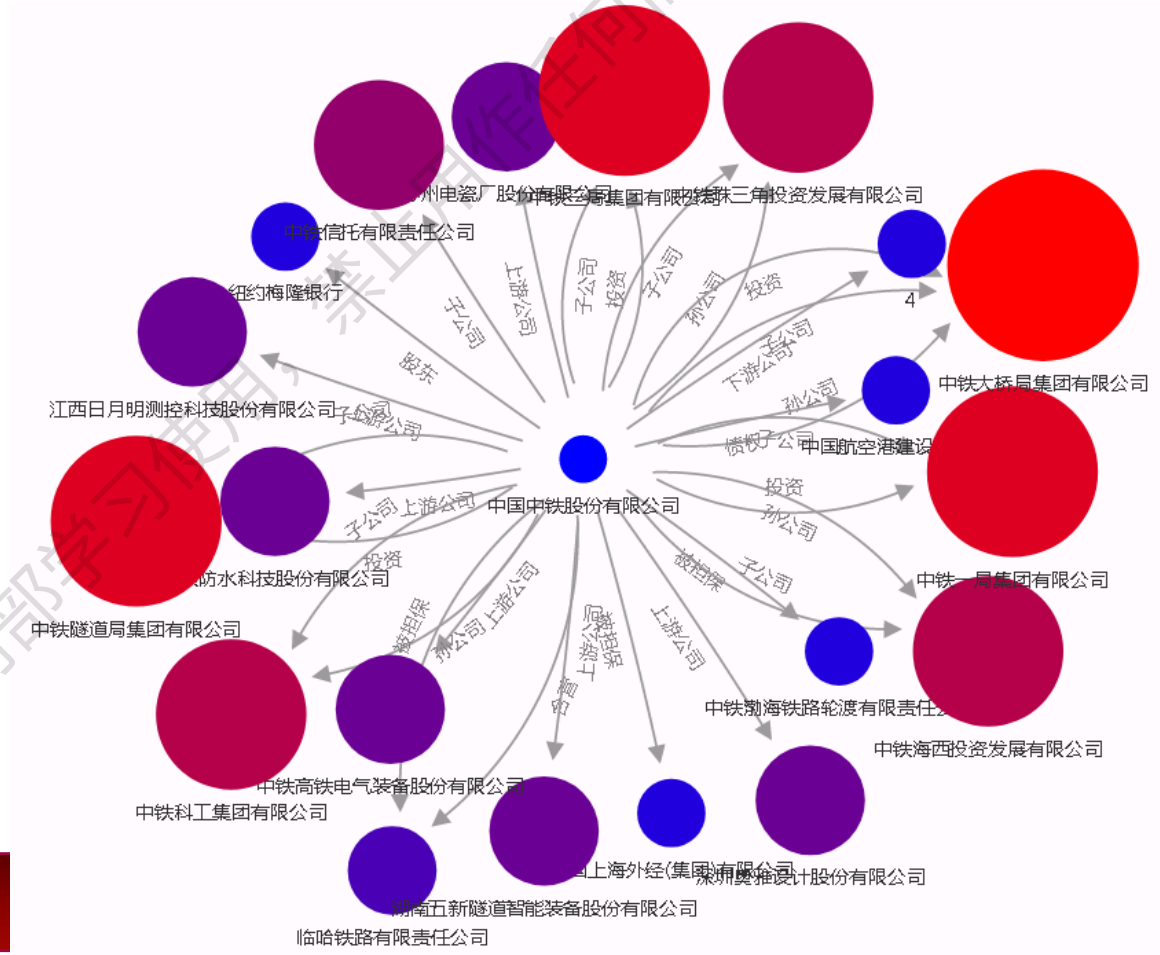
知识图谱-实例



搜狗人物知识图谱

企业知识图谱

企查查/天眼查



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

2. 知识图谱概念的演化

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

语义网络 ⇩ 1960

本体论 ⇩ 1980

Web ⇩ 1989

语义网 ⇩ 1998

链接数据 ⇩ 2006

知识图谱 ⇩ 2012

我有两个梦想：第一个是连接世界上的每一个人。现在这个梦想已经实现了。

我的第二个梦想是连接世界上的每一个事物。这个光荣的使命交给了语义网！



万维网之父
Tim Berners

Semantic web, web 3.0
Web of knowledge, or web of things
***语义网是一种数据互联的语义网络，它仍然基于图和链接的组织方式，但结点不再是网页，而是实体。

2. 知识图谱概念的演化

中国人民大學 RENMIN UNIVERSITY OF CHINA

语义网络 ⇩ 1960

本体论 ⇩

Web ⇩ 1989

语义网 ⇩ 1998

链接数据 ⇩ 2006

知识图谱 ⇩ 2012

我有两个梦想：第一个是连接世界上的每一个人。现在这个梦想已经实现了。

我的第二个梦想是连接世界上的每一个事物。这个光荣的使命交给了语义网！

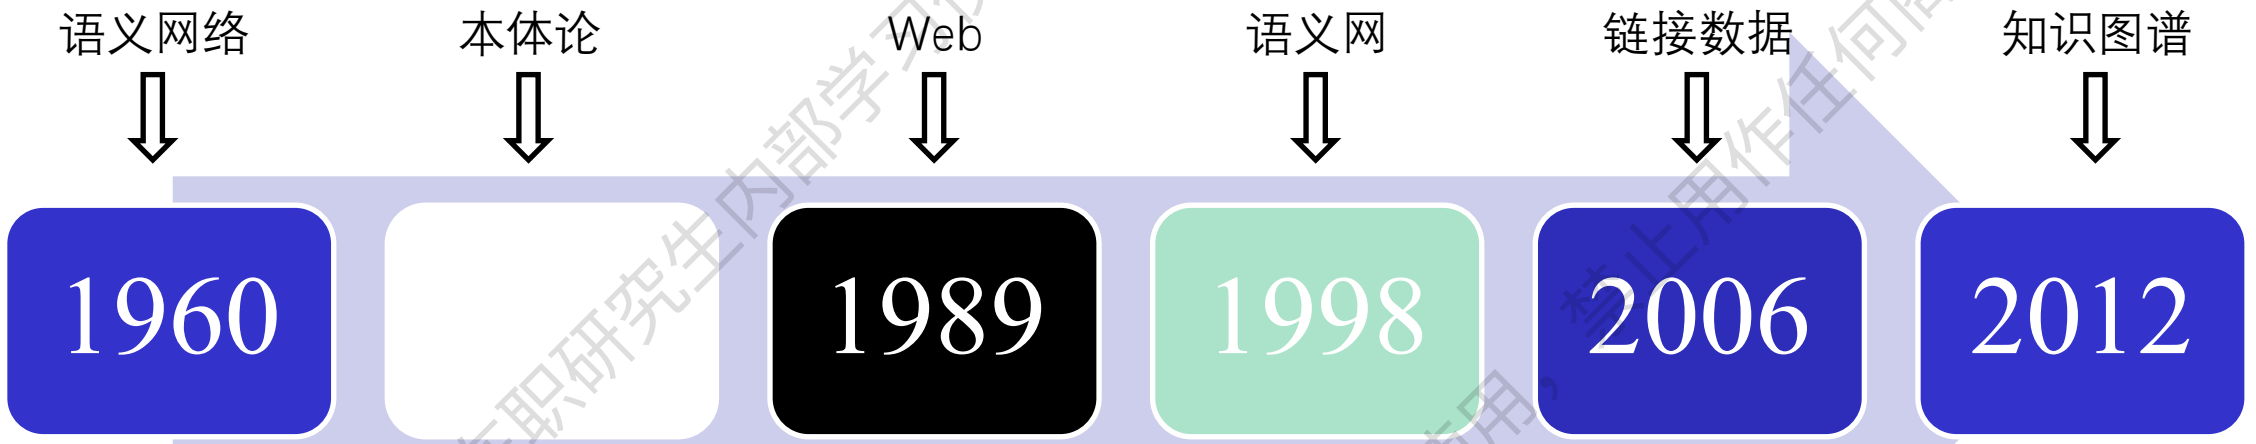


万维网之父
Tim Berners

Linked Data
链接数据起初是用于定义如何利用语义网技术在网上发布数据，其强调在不同的数据集间创建链接。

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

2. 知识图谱概念的演化



Google基于语义网中的一些理念进行了商业化实现，提出的知识图谱概念沿用至今

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱中的常见概念

- 实体
  - 知识图谱中的结点，人、地方、组织机构、概念等
- 属性
  - 描述一类实体的特性，如身高、年龄等，属性也可以定义为关系
- 关系
  - 对应实体之间的关系，将实体链接起来，如姚明的国籍是中国

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱的形式化表示

- 以结构化三元组的形式存储现实世界中的实体以及实体之间的关系，

$$G = (\mathcal{E}, \mathcal{R}, \mathcal{S})$$

$\mathcal{E}$实体集合， $\mathcal{R}$关系集合， $\mathcal{S}$三元组集合。

- 实体也可以是音频、视频等 【多模态知识图谱】

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

3. 为什么需要知识图谱

- 和传统数据库相比，知识图谱与哪些优势？

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

关系数据库&知识图谱

学生表（Student）

S#	Sname	Sage	Ssex
1	刘一	18	男
2	钱二	19	女
3	张三	17	男
4	李四	18	女
5	王五	17	男
6	赵六	19	女

课程表（Course）

C#	Cname	T#
1	语文	1
2	数学	2
3	英语	3
4	物理	4

教师表（Teacher）

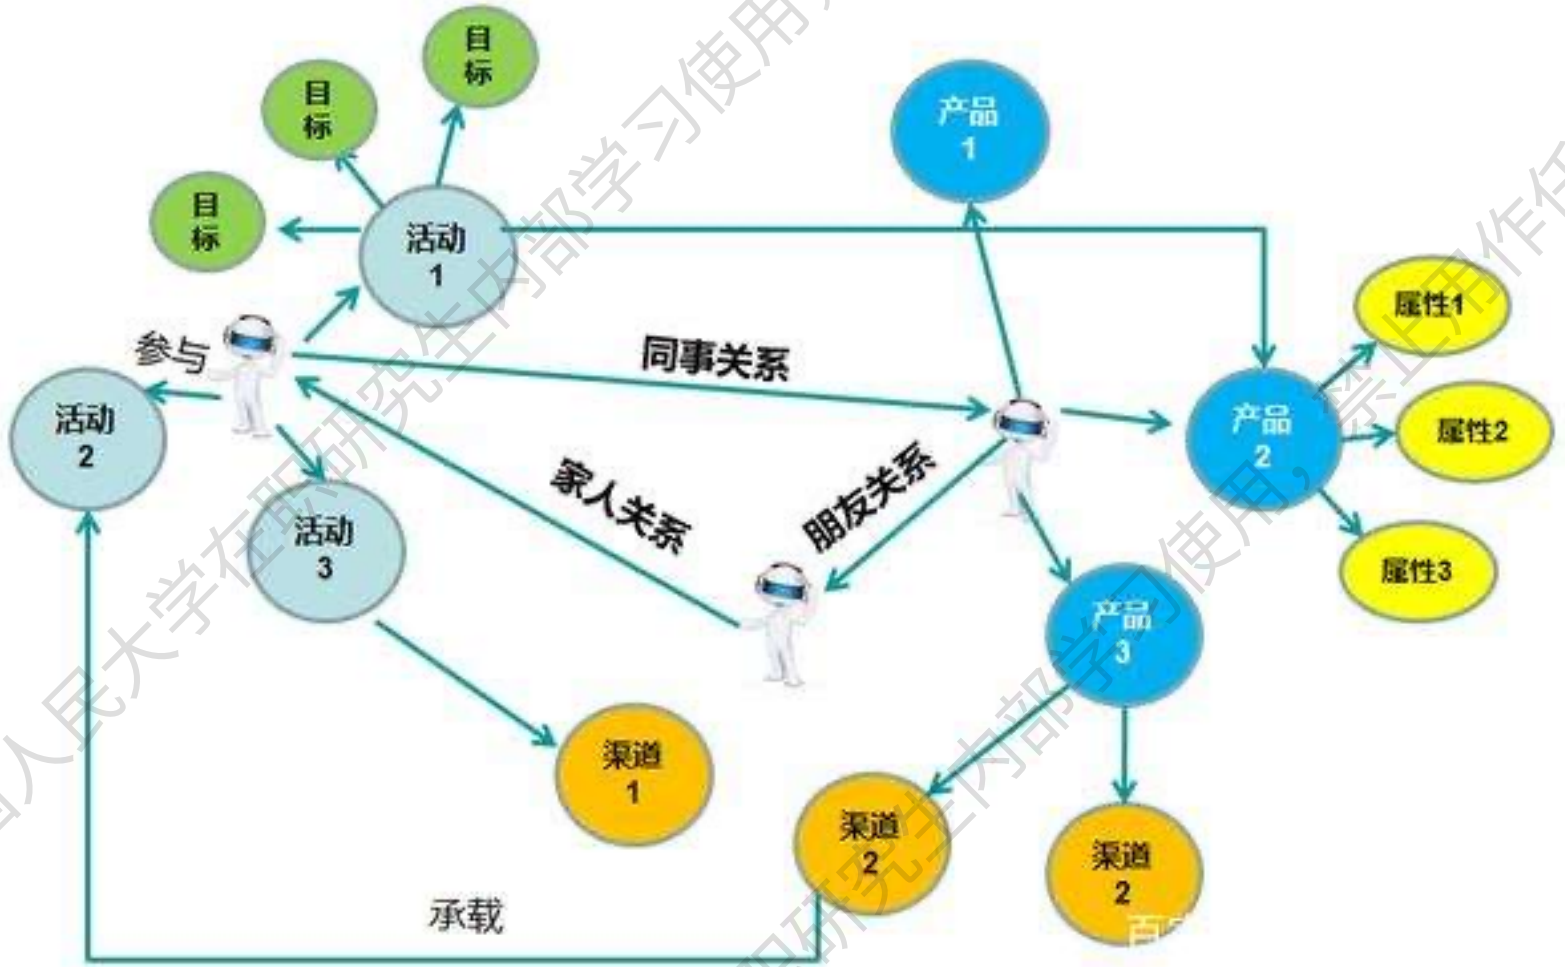
T#	Tname
1	叶平
2	贺高
3	杨艳
4	周磊

成绩表（Sc）

S#	C#	score
1	1	56
1	2	78
1	3	67
1	4	58
2	1	79
2	2	81
2	3	92
2	4	68
3	1	91
3	2	47
3	3	88
3	4	56
4	2	88
4	3	90
4	4	93
5	1	46
5	3	78
5	4	53
6	1	35
6	2	68
6	4	71

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

关系数据库&知识图谱



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

4. 知识图谱类型

- 通用知识图谱
  - 语言知识图谱

    WordNet; 中文知网词库HowNet
  - 常识知识图谱

    Cyc/OpenCyc; ConceptNet
  - 百科知识图谱 [众包]

    Freebase; DBpedia; YAGO; Wikidata



- 领域知识图谱

  医学知识图谱SIDER（Side Effect Resource）；电影知识图谱IMDB（Internet Movie Database）；音乐知识图谱（MusicBrainz）

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5. 知识图谱生命周期



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.1 知识体系构建

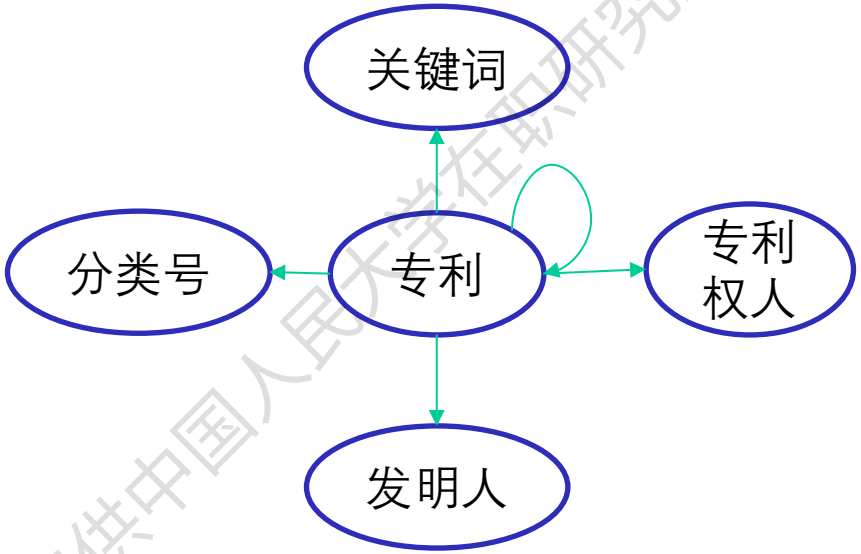
- 目标：构建一个本体对目标知识进行描述
- 在这个本体中，需要定义出：
  - 知识的类别体系
  - 每个类别下所属的概念和实体
  - 某类概念和实体所具有的属性
  - 概念之间、实体之间的语义关系

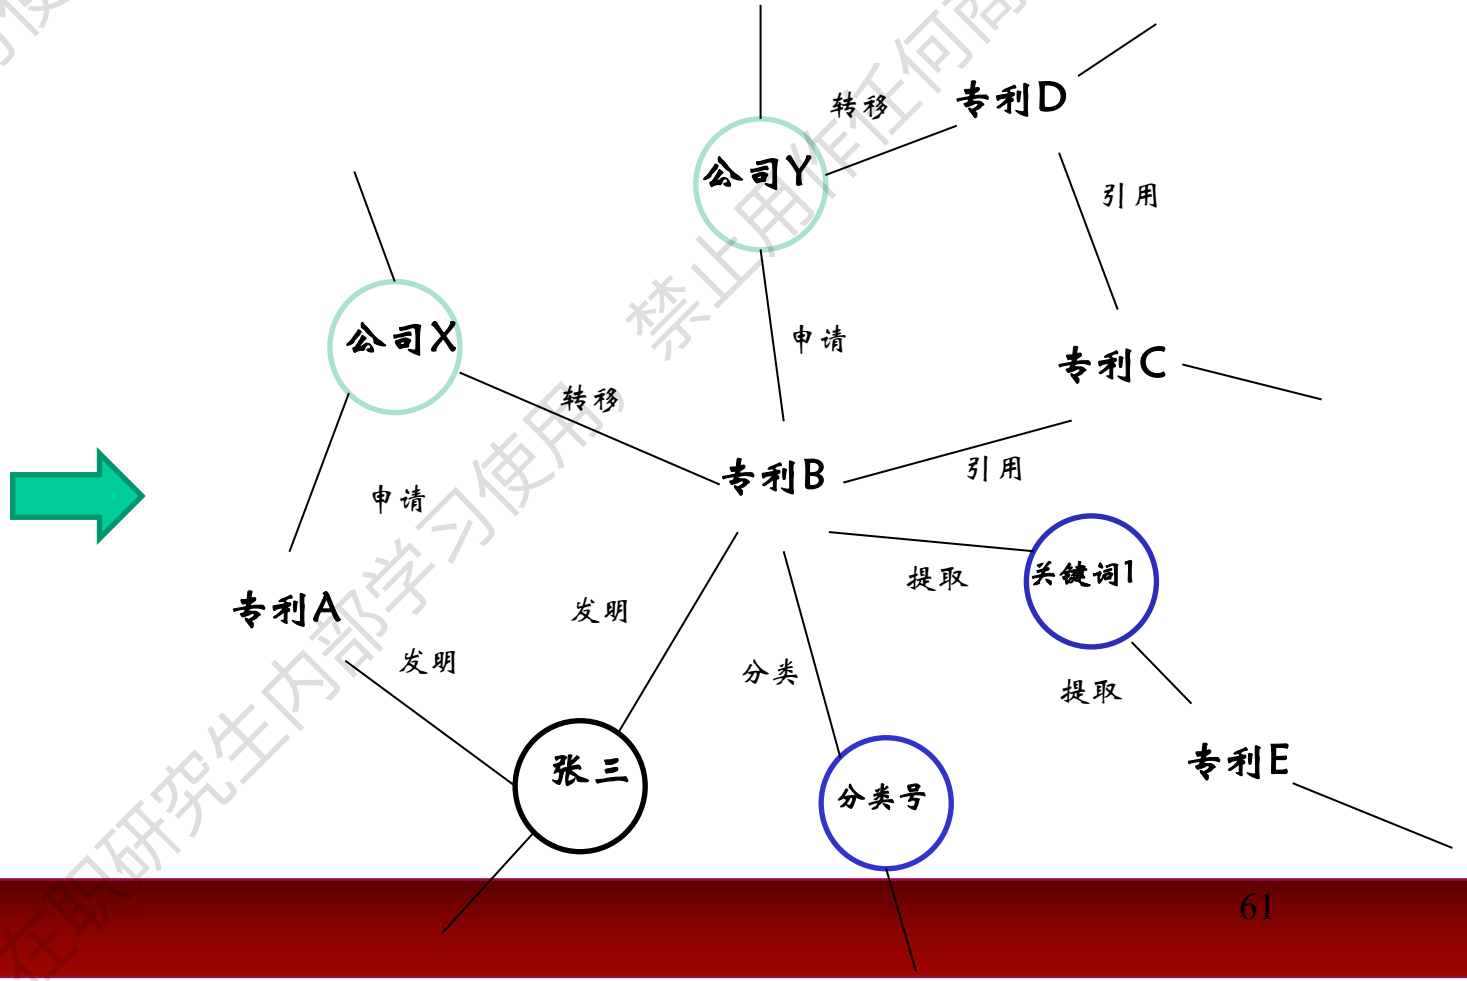
- 常用工具：Protégé本体编辑器

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识体系构建

- E.g., 专利知识体系

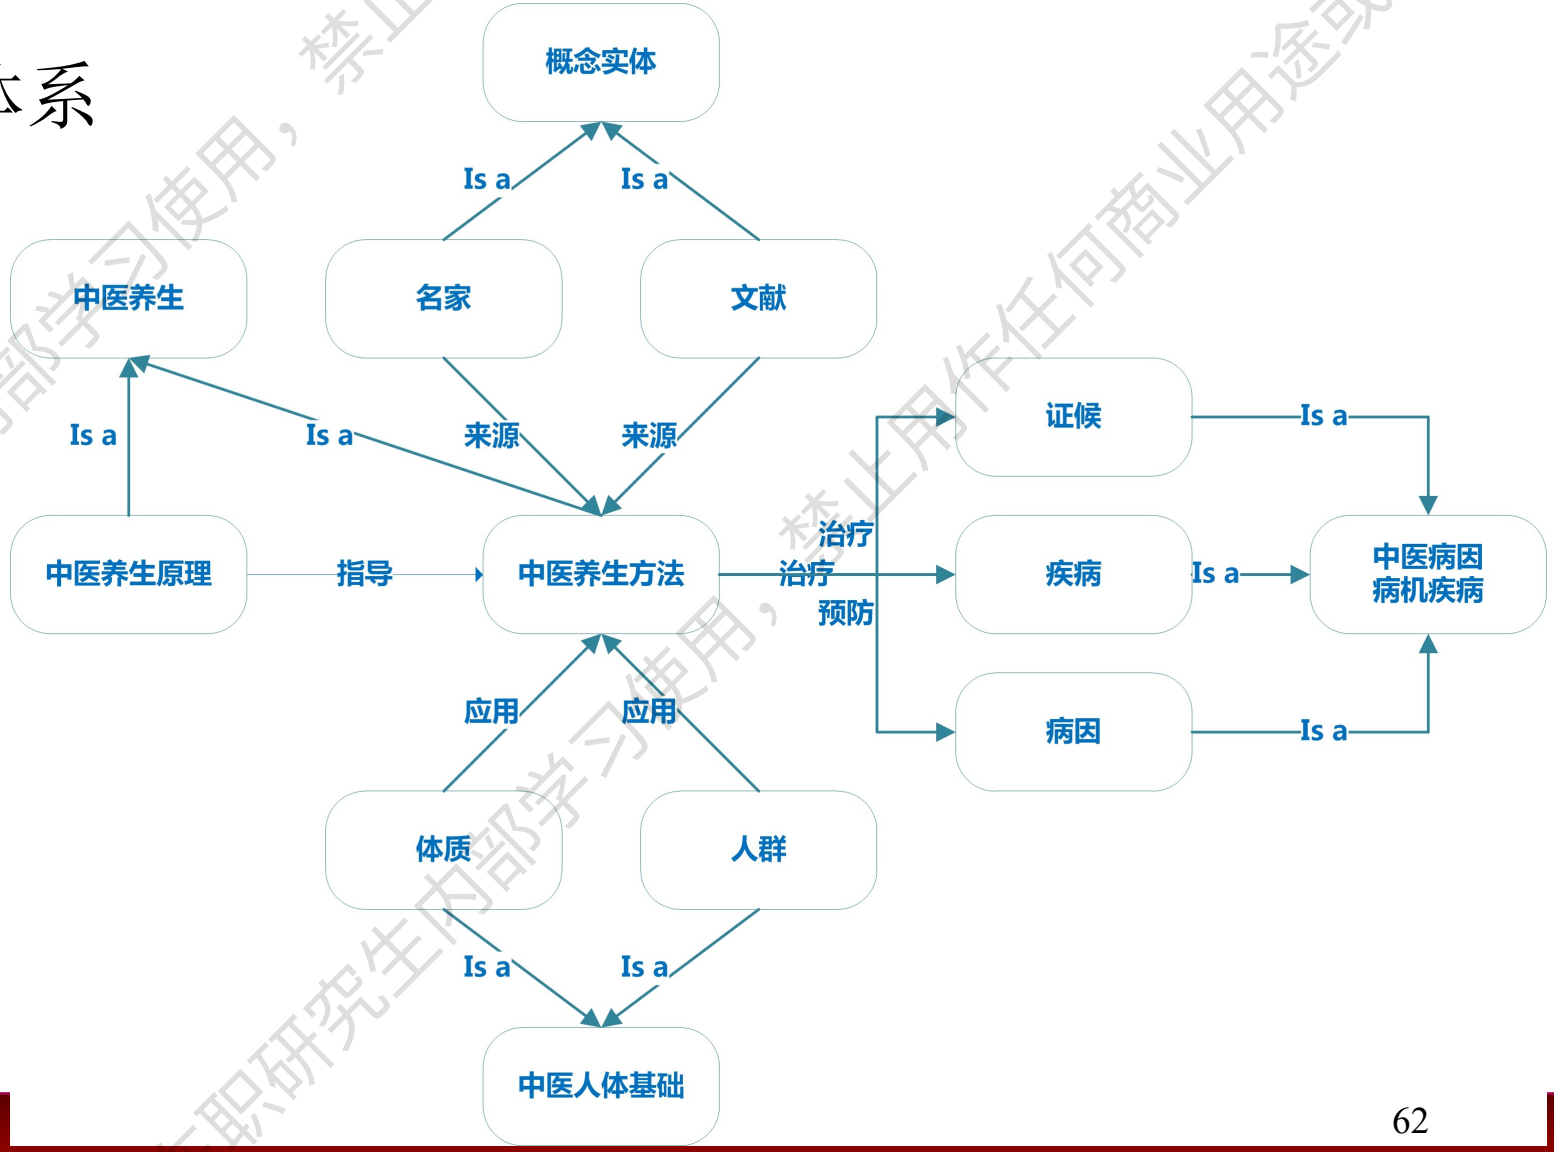




仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识体系构建

- E.g.,中医养生知识体系

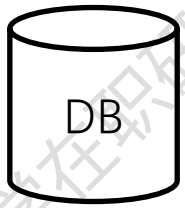


仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.2 知识获取

- 目标：从海量的文本数据中通过信息抽取的方式获取知识

- 数据来源：



I. 结构化数据



II. 半结构化数据



III. 非结构化文本数据

- 工业界常用
- 信息抽取方法简单
- 数据噪声少

- 学术界常用
- 自然语言分析和处理技术，难度较大
- KG构建的核心部分

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

结构化数据

- 数据库；网页表格数据（可通过固定模板直接获得）
- 数据质量较高；长期存在，不易随时间的变化而改变

- 优点：置信度高，数据质量可靠
- 缺点：数据规模小，不易获得

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

结构化数据

基本信息

中文名	邓丽君	毕业院校	台湾金陵女中
外文名	Teresa Teng、テレサ·テン	经纪公司	宇宙唱片、丽风唱片、Polydor、PolyGram、Taurus
别　名	邓丽筠	代表作品	月亮代表我的心、时の流れに身をまかせ、つぐない、小城故事、甜蜜蜜、別れの予感、爱人、空港
国　籍	中国		
民　族	汉族	主要成就	台湾金钟奖最佳女歌星奖
星　座	水瓶座		台湾金曲奖特别贡献奖
血　型	O型		香港十大中文金曲金针奖
身　高	167cm		香港十大劲歌金曲金曲荣誉大奖
体　重	47kg		日本有线大赏三连冠 展开
出生地	台湾省云林县	语　言	普通话、英语、日语、法语等
出生日期	1953年1月29日	音乐类别	POP、歌谣曲、演歌
逝世日期	1995年5月8日	祖　籍	河北省大名县邓台村 [5]
职　业	歌唱家	墓　地	台湾省新北市

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

半结构化数据

- 不能够通过固定的模板直接获得的结构化数据
- 相对于结构化数据较为松散，具有结构多变、模式不统一的特点

- 优点：置信度高，规模比较大，个性化信息丰富而且形式多样
- 缺点：样式多变且含有噪声，很难通过人工编写模板的方式进行抽取

好大夫病例信息

病例信息

疾病描述：

孩子7个月，之前呕吐，起湿疹，现在辅食停掉后呕吐症状没有了，湿疹也在消退，但新增了咳嗽和流鼻涕。咳嗽次数一天达数十次往上。精神状态，饮食和睡眠状态良好。但易哭闹。（2023-05-12填写）
最后一次吃辅食是5月10号。今天凌晨孩子又吐了。伴有抓痒，咳嗽的症状。（2023-05-13填写）

身高体重：

73cm，8.5kg（2023-05-12测量）

疾病：

肠道功能以及辅食过敏判断（2023-05-11填写）

希望得到的帮助：

是否需要药物治疗或者门诊就诊

患病时长： 一周内

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

非结构化文本数据

- “邓丽君1953年出生于台湾省云林县”

- 当前互联网上大多数信息以非结构化的文本形式存储
  - 新闻；聊天内容；帖子；博文；微博等

- 知识抽取：实体识别；实体消歧；关系抽取；事件抽取

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

非结构化文本数据-实体识别

- 从文本中识别出实体信息
  - 确定实体的前后边界
  - 确定实体的类别

“邓丽君 1953年 出生于 台湾省云林县”

人名 时间词 地名

- 早期：针对命名实体的识别（Named Entity Recognition）

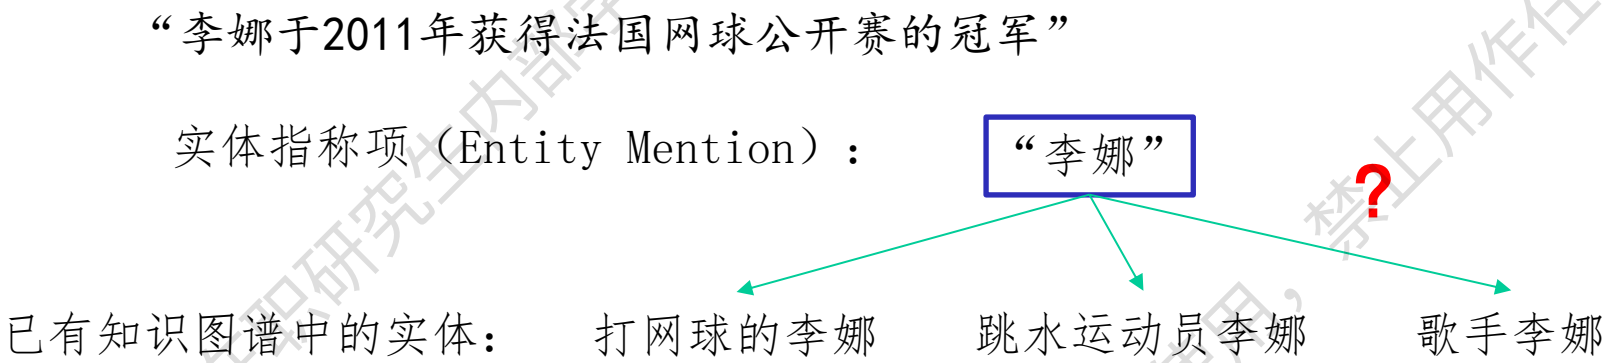
  三大类（实体类、时间类、数字类）

  七小类（人名、地名、机构名、时间、日期、货币和百分比）
- 领域实体：股票名；汽车品牌；餐馆名

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

非结构化文本数据-实体消歧

- 消除指定实体的歧义



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

非结构化文本数据-关系抽取

- 获取两个实体之间的语义关系
- 抽取任务：关系分类；属性抽取；关系实例抽取

“邓丽君 1953年 出生于 台湾省云林县”

- 是确定图谱中两个节点语义关系的关键环节
- 抽取困难，语义关系的自然语言表达多种多样、十分丰富
  - 具有“出生地”关系
  - “出生地”的属性值：台湾省云林县

“出生于” ；“在…出生”；“是…人”

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

非结构化文本数据-事件抽取

- 从描述事件信息的文本中抽取出用户感兴趣的事件信息，并以结构化的形式呈现

“结婚” 事件元素：结婚双方；结婚时间；结婚地点

“AngelaBaby和黄晓明于2015年10月8日在上海举行婚礼”

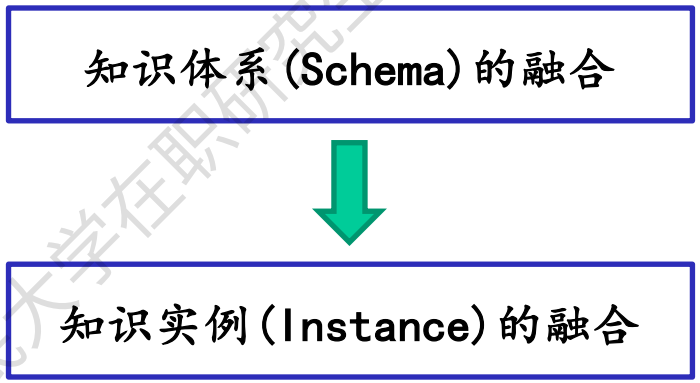
- 事件符合人们的日常认知规律
- 事件知识能弥补现有的以实体和实体关系为核心的知识图谱知识表达能力不足的问题

定义 事件元素（event argument） 和 元素角色(argument role)

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.3 知识融合

- 对不同来源、不同语言和不同结构的知识进行融合，从而对已有知识图谱进行补充



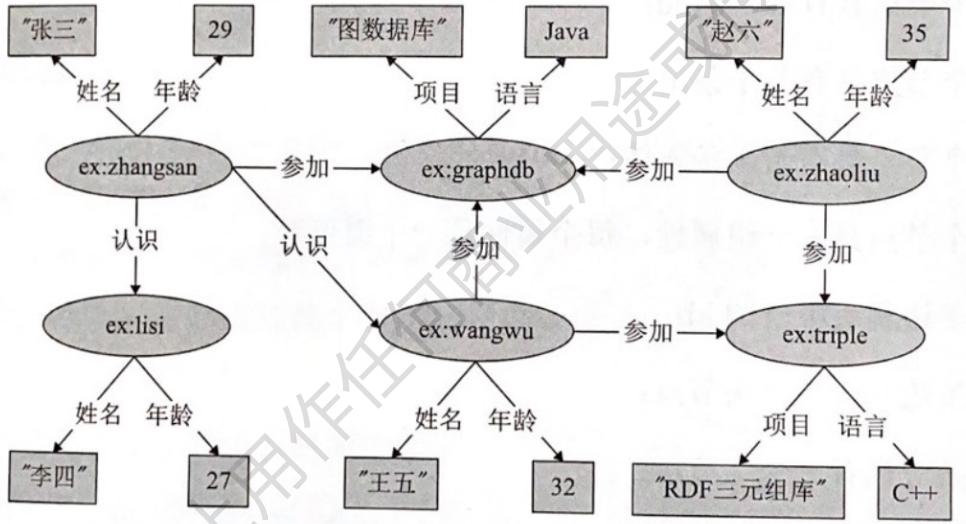
- 对两个或多个异构知识体系进行融合，对相同的属性、类别、关系进行映射
- 实体实例、关系实例进行融合

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

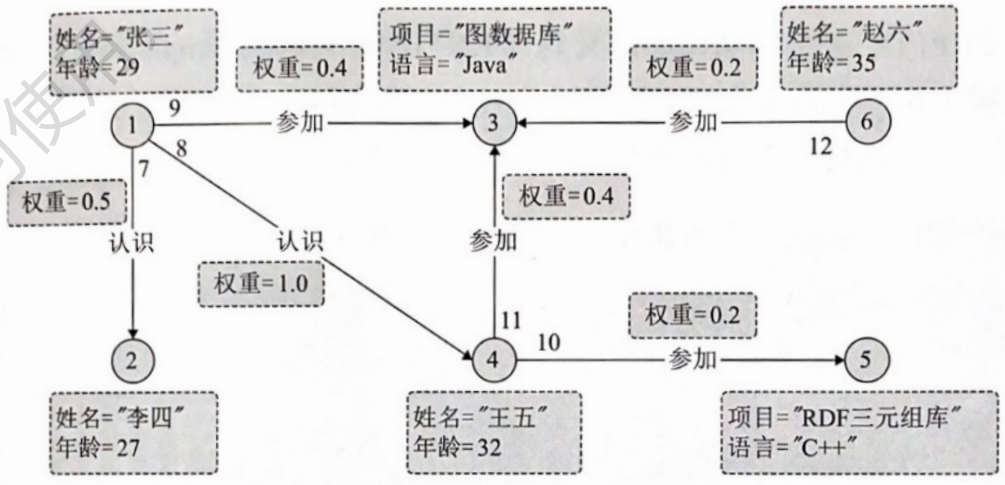
5.4 知识存储

- 知识图谱数据模型基于图论中图的定义，主要有两种图数据模型
  - RDF图
  - 属性图

- 图数据库存储：Neo4j，具有完善的图查询语言，支持图挖掘算法



RDF图



属性图

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.5 知识推理

- 由于处理数据的不完备性，所构建的知识图谱肯定存在知识缺失（实体缺失；关系缺失）
- 利用推理发现已有知识中隐含的知识

A是B的爸爸，B是C的爸爸→A是C的爷爷

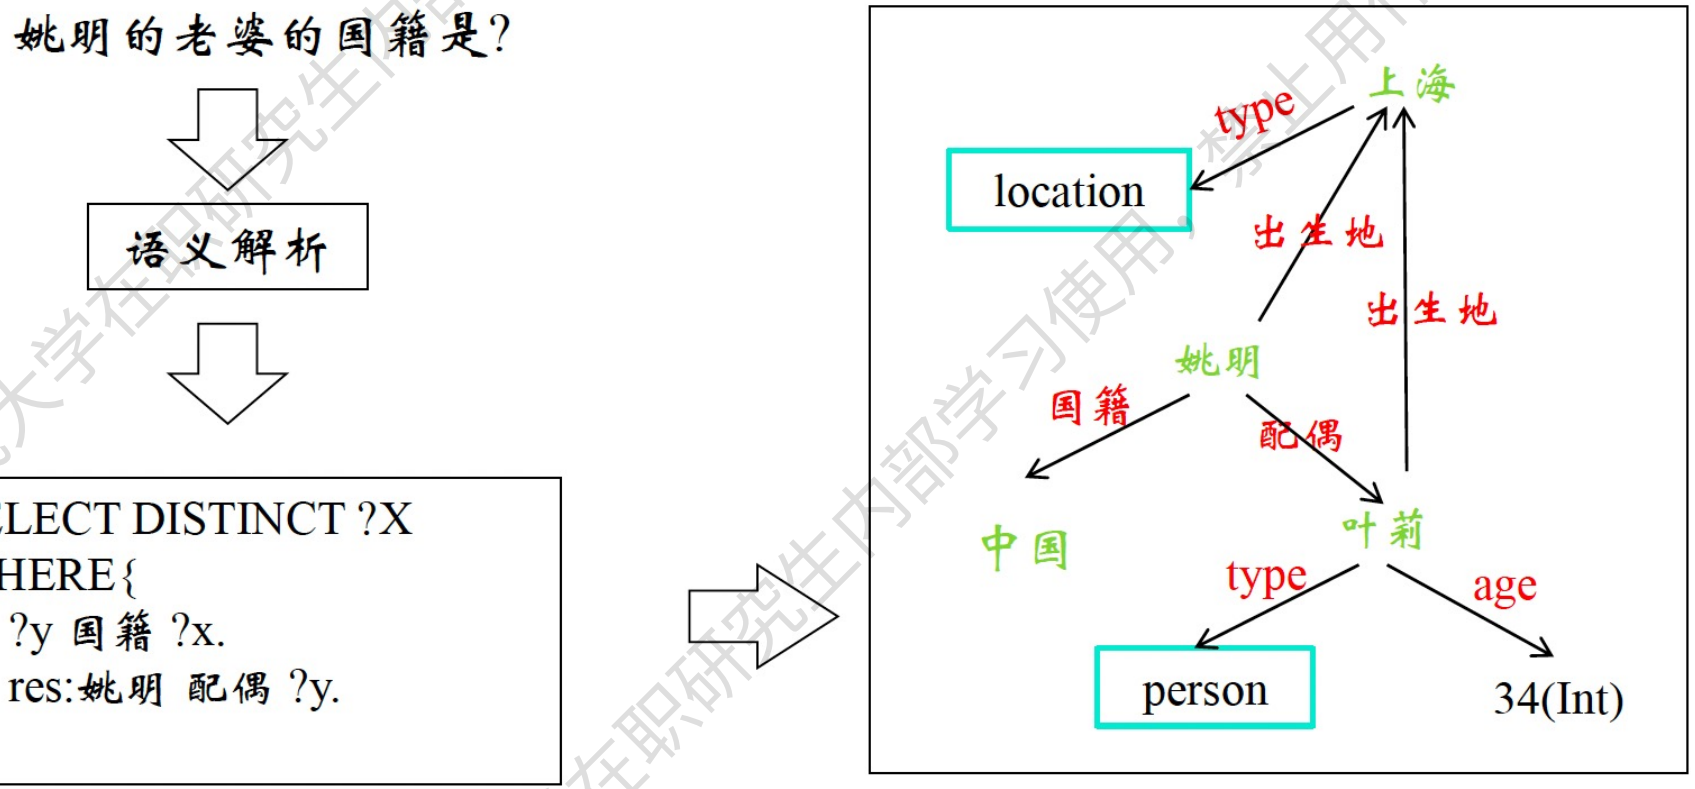
- 知识推理也可以直接用于相关应用任务，如推荐、自动问答系统等

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱中的典型推理任务

知识问答

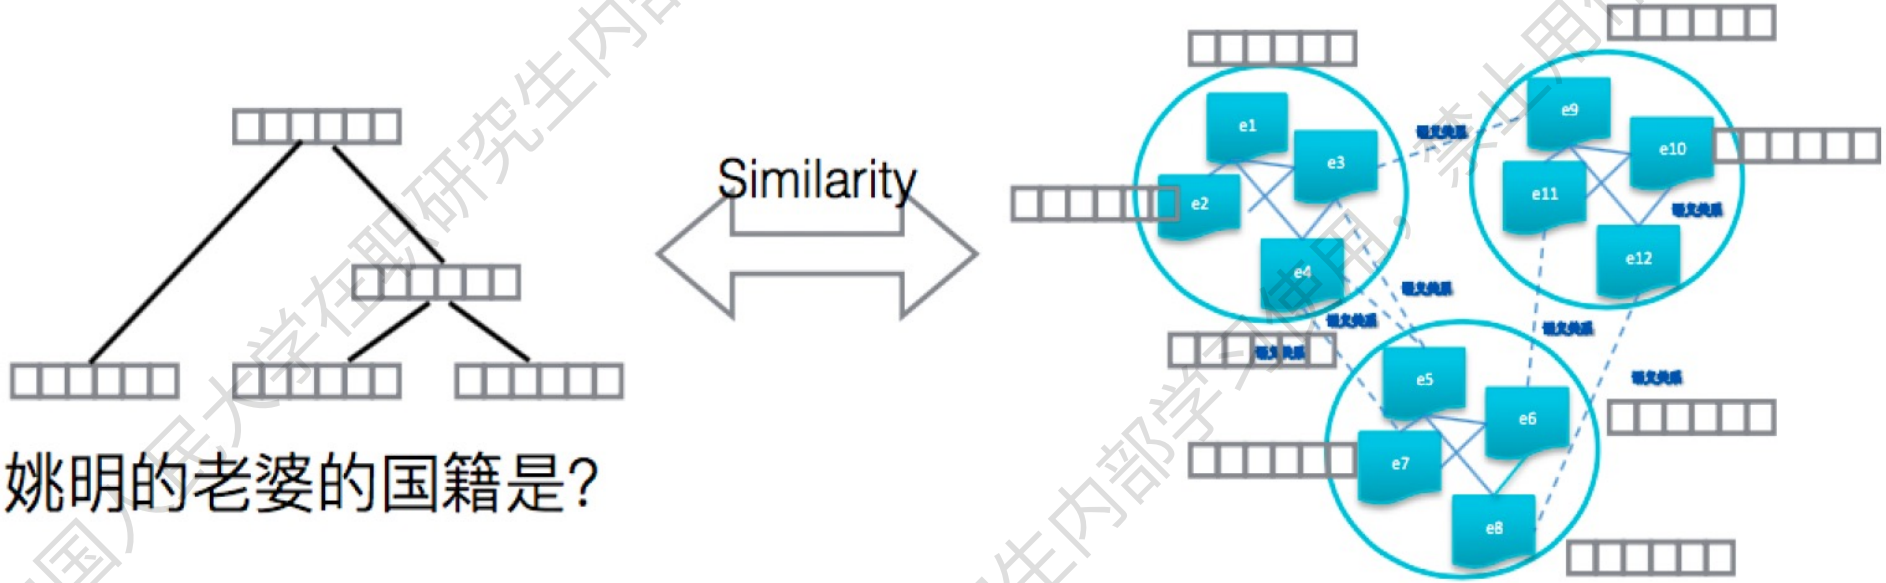
– 基于符号表示的知识库问答——映射自然语言表达式到知识图谱元素词汇



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱中的典型推理任务

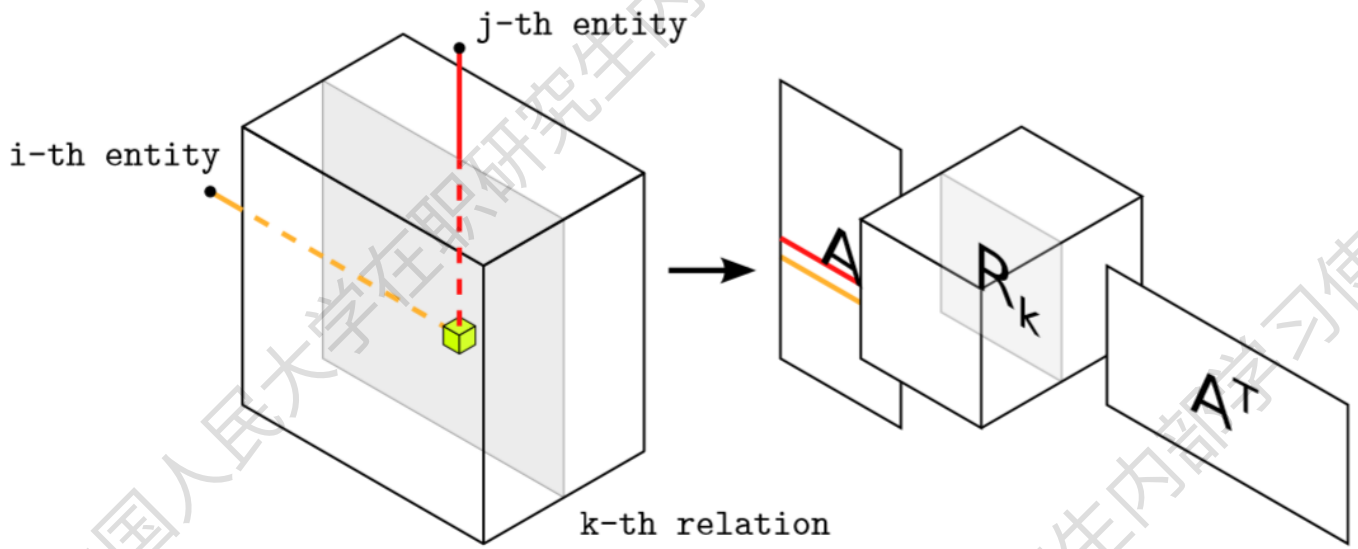
- 知识问答
  - 基于分布式表示的知识库问答

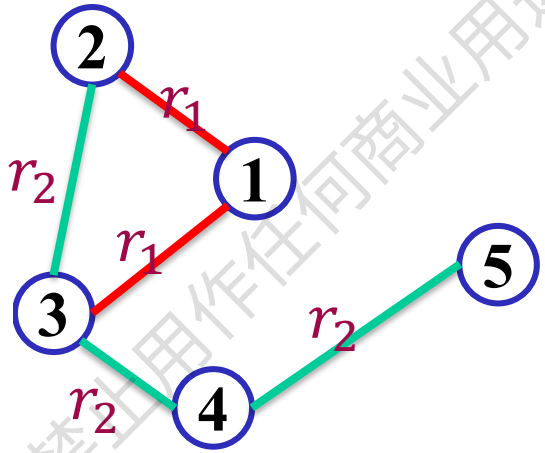


仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱表示学习

- 知识图谱表示：张量矩阵$\mathbf{X} \in \mathcal{R}^{n \times f \times r}$





仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱表示学习

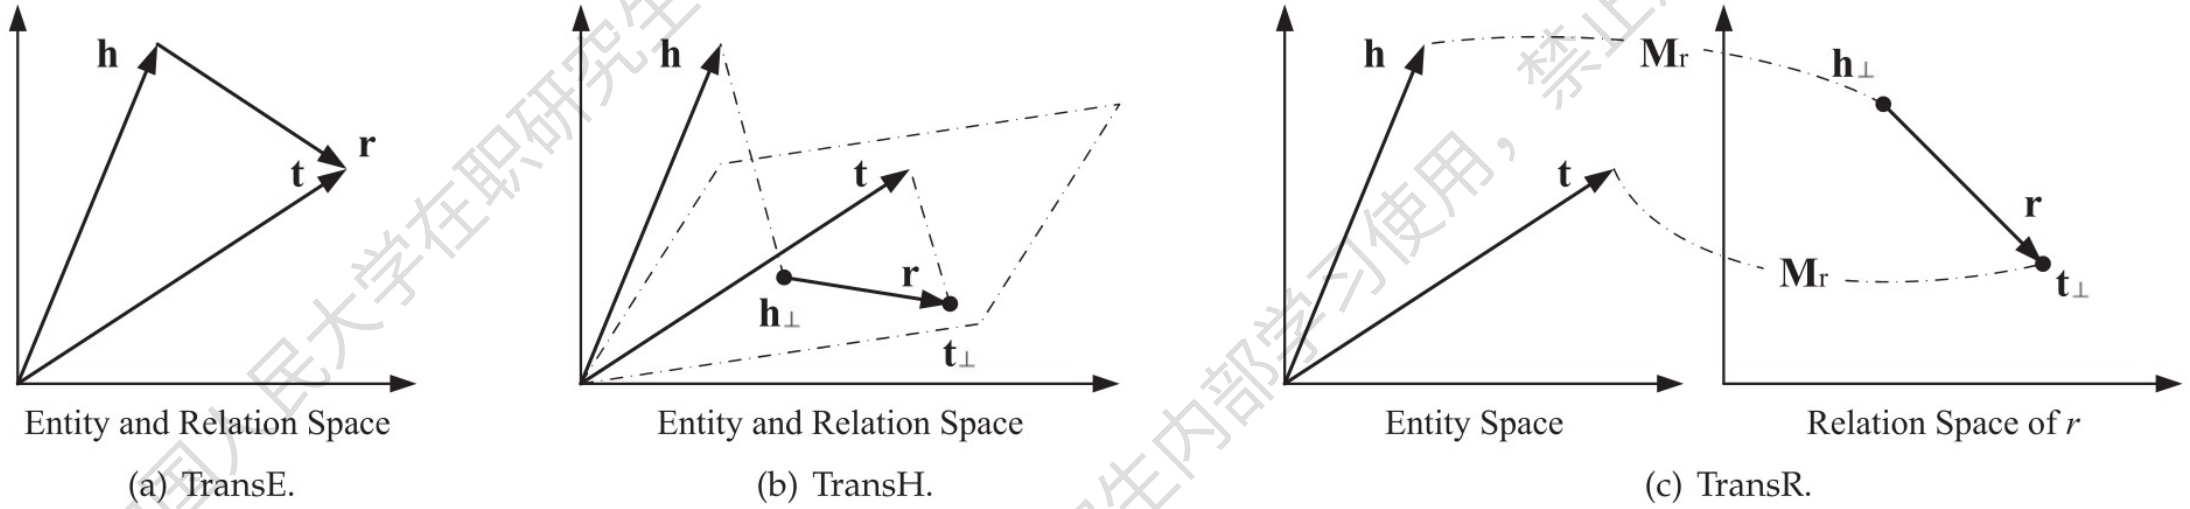
- 知识图谱表示学习，又称知识图谱嵌入Knowledge Graph Embedding, KGE

- 翻译距离模型（translational distance models ）
  - 基于距离的评分函数
- 语义匹配模型（ semantic matching models ）
  - 基于相似度的评分函数

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

I. 翻译距离模型

- 翻译距离模型利用基于距离的评分函数。通常是在通过关系进行翻译之后，用两个实体之间的距离来衡量一个事实的合理性。



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

TransE：最具代表性的知识图谱嵌入

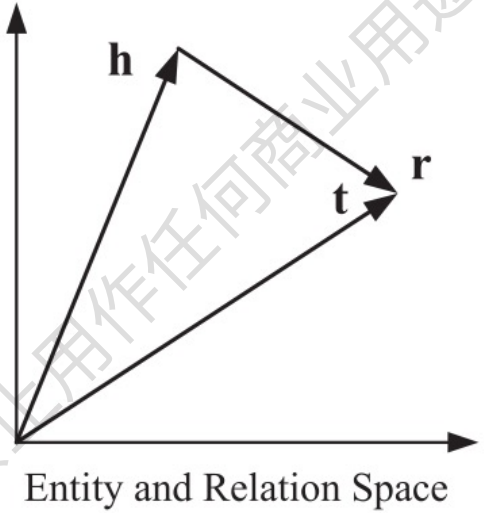
实体和关系都在同一空间
对于每一个三元组(h, r, t)，TransE希望：

$$\mathbf{h} + \mathbf{r} \approx \mathbf{t}$$

评分函数为：

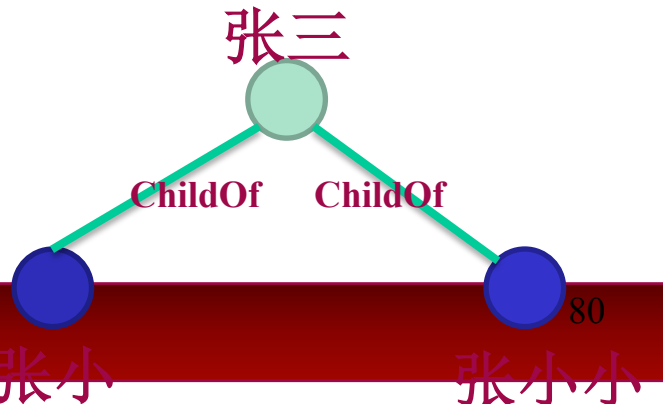
$$f_r(\mathbf{h}, \mathbf{t}) = -\| \mathbf{h} + \mathbf{r} - \mathbf{t} \|_2^2$$

缺点：复杂关系例如，一对多 、 多对一 、
多对多关系不适用。



(a) TransE.

Translating Embeddings for Modeling Multi-relational Data, NIPS2013



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

TransH：解决TransE在多元关系上的缺陷

- TransH引入**超平面**来代替原有关系向量，可以让一个实体在不同的关系下拥有不同的表示
- TransH 首先将头实体向量 h 和尾实体向量 t，沿法线w_r投影到关系 r 对应的超平面上，用 $h_\perp$和 $t_\perp$ 表示如下:

$$\mathbf{h}_\perp = \mathbf{h} - \mathbf{w}_r^T \mathbf{h} \mathbf{w}_r$$

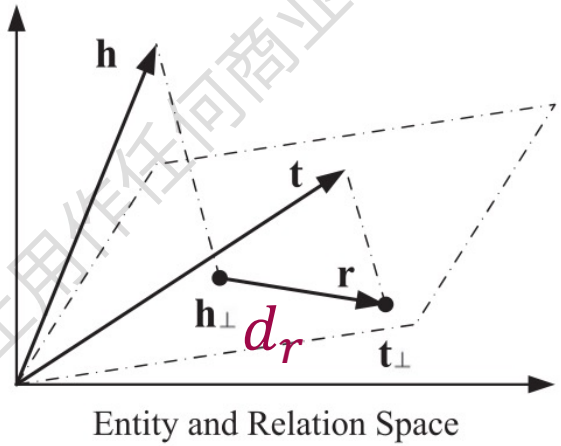
$$\mathbf{t}_\perp = \mathbf{t} - \mathbf{w}_r^T \mathbf{t} \mathbf{w}_r$$

$\mathbf{w}_r^T \mathbf{h} = |\mathbf{w}||\mathbf{h}|\cos\theta$表示$h$在$w_r$方向上投影的长度，$\mathbf{w}_r^T \mathbf{h} \mathbf{w}_r$即$h$在$w_r$上的投影

评分函数为:

$$f_r(\mathbf{h}, \mathbf{t}) = -\| \mathbf{h}_\perp + \mathbf{d}_r - \mathbf{t}_\perp \|_2^2$$

其中$\mathbf{d}_r$是关系r的translation vector



Entity and Relation Space

(b) TransH.

Knowledge Graph Embedding by Translating on Hyperplanes, AAAI2014

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

TransR：实体和关系在不同的语义空间中

- TransR提出一种新的策略，将实体和关系分别映射到不同的语义空间中，分别为entity space（实体空间）和relation space（关系空间)
- 对于每个关系r，给定一个从实体空间到关系空间的映射矩阵$\mathbf{M}_r$

$$\mathbf{h}_r = \mathbf{h}\mathbf{M}_r$$

$$\mathbf{t}_r = \mathbf{t}\mathbf{M}_r$$

评分函数为：

$$f_r(\mathbf{h}, \mathbf{t}) = -\| \mathbf{h}_r + \mathbf{r} - \mathbf{t}_r \|_2^2$$

- 缺点：转换方式是空间投影，复杂度高。
- **TransD**：对TransR的简化

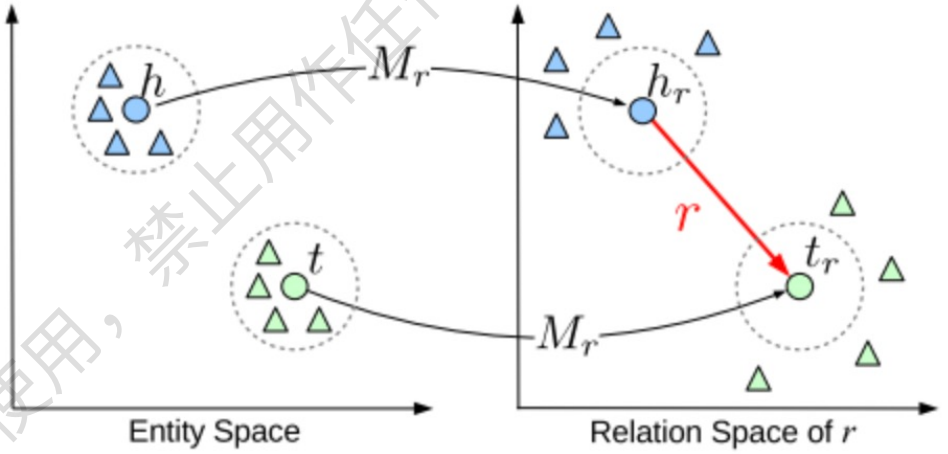


Figure 1: Simple illustration of TransR.

Learning Entity and Relation Embeddings for Knowledge Graph Completion, AAAI2015

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

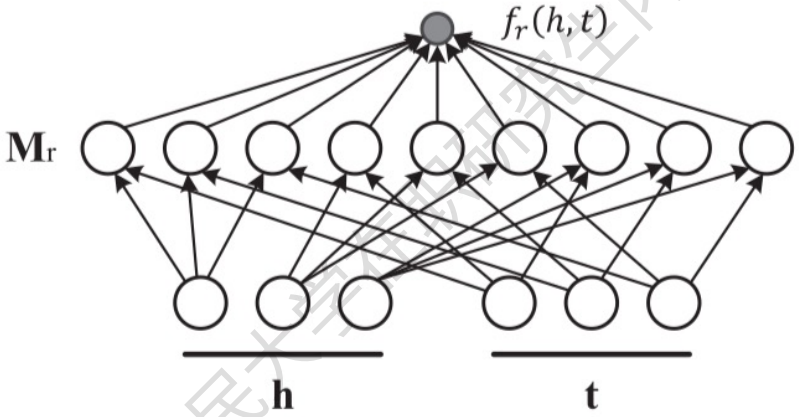
翻译距离模型一览

Method	Ent. embedding	Rel. embedding	Scoring function $f_r(h,t)$	Constraints/Regularization
TransE [14]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^d$	$-\|\mathbf{h}+\mathbf{r}-\mathbf{t}\|_{1/2}$	$\|\mathbf{h}\|_2=1, \|\mathbf{t}\|_2=1$
TransH [15]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r},\mathbf{w}_r\in\mathbb{R}^d$	$-\|(\mathbf{h}-\mathbf{w}_r^\top\mathbf{h}\mathbf{w}_r)+\mathbf{r}-(\mathbf{t}-\mathbf{w}_r^\top\mathbf{t}\mathbf{w}_r)\|_2^2$	$\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1$
TransR [16]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^k, \mathbf{M}_r\in\mathbb{R}^{k\times d}$	$-\|\mathbf{M}_r\mathbf{h}+\mathbf{r}-\mathbf{M}_r\mathbf{t}\|_2^2$	$\|\mathbf{w}_r^\top\mathbf{r}\|/\|\mathbf{r}\|_2\le\epsilon, \|\mathbf{w}_r\|_2=1$ $\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$
TransD [50]	$\mathbf{h},\mathbf{w}_h\in\mathbb{R}^d$ $\mathbf{t},\mathbf{w}_t\in\mathbb{R}^d$	$\mathbf{r},\mathbf{w}_r\in\mathbb{R}^k$	$-\|(\mathbf{w}_r\mathbf{w}_h^\top+\mathbf{I})\mathbf{h}+\mathbf{r}-(\mathbf{w}_r\mathbf{w}_t^\top+\mathbf{I})\mathbf{t}\|_2^2$	$\|\mathbf{M}_r\mathbf{h}\|_2\le 1, \|\mathbf{M}_r\mathbf{t}\|_2\le 1$ $\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$ $\|(\mathbf{w}_r\mathbf{w}_h^\top+\mathbf{I})\mathbf{h}\|_2\le 1$ $\|(\mathbf{w}_r\mathbf{w}_t^\top+\mathbf{I})\mathbf{t}\|_2\le 1$
TranSparse [51]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^k, \mathbf{M}_r(\theta_r)\in\mathbb{R}^{k\times d}$ $\mathbf{M}_r^1(\theta_r^1), \mathbf{M}_r^2(\theta_r^2)\in\mathbb{R}^{k\times d}$	$-\|\mathbf{M}_r(\theta_r)\mathbf{h}+\mathbf{r}-\mathbf{M}_r(\theta_r)\mathbf{t}\|_{1/2}^2$ $-\|\mathbf{M}_r^1(\theta_r^1)\mathbf{h}+\mathbf{r}-\mathbf{M}_r^2(\theta_r^2)\mathbf{t}\|_{1/2}^2$	$\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$ $\|\mathbf{M}_r(\theta_r)\mathbf{h}\|_2\le 1, \|\mathbf{M}_r(\theta_r)\mathbf{t}\|_2\le 1$ $\|\mathbf{M}_r^1(\theta_r^1)\mathbf{h}\|_2\le 1, \|\mathbf{M}_r^2(\theta_r^2)\mathbf{t}\|_2\le 1$
TransM [52]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^d$	$-\theta_r\|\mathbf{h}+\mathbf{r}-\mathbf{t}\|_{1/2}$	$\|\mathbf{h}\|_2=1, \|\mathbf{t}\|_2=1$
ManifoldE [53]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^d$	$-(\|\mathbf{h}+\mathbf{r}-\mathbf{t}\|_2^2-\theta_r^2)^2$	$\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$
TransF [54]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^d$	$(\mathbf{h}+\mathbf{r})^\top\mathbf{t}+(\mathbf{t}-\mathbf{r})^\top\mathbf{h}$	$\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$
TransA [55]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{r}\in\mathbb{R}^d, \mathbf{M}_r\in\mathbb{R}^{d\times d}$	$-(\|\mathbf{h}+\mathbf{r}-\mathbf{t}\|)^\top\mathbf{M}_r(\|\mathbf{h}+\mathbf{r}-\mathbf{t}\|)$	$\|\mathbf{h}\|_2\le 1, \|\mathbf{t}\|_2\le 1, \|\mathbf{r}\|_2\le 1$
KG2E [45]	$\mathbf{h}\sim\mathcal{N}(\boldsymbol{\mu}_h,\boldsymbol{\Sigma}_h)$ $\mathbf{t}\sim\mathcal{N}(\boldsymbol{\mu}_t,\boldsymbol{\Sigma}_t)$ $\boldsymbol{\mu}_h,\boldsymbol{\mu}_t\in\mathbb{R}^d$ $\boldsymbol{\Sigma}_h,\boldsymbol{\Sigma}_t\in\mathbb{R}^{d\times d}$	$\mathbf{r}\sim\mathcal{N}(\boldsymbol{\mu}_r,\boldsymbol{\Sigma}_r)$ $\boldsymbol{\mu}_r\in\mathbb{R}^d, \boldsymbol{\Sigma}_r\in\mathbb{R}^{d\times d}$	$-\mathrm{tr}(\boldsymbol{\Sigma}_r^{-1}(\boldsymbol{\Sigma}_h+\boldsymbol{\Sigma}_t))-\boldsymbol{\mu}^\top\boldsymbol{\Sigma}_r^{-1}\boldsymbol{\mu}-\ln\frac{\det(\boldsymbol{\Sigma}_r)}{\det(\boldsymbol{\Sigma}_h+\boldsymbol{\Sigma}_t)}$ $-\boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}-\ln(\det(\boldsymbol{\Sigma}))$ $\boldsymbol{\mu}=\boldsymbol{\mu}_h+\boldsymbol{\mu}_r-\boldsymbol{\mu}_t$ $\boldsymbol{\Sigma}=\boldsymbol{\Sigma}_h+\boldsymbol{\Sigma}_r+\boldsymbol{\Sigma}_t$	$\|\mathbf{M}_r\|_F\le 1, [\mathbf{M}_r]_{ij}=[\mathbf{M}_r]_{ji}\ge 0$ $\|\boldsymbol{\mu}_h\|_2\le 1, \|\boldsymbol{\mu}_t\|_2\le 1, \|\boldsymbol{\mu}_r\|_2\le 1$ $c_{min}\mathbf{I}\le\boldsymbol{\Sigma}_h\le c_{max}\mathbf{I}$ $c_{min}\mathbf{I}\le\boldsymbol{\Sigma}_t\le c_{max}\mathbf{I}$ $c_{min}\mathbf{I}\le\boldsymbol{\Sigma}_r\le c_{max}\mathbf{I}$
TransG [46]	$\mathbf{h}\sim\mathcal{N}(\boldsymbol{\mu}_h,\sigma_h^2\mathbf{I})$ $\mathbf{t}\sim\mathcal{N}(\boldsymbol{\mu}_t,\sigma_t^2\mathbf{I})$ $\boldsymbol{\mu}_h,\boldsymbol{\mu}_t\in\mathbb{R}^d$	$\boldsymbol{\mu}_r^i\sim\mathcal{N}(\boldsymbol{\mu}_t-\boldsymbol{\mu}_h,(\sigma_h^2+\sigma_t^2)\mathbf{I})$ $\mathbf{r}=\sum_i\pi_r^i\boldsymbol{\mu}_r^i\in\mathbb{R}^d$	$\sum_i\pi_r^i\exp\left(-\frac{\|\boldsymbol{\mu}_h+\boldsymbol{\mu}_r^i-\boldsymbol{\mu}_t\|_2^2}{\sigma_h^2+\sigma_t^2}\right)$	$\|\boldsymbol{\mu}_h\|_2\le 1, \|\boldsymbol{\mu}_t\|_2\le 1, \|\boldsymbol{\mu}_r^i\|_2\le 1$
UM [56]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	—	$-\|\mathbf{h}-\mathbf{t}\|_2^2$	$\|\mathbf{h}\|_2=1, \|\mathbf{t}\|_2=1$
SE [57]	$\mathbf{h},\mathbf{t}\in\mathbb{R}^d$	$\mathbf{M}_r^1,\mathbf{M}_r^2\in\mathbb{R}^{d\times d}$	$-\|\mathbf{M}_r^1\mathbf{h}-\mathbf{M}_r^2\mathbf{t}\|_1$	$\|\mathbf{h}\|_2=1, \|\mathbf{t}\|_2=1$

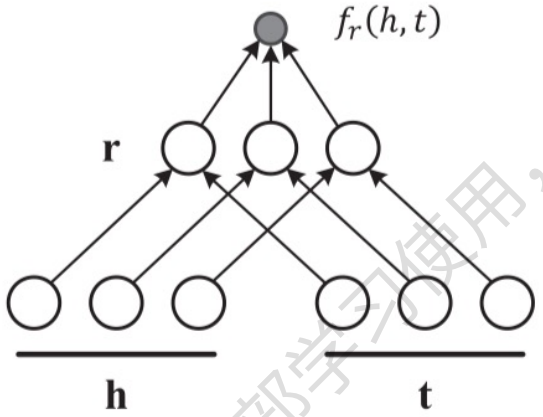
仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

II. 语义匹配模型

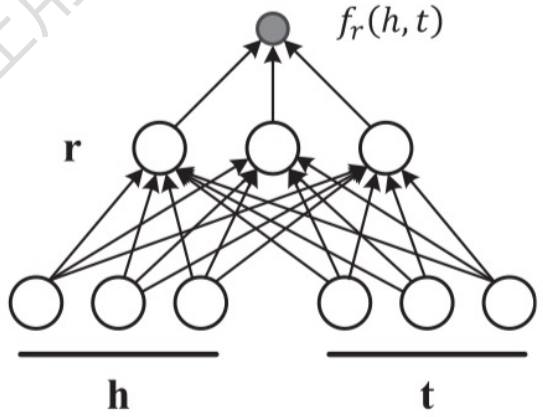
- 语义匹配模型利用基于相似性的评分函数。通过匹配实体和关系在嵌入向量空间的潜在语义衡量三元组事实成立的可能性。



(a) RESCAL.



(b) DistMult.

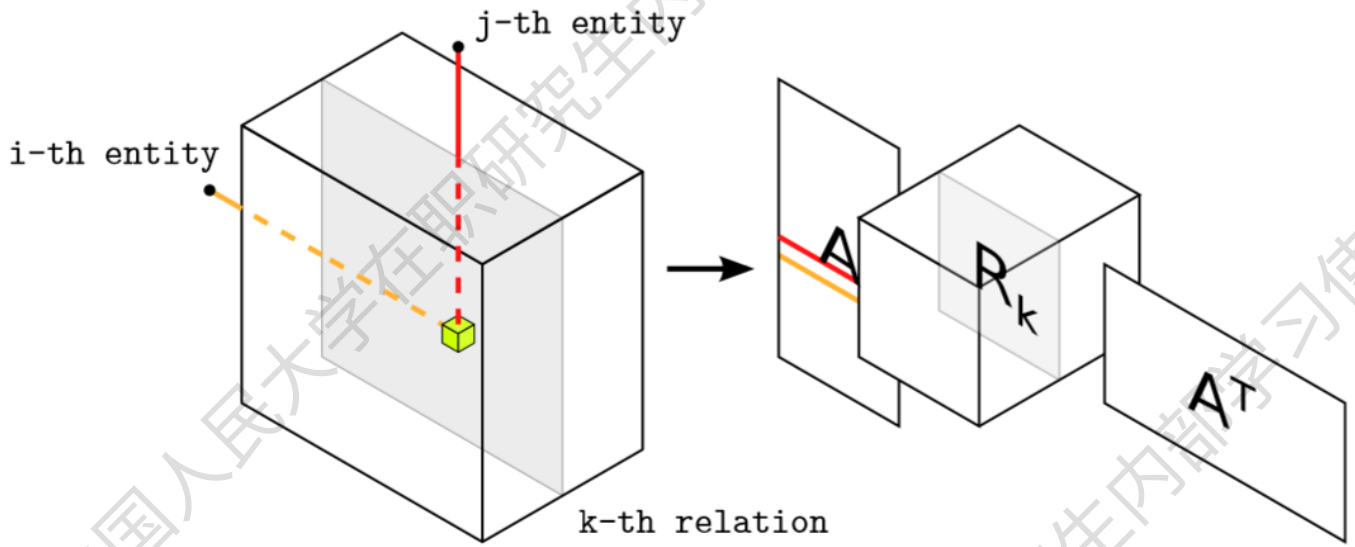


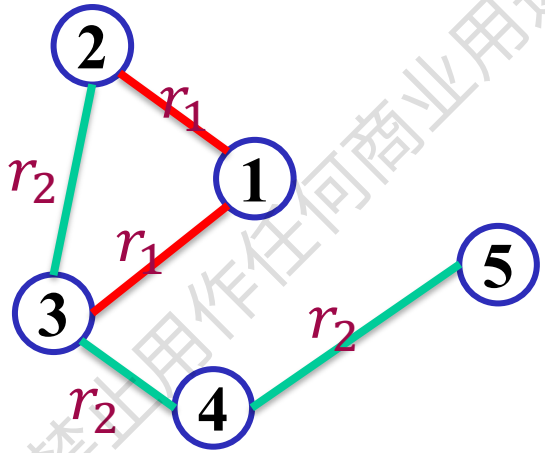
(c) HolE.

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

知识图谱表示学习

- 知识图谱表示：张量矩阵$\mathbf{X} \in \mathcal{R}^{n \times f \times r}$





仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

RESCAL模型（双线性模型）

- RESCAL又称双线性模型，该模型用向量表示实体，用矩阵表示关系，并通过自定义的打分函数捕捉三元组的内部交互。
- 核心思想：三维张量分解

Given a $n \times n \times m$ tensor χ, each slice χ_k is factorized as:

$$\chi_k \approx A R_k A^T, \text{ for } k = 1,2,\ldots,m$$

A: a $n \times r$ matrix that contains the latent-component representation of the entities

R_k: is an asymmetric $r \times r$ matrix that models the interactions of the latent components in the k-th predicate

- 优化目标：$\min_{A,R_k} f(A,R_k) + g(A,R_k)$

模型重构　　防止过拟合

$$f(A,R_k) = \frac{1}{2}\left(\sum_k \|\mathcal{X}_k - A R_k A^T\|_F^2\right)$$

$$g(A,R_k) = \frac{1}{2}\lambda\left(\|A\|_F^2 + \sum_k \|R_k\|_F^2\right)$$

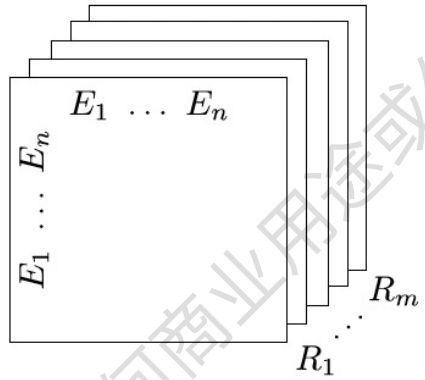
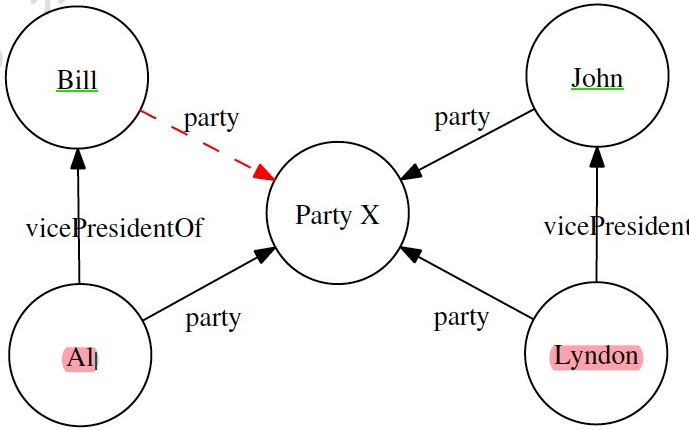


Figure 1: Tensor model for relational data. $E_1 \cdots E_n$ denote the entities, while $R_1 \cdots R_m$ denote the relations in the domain

A tensor entry $x_{ijk} = 1$ denotes the fact that there exists a relation (i-th entity, k-th predicate, j-th entity).



$$a_{\text{Bill}}^T R_{\text{party}} a_{\text{PartyX}} \approx a_{\text{John}}^T R_{\text{party}} a_{\text{PartyX}}$$

A Three-Way Model for Collective Learning on Multi-Relational Data, ICML 2011

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.6 知识应用

- I. 智能搜索

- 用户意图理解



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.6 知识应用

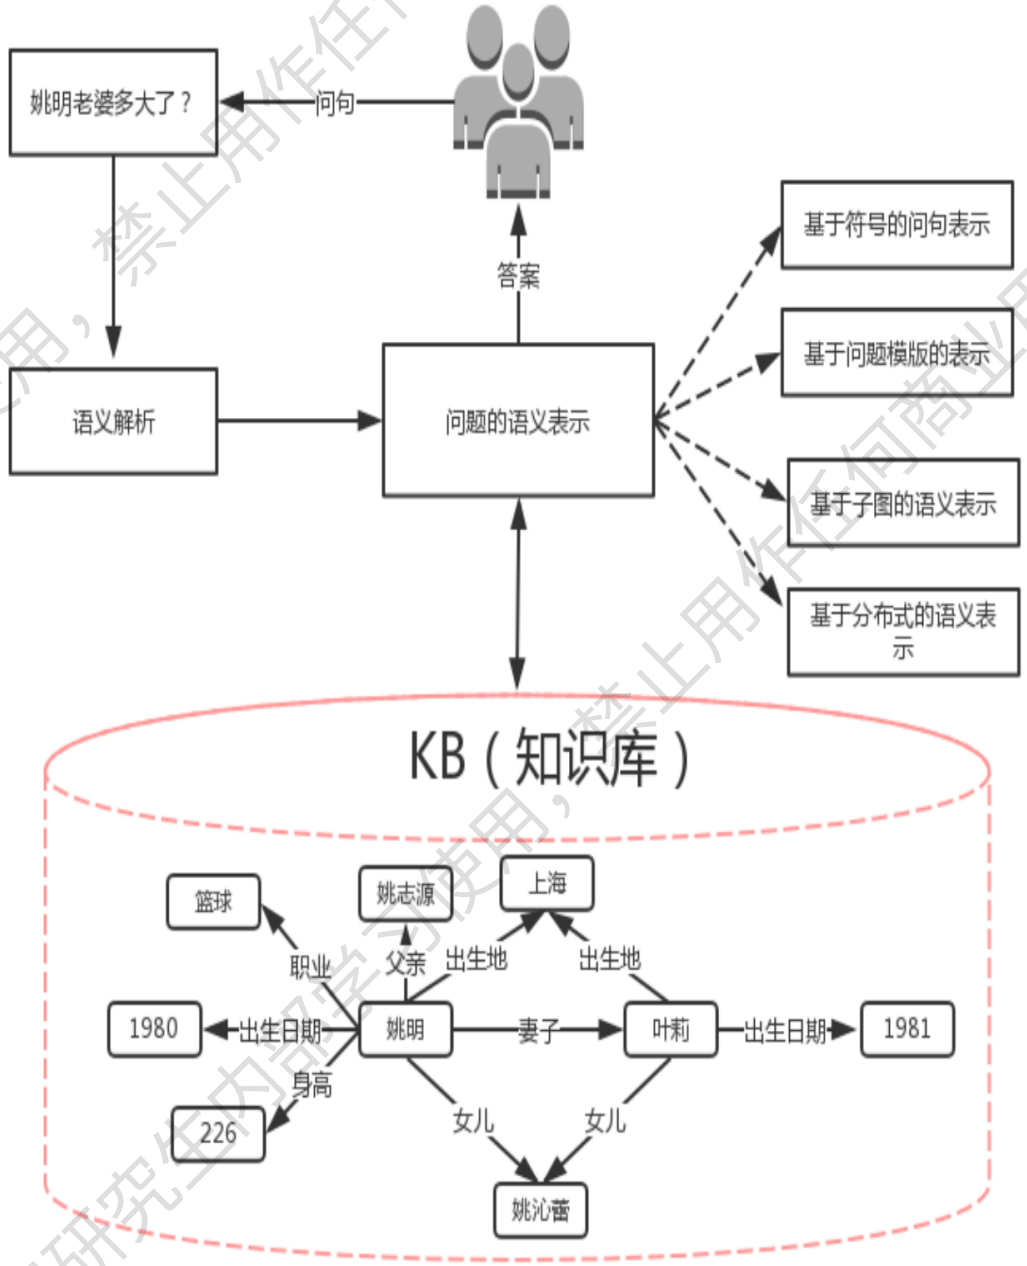
- II. 自动问答



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.6 知识应用

- II. 自动问答
  - 聊天机器人



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.6 知识应用

- III. 推荐

- 电影在知识图谱中类型标签进行推荐

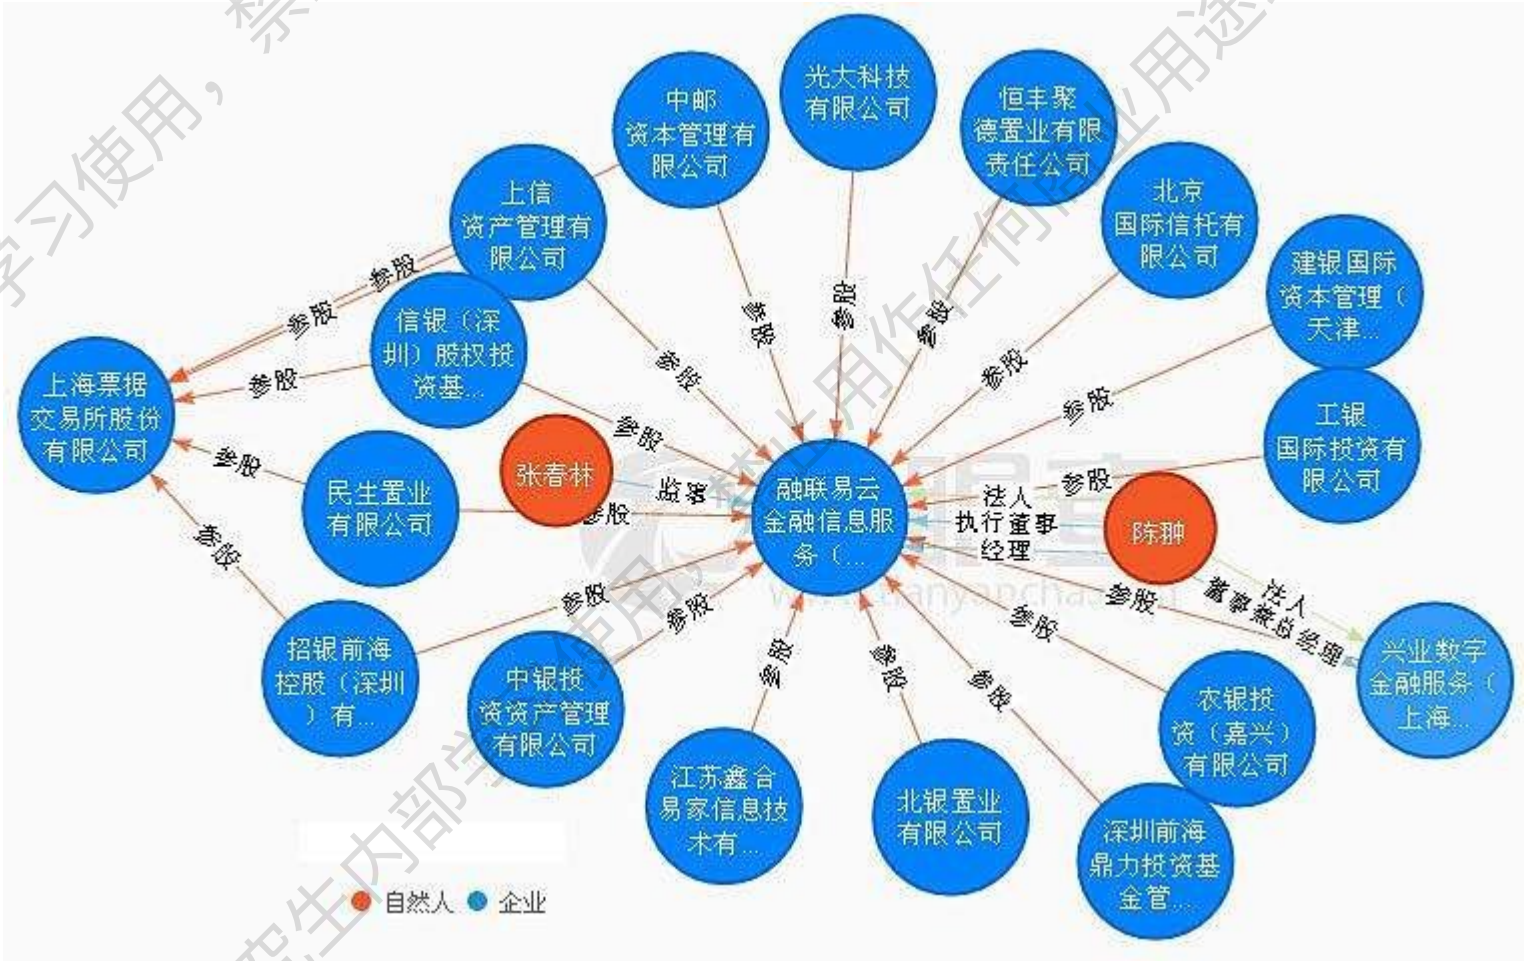


仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

5.6 知识应用

- IV. 决策支持

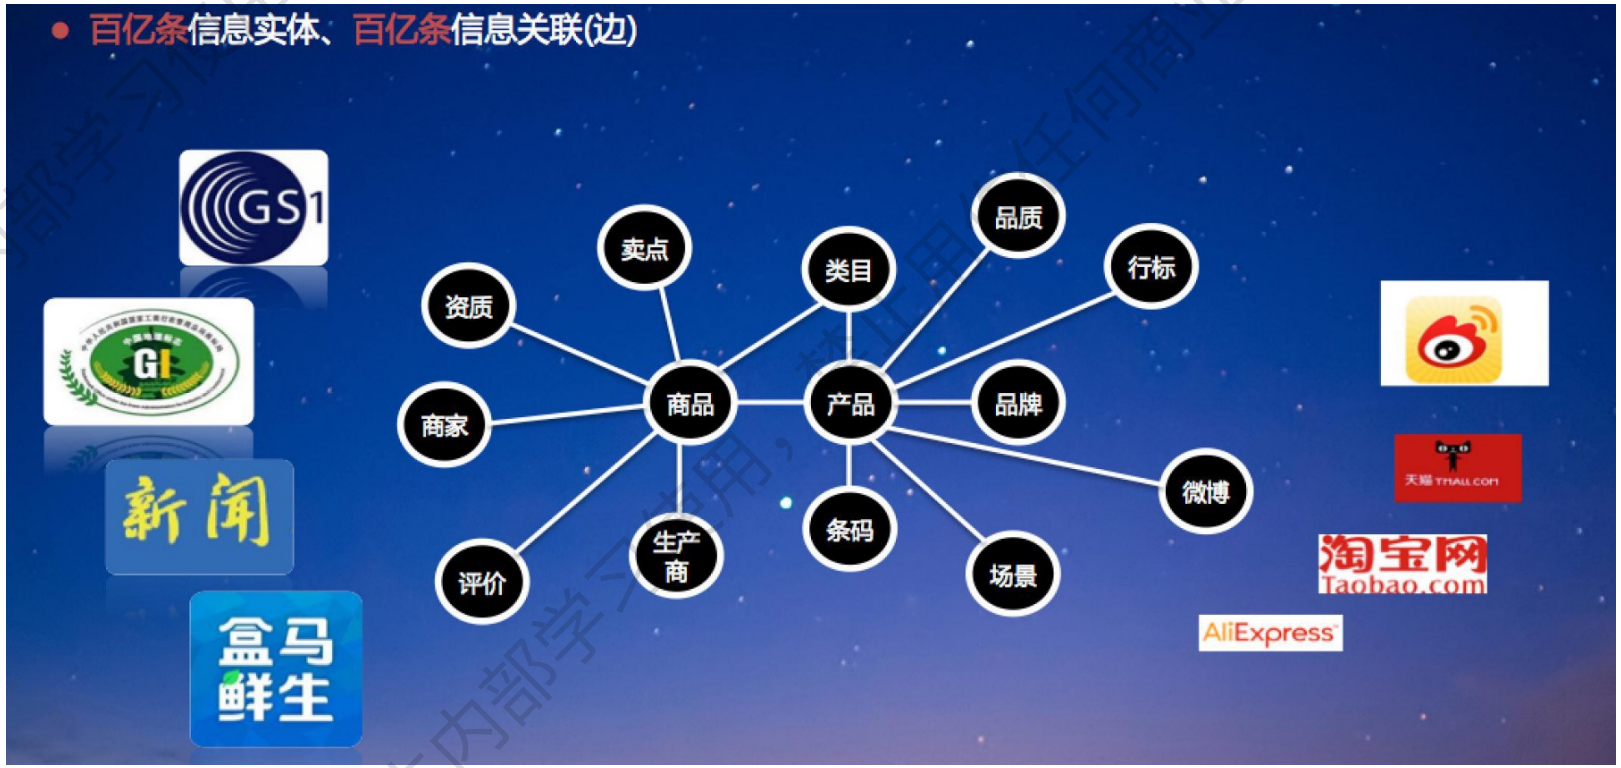
- 天眼查，挖掘企业和企业家之间的关系，企业之间的关系



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

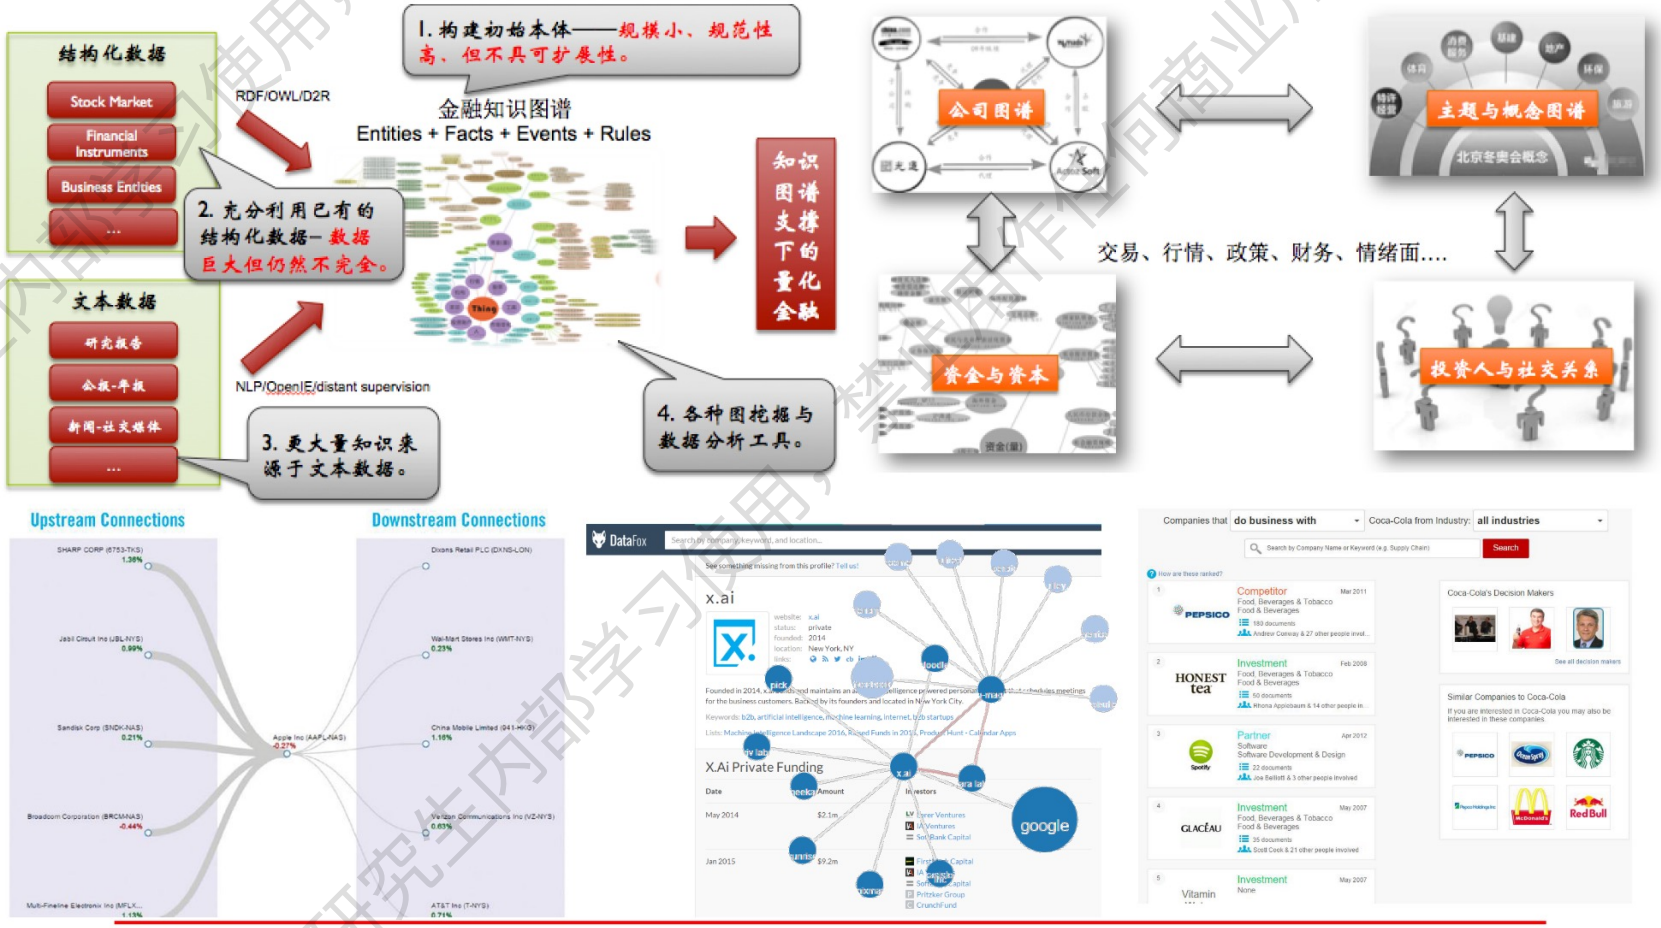
6. 知识图谱领域应用

- 电商知识图谱
  - 智能导购
  - 消费者精准画像
  - 商品推荐



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

- 金融知识图谱
  - 企业关系发现
  - 公司表现研究
  - “组团骗贷”



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

- 医疗健康知识图谱
  - 新药发现
  - 特定人群药物推荐
  - 辅助医生决策



仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

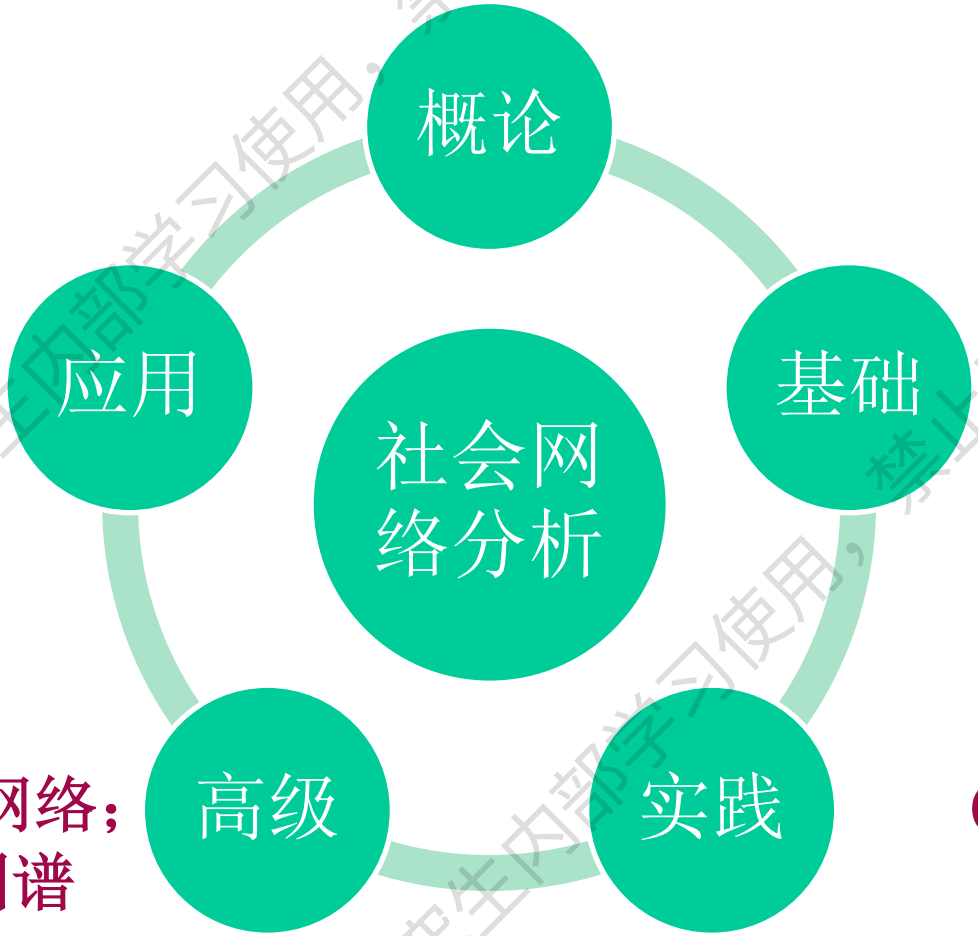
三、社会网络分析前沿

- Paper sharing

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

四、课程总结

一些应用，几个理论



社会网络类型；节点度量；路径搜索；社群发现

Gephi

图神经网络；知识图谱

能看懂；尝试做

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播

The end



Email: ahduwei@ruc.edu.cn

仅供中国人民大学在职研究生内部学习使用，禁止用作任何商业用途或传播