

高级信息系统 Advanced Information Systems

面向在线问诊服务的医生推荐

主讲教师：蒋洪迅

时间：2025-03-16

实事求是

目录 / CONTENTS

中国人民大学
RENMIN UNIVERSITY OF CHINA

01 背景和选题意义
Background and significance

02 公平性推荐研究现状
Literature of Fairness Recmdr

03 研究方法
Research methodology

04 难点和创新之处
Challenges and innovations

实事求是



01 背景和选题意义

BACKGROUND AND SIGNIFICANCE

好大夫在线

在线健康社区

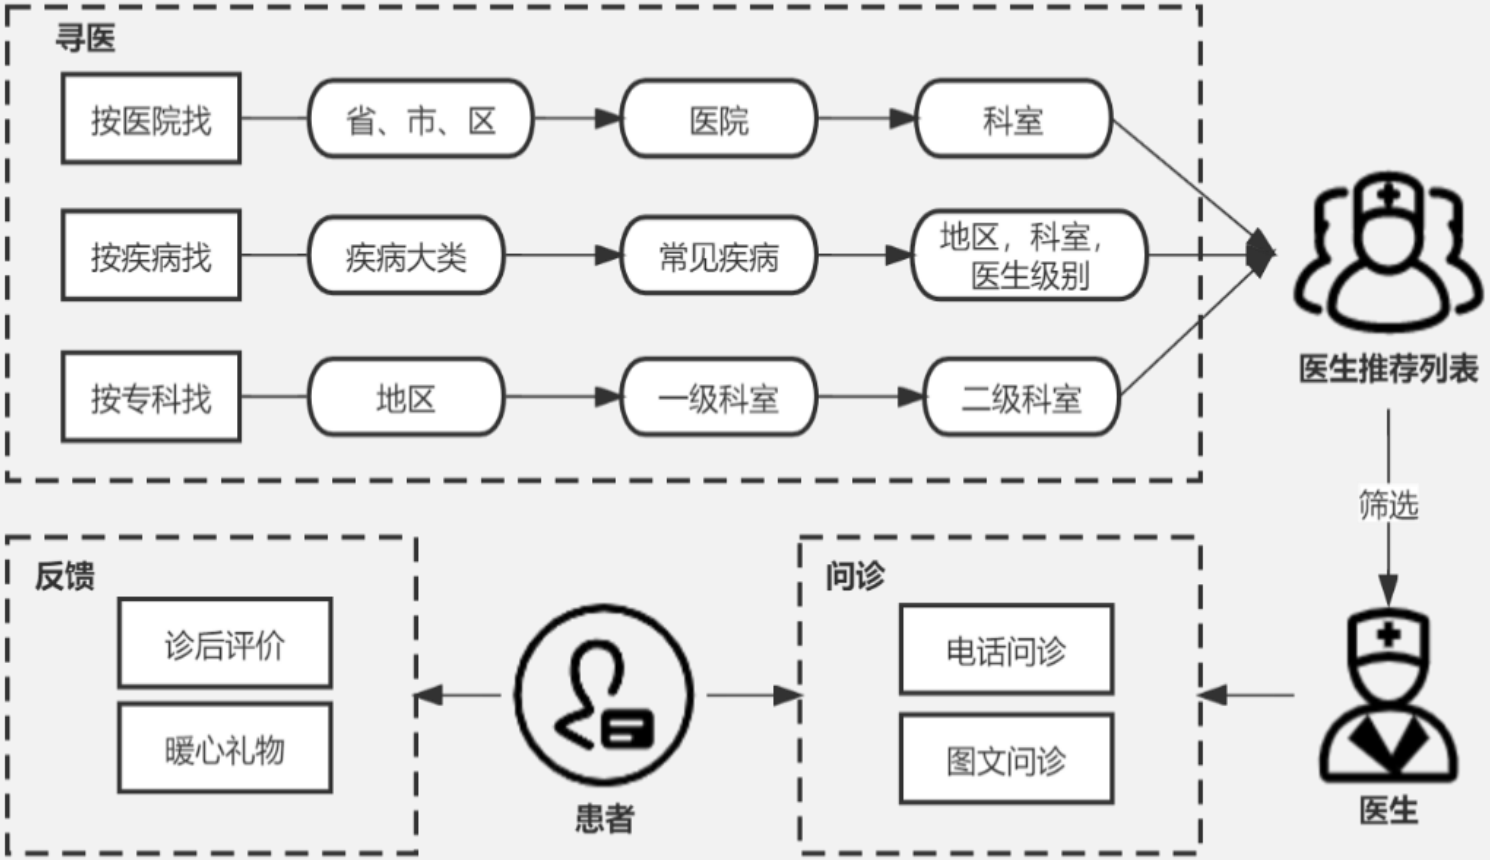
好大夫在线创立于2006年，中国领先互联网医疗平台（Online healthcare community，OHC）之一，业务涵盖医院/医生信息查询、图文问诊、电话问诊、远程视频门诊、门诊精准预约、诊后疾病管理、家庭医生、疾病知识科普等多个领域。其中，在线问诊是其线上最重要的营收渠道。平台收录了国内10000余家正规医院的91万名医生信息，27万名医生实名注册，直接向患者提供线上医疗服务，其中，三甲医院的医生比例占到73%，具有很高的医疗服务权威性。



医生推荐系统

患者关心如何找到最专业的医学专家来解决他们的健康问题。但对患者而言,自己挑选合适的专家极具挑战性,尤其是在没有合适匹配机制的情况下。面对信息体量的快速增长,由于患者缺乏专业的医疗背景和知识,他们在寻找合适的专家时不知所措,面临巨大的时间和搜索成本。医生推荐能够从专业层面帮助患者快速准确地找到符合需求的医生，确保医疗服务价值的有效实现。

研究背景



好大夫在线平台业务流程图



02 国内外研究现状

LITERATURE REVIEW

国内外研究现状

中国人民大學 RENMIN UNIVERSITY OF CHINA

Review type	Article	Article selection process	Applied tool	Evaluation Factor	Future work	Cover year
Surveys	(Kamran & Javed, 2015)	Not clear	Not presented	Presented	Presented	Not mentioned
	(Kumar & Thakur, 2018)	Not clear	Not presented	Presented	Not presented	2000–2016
	(Hors-Fraile et al., 2018)	Clear	Not presented	Presented	Presented	Not mentioned
	(D. Sharma et al., 2019)	Not clear	Presented	Presented	Presented	Not mentioned
	(Yue et al., 2021)	Not clear	Not presented	Presented	Presented	Not mentioned
	(Tiwari & Singh, 2021)	Not clear	Not presented	Presented	Presented	Not mentioned
SLRs	(Sezgin & Ozkan, 2013)	Clear	Not presented	Not presented	Presented	2002–2012
	(Adekunle Oluseyi Afolabi et al., 2015)	Clear	Not presented	Presented	Presented	2000-2015
	(Ferretto et al., 2017)	Clear	Not presented	Not presented	Not presented	2009-2016
	(Pincay et al., 2019)	Clear	Not presented	Presented	Not presented	2006-2018
	(Çelik Ertugrul & El ç, 2019)	Clear	Not presented	Not presented	Presented	2015-2019
	(Cheung et al., 2019)	Clear	Not presented	Not presented	Not presented	2007-2017
	(Tran et al., 2021)	Clear	Not presented	Presented	Presented	2000-2020
	Our study	Clear	Presented	Presented	Presented	2010-2021

国内外研究现状

面向医疗领域的推荐模型

01 Collaborative-based

基于协同过滤的方法 考虑了新用户与过去相似用户之间的相似性，即如果用户过去喜欢相同的服务，他们未来对其他服务可能会有相同的看法

02 Content-based

基于内容的方法根据服务之间的相似性推荐服务。

03 Knowledge-based

推荐结果主要依赖用户需求与产品之间相似度的形式，或者是根据明确的推荐规则。例如，可以直接询问用户对服务功能和响应时间等需求。由于基于知识的推荐系统不是基于用户评分，并且他们的决策独立于个人口味，因此免去收集关于用户信息的过程，并避免了冷启动问题。

04 Context-based

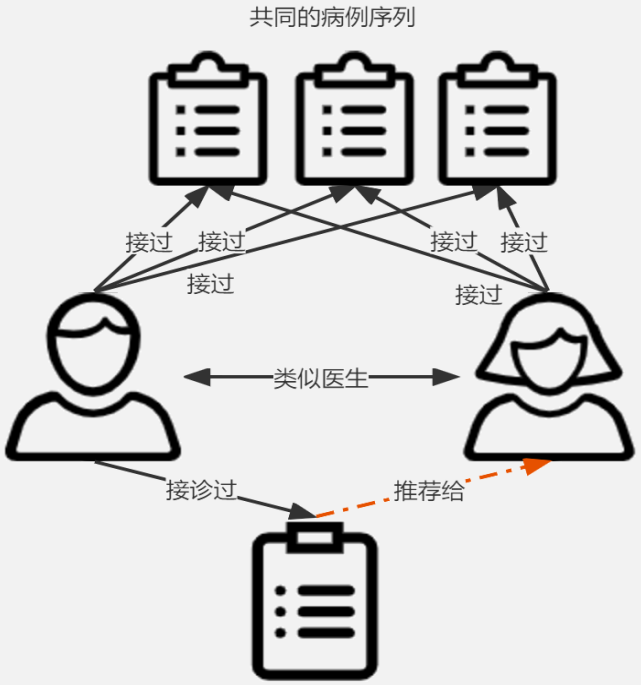
上下文信息包括(1)人口统计信息，如用户的性别、年龄、国籍、职业、教育和收入水平；(2)社交信息，如用户之间的联系和互动，如关注者、被关注者、声誉、信任、社交标记和可信度；(3)认知信息，如用户的目标、心情和当前心理状态可以显著提高推荐过程的有效性。

05 Hybrid

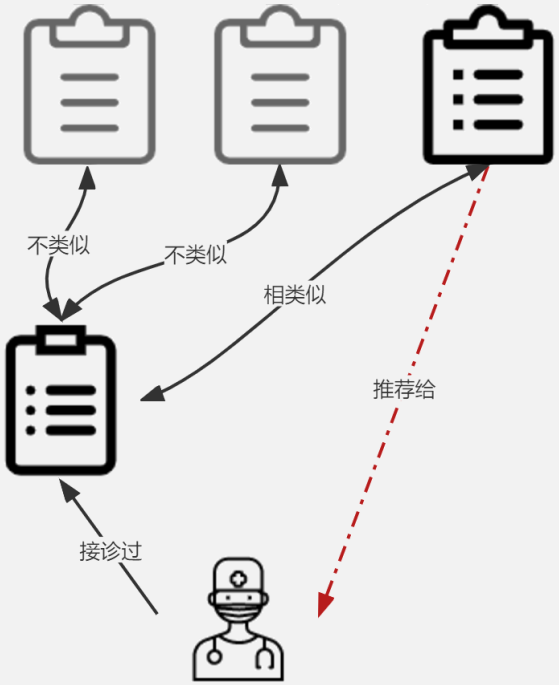
混合方法将两种或更多不适用于单独处理某些情况的基本方法混合在一起，通过应用各种模型和推荐算法的优势来克服它们的一些缺点。

国内外研究现状

协同过滤推荐算法



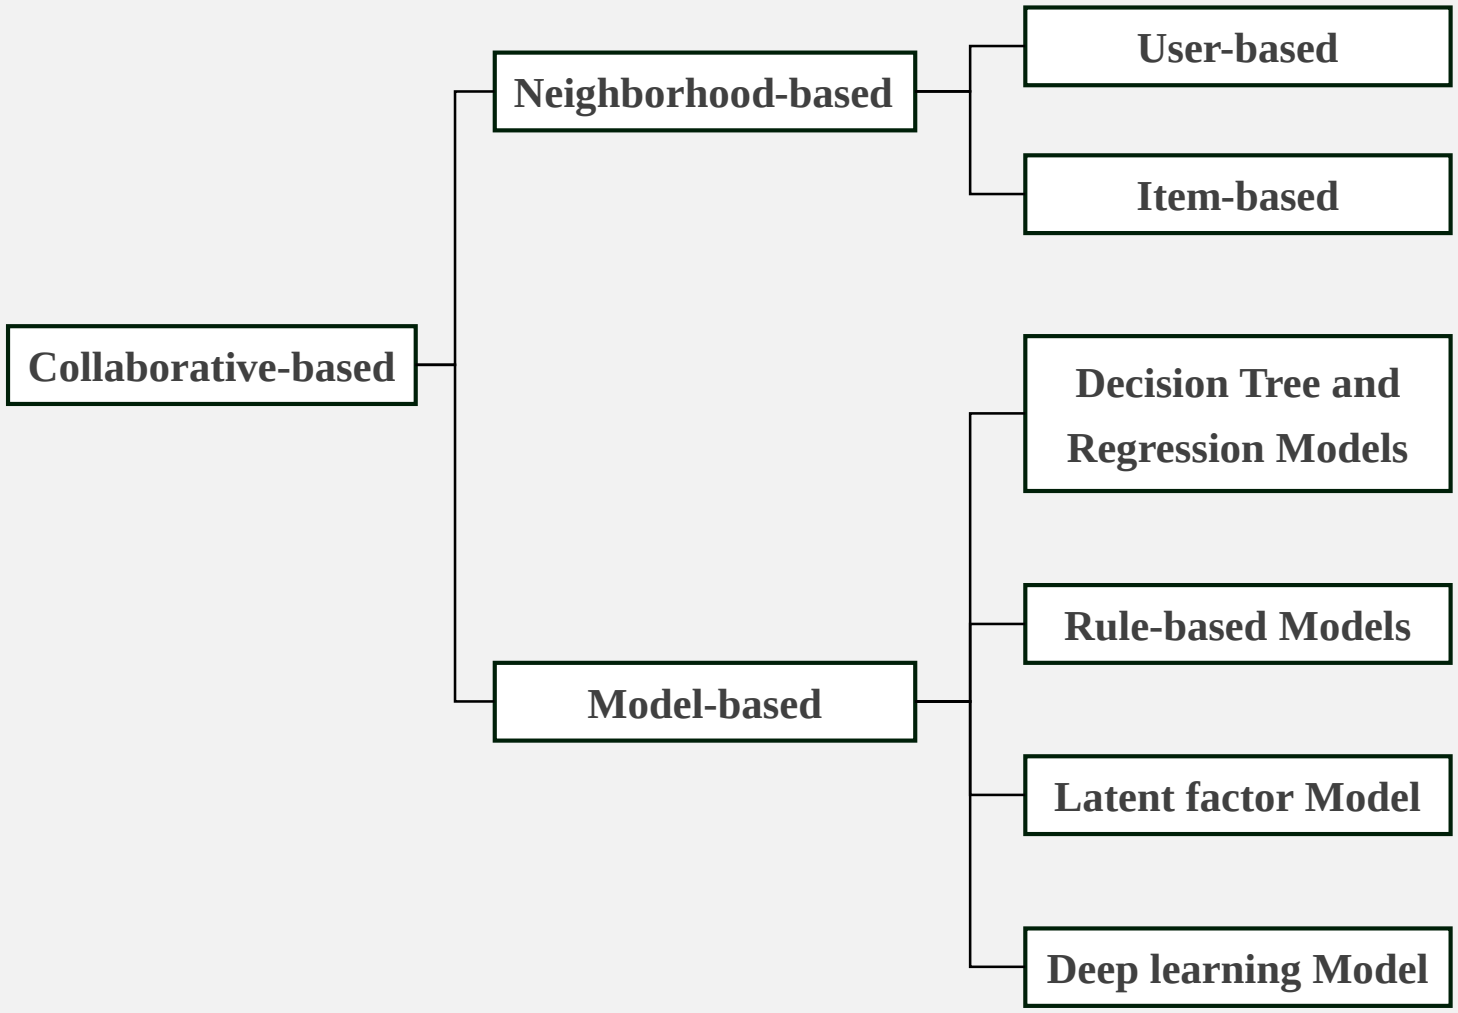
基于医生协同过滤User-CF



基于病例协同过滤Item-CF

国内外研究现状

Collaborative-based



(Hoens et al., 2013) 设计了一个可信赖的医药推荐系统。

(Yang et al., 2017) 结合社交网络与情感分析，进行糖尿病病友社交推荐。

(Guzman et al., 2018) 提出用于感知生理变量的协作框架，第一阶段利用决策树跟踪心率，进行风险分类；第二阶段进行医护推荐。

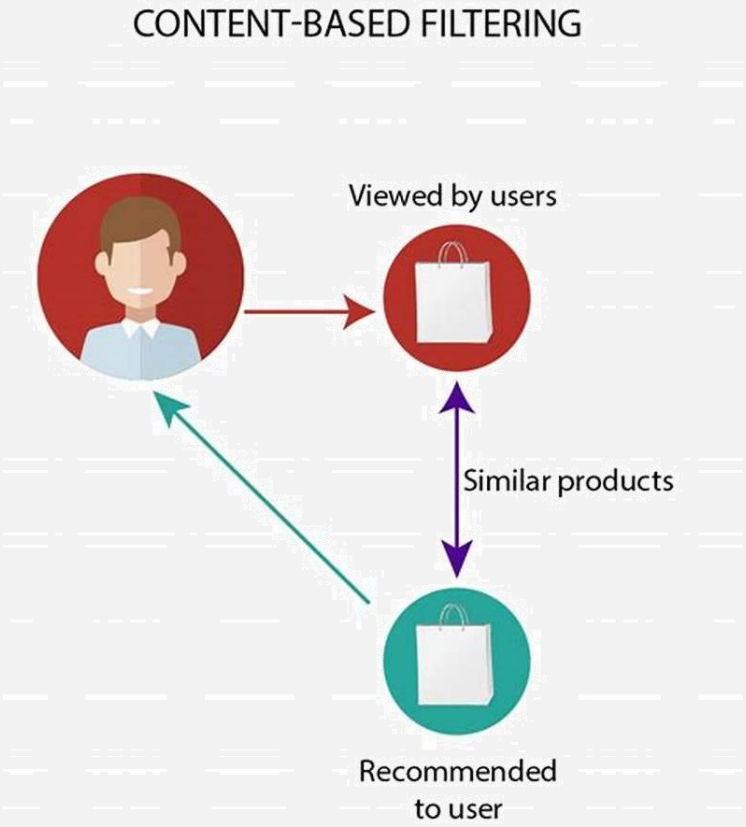
(Hussein et al. 2014) 应用聚类和分类方法开发慢性病推荐系统，提供健康生活建议。

(Yu et al., 2021)应用因子分解算法来融合收集到的用户特征和目标领域信息，以提供可穿戴医疗设备推荐。

(Deng & Huangfu, 2019)提出了一种协作振动深度学习模型（CVDL），利用多源信息为初级保健服务提供医疗建议。

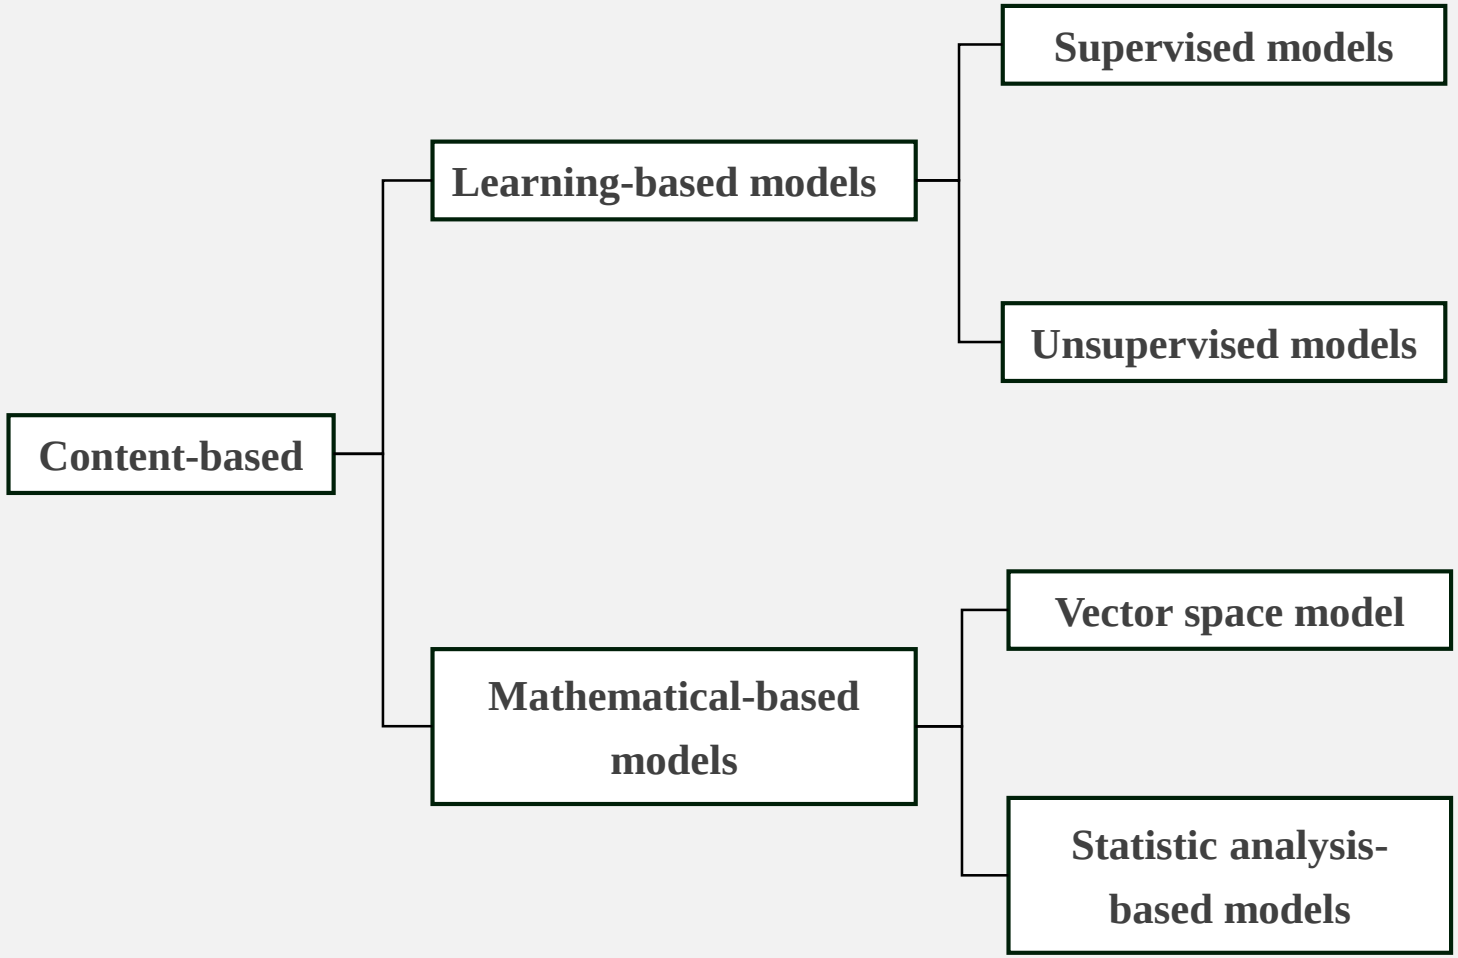
国内外研究现状

基于内容的推荐算法



国内外研究现状

Content-based



(M. Sharma & Ahuja, 2017) 根据患者的新医疗状况、病史和疾病进行医疗保健推荐。

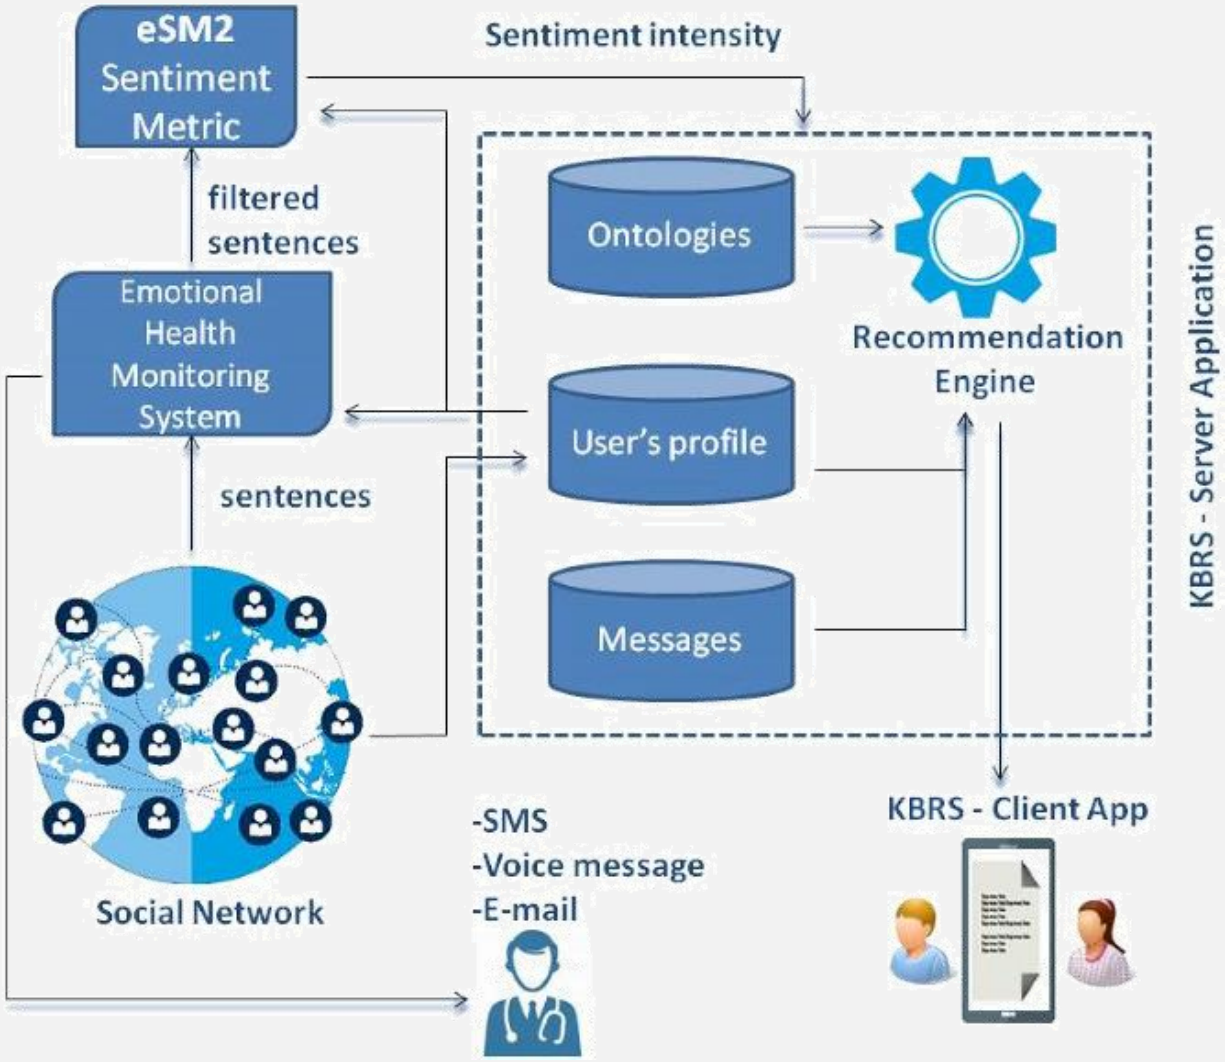
(Neloy et al., 2019) 基于关联规则与K近邻，使用基于内容的推荐系统监测ICU患者的健康状况。

(Ju & Zhang, 2021) 基于本体特征和疾病文本挖掘（词频统计和词向量计算）开发了一个在线预诊医生推荐系统。

(Marcu et al., 2020) 利用跨行业标准数据挖掘流程、数据集分割和动态缓存机制，优化医疗推荐系统。

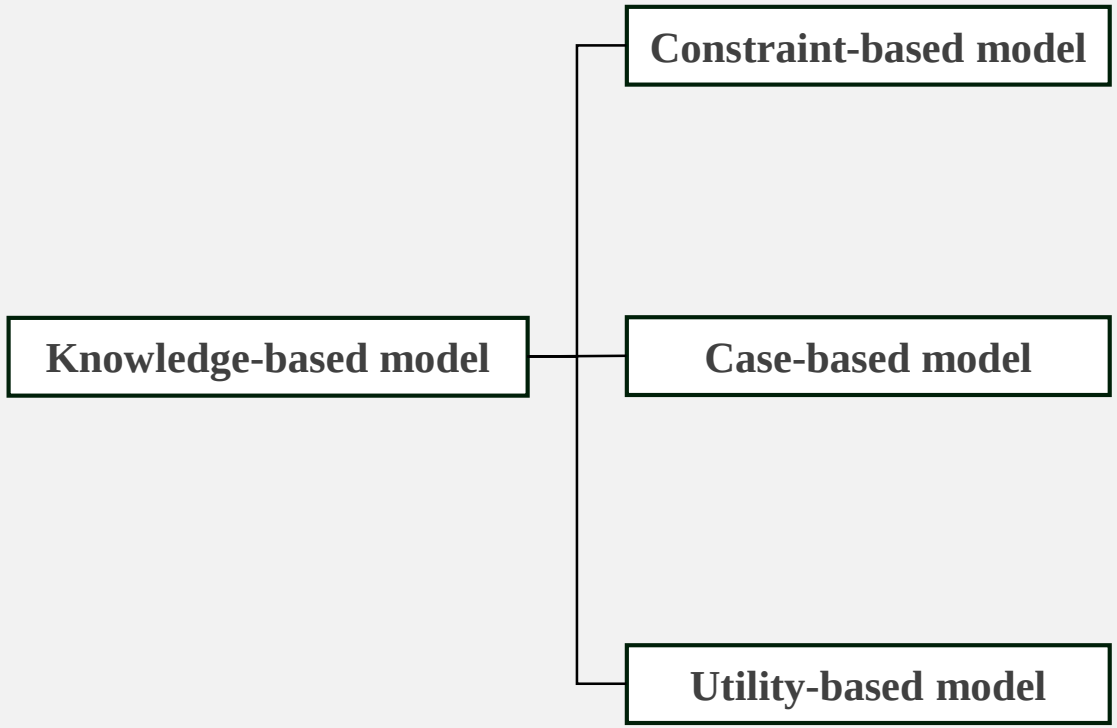
国内外研究现状

基于知识的推荐算法



国内外研究现状

Knowledge-based

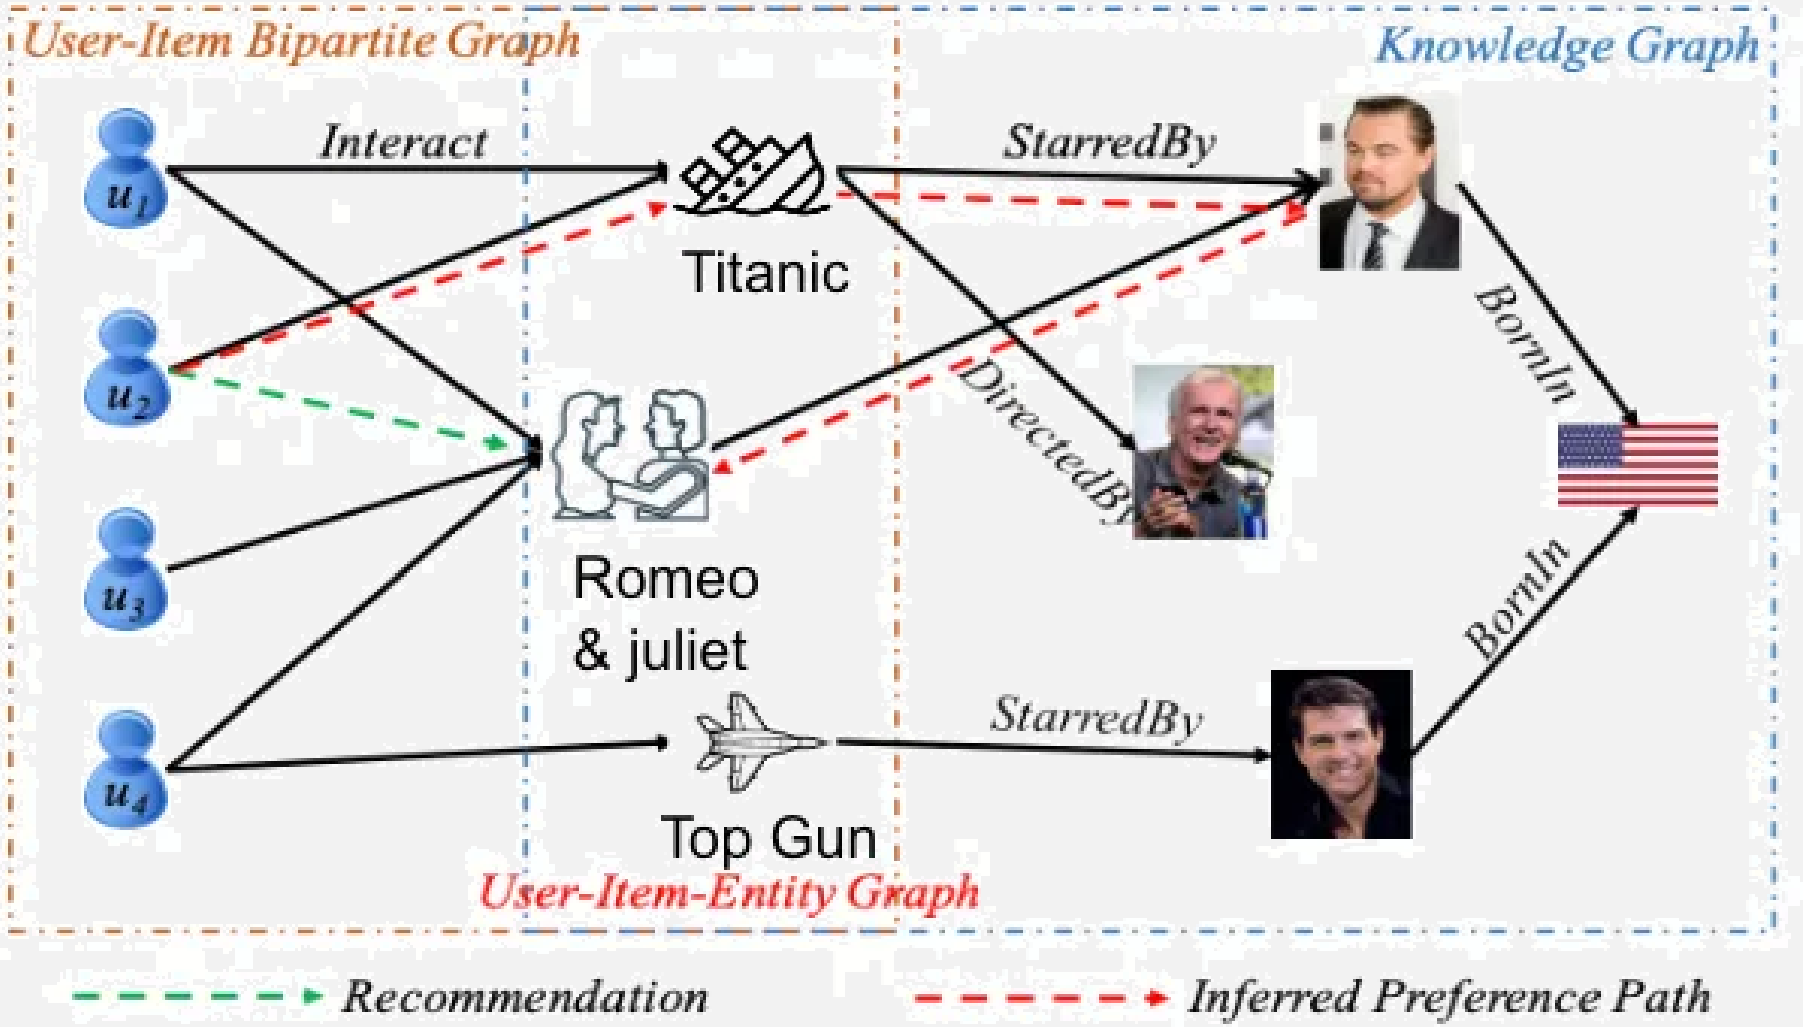


(M. Sharma & Ahuja, 2017) 提出了一个预测模型，在该模型中利用患者过去的病史来定义个体未来疾病风险（同时出现在同一患者身上的常见疾病集合而生成）。同时还构建了一个表型共病网络，研究其结构特性以理解疾病之间的联系。

(Ali et al., 2018) 提出了一个系统，通过可穿戴传感器提取患者的风险因素数值，定义患者的健康状况，给出关于糖尿病特定处方的建议，并为智能冰箱推荐食物。

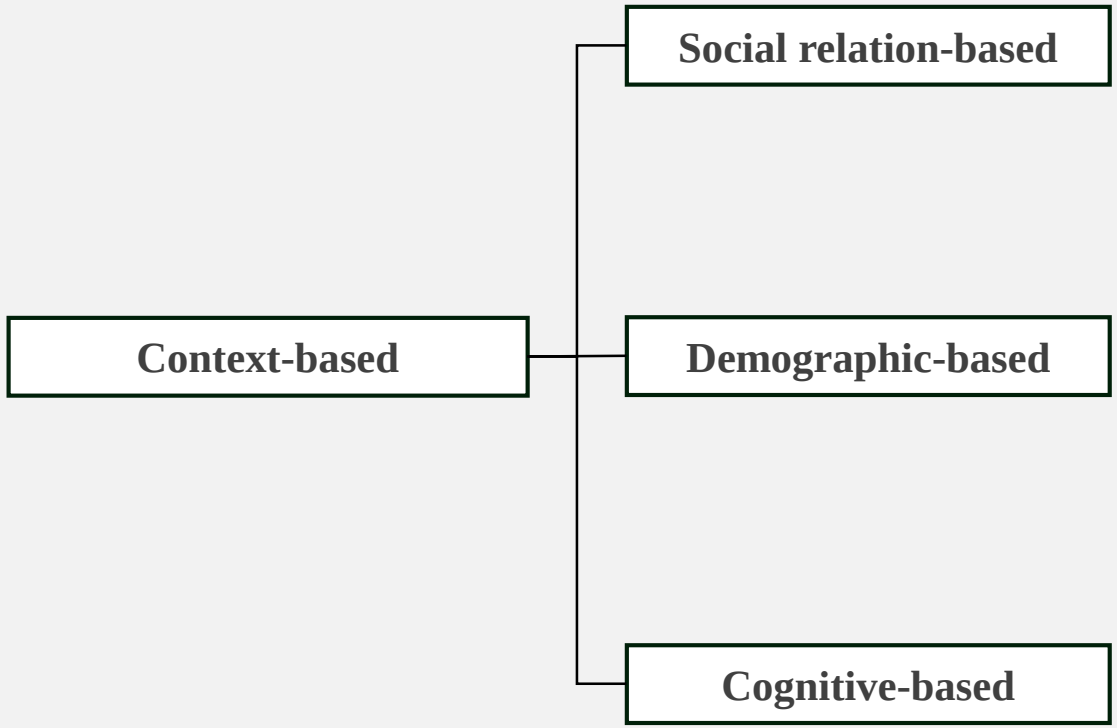
(Ju & Zhang, 2021) 提出了一个疾病诊断治疗的推荐系统，首先更准确地识别了疾病的症状，并引入了一种密度峰聚类分析算法来对疾病症状进行聚类。其中，与疾病诊断和治疗相关的规则分别由apriori算法执行关联分析。

国内外研究现状


User-Item Bipartite Graph
Knowledge Graph
Interact
StarredBy
Titanic
DirectedBy
BornIn
Romeo
& juliet
StarredBy
BornIn
Top Gun
User-Item-Entity Graph
Recommendation
Inferred Preference Path

国内外研究现状

Context-based



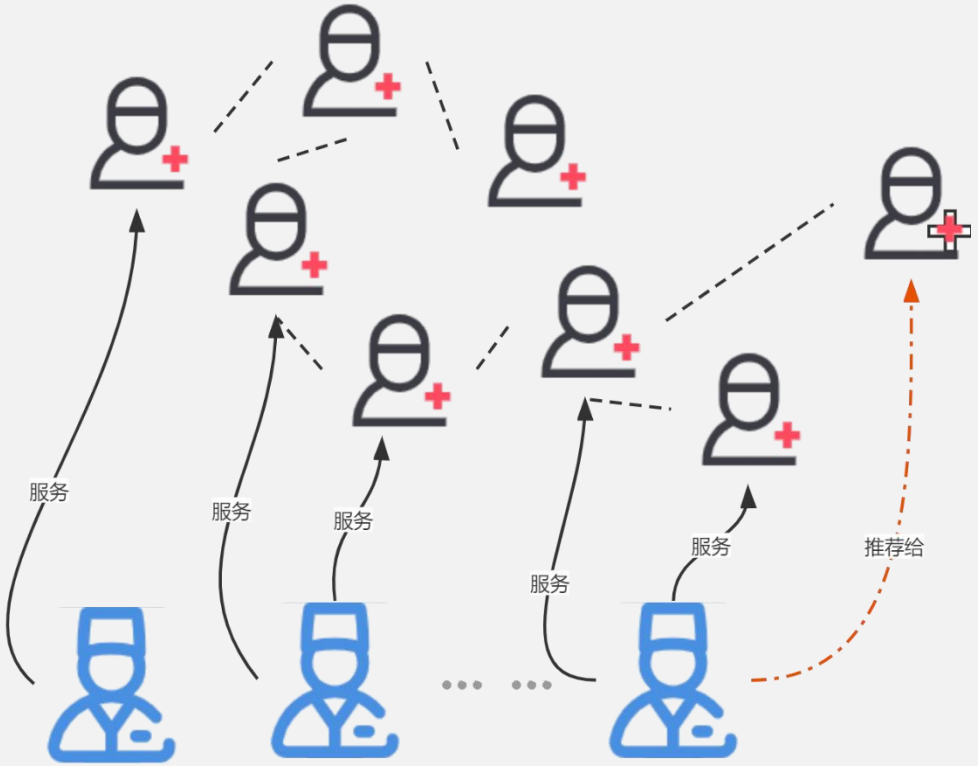
(M. Sharma & Ahuja, 2017) 提出了一个基于社区主题的链接预测模型，将传染病临床试验建模为赞助商和研究领域之间的二部网络，以区分受到研究人员关注较多和受到较少关注的传染病研究领域。该模型通过结合社区和主题向赞助商或调查员推荐临床试验研究主题。

(Iwendi et al., 2020) 基于深度学习技术，利用每位患者的疾病和其他因素，如年龄、性别、体重、卡路里、蛋白质、脂肪、钠、胆固醇、纤维等，制定个性化的饮食方案。

(J. Kim et al., 2014) 提出了一种情境感知推荐方法，依赖于神经学习，根据不同的生理生命体征来识别情况，如从医疗保健系统的传感器设备中获取并存储的体温、血压、心率和呼吸频率等生理信号。

国内外研究现状

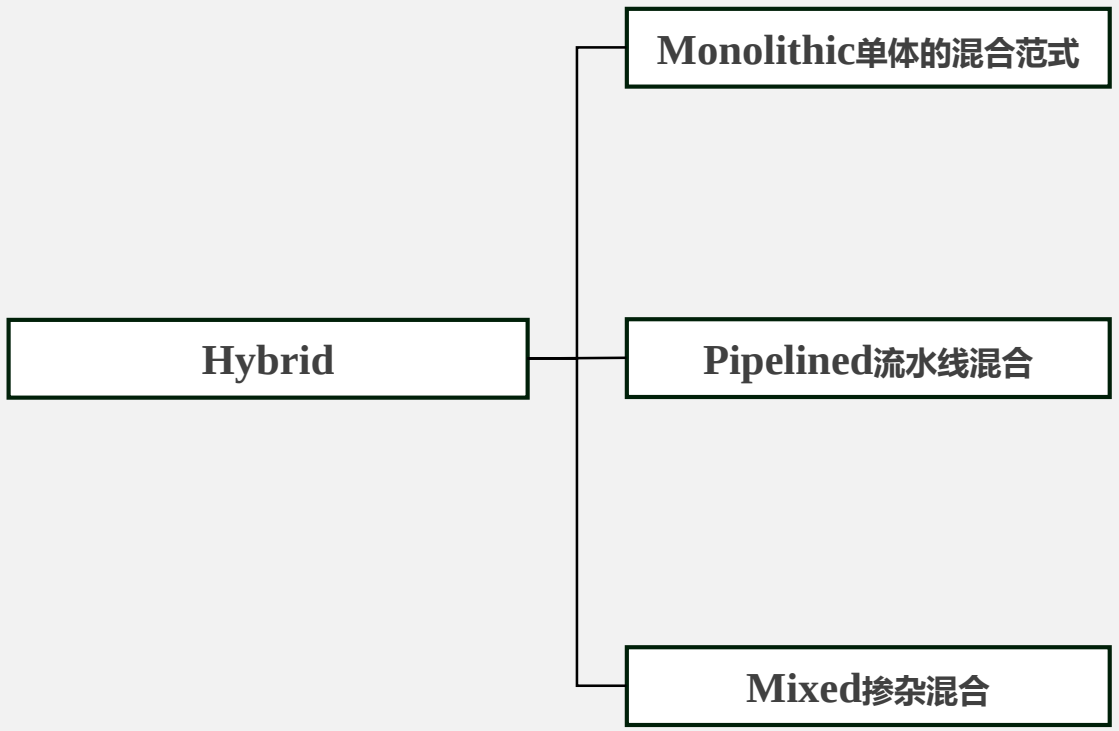
基于社交网络推荐算法



基于病友社交网络的一个医生推荐样例

国内外研究现状

Hybrid



(Jiang & Yang, 2017) 研究混合方法在作为异构医疗信息网络的医疗社交媒体数据中的效率

(Hussein et al., 2012) 提出了一种基于混合方法的慢性疾病诊断（CDD）RS方法，该方法在CDD方法的第二阶段应用了统一的协同过滤方法和多重分类方法，实现了在医疗建议推荐方面的高准确性

(Graßer et al., 2016) 提出了基于人口统计学和协同过滤的混合推荐系统，用以支持治疗决策。

困难与挑战

隐私与法律

隐私安全日益受到挑战，如同信息保密性、隐私条款、访问控制、患者信息去标识化、患者数据所有权的管理等问题越来越受到重视

1

2

标准化对齐

不同医疗机构常常遵循不同的标准，例如在药物、病例报告、检查和疾病的代码和名称方面各不相同。通用标准标准能够允许不同的平台、系统、技术和工具之间的互操性。

3

系统冷启动

匮乏跨医生或跨患者的评分信息，很难找到患者和医生之间的相似性，新患者偏好无法预测，新医生也无法被用户评分或访问，导致更少的正确推荐。

4

花费与时间成本

当病人去看病时，医生会建议最好的治疗方法，而这种治疗方法可能会很昂贵，从而导致病人及其亲属之间产生分歧。在智能医疗系统中也会出现类似情况，会针对可能更加昂贵的问题推荐最佳解决方案。

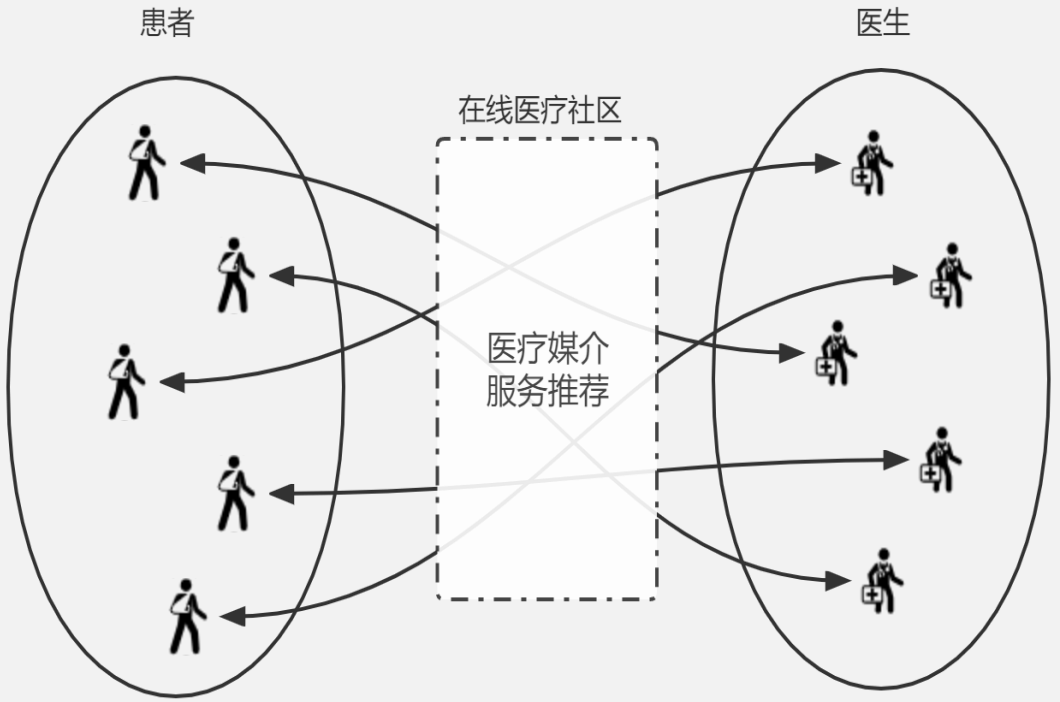


03 研究方法

RESEARCH METHODOLOGY

研究方法

- OHC是患者和医生联合构成的一个双边市场，该市场存在交叉网络外部性，即一方用户数量将影响另一方用户数量和市场整体交易量。
- 只考虑患者一方需求，不考虑医生一方意愿，即便推荐方案再“好”显然也难以达成。
- 既然双边用户具备各自的外在需要和内在偏好，显然需要建立一种全新的、面向服务的双边公平性推荐研究范式。



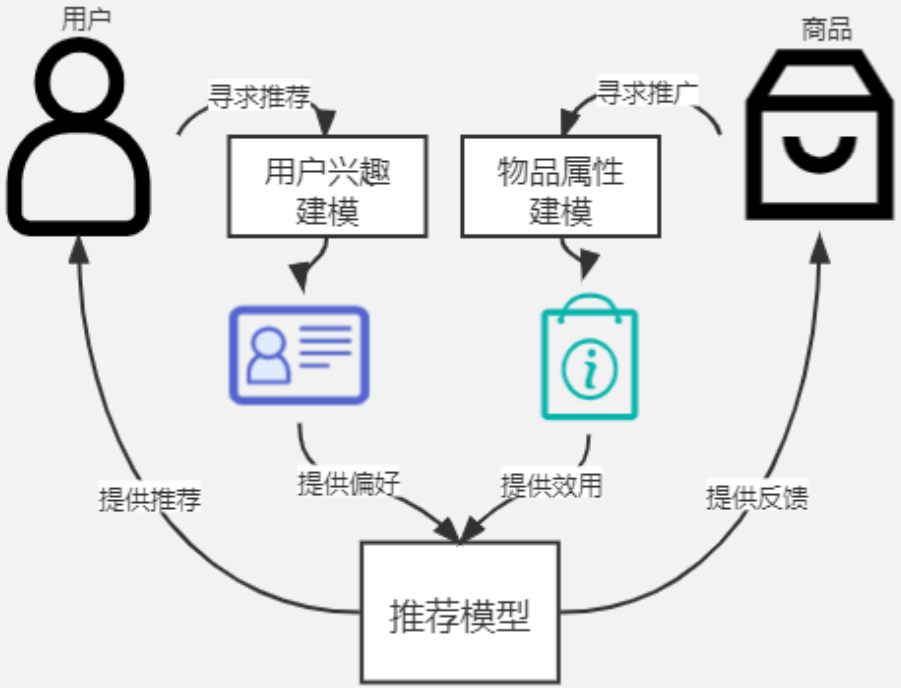
患者与医生联合构成的一个双边市场



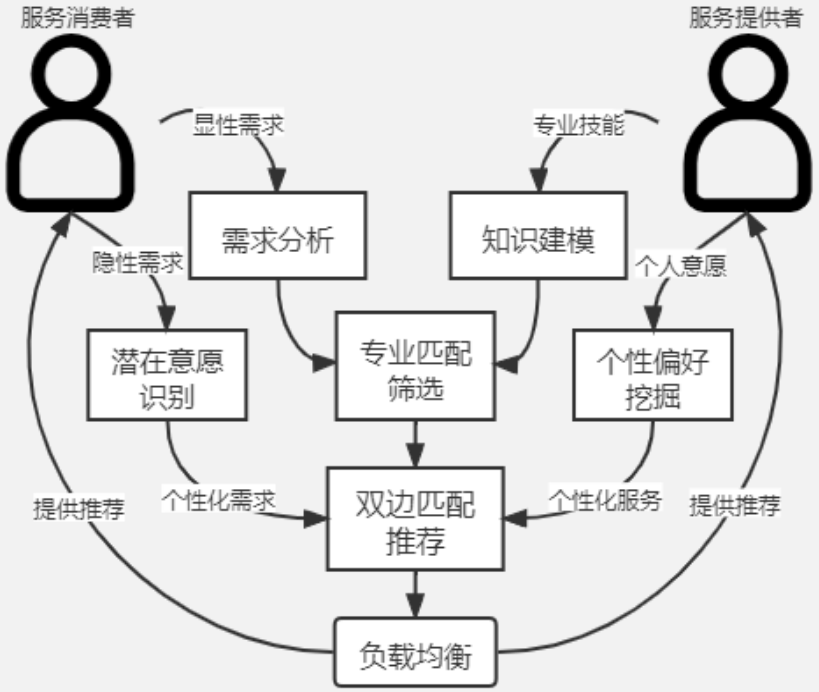
问诊推荐系统

面向在线问诊服务（Online medical consultation，OMC）推荐系统，其推荐标的物并非一个商品，而是一种以人为载体的专业服务。以往个性化推荐研究只需考虑用户需求和偏好，无须关心被推荐物品的感受；然而OMC能否推荐成功，不仅取决于患者是否采纳，也取决于医生是否接受，且在医疗领域由于后者认知水平更高，其意见也更重要。由于在线咨询数据以及医学数据复杂多样，生成速度快，其处理与分析工作变得日益困难。

研究方法

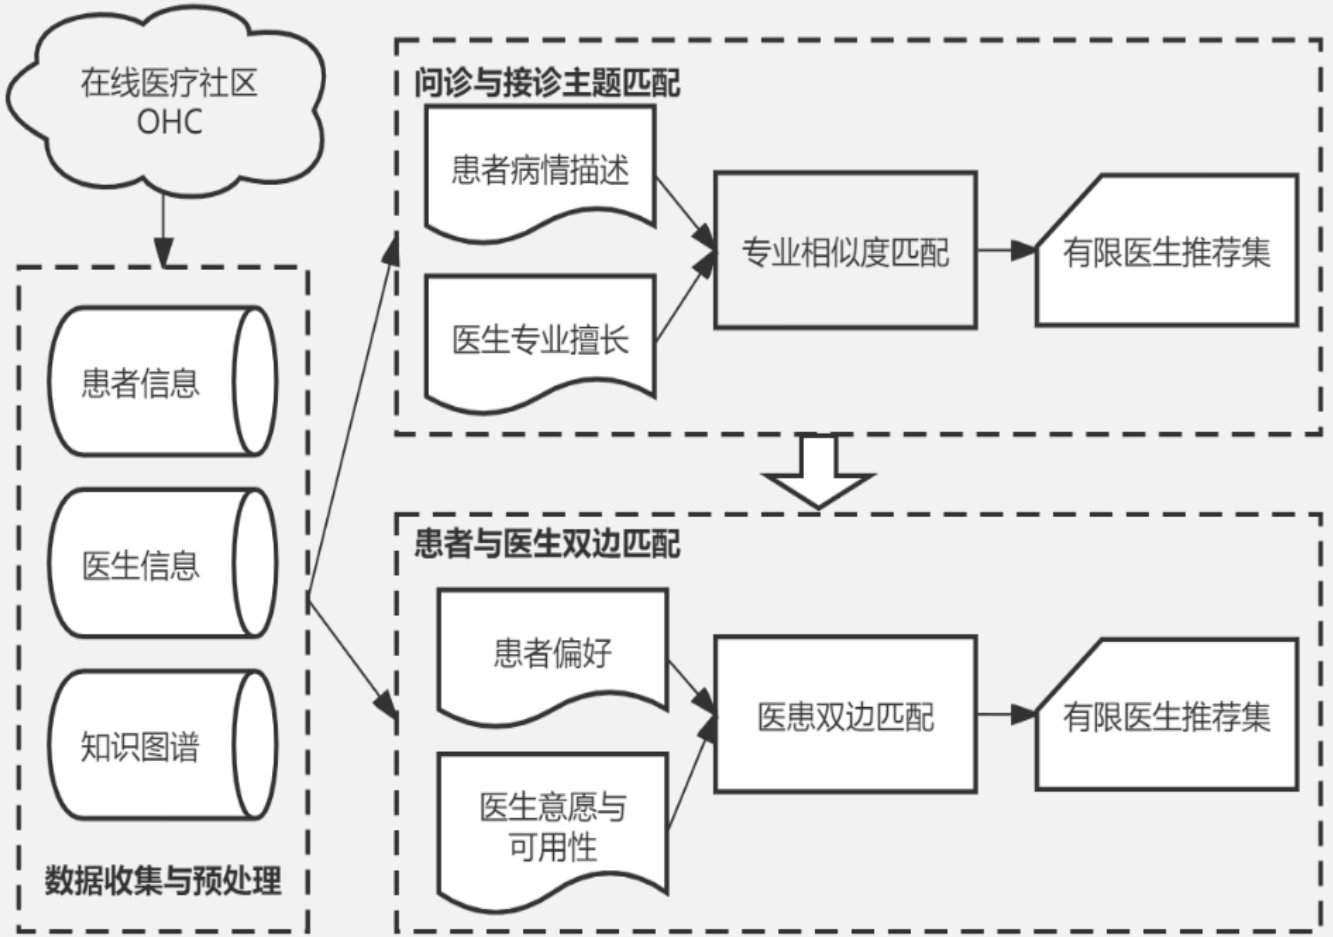


面向商品的个性化推荐系统



面向服务的个性化推荐系统

研究方法



医生推荐框架图



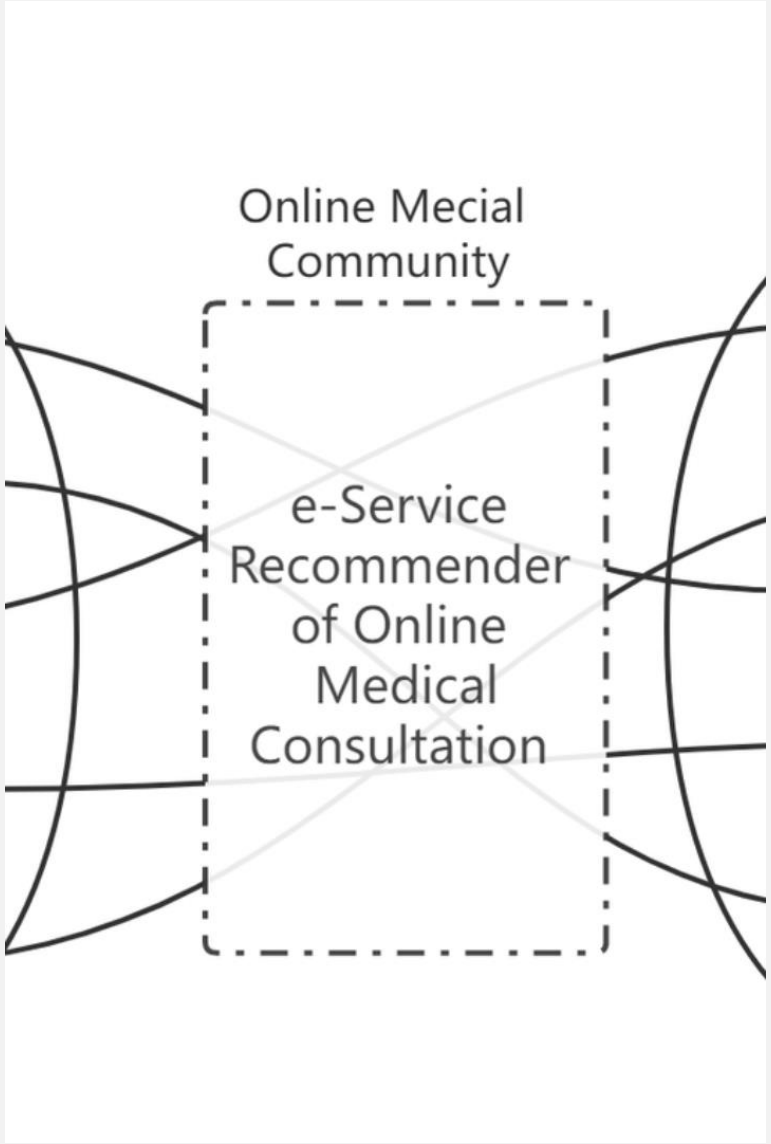
中国人民大学
RENMIN UNIVERSITY OF CHINA

BalanRec: A Two-Sided Personalized Recommendation Framework for Optimal Patient-Doctor Pairings in Online Medical Consultations

实事求是

BalanRec: 一种双侧个性化推荐框架

本研究旨在优化患者与医生之间的关系，提供双侧个性化推荐系统的设计和实现。



研究背景

- 在线医疗社区（OHCs）已成为在线医疗咨询（OMCs）的重要电子服务平台。
- COVID-19加速了OHCs的普及，强调了医生和患者之间的无接触交流。
- 在充满活力的OHC环境中，寻找合适的医生和患者仍然是一个挑战。

研究意义

我们的创新框架BalanRec将为患者和医生带来革命性的推荐服务，大大提高医患之间的沟通效率。

挑战

当前的医疗推荐系统存在着单一和不够个性化的问题，我们需要一个更加灵活、全面的解决方案。

目标

我们的目标是改善在线医疗咨询（OMCs）场景下的医患双方个性化推荐效果。

- 在OHCs中，患者和医生发挥着同样关键的作用，患者推动收入增长，医生提供必要的服务。
- 由于缺乏高效的推荐系统，患者面临信息过载的问题。
- 由于与患者的匹配效果不佳，有能力的新医生被低效利用。

研究动机

1 实现一体化

建立一个全面的双向沟通框架，促进医患关系更加平等、透明。

2 提高满意度

通过个性化推荐，提高患者对医疗服务的满意度，增强医生的专业形象。

3 优化治疗方案

帮助医生更好地了解患者需求，提供更贴合的治疗方案，提高治疗效果。

- BalanRec是一种专门为面向人类的OMCs设计的平衡推荐模型。
- 它为医生和患者提供个性化推荐，考虑到专业特点和偏好。
- 关键特征包括基于前景理论的个性化建模和双侧方的平衡推荐。



BalanRec主要贡献

01 前景理论

基于前景理论的个性化建模：利用前景理论对医生进行建模，并引入个性化指标来衡量患者的偏好。

02 平衡推荐

针对双方的平衡推荐：基于多尺度特征矩阵和加权偏好为医生和患者提供推荐。

03 更新机制

随时间更新机制：通过挖掘医生的拒绝列表并更新推荐结果，适应个体行为变化。

框架设计

中国人民大学 RENMIN UNIVERSITY OF CHINA

平衡性

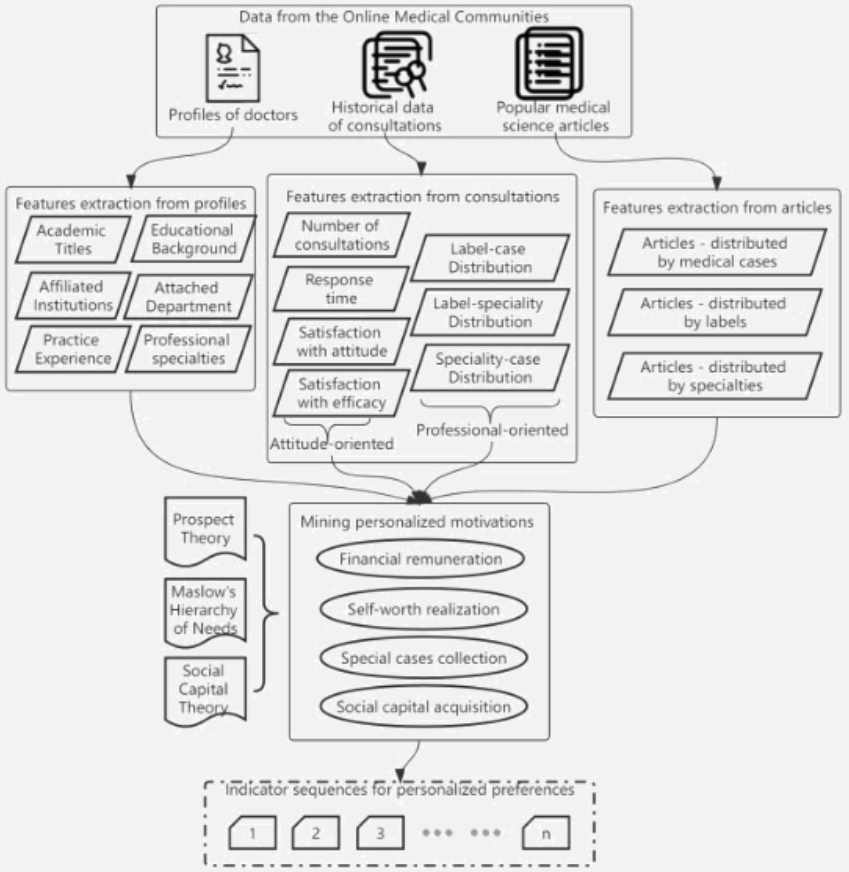
平衡医生和患者双方需求，实现双向个性化推荐。

医生画像

关注医生的前景，推荐符合其主治方向的患者。

互动性

促进医患之间双向沟通和信息共享。



医生端学习：

- **专业特长挖掘（Expertise mining）**：通过医生的历史咨询对话进行聚类，识别医生在特定领域的专业特长。这样的特长信息通过预训练的 MC-BERT 文本编码器进行嵌入，形成医生的多尺度专业特长嵌入矩阵。
- **偏好挖掘（Preferences mining）**：分析医生的决策偏好，包括黑名单（被拒绝的咨询）、响应速度、在线离线声誉等因素。这些信息用于构建医生的个性化偏好模型。

患者端学习：

- **特征挖掘（property mining）**：对患者咨询文本编码，以理解其时间敏感性和费用敏感性需求。根据患者的需求，对医生进行个性化推荐。

terms related to time-sensitive (Z_p^t)	terms related to cost-sensitive (Z_p^c)
how long does it take to treat	how much is it
how long does it take; How long will it take me	not so/that expensive
how long can I recover	not much money/underbudget/limited budget
when will I/When to check in / be admitted / discharged?	cost/fees
very urgent	diagnostic/consultation fee
hopefully soon/hurry up/be quick	cheap

推荐算法

医患配对

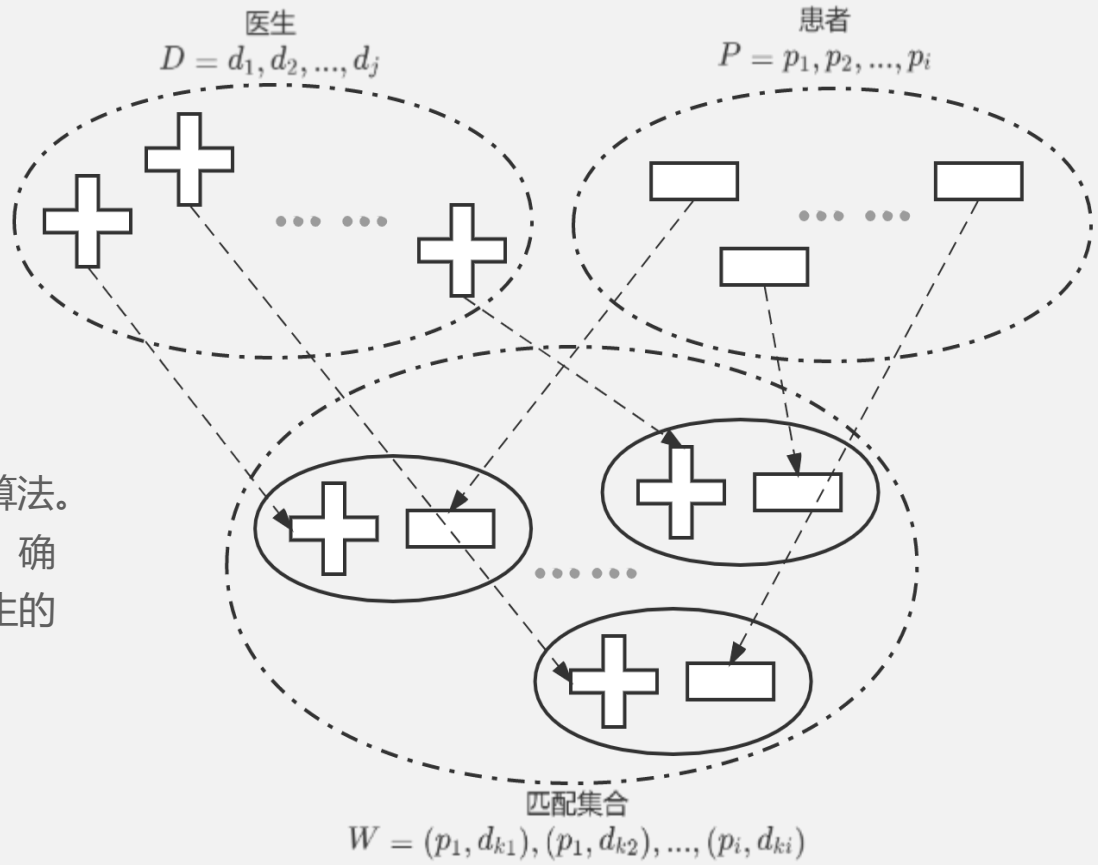
将患者查询和医生表示连接起来，
通过多层感知器（MLP）进行推荐。
综合考虑医生和患者的匹配程度，
以确定最佳医患配对。

负载均衡

基于医生曝光度的启发式重新排序算法。
通过设定医生的曝光度下限和上限，确保医生的公平曝光度，同时考虑医生的工作负荷和历史访问量。

集成模型

BalanRec 系统通过对医生和患者的学习，
结合个性化的推荐和平衡导向的重新排序，
实现了更好的医患配对，提高了在线医疗咨询的效率和质量。





中国人民大学
RENMIN UNIVERSITY OF CHINA

Bridging Expertise: Doctor Recommendations for Cross-Disciplinary Collaborations in Online Medical Consultations

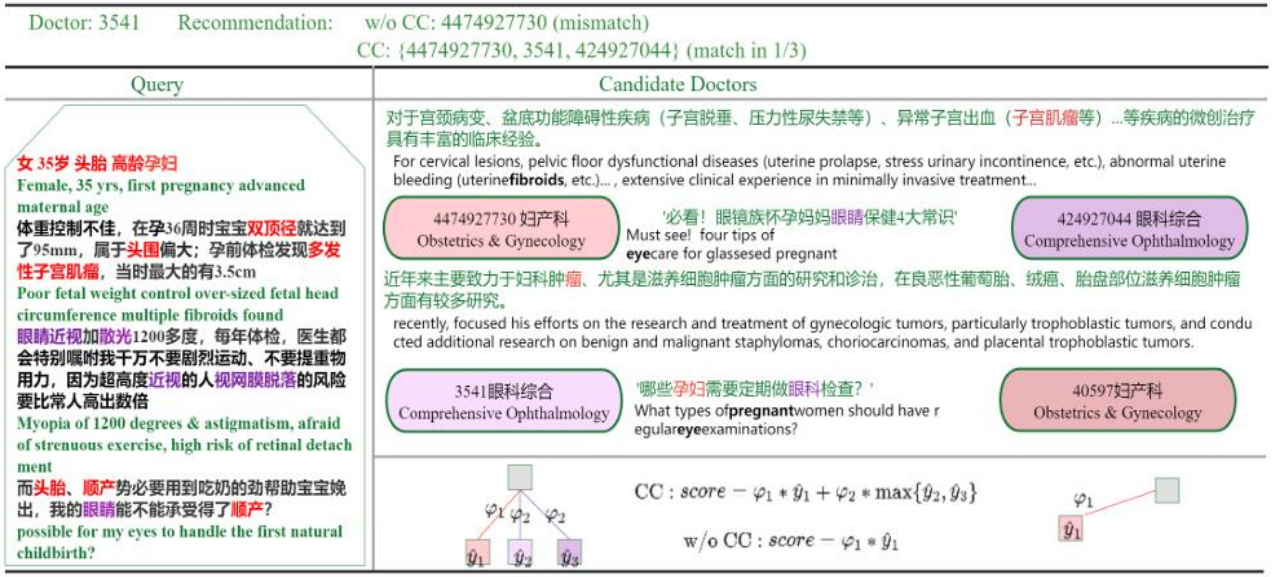
实事求是

医生推荐的价值和意义

- 互联网的发展带来了更加专业和丰富的在线医疗问诊社区，其代表有好大夫、春雨医生、 平安在线等OHC（Online Healthcare Community）社区
- 社区平台基于最基本的关键词索引引导患者自己寻找医生，带来了搜索成本的提高，以及患者专业知识不够带来的需求错配



医生推荐的价值和意义



- 在线医疗保健社区（OHCs）已成为疫情后医疗保健的关键组成部分，使偏远地区的患者能够通过在线医疗咨询（OMCs）与医疗专业人员建立联系
- 传统医生推荐集中在单一专业医生的推荐
- 缺少跨学科专业医生组合的推荐
- 病症的症状可能覆盖了多种科室，其主次和比重需要被认识和高质量的分析解决
- 细分的专业和科室分割阻碍了真正病情的诊断，对于模糊、似是而非和棘手的症状，跨部门和医院的合作往往是必不可少的

Related Work

- 目前医生推荐主要是两种算法:
  - text mining-based algorithms
  - knowledge graph-based algorithms
- 目前的医疗保健研究集中于单一领域的专家建议，缺乏跨学科合作的研究
- 主要集中在将患者的询问与医生的专业知识相一致，优先考虑主题相关性，但在主观和客观上对医生质量的评估存在显著差距。
- 使用了医生的简介及其学术出版物等外部信息
- 在医生信息的高质量编码方面，图及图的多样化处理也成为一个热门的突破口
- 基于对话的医生推荐（DDR）、结合异构图形注意力网络、基于图形增强存储模块对电子健康记录（EHR）和药物-药物相互作用（DDI）图形进行编码，等等，都是图形智能算法在医疗领域的应用;

- 在外部信息的获取上，除了传统的基于人际交往和专业交流的社区关系，基于地理信息的关系也是医生推荐中可行的突破口;

Methodology

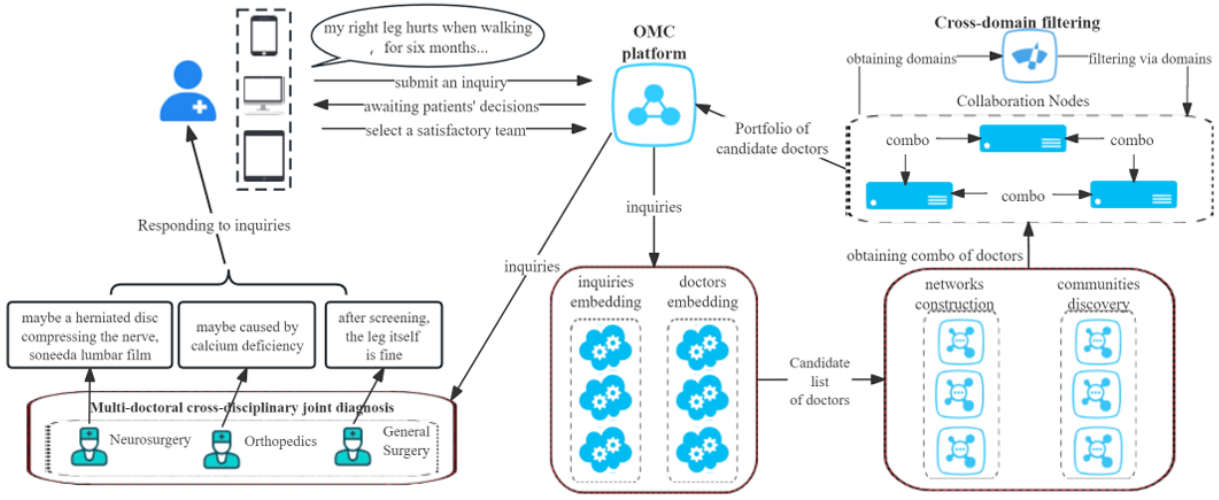


Fig. 1. Doctor combination recommendations for multi-disciplinary treatment (Mdt)

- 平台处理query流程
  - 平台获取患者的query将其embed后在我们构建的cross-domain知识图谱网络中寻找候选医生，之后通过医生列表的基础排序和重排推荐给患者高质量的跨科室医生推荐列表，并交给患者进行一定程度的再选择，最后由医生专家组形成一些诊断建议

Methodology

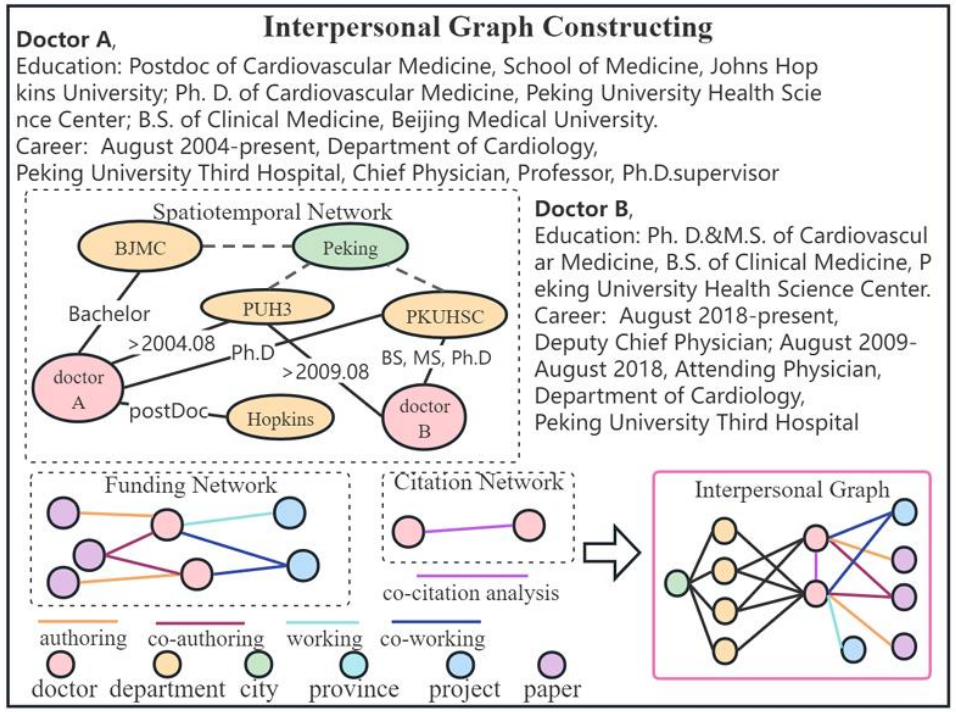


Fig. 3. The construction process of the doctor's interpersonal graph

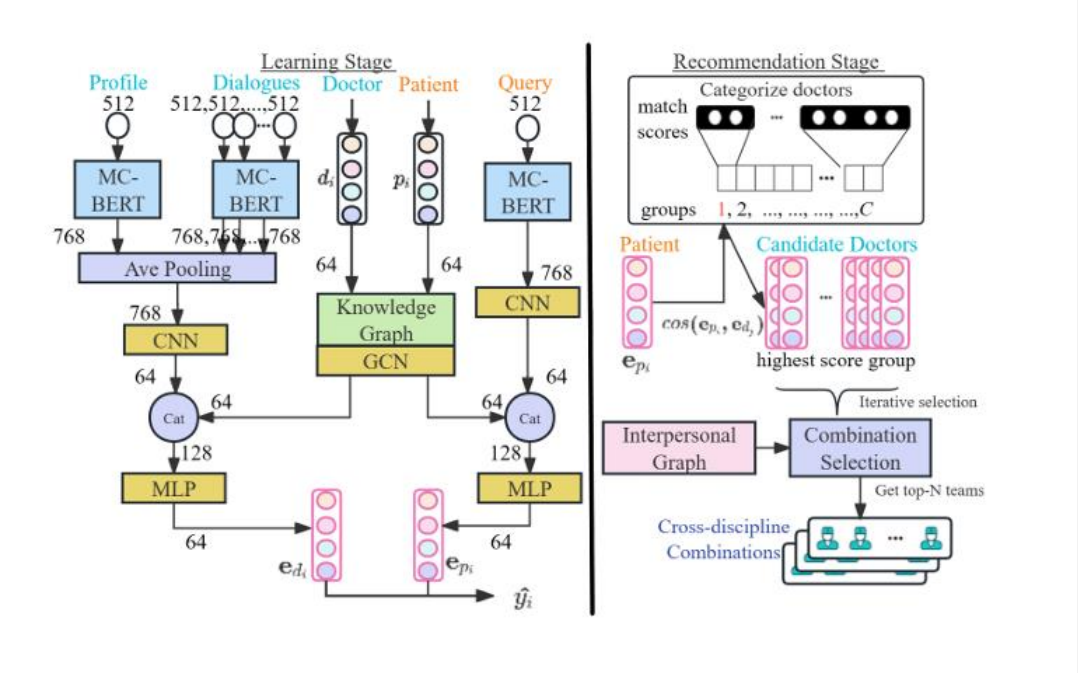
- 知识图谱组成部分
  - Funding network
  - Citation network
  - Spatiotemporal network

Methodology

- 模型部分（两阶段模型）
  - 第一阶段（learning stage）：

    将医生的profile和dialogue以及患者的query基于BERT模型进行编码；之后基于降维模型进行重新嵌入组织；同时基于构建的知识图谱使用GCN等模型进行图嵌入；两者得到的嵌入进行重新组合，通过MLP获取医患两两匹配得分score；
  - 第二阶段（Cross-Disciplinary reranking stage）

    将得到的每个query的医生排序序列通过自己设计的跨科室重排算法，让最终的推荐序列中包含尽可能多的高相关科室，并确保这些医生同时满足患者的专业性和个性化偏好需求；





04 难点和创新之处

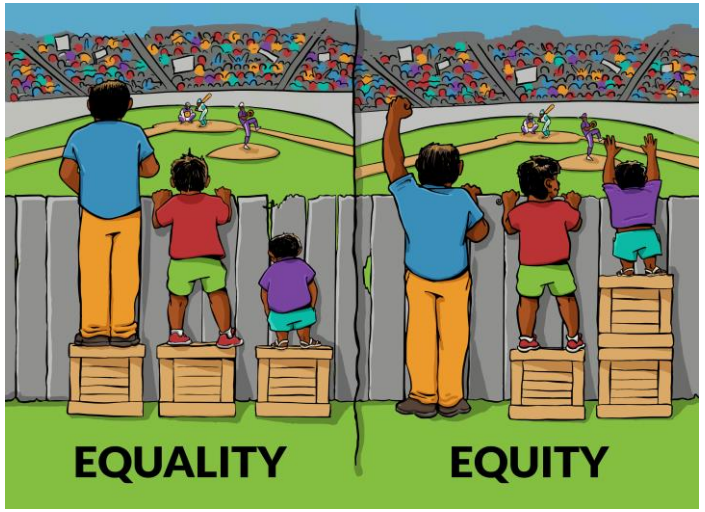
CHALLENGES AND INNOVATIONS

公平性推荐



过程公平性

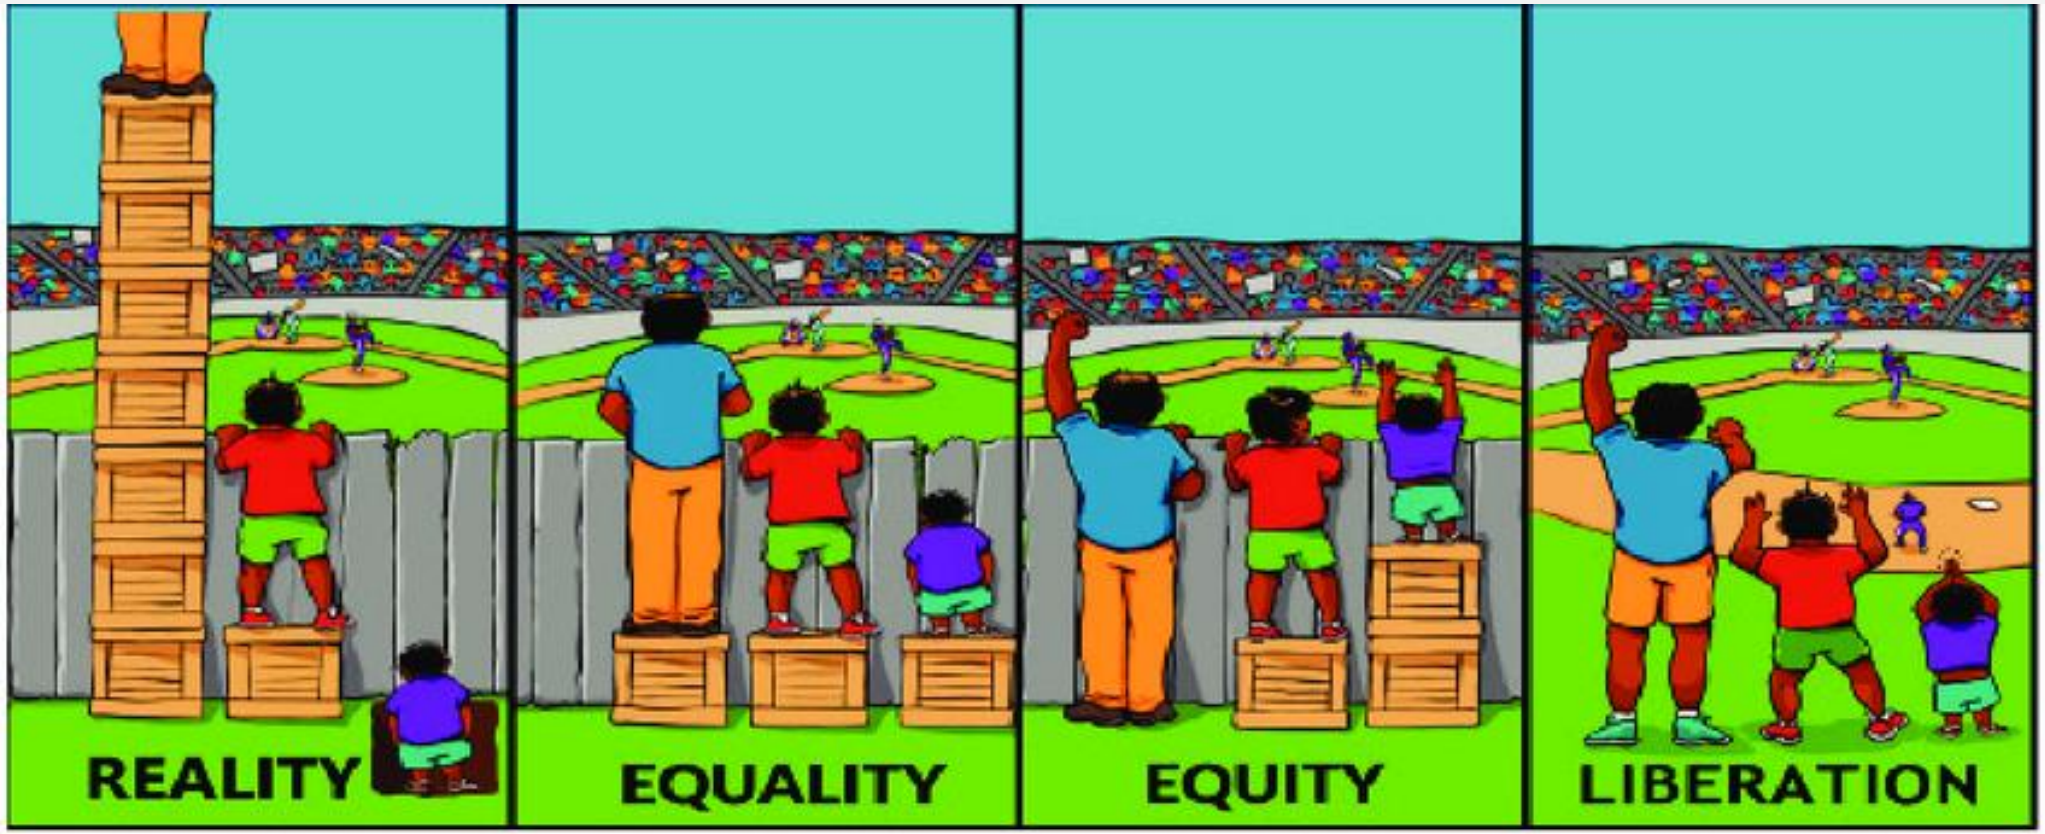
公平的分配应该在过程中就体现出公平，这也被称为程序正义。主要关注分配过程中使用的信息是否公平，如在工作推荐中，是否使用了某些不公平的特征（例如种族），以及学习到的表示是否公平。



结果公平性

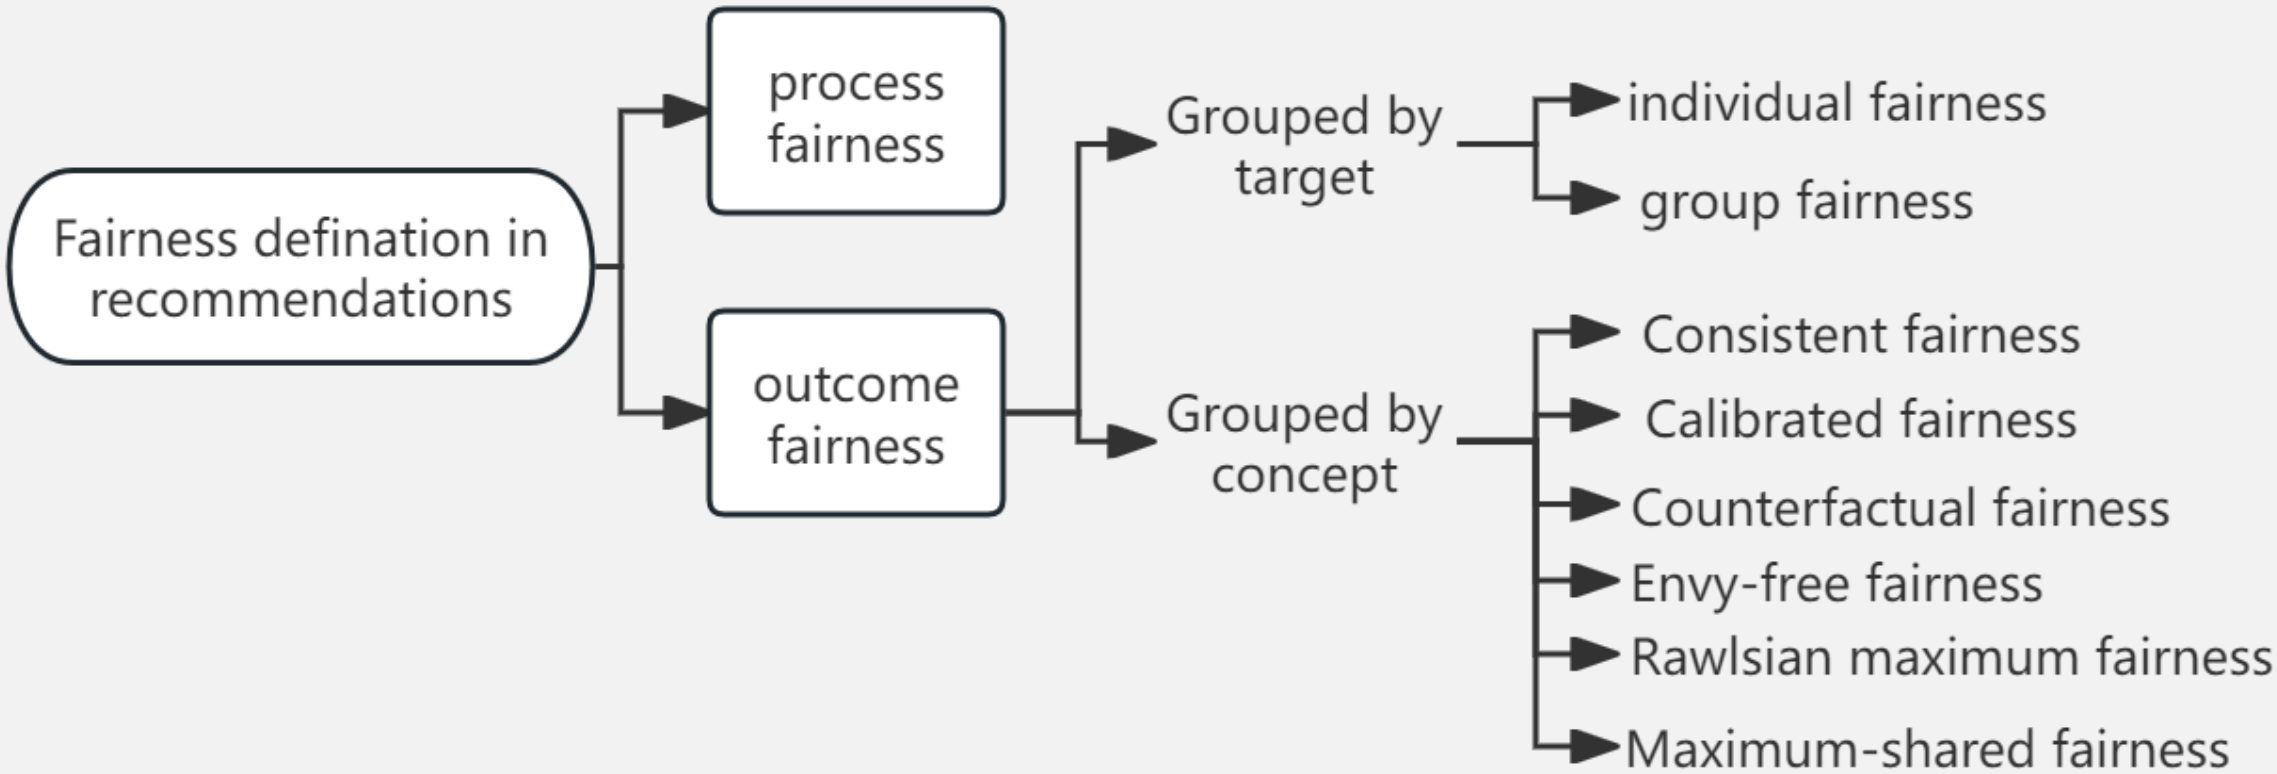
公平的分配应该导致公平的结果，这也被称为分配正义。例如，在工作推荐的情况下，结果公平性关注的是推荐结果是否公平，如不同能力相同的白人和黑人是否有同等的被推荐机会。

公平性推荐



公平性推荐

推荐系统中公平性定义



公平性推荐

推荐系统公平性涉及其作为资源分配工具的角色，旨在公平地向用户分配信息和向项目提供曝光。

公平性问题在不同的推荐场景和不同资源（用户和项目）之间都存在，对个人体验和社会利益产生重大影响。

- 在电影和音乐推荐中，不同年龄和性别的用户之间推荐准确度存在显著差异，女性用户和年长用户经常得到较差的推荐结果。
- 研究还发现在多样性和新颖性等其他推荐度量上也存在相当大的差异。

对于项目而言，少数群体的项目可能会得到较差的排名表现和较少的曝光机会。

- 在高级业务场景中，付费项目可能比非付费项目获得更差的平台服务。

公平性推荐

推荐系统公平性评价指标

01 NDKL 散度

NDKL (Normalized Discounted Kullback-Leibler Divergence)基于KL散度的项目不公平度量指标。它计算每个位置的KL散度，然后获取一个标准化的折扣累积值。该值越低，表示推荐结果越公平。

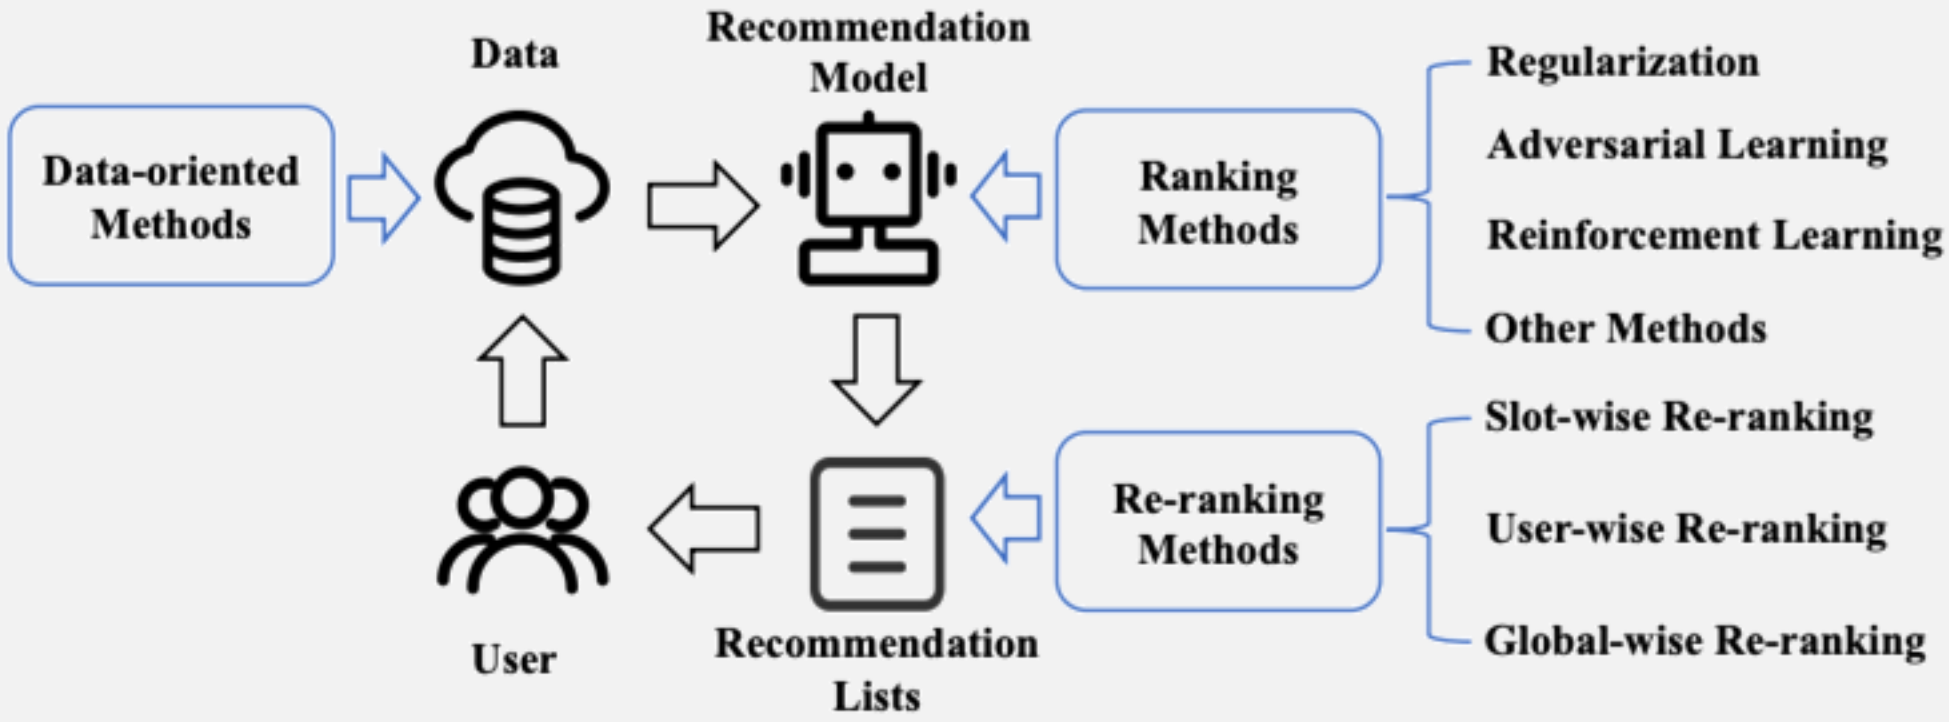
02 JS散度

JS (Jensen-Shannon Divergence)类似于KL散度，也是用来衡量两个概率分布之间差异的指标。不同之处在于JS散度是对称的，而KL散度是不对称的。JS散度的值越低，推荐结果被认为越公平。

03 总体差异性

总体差异性 (Overall Disparity)衡量不同群体之间效用与价值比例的平均差异。效用可以是基于曝光或点击的。该值越低，表示推荐结果越公平。

公平性推荐方法



Taxonomy of fairness methods in the recommendation and their position in the recommendation pipeline.

公平性推荐

A. **数据驱动的方法**：通过分析数据找出潜在的不公平因素，并针对性地进行优化。例如，通过分析用户和物品的特征，找出可能存在的偏见，并调整推荐算法以减少这些偏见。

B. **模型排名的方法**：通过调整推荐结果的排序，使得不同用户或物品之间的推荐结果更加公平。例如，通过调整推荐结果的排序，使得不同性别的用户得到相似的推荐结果。

C. **重排序的方法**：在推荐结果已经生成的情况下，通过调整推荐结果的顺序，使得不同用户或物品之间的推荐结果更加公平。例如，通过调整推荐结果的顺序，使得不同年龄的用户得到相似的推荐结果。

D. **应用场景**：未来研究需要关注公平性算法在不同应用场景下的适用性，包括如何针对不同场景设计合适的公平性算法、如何评估公平性算法在不同场景下的效果以及如何将公平性算法应用于实际推荐系统中。

公平性推荐

现有的公平推荐研究数据集相对丰富，包含属性信息的推荐数据集数量相对较大。这些数据集的场景多样，包括电影推荐（例如Movielens、Flixter和Netflix）、电子商务推荐（例如Amazon和ModCloth）和职位推荐（例如Xing）。这些数据集既包含大规模数据集（例如Amazon），也包含小规模数据集（例如Movielens 100K）。现有数据集中的交互类型多样，包括印象、点击和评分。此外，一些数据集包含多模态信息，例如Amazon和Yelp。

数据集与评估

大多数关于公平的研究都致力于提高群体公平性，而群体公平性需要满足一定的标准来划分群体，通常使用数据集中的属性，例如用户的性别。然而，并非所有的推荐数据集都包含这些属性，现有的研究也没有同等关注不同的属性。

难点与创新之处

1. 数据清洗过程

省略了前期数据清洗、表关联、欺诈标签的定义的过程。

2. 评价指标不同

账户伪阳性比例：$\frac{\text{错误地被判定为欺诈的账户数}}{\text{正确地被判定为欺诈的账户数}}$　　账户发现比例：$\frac{\text{正确地被判定为欺诈的账户数}}{\text{总欺诈账户数目}}$

价值发现比例：$\frac{\text{正确地判定为欺诈的交易总金额}}{\text{欺诈交易总金额}}$

3. 没有评分标准化过程

按照0-1的阈值进行判断交易是否为欺诈，没有进行评分标准化过程。



本节结束 感谢聆听！

THANKS FOR YOUR LISTENING！

汇报人：蒋洪迅　　时间：2025-03-16

实事求是