tm26projects

1 在overleaf.com 网站注册账号 (https://www.overleaf.com/), 论文项目共享 info.ruc@163.com

2 在openi.pcl.ac.cn 网站注册账号 (https://openi.pcl.ac.cn/user/sign_up?sharedUser=info-ruc)

3 从如下题目中挑选感兴趣的，课堂展示选题报告 (20260607下午)

选题一：思维链的几何结构：思维流形与信息瓶颈

1. 核心概念

我们通常认为思维链（CoT）是一条线性的序列。本选题提出：**思维链在隐藏空间（Hidden Space）中实际上构成了一个高维流形（Manifold），而推理的失败源于"信息瓶颈"（Information Bottleneck）。**

2. 创新思路

- **假设：** 大模型在生成推理步骤时，其激活向量（Activations）并非随机游走，而是沿着语义流形上的测地线（Geodesic）移动。
- **创新：** 引入**流形正则化（Manifold Regularization）**约束 CoT 的生成，防止模型在流形边界上"滑落"导致逻辑断裂。
- **算力分析：** 使用 Qwen2.5-3B，通过计算激活向量的协方差矩阵进行流形分析，不需要额外的训练，仅用 PCA/t-SNE 可视化验证。

3. 方法设计

- **激活空间追踪：** 提取 LLM 中间层的激活值，构建"推理流形"。
- **几何诊断：** 计算 CoT 生成的每一步在流形上的切空间（Tangent Space）偏差，找出导致幻觉的"逻辑断裂点"。
- **验证：** 证明经过流形约束的模型，其逻辑准确率随"几何紧致度"提升而提升。

选题二：量化即正则化：低精度微调对泛化的非直觉提升

1. 核心概念

业界普遍认为量化（Quantization）会导致性能损失。本选题提出一个反直觉假说：**INT8 量化引入的随机噪声（Quantization Noise）本质上等同于权重的 Dropout 正则化，从而在微调过程中反而提升了模型的泛化能力（Generalization）。**

2. 创新思路

- **反直觉洞察：** 证明在低资源（单卡 8GB-12GB 显存）下，INT8 微调在 OOD（分布外）测试集上的表现优于 FP16 微调。
- **理论支撑：** 从**随机矩阵理论（Random Matrix Theory）**出发，分析量化噪声如何平滑损失曲面（Loss Landscape），使模型陷入更平坦的极小值（Flat Minima）。

- **算力分析：** 使用 `transformers` + `bitsandbytes` 进行 4-bit/8-bit QLoRA 微调，在 GSM8K 和 Alpaca 上验证泛化性。

3. 方法设计

- **对比实验：** FP16 LoRA vs. INT8 QLoRA vs. INT4 QLoRA。
- **指标：** 不仅看准确率，重点分析**验证集与测试集的方差（Variance）以及鲁棒性（对抗攻击下的表现）**。
- **理论可视化：** 绘制不同精度下的损失地形图（Loss Landscape），展示 INT8 如何"抹平"尖锐的极小值。

选题三：大模型的"萨丕尔-沃夫"假说验证：语法如何决定逻辑

1. 核心概念

语言学中的**萨丕尔-沃夫假说（Sapir-Whorf Hypothesis）**认为语言结构决定思维。本选题尝试证明：**强制语言模型学习强语法约束（如德语的性别系统或拉丁语的变格）会改变其因果推理（Causal Reasoning）的路径。**

2. 创新思路

- **跨学科验证：** 这是一个连接计算语言学、认知科学与深度学习的"交叉"选题。
- **实验设计：** 训练一个 3B 模型在强语法语言（德语/俄语）和弱语法语言（英语/中文）上，对比其在**句法树解析（Parsing）**和**指代消解（Coreference Resolution）**上的注意力头分布。
- **发现：** 强语法训练会激活特定的"语法-逻辑"注意力簇（Attention Clusters），使模型在处理复杂长句逻辑时表现出类似"语法直觉"的现象。

3. 方法设计

- **语料构建：** 平行语料库（Wikipedia 多语言版），强制不同的语法权重。
- **机制探测：** 使用**激活插值（Activation Interpolation）**技术，分析语法约束如何影响因果逻辑模块。
- **算力分析：** 多语言 LoRA 微调，模型规模 1.3B-3B。

选题四：涌现能力的相变临界点：从 Ising 模型视角看涌现

1. 核心概念

Scaling Law（缩放定律）是当前的热点，但人们不知道"涌现"（Emergence）发生的精确临界点。本选题将 LLM 训练过程类比为**统计物理中的 Ising 模型（铁磁相变）**，寻找涌现能力的**相变临界温度（Critical Temperature）**。

2. 创新思路

- **物理学视角：** 将 LLM 的参数或 Loss 视为自旋（Spin），将训练步骤视为降温过程。
- **核心发现：** 证明某些能力（如数学推理）不是在数据量线性增加时缓慢上升，而是在特定的"临界宽度"发生**阶跃（Phase Transition）**。
- **实用价值：** 通过计算临界参数，我们可以预测何时停止训练以节省算力，或何时增加数据以激活新能力。

3. 方法设计

- **临界点计算：** 使用 Qwen2.5-7B 进行不同规模的子集训练，监控推理能力的"导数"。
- **关联长度（Correlation Length）分析：** 计算模型内部节点依赖性的变化，寻找发散点。
- **算力分析：** 只需要对极小比例的数据（1%）进行不同步数的早停训练，分析 Loss 下降轨迹。

选题五：提示词优化的贝叶斯框架：Prompt 即先验

1. 核心概念

Prompt Engineering 通常被视为启发式搜索。本选题提出：**Prompt 本质上是在参数空间中移动模型的"先验分布（Prior Distribution）"。** 我们可以通过**贝叶斯优化（Bayesian Optimization）**来寻找最优的 Prompt 嵌入。

2. 创新思路

- **理论重构：** 将 Text-to-Vector 的 Prompt 视为一个可微分的隐变量（Latent Variable）。
- **创新：** 提出**Prompt-VAE**（变分自编码器），将离散的文本 Prompt 映射到连续的潜在空间，在这个空间中进行梯度下降搜索最优 Prompt。
- **效果：** 用更少的 Token 获得更好的 Few-shot 效果，且理论上有收敛性保证。

3. 方法设计

- **Prompt 编码器：** 训练一个小型的 Prompt-Encoder 将自然语言 Prompt 映射为连续向量。
- **贝叶斯搜索：** 使用高斯过程（Gaussian Process）在潜在空间中搜索最大化目标函数（如准确率/置信度）的向量。
- **算力分析：** 冻结大模型主网络，仅训练 50MB 左右的 Prompt Encoder。

选题六：对抗性遗忘：利用梯度冲突实现"安全对齐"

1. 核心概念

对齐（Alignment）通常通过 RLHF 增加安全能力。本选题提出反向思路：**利用不同类别样本的"梯度冲突（Gradient Conflict）"来显式地在参数空间中挖掘"安全超平面"。**

2. 创新思路

- **几何视角：** 安全对齐不是"增加权重"，而是"切除参数空间中有害的方向"。
- **创新机制：** 定义一个**梯度投影算子**，将有害数据的梯度投影到无害数据的切空间正交补空间上，实现数学上的"纯净对齐"。
- **优势：** 无需额外的安全数据或 Reward Model，仅通过数学约束实现。

3. 方法设计

- **梯度解耦：** 分别计算正常数据和恶意数据的梯度。
- **冲突检测：** 计算两个梯度向量的夹角（余弦相似度），负相关即发生冲突。
- **实验：** 在 Alpaca 数据上，通过调整梯度投影比例，观察模型在 TruthfulQA 上的表现。

选题七：长文本的"海马体"假说：外部记忆与神经网络的协同

1. 核心概念

人类的长短期记忆依赖于海马体。本选题将**外部向量数据库（Vector DB）视为 LLM 的"海马体"**，研究神经网络与外部存储的**接口动力学（Interface Dynamics）**。

2. 创新思路

- **理论问题：** 检索（Retrieval）与生成（Generation）之间是否存在"语义摩擦"？
- **创新：** 提出**记忆流形对齐（Memory Manifold Alignment）**，证明 RAG（检索增强生成）效果差的原因是检索 Chunk 的嵌入空间与 LLM 的生成空间存在错位（Misalignment）。
- **解决方案：** 一个极小的、单卡可跑的**跨模态对齐适配器（Cross-modal Adapter）**，用于平滑接口，无需微调大模型本身。

3. 方法设计

- **错位分析：** 可视化 RAG 检索出的文本嵌入与 LLM 关注词汇的 Embedding 距离。
- **对齐实验：** 引入一个简单的 MLP 层作为"翻译层"，解决语义断层。
- **算力分析：** 模型保持冻结，仅训练 2M 参数的 Adapter。

选题八：注意力机制的稀疏性拓扑：从全连接到"极简主义"

1. 核心概念

Transformer 的注意力矩阵通常是稠密的。本选题通过**拓扑数据分析（Topological Data Analysis, TDA）**，揭示注意力矩阵其实是一个**高维复形（Simplicial Complex）**，并证明**保留最关键的拓扑特征（如空洞 Holes）即可重构模型性能。**

2. 创新思路

- **数学美学：** 将 NLP 问题转化为代数拓扑问题。
- **压缩理论：** 如果注意力矩阵的"拓扑指纹"不变，我们可以将注意力矩阵压缩 100 倍而不损失性能。
- **算力分析：** 使用 `topology` 库（如 GUDHI 或 VietorisRips）分析注意力头，结合 Pruning 技术。

3. 方法设计

- **持久同调（Persistent Homology）：** 计算注意力矩阵在不同阈值下的 Betti 数（连通分量、环、空洞数量）。
- **精简：** 识别出构成主要"同调类"的关键注意力连接，删除其余连接。
- **验证：** 在 LLaMA 或 Qwen 上验证拓扑压缩后的推理能力。

选题九：大模型的"元学习"能力：自进化代码生成的动力学分析

1. 核心概念

LLM 不仅是编码器，更是**元学习器（Meta-Learner）**。本选题研究 LLM 如何通过自我修正（Self-Correction）进行**"一阶微分"式的自我进化**。

2. 创新思路

- **动力学视角：** 将 LLM 的迭代优化过程建模为一个**微分方程** $\frac{dP}{dt} = f(P)$。

- **核心发现：** 证明 LLM 的自我修复轨迹遵循**“梯度下降 + 探索噪声”**的组合，且存在一个最优的“修正轮次”（Turn-taking limit），超过此限制会导致“过修（Over-correction）”。
- **应用：** 基于此理论，提出**Early-Stopping for Hallucination**（在模型开始自我毁灭前停止）。

3. 方法设计

- **轨迹追踪：** 记录 LLM 修改代码的全过程（Prompt -> Code -> Error -> Code' -> Code''）。
- **收敛性分析：** 绘制准确率随修正步数变化的曲线，寻找极值点。
- **算力分析：** 使用 Codestral 或 Qwen-Coder 进行 10 轮迭代测试。

选题十：语言模型中的因果发现：从相关性到干预

1. 核心概念

目前大多数评估都是基于“相关性”（输入和输出的统计关系）。本选题试图利用**因果推断（Causal Inference）技术（如 do-calculus），在大模型中识别并切断“偏见因果路径”。**

2. 创新思路

- **干预实验：** 构建一个反事实数据集（Counterfactual Dataset），通过修改输入中的敏感属性（如性别、职业），观察模型输出的变化。
- **去偏理论：** 提出**因果去偏（Causal Debiasing）**，即在微调时，显式地最小化“敏感属性 -> 偏见输出”这一路径的互信息（Mutual Information）。
- **理论深度：** 证明去除偏差不会降低语言能力，因为“公平性”是正交于“语法结构”的流形方向。

3. 方法设计

- **因果图构建：** 分析偏见产生的依赖关系图。
- **干预微调：** 使用 `do-operator` 风格的数据增强进行微调。
- **算力分析：** 使用 BiasBench 或 BBQ 数据集进行 1B-3B 模型微调。

选题十一：自拟题目