数据仓库与数据挖掘 2022 B 卷

Please note that due to my limited knowledge, the following answer are for reference only. by Albert Yang

一．什么是支持度，什么是可信度？给定如下交易数据库，如果用户给定的最小支持度是60%，请问项目集合{牙膏、牙刷、面包} 是否是频繁项集？如果用户给定的最小可信度是80%，请问能否产生关联规则{牙膏、牙刷}—>{饼干}？(20分)

交易号	items bought
10 20 30 40 50	{牙膏、牙刷、牛奶、饼干} {牙膏、牙刷、饼干} {牙膏、牙刷、面包} {牙膏、牙刷、面包、面包、饼干} {牙膏、牙刷、牛奶、饼干}

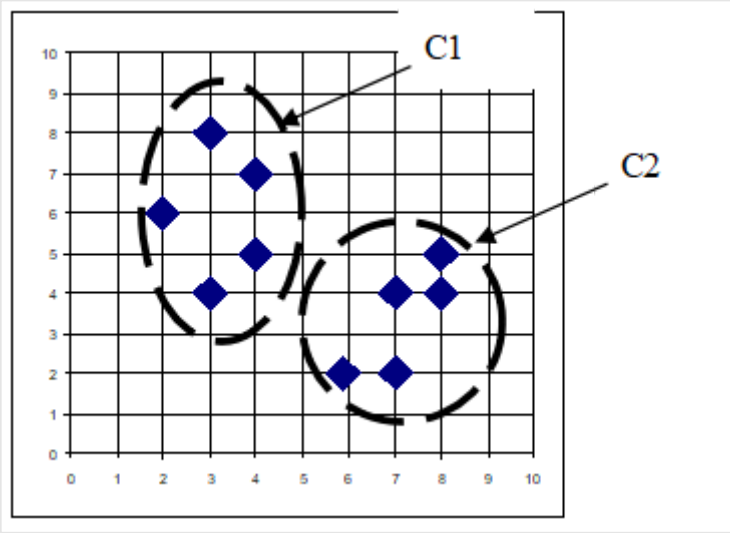
答:

- 什么是支持度，什么是可信度?
  - 支持度是指项集 X 和 Y在数据库 D 中同时出现的概率，即 $\sup = P(X \cup Y)$
  - 可信度是指项集 X 出现的情况下，项集 Y 在数据库 D 中同时出现的条件概率，即 $\text{conf} = P(Y|X) = \frac{P(X \cup Y)}{P(X)}$
- 频繁项集
  - {牙膏、牙刷、面包}的频度为2，而最小支持度是60%，最小支持频度为3，所以该项目集不是频繁项集。
- 关联规则
  - {牙膏、牙刷} 出现的频度为 5，而{牙膏、牙刷、饼干}出现的频度为4，上述两个项目集都满足最小支持60%，而且该关联规则的可信度为 4/5 = 80%，满足最小可信度的要求，所以能产生关联规则。

二．请从输入参数个数、能找出的聚类模式的形状、鲁棒性3个方面对如下聚类算法进行比较：k-Means算法、DBSCAN算法、OPTICS算法和BIRCH算法。（20分）

	K-means	DBSCAN	OPTICS	BIRCH
参数个数	1个参数为 k	x	x	x
聚类模式的形状	一般只能找出凸的形状	x	x	x
鲁棒性	对噪声敏感，不够鲁棒	x	x	x

三．设某聚类算法的聚类结果如下图所示，第一个簇（C1）中5个对象分别为（3，4）、（4，5）、（2，6）、（3，8）、（4，7），第二个簇（C2）中5个对象分别为（6，2）、（7，2）、（7，4）、（8，4）、（8，5），请算出C1和C2之间的中心点距离（用欧几里得距离函数）。(10分)



答：C1 中心点为:

$$\left\lfloor \frac{3+4+2+3+4}{5} \right\rfloor = 3$$

$$\left\lfloor \frac{4+5+6+8+7}{5} \right\rfloor = 6$$

即为(3, 6)

C2 中心点为：

$$\left\lfloor \frac{6+7+7+8+8}{5} \right\rfloor = 7$$

$$\left\lfloor \frac{2+2+4+4+5}{5} \right\rfloor = 3$$

即为(7, 3)

欧几里得距离为 $d(x,y) = \sqrt[2]{\sum (x-y)^2}$

$d = \sqrt[2]{(3-7)^2 + (6-3)^2} = \sqrt[2]{25} = 5$

四、什么是频繁序列？什么是最大序列？现有如下序列数据库，假设用户给定的最小支持度是50%，请问序列和序列<(EB)>的支持度分别是多少？它们是否是频繁序列？它们是否是最大序列？（20分）

顾客号	购物事件
0001	<A(ABC)>
0002	<CE(BC)>
0003	<(EBC)>
0004	<(EF)(BFE)>

答：

- 频繁序列
  - 如果某序列 x 在一个给定的序列数据库 D 里，并给定最小频度，如果 x 在数据库 D 里出现的频度大于最小频度，则说序列 x 是频繁的。
- 最大序列
  - 给定一个序列集合，如果某序列 x 不包含于任何一个其他的序列中，则称 x 是最大的序列。

- 支持度为 2 / 4 = 50%
- 是频繁序列
- 是最大序列

- <(EB)>
  - 支持度为 1/4 = 25%
  - 不是频繁序列
  - 不是最大序列

五、在下面的顾客数据库表中，假设Buys_computer是类标签属性，给定新元组“>40, High, no,fair”，请问如果用朴素贝叶斯分类法的话，该新元组的类标签应该是什么？请写出计算步骤。(30分)

Age	Income	student	credit_rating	Class: buys_computer
<=30	High	no	fair	No
<=30	High	no	excellent	No
31...40	High	no	fair	Yes
>40	Medium	no	fair	Yes
>40	Low	yes	fair	Yes
>40	Low	yes	excellent	No
31...40	Low	yes	excellent	Yes
<=30	Medium	no	fair	No
<=30	Low	yes	fair	Yes
>40	Medium	yes	fair	Yes
<=30	Medium	yes	excellent	Yes
31...40	Medium	no	excellent	Yes
31...40	High	yes	fair	Yes
>40	Medium	no	excellent	No

答:

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

$$P(C_i|X) \propto P(X|C_i)P(C_i)$$

$$P(C_i|>40, \text{High}, \text{no}, \text{fair}) = P(>40, \text{High}, \text{no}, \text{fair}|C_i)P(C_i)$$

$$P(C_{yes}) = 9/14, \quad P(C_{no}) = 5/14$$

$$P(>40|C_{yes}) = 2/9, \quad P(\text{High}|C_{yes}) = 2/9, \quad P(\text{no}|C_{yes}) = 3/9, \quad P(\text{fair}|C_{yes}) = 6/9$$

$$P(>40|C_{no}) = 1/5, \quad P(\text{High}|C_{no}) = 2/5, \quad P(\text{no}|C_{no}) = 4/5, \quad P(\text{fair}|C_{no}) = 2/5$$

$$\begin{aligned} P(C_{yes}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{yes}) \cdot P(\text{High}|C_{yes}) \cdot P(\text{no}|C_{yes}) \cdot P(\text{fair}|C_{yes}) \cdot P(C_{yes}) \\ &= \frac{2}{9} \cdot \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} \cdot \frac{9}{14} = \frac{4}{567} = 0.007 \end{aligned}$$

$$\begin{aligned} P(C_{no}|>40, \text{High}, \text{no}, \text{fair}) &= P(>40|C_{no}) \cdot P(\text{High}|C_{no}) \cdot P(\text{no}|C_{no}) \cdot P(\text{fair}|C_{no}) \cdot P(C_{no}) \\ &= \frac{1}{5} \cdot \frac{2}{5} \cdot \frac{4}{5} \cdot \frac{2}{5} \cdot \frac{5}{14} = \frac{8}{175} = 0.046 \end{aligned}$$

即该新元组的标签为 No