《数据仓库与数据挖掘》试题

一．现有如下交易数据库，设用户给出的最小支持度是 60%、最小可信度是 75%

(a) 请用 **Apriori** 算法找出所有的频繁项目集。（10 分）

(b) 请找出所有的关联规则。（10 分）

(b) 请用 FP-Growth 算法找出频繁项(item)，并据此画出相应的 FP-tree。（5 分）

(d) 请从算法组件化思想的角度，比较 Apriori 算法和 FP-Growth 算法的异同。（5 分）

顾客号	交易商品集合
1	{O, P, Q, R, S, T}
2	{O, P, R, S }
3	{O, P, S }
4	{O, P, Q, Q }
5	{O, P, P }

二、假设数据挖掘的任务是将如下的 6 个点（用(x,y)代表位置）聚类为三个类。

A1(3,9)，A2(2,7)，A3(6,9)，A4(1,3)，A5(4,9)，A6(2,7)

距离函数是曼哈顿函数。

(a) 假设初始我们选择 A1，A3 和 A5 为每个聚类的中心，请用 k-means 算法给出在第二次循环执行后的聚类结果及其中心。(20 分)

(b) 请分析并举例说明 K-means 算法的缺点，针对这些缺点，请设计一种改进的聚类算法，给出算法思路的描述（可以是学过的或者没有学过的算法，言之有理即可）。(10 分)

三、什么是子序列？如何判定序列 A 是否是序列 B 的子序列？在如下序列数据库中， <ad> 分别是哪些序列的子序列？<ad>的支持度是多少？<(ab)>的支持度又是多少？（20 分）

SID	Sequence
10	<a(abc)(ac)d(cf)>
20	<(ad)c(bc)(ae)>
30	<(ef)(ab)(df)cb>
40	<eg(af)cbc>

四、请对任意一种决策树算法（比如 ID3 算法）的建树过程和决策过程进行描述。（20 分）